人工智能学院课程：《智能传感与信息处理》第 11 讲

点云数据处理

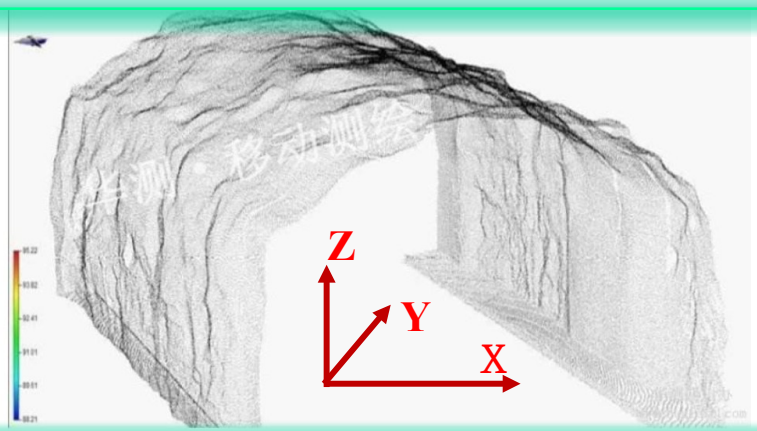
中国科学院自动化研究所

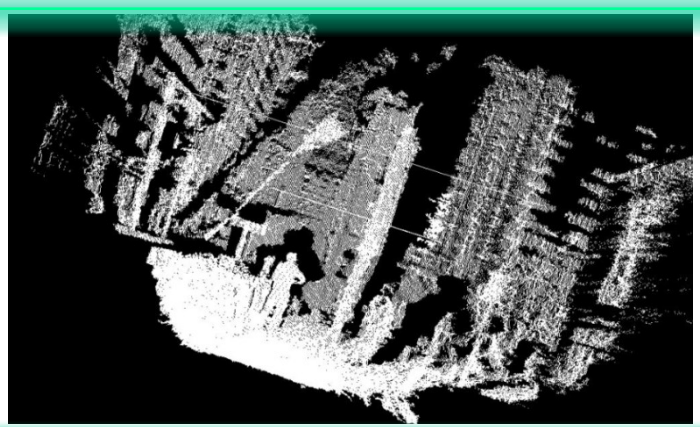
刘希龙

2026.10.14

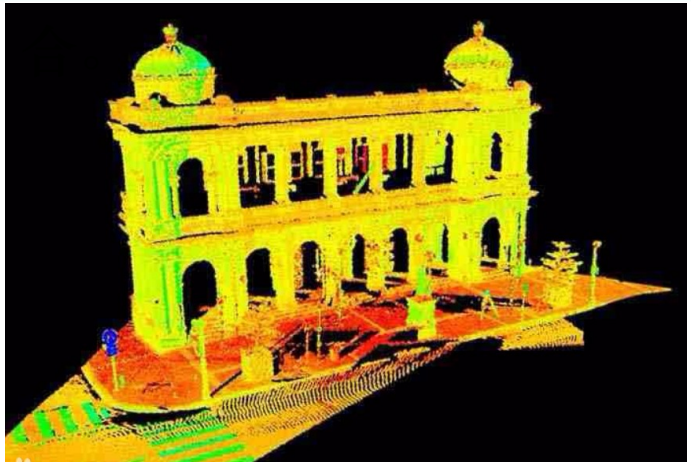
一、概述与内容

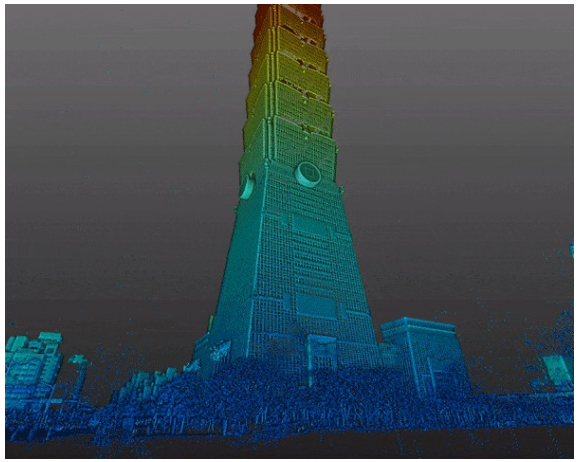
在获取物体表面每个采样点的空间坐标后，得到的是三维空间点的集合，称之为点云。获取设备：激光扫描仪、雷达、立体视觉、 RGB-D 相机等





点云：在同一空间参考系下表达目标空间分布和目标表面特性的海量点集





点云：数据集，集中的点：

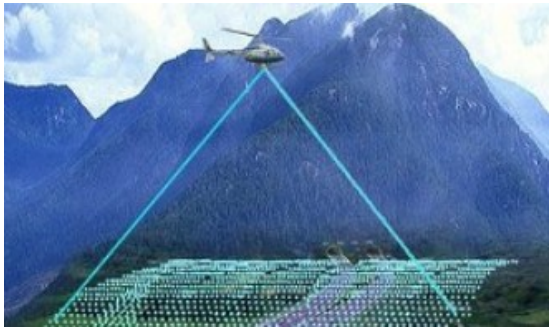
- 几何坐标—（ x,y,z ）表示空间位置
- 强度值—根据物体表面反射率记录返回信号强度

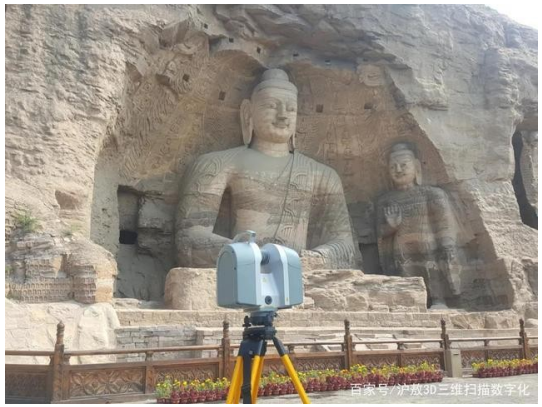
一、概述与内容

点云来源

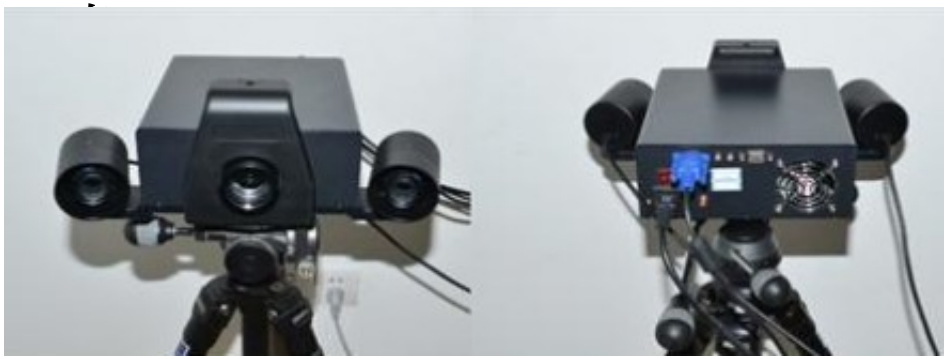
- ✓ 根据激光测量原理得到的点云：包括三维坐标（XYZ）和激光反射强度





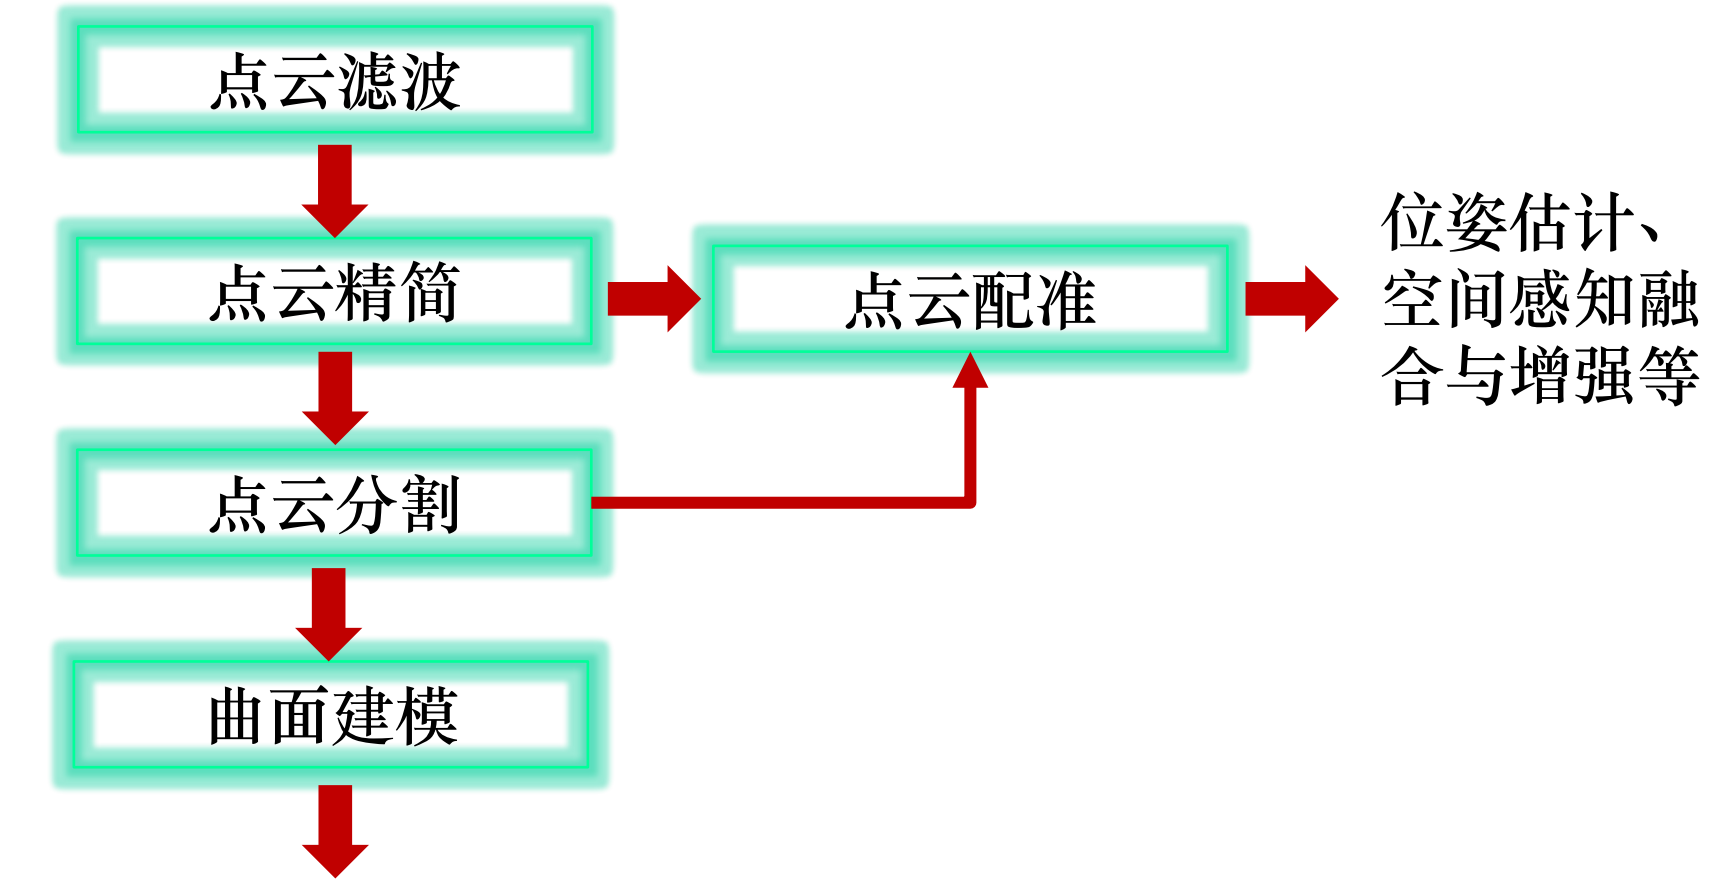


- ✓ 根据摄影测量原理得到的点云，包括三维坐标（XYZ）、颜色、纹理等信





一、概述与内容



二、点云滤波

2.1 概述

- 点云滤波的主要原因
  - 点云数据的密度不规则，需要进行平滑
  - 大量数据需要下采样。
  - 有离群点出现，需要去除
  - 噪声数据需要去除。

- 点云滤波的主要方案
  - 按照给定的规则限制过滤去除点
  - 通过常用滤波算法修改点的部分属性
  - 对数据进行下采样

- 常见滤波算法：

  直通滤波器、体素滤波器、统计滤波器、半径滤波器、

  高斯滤波器、双边滤波器、移动最小二乘法光滑滤波、 DoN 算法、

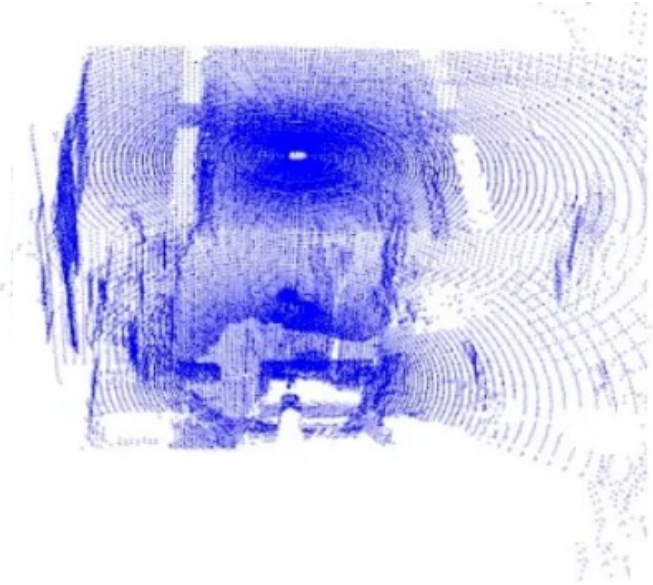
二、点云滤波

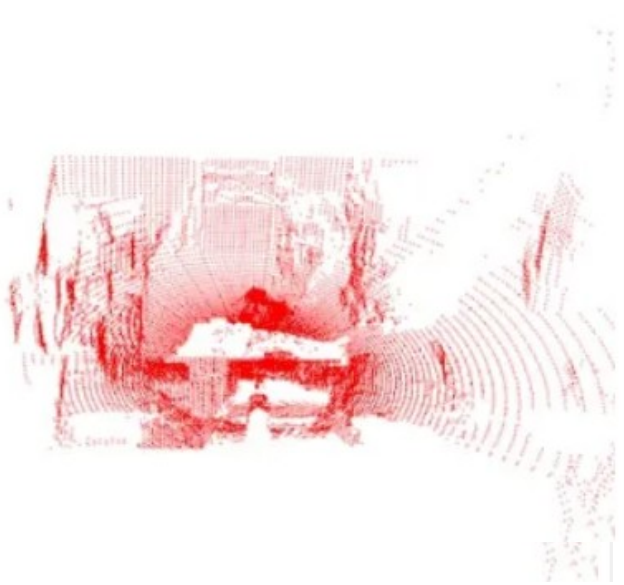
2.1 直通滤波器

原理：直通滤波器就是根据点云的属性（x、y、z、颜色值等），在点的属性上设置范围，对点进行滤波，保留范围内的或保留范围外的。可较快剪除离群点，达到第一步粗处理的目的。

```
pass.setFilterFieldName ("z");
pass.setFilterLimits (0.0, 20.0);
pass.setFilterLimitsNegative (true);
```

滤除 z 坐标位于 [0,20] 范围内的点



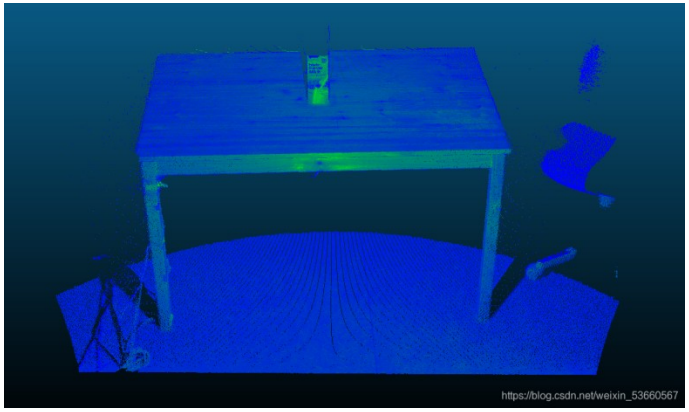


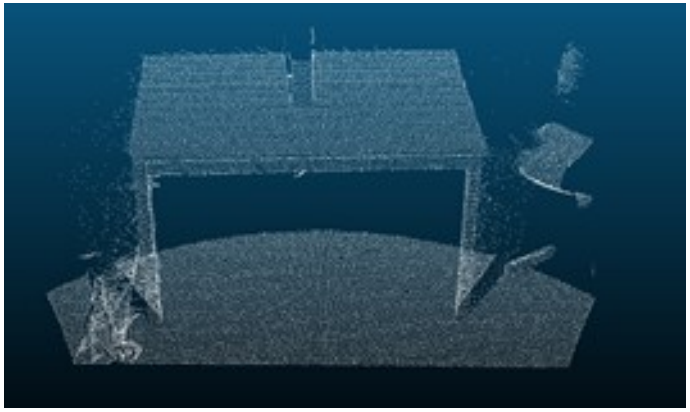
二、点云滤波

2.2 体素滤波器

- 原理：计算整个点云的立方体包围盒，按照设定分辨率对其进行立方体划分，计算划分后各小立方体中的所有点的质心，利用该质心坐标代替对应的小立方体。

- 作用与特点
  - 主要功能是降采样
  - 不破坏点云本身几何结构；
  - 会移动点的位置；
  - 可去除一定程度的噪音点及离群点。

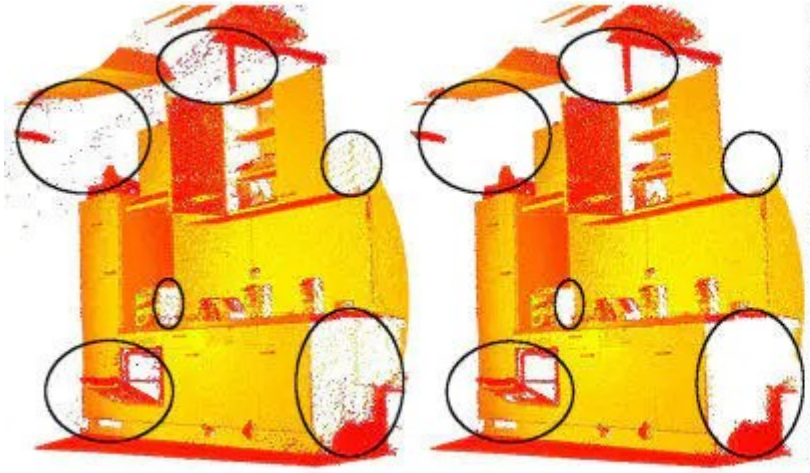


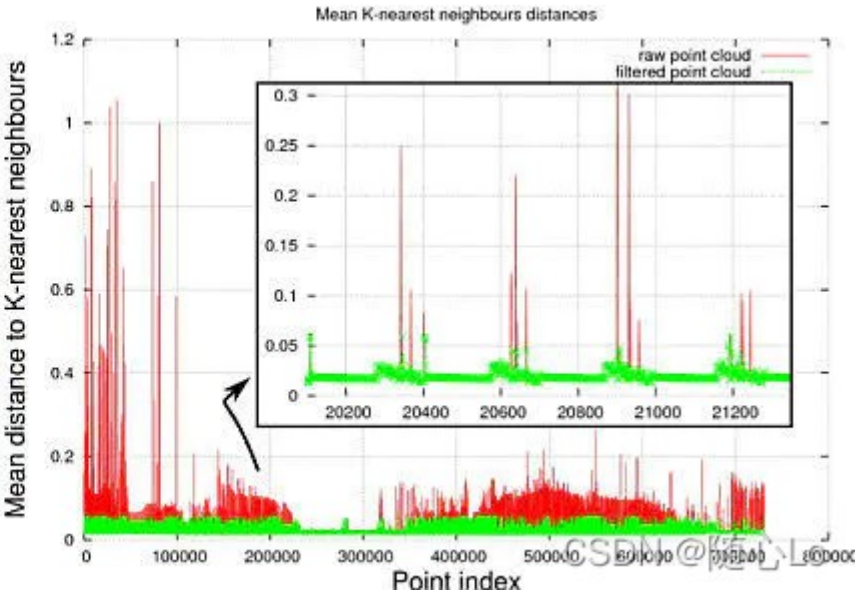


二、点云滤波

2.3 统计滤波器

- 基本思想：离群点在空间中分布稀疏，根据某点处的点云密度，判断是否为离散点。利用统计学思想实现：
  - ✓ **Step1**：距离计算：计算每个点到其最近的 **k** 个点平均距离；
  - ✓ **Step2**：统计均值和方差：假设上述距离值服从高斯分布；
  - ✓ **Step3**：**3σ** 准则滤波：将方差在 **3σ** 之外的点认为是离群点剔除。
- 特点：根据密度去除离群点，对密度差异较大的离群点去除效果较





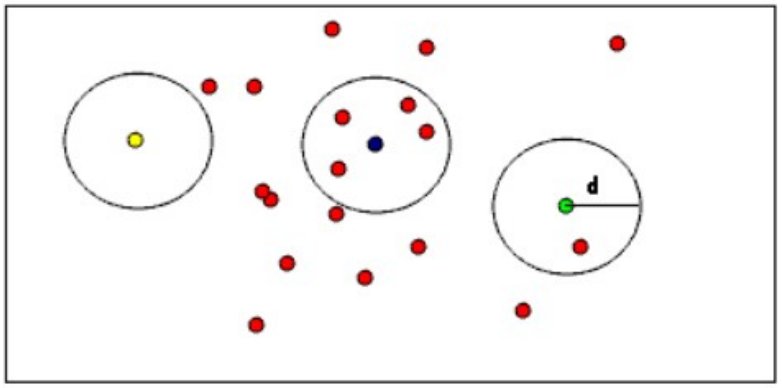
CSDN@

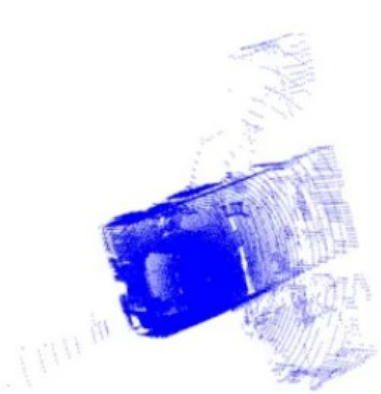
二、点云滤波

2.4 半径滤波器

- 基本思想。以某点为中心画一个圆计算落在该圆中点的数量，当数量大于给定值时，则保留该点，数量小于给定值则剔除该点。

- 作用与特点
  - 运行速度快；
  - 主要用于去除离群点；
  - 在一定程度上可以用来筛选边缘点；
  - 圆的半径和圆内点的数目都需要人工指定。







二、点云滤波

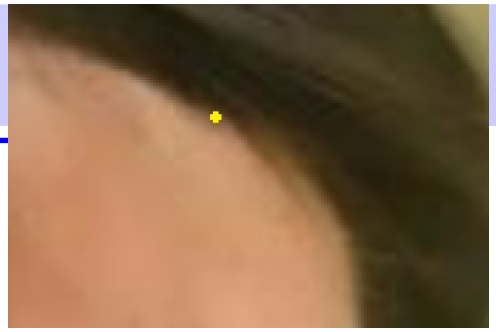
2.5 移动最小二乘法光滑滤波

- 基本思想：根据点云利用移动最小二乘法拟合一个光滑函数，该函数可由系列局部函数构成，然后将点投影到函数上，达到平滑目的。

2.6 高斯滤波器

- 基本思想：采用加权平均的方式，在指定域内的权重是根据欧式距离的高斯分布，通过权重加权平均的方式得到当前点的滤波后的点。

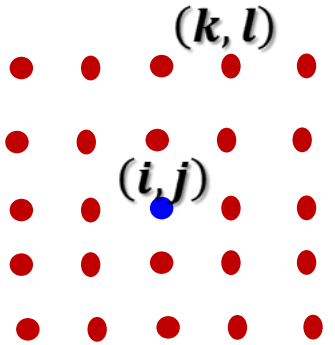
二、点云滤波



2.7 双边滤波器

双边滤波器（Bilateral filter）：用在图像处理领域，可以保边去噪。同时考虑中心像素点与邻域像素点的距离以及像素亮度差值确定权值进行平滑滤波

滤波器公式：$$g(i,j)=\frac{\sum_{k,l} f(k,l)w(i,j,k,l)}{\sum_{k,l} w(i,j,k,l)}$$



$$w(i,j,k,l)=d(i,j,k,l)\cdot r(i,j,k,l)$$

几何空间距离信息

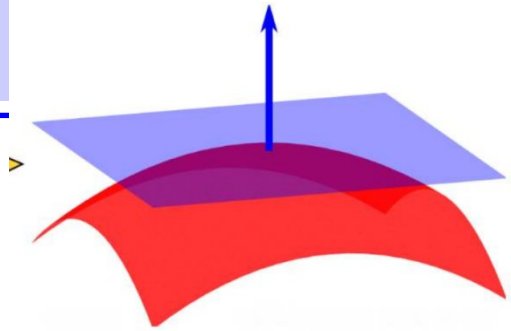
灰度差值信息

$$d(i,j,k,l)=exp\left(-\frac{(i-k)^2+(j-l)^2}{2{\sigma_d}^2}\right)$$

$$r(i,j,k,l)=exp\left(-\frac{\|f(i,j)-f(k,l)\|^2}{2{\sigma_r}^2}\right)$$

$$w(i,j,k,l)=exp\left(-\frac{(i-k)^2+(j-l)^2}{2{\sigma_d}^2}-\frac{\|f(i,j)-f(k,l)\|^2}{2{\sigma_r}^2}\right)$$

二、点云滤波

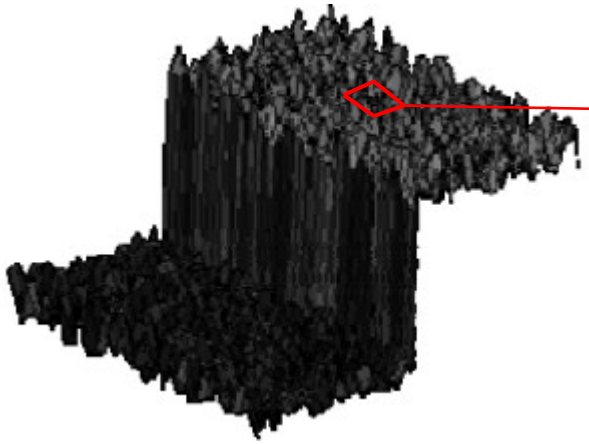


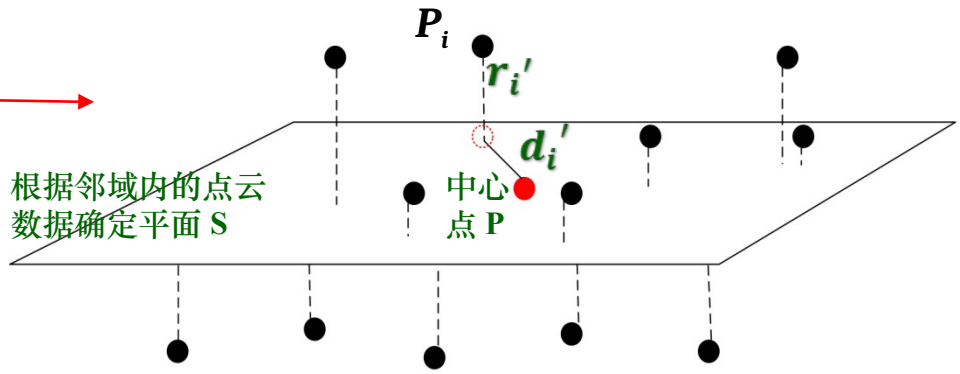
2.7 双边滤波器

- ✓ 滤波目标值：深度信息（x, y 方向通常决定视场）
- ✓ 如何确定两部分信息？（对应于图像中的像素点灰度差值和像素点距离）

利用中心扫描点的局部邻域点确定一局部平面S，作为点云表征曲面的局部逼近。对于邻域区域内的任意一点P_i，

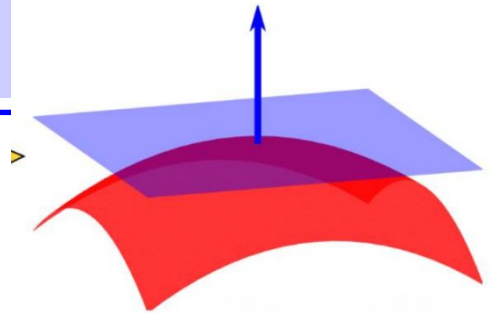
- **P_i相对于平面S的符号距离r_i'可以看作是双边过滤时的像素点强度差值**
- **P_i与中心扫描点之间距离在S上的投影d_i'可认为是双边过滤的像素点距离**



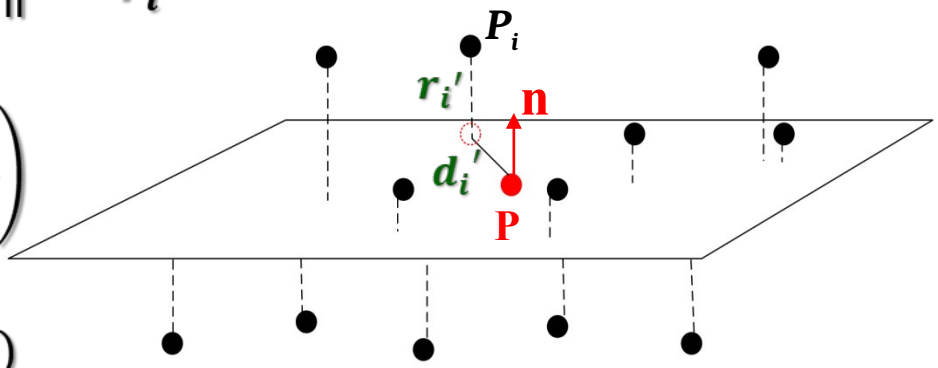


二、点云滤波

2.7 双边滤波器

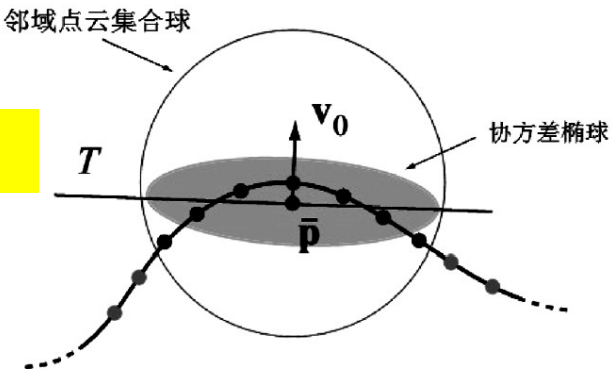


距离计算：$r_i' = \overrightarrow{P_iP} \cdot \mathbf{n} \qquad d_i' = \sqrt{\left\|\overrightarrow{P_iP}\right\|^2 - r_i'^2}$



权值计算：$w(P_i, P) = exp\left(-\frac{d_i'^2}{2\sigma_d^2} - \frac{r_i'^2}{2\sigma_r^2}\right)$

滤波器：$z(P) = \frac{\sum_{P_i \in N(P)} z(P_i) w(P_i, P)}{\sum_{P_i \in N(P)} w(P_i, P)}$



问题及关键：平面 S 法线 n？ -- 基于 PCA 的法线估计

$$\bar{P} = \sum_{P_i \in N(P)} P_i$$

$$C = \begin{bmatrix} (P_1 - \bar{P})^T \\ \cdots \\ (P_N - \bar{P})^T \end{bmatrix}^T \begin{bmatrix} (P_1 - \bar{P})^T \\ \cdots \\ (P_N - \bar{P})^T \end{bmatrix}$$

特征值分解：C 为对称半正定，特征值均为实数

$$\lambda = \min(\lambda_1, \lambda_2, \lambda_3)$$

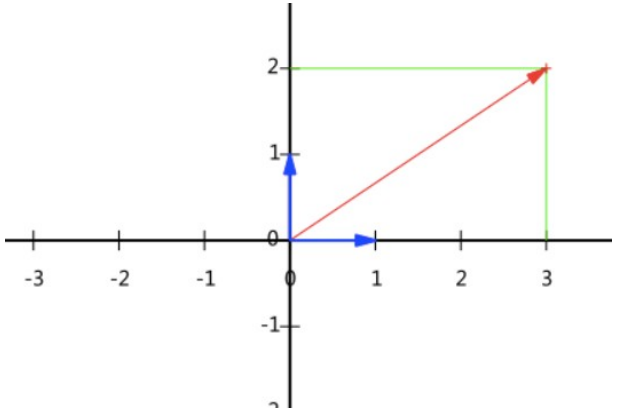
与之对应的特征矢量作为平面法线矢量 n

协方差矩阵：描述了邻域点云几何空间分布的统计特性

二、点云滤波

□ 知识点补充： PCA 算法

如何理解向量？ $(3,2)^T$ $x(1,0)^T + y(0,1)^T$



向量准确描述：给定一组基，确定向量在基向量方向上的投影。

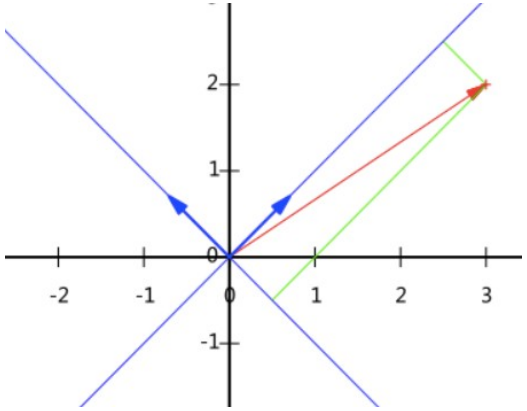
基变换：

基向量1，基向量2：

$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}\begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}\begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 2/\sqrt{2} & 4/\sqrt{2} & 6/\sqrt{2} \\ 0 & 0 & 0 \end{pmatrix}$$

$\left(\frac{5}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)^T$ ⇓ $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^T$ $\left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^T$



行向量 基向量

$$\begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_R \end{pmatrix}(a_1 \quad a_2 \quad \cdots \quad a_M) = \begin{pmatrix} p_1a_1 & p_1a_2 & \cdots & p_1a_M \\ p_2a_1 & p_2a_2 & \cdots & p_2a_M \\ \vdots & \vdots & \ddots & \vdots \\ p_Ra_1 & p_Ra_2 & \cdots & p_Ra_M \end{pmatrix}$$

列向量 原始数据向量

a_1' a_2' a_M'

二、点云滤波

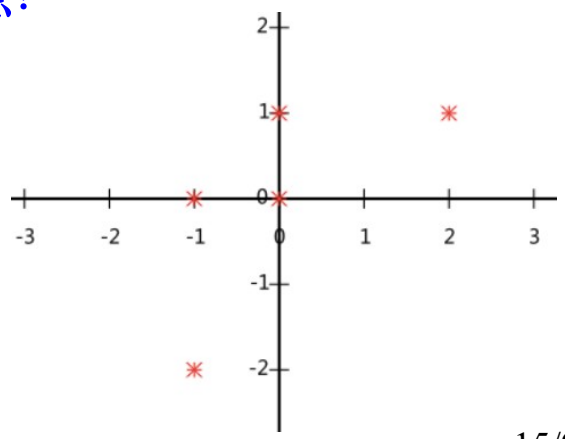
□ 知识点补充： PCA 算法

选择不同基可以对同一组数据给出不同表示，而且如果基的数量少于向量本身的维数，则可以达到降维的效果。

$$\underset{K\text{个}}{\begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_R \end{pmatrix}} \underset{N\text{维}}{\begin{pmatrix} a_1 & a_2 & \cdots & a_M \end{pmatrix}} = \underset{K\text{维}}{\begin{pmatrix} p_1a_1 & p_1a_2 & \cdots & p_1a_M \\ p_2a_1 & p_2a_2 & \cdots & p_2a_M \\ \vdots & \vdots & \ddots & \vdots \\ p_Ra_1 & p_Ra_2 & \cdots & p_Ra_M \end{pmatrix}} \begin{matrix} a_1' & a_2' & & a_M' \end{matrix}$$

关键问题：如何选择基，才能最大程度上保留原有信息?

$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix} \xrightarrow{\text{减掉均值}} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$



二、点云滤波

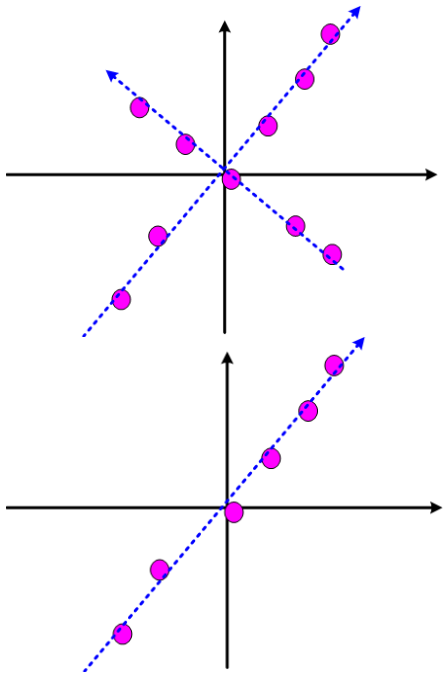
□ 知识点补充： PCA 算法

协方差矩阵：m个n维数据，将其按列排成$n \times m$维矩阵X，协方差矩阵确定为

$$C_{n\times n} = \frac{1}{m} XX^T \qquad n \times n\text{维实对称矩阵}$$

$$X = \begin{pmatrix} a_1 & a_2 & \cdots & a_m \\ b_1 & b_2 & \cdots & b_m \end{pmatrix}$$

$$\frac{1}{m} XX^{\mathsf{T}} = \begin{pmatrix} \frac{1}{m}\sum_{i=1}^{m} a_i^2 & \frac{1}{m}\sum_{i=1}^{m} a_i b_i \\ \frac{1}{m}\sum_{i=1}^{m} a_i b_i & \frac{1}{m}\sum_{i=1}^{m} b_i^2 \end{pmatrix}$$



思想：设基转换后的 m 个矢量组成矩阵 Y，如果 Y 的协方差矩阵为对角阵（除对角线外的其它元素化为 0），则表征该 m 个矢量可以将主要信息都较为独立的投影至各基矢量方向上，可以通过选用更少的基矢量表征这些矢量，达到降维

二、点云滤波

□ 知识点补充： PCA 算法

$$Y = PX \qquad P = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix}$$

$$\begin{aligned} D &= \frac{1}{m} YY^{\mathsf{T}} \\ &= \frac{1}{m} (PX)(PX)^{\mathsf{T}} \\ &= \frac{1}{m} PXX^{\mathsf{T}}P^{\mathsf{T}} \\ &= P(\frac{1}{m} XX^{\mathsf{T}})P^{\mathsf{T}} \\ &= PCP^{\mathsf{T}} \end{aligned}$$

由基矢量组成的矩阵P，为将原始协方差矩阵C进行对角化的相似变换矩阵。

任务描述：寻找矩阵P，满足PCP^T为对角阵，并且对角元素按从大到小排列，则P的前K行就是要寻找的基，用P的前K行组成的矩阵乘以X就能将X从N维降到K维，并满足优化条件。

协方差矩阵对角化

根据矩阵理论，实对称矩阵满足

- 不同特征值对应特征向量必然正交
- 对于重数为r的特征值λ，必有r个线性无关向量对应于λ，可将其单位正交化处理

$$E = \begin{pmatrix} e_1 & e_2 & \cdots & e_n \end{pmatrix}$$

$$E^{\mathsf{T}}CE = \Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}$$

二、点云滤波

□ 知识点补充： PCA 算法

理论分析：选择一个最佳向量 $p^*_{1\times n}$

$$Y_{1\times m} = p_{1\times n} X_{n\times m}$$

由 1 维恢复为 n 维 ⟹

$$X' = p^T Y = p^T p X$$

满足：

$$p^* = \arg\min_p \|X - X'\|_F^2 = \arg\min_p \|X - p^T p X\|_F^2$$

Frobenius 范

$$\|A\|_F = \sqrt{\sum_i \sum_j (a_{ij})^2} = \sqrt{Tr(A^T A)}$$

$$p^* = \arg\min_p \|X - p^T p X\|_F^2 \Leftarrow$$

$$= \arg\min_p Tr\left[(X - p^T p X)^T (X - p^T p X)\right]$$

$$= \arg\min_p Tr[X^T X - X^T p^T p X - X^T p^T p X + X^T p^T p p^T p X] \Leftarrow p\,p^T = 1$$

$$= \arg\min_p Tr[-X^T p^T p X] = \arg\min_p Tr[-p X X^T p^T] \Leftarrow Tr(AB) = Tr(BA)$$

$$= \arg\max_p Tr[p X X^T p^T]$$

$$= \arg\max_p \lambda_p \Longrightarrow p^* \text{为} XX^T \text{最大特征值对应的特征向量}$$

二、点云滤波

□ 知识点补充： PCA 算法

PCA （主成分分析： principal components analysis ）基本步骤

Ste

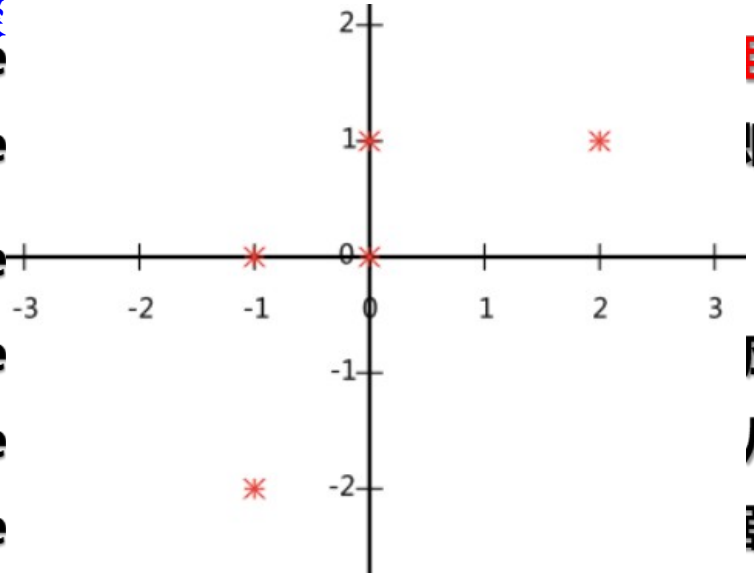
Ste

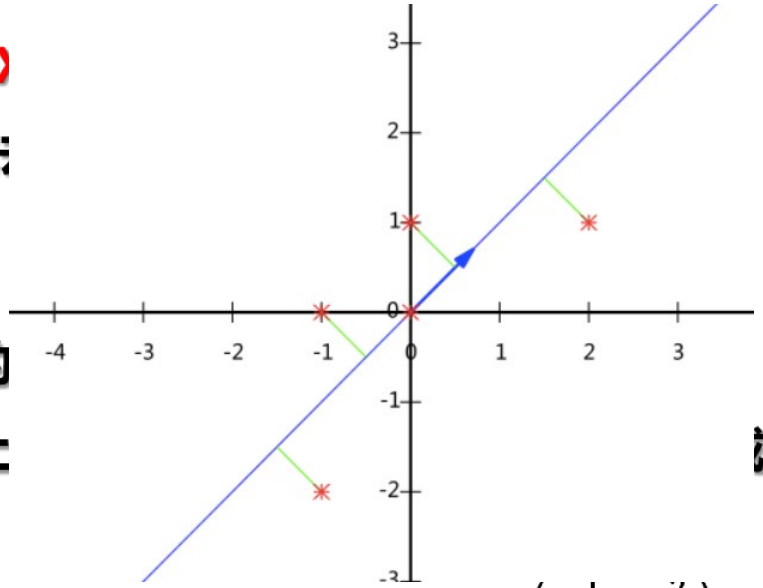
Ste

Ste

Ste

Ste





$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix} \rightarrow \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \rightarrow C = \frac{1}{5}\begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}\begin{pmatrix} -1 & -2 \\ -1 & 0 \\ 0 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix}$$

$$PCP^{\mathsf{T}} = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}\begin{pmatrix} 6/5 & 4/5 \\ 4/5 & 6/5 \end{pmatrix}\begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2/5 \end{pmatrix}$$

$$\lambda_1 = 2, \lambda_2 = 2/5 \qquad P = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

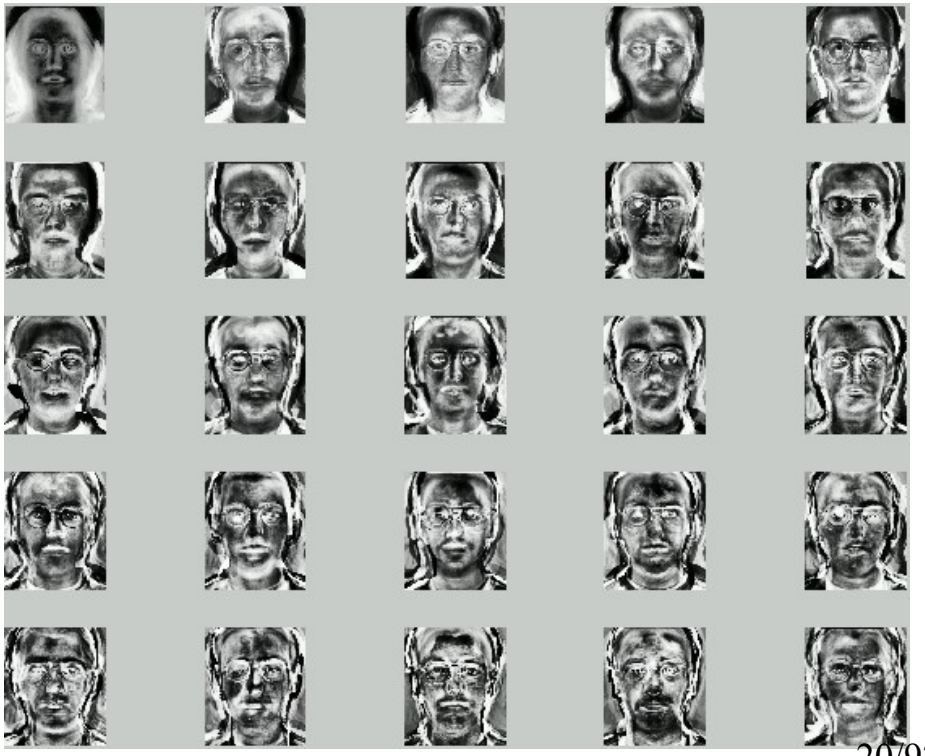
$$Y = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}\begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} -3/\sqrt{2} & -1/\sqrt{2} & 0 & 3/\sqrt{2} & -1/\sqrt{2} \end{pmatrix}$$

二、点云滤波

□ 知识点补充： PCA 算法



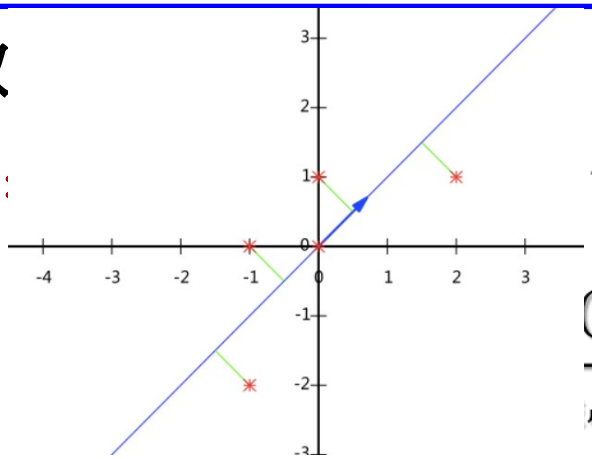
经典应用：
人脸识别中的特征脸方法 **Eigenface**



二、点云滤波

2.7 双

权值计算：

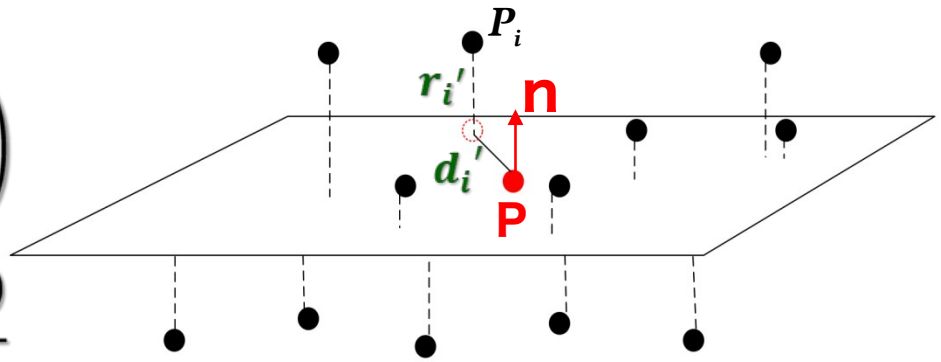


$$\frac{r_i'^2}{2\sigma_r^2}\Bigg)$$

$$(P_i, P)$$

$$, P)$$

滤波器：

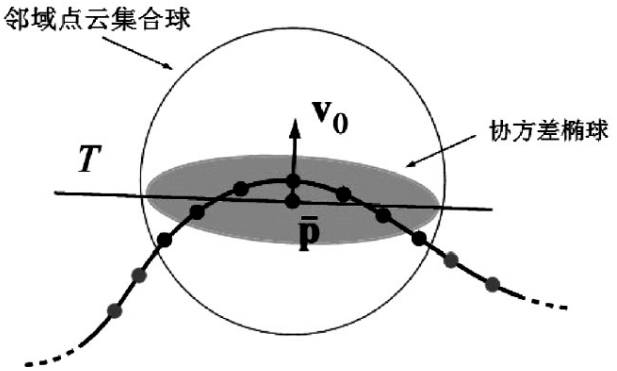


问题及关键：平面 S 法线 n？ -- 基于 PCA 的法线估计

$$\bar{P} = \sum_{P_i \in N(P)} P_i$$

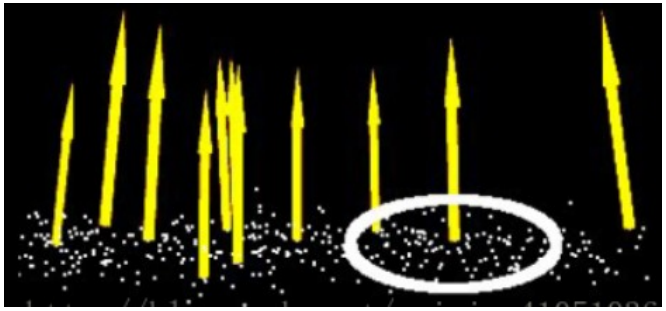
$$\mathbf{C} = \begin{bmatrix} (P_1 - \bar{P})^{\mathrm{T}} \\ \cdots \\ (P_N - \bar{P})^{\mathrm{T}} \end{bmatrix}^{\mathrm{T}} \begin{bmatrix} (P_1 - \bar{P})^{\mathrm{T}} \\ \cdots \\ (P_N - \bar{P})^{\mathrm{T}} \end{bmatrix}$$

特征值分解：C 为对称半正定，特征值均为实数



$$\lambda = \min(\lambda_1, \lambda_2, \lambda_3)$$

协方差矩阵：描述了邻域点云几何空间分布的统计特性

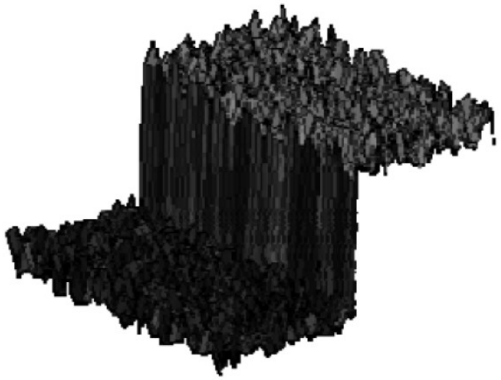


与之对应的特征矢量作为平面法线矢量 n

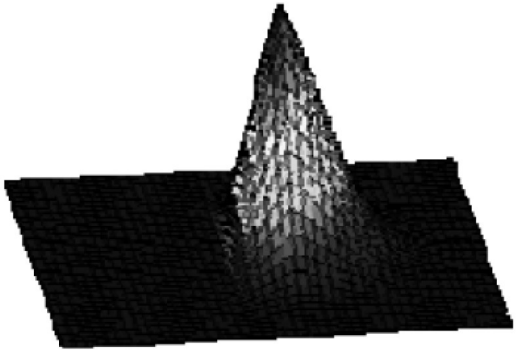
二、点云滤波

2.7 双边滤波器

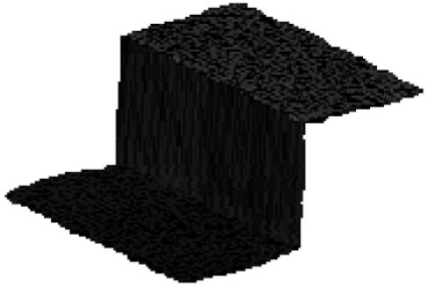
原始点云

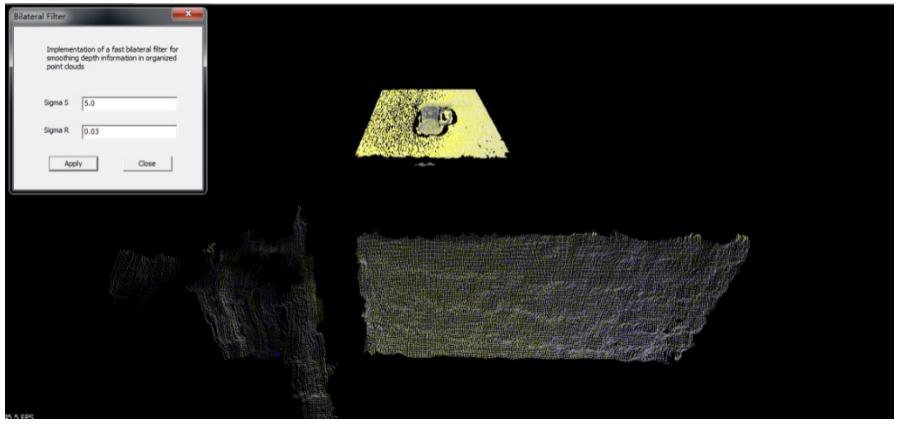


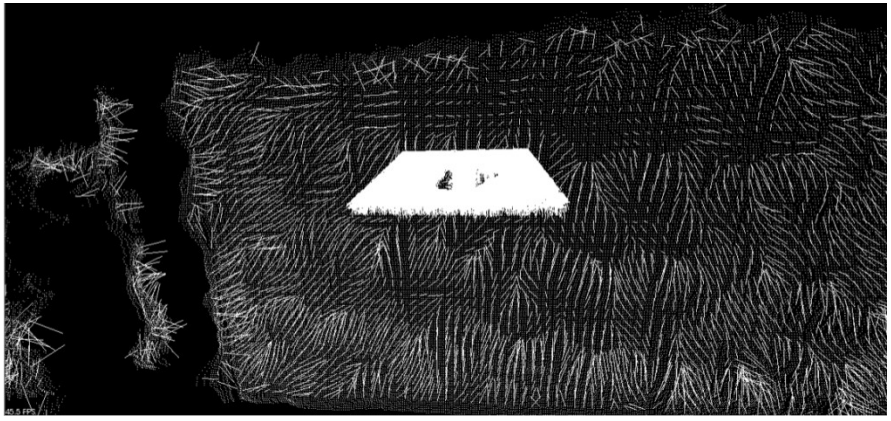
滤波器权值分布

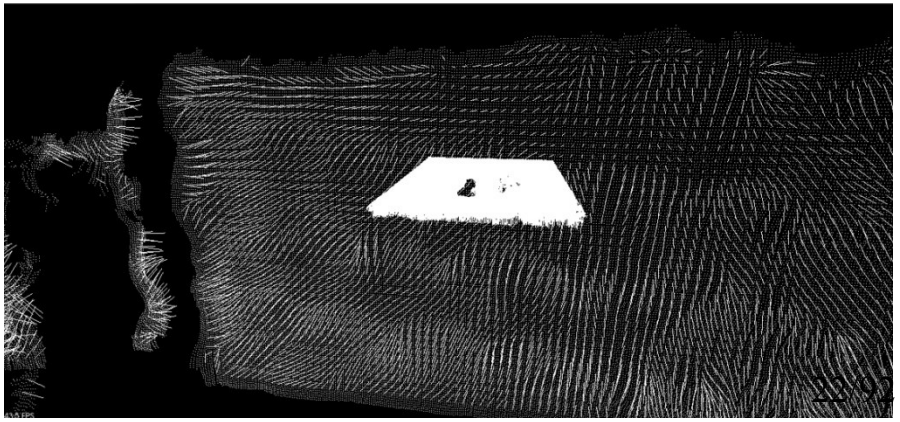


滤波后点云





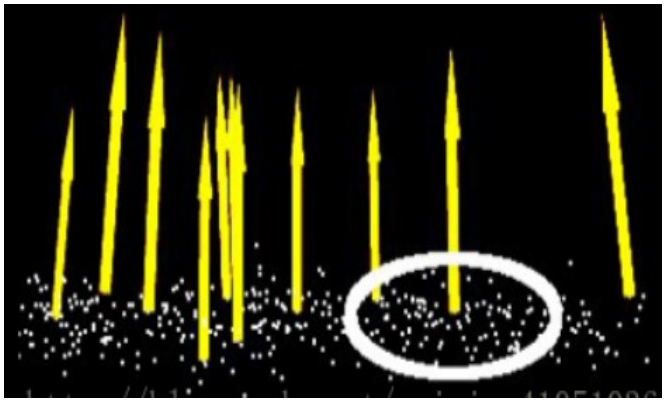




二、点云滤波

2.8 *DoN*（*Difference of Normal*）算法（基于点云频率的滤波方法）

- 算法动机：法线总是通过支撑半径（或通过固定数量的邻域）进行估计；任何给定半径下估计的曲面法线反映了支撑半径范围内曲面的基础几何结构，而支撑半径确定了法线表示的曲面结构所采用的尺度。



因此，可利用多尺度思想，直接使用无组织点云的估计表面法线图来定义无组织点云的多尺度算子进行滤波。

- 点云处理中的频率概念理解：高频信号变化快，低频信号变化缓慢
  - 图像处理：高低频引申至不同方向上图像灰度的变化 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$
  - 点云处理：将点云法线向量定义为点云所表达的信号。 $\frac{d\vec{n}}{dr}$

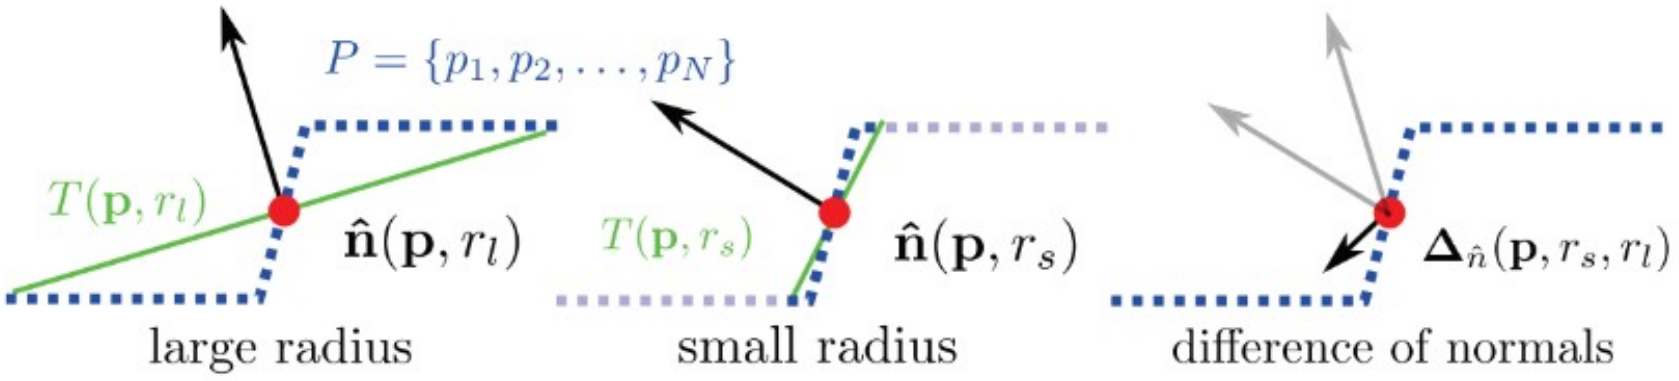
    如果某处点云曲率大，则表达的是一个变化的信号，频率高。

    如果某处点云曲率小，则表达的是一个不变的信号，频率低。

二、点云滤波

2.8 *DoN*（*Difference of Normal*）算法（基于点云频率的滤波方法）

- 算法原理：利用不同支撑半径下估计得到的法线向量的差值进行滤波



$$\Delta_{\hat{\mathbf{n}}}(\mathbf{p}, r_1, r_2) = \frac{\hat{\mathbf{n}}(\mathbf{p}, r_1) - \hat{\mathbf{n}}(\mathbf{p}, r_2)}{2}$$

- 算法步骤

（1）在小尺度上计算点云法线 1

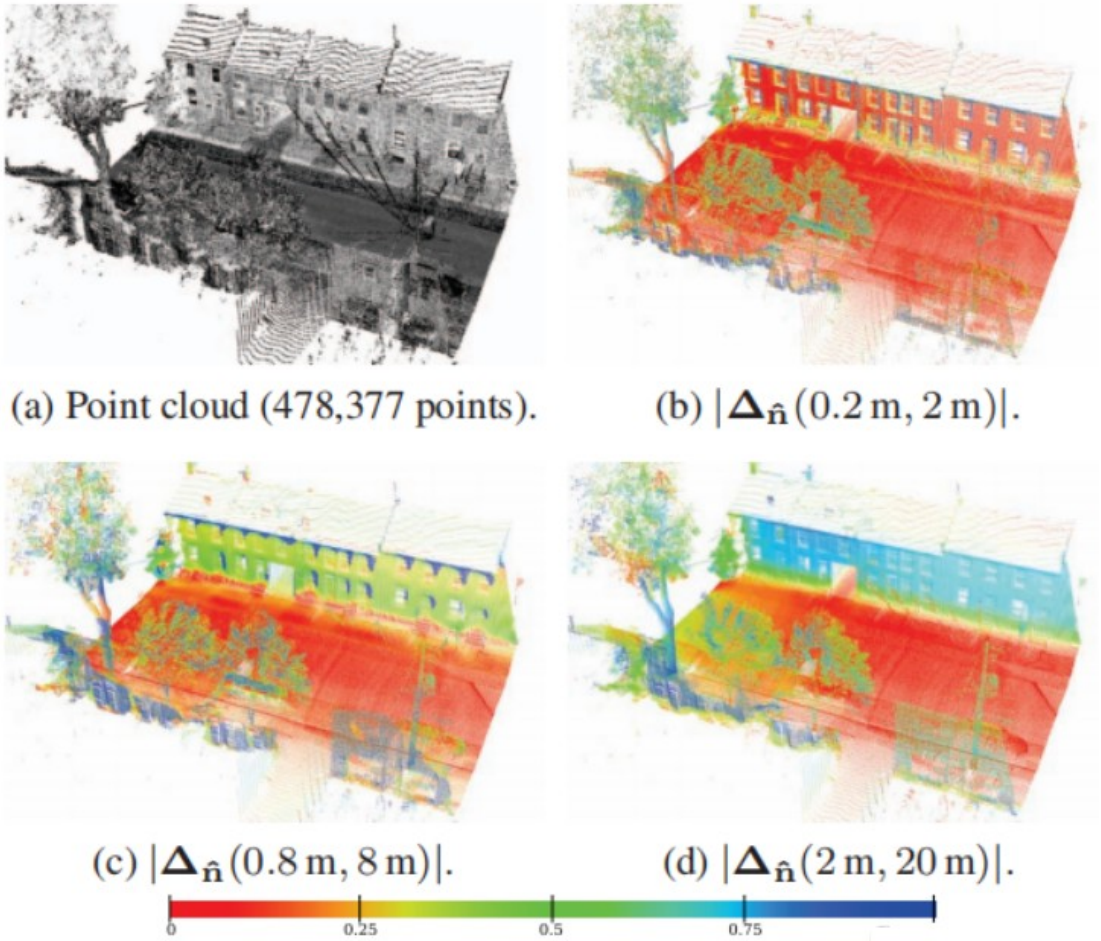
（2）在大尺度上计算点云法线 2

（3）法线 1- 法线 2

（4）滤去 3 中值较小的点（低频信息为较平坦部分，如墙面地面等）

二、点云滤波

2.8 *DoN*（*Difference of Normal*）算法（基于点云频率的滤波方法）



(a) Point cloud (478,377 points). (b) $|\Delta_{\hat{\mathbf{n}}}(0.2\,\mathrm{m}, 2\,\mathrm{m})|$.

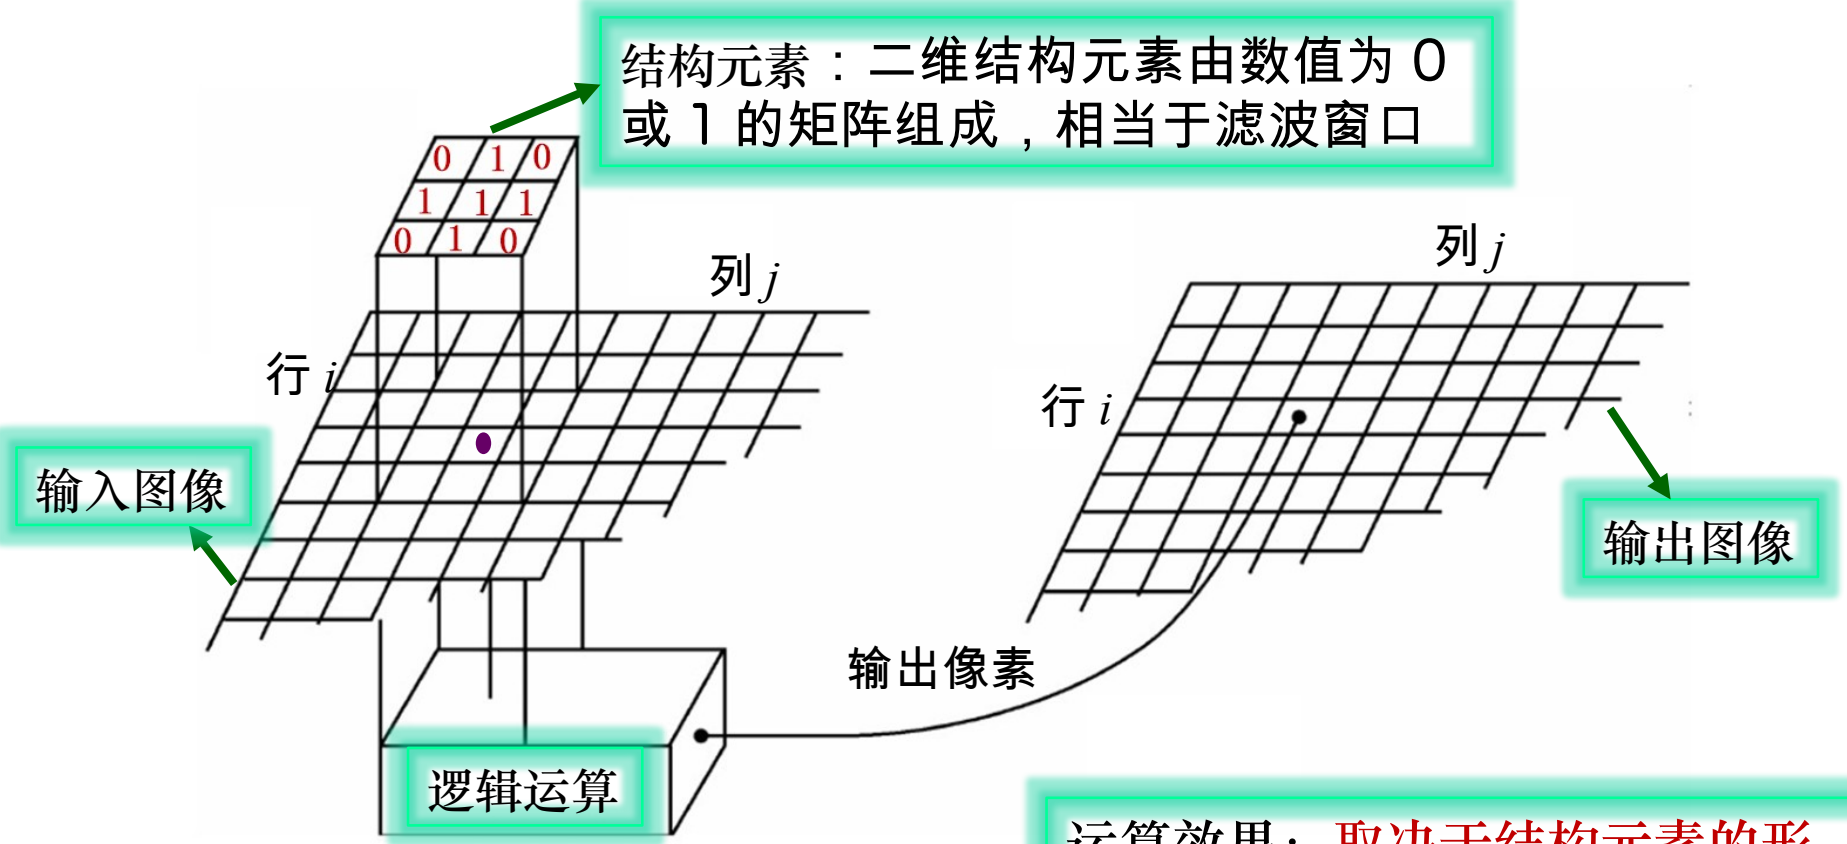
(c) $|\Delta_{\hat{\mathbf{n}}}(0.8\,\mathrm{m}, 8\,\mathrm{m})|$. (d) $|\Delta_{\hat{\mathbf{n}}}(2\,\mathrm{m}, 20\,\mathrm{m})|$.

- 对于小尺度 **DoN** 参数 **(0.2−2m)**，属于低尺度物体的点具有很强的响应。例如：图 **(b)** 中尺度结构响应最强是这些建筑道路路缘、窗台和建筑立面的细节。
- 对于较大尺度 **DoN** 参数 **(** 即 **2−20m)**，属于较大结构的点具有较强的响应。例如：图 **(d)** 中建筑有很大的响应，但非常大规模的结构（即路面）仍然表现出很小的响应。

二、点云滤波

2.9 基于数学形态学的滤波方法

基本原理：使用结构元素的窗口模板作为处理单元，利用形态学中的膨胀与腐蚀算法相组合，形成开、闭两种算子进行综合处理。



在结构元素每个像素位置上与二值图像对应的区域进行特定的逻辑运算

运算效果：取决于结构元素的形状、大小、内容以及逻辑运算性质

二、点云滤波

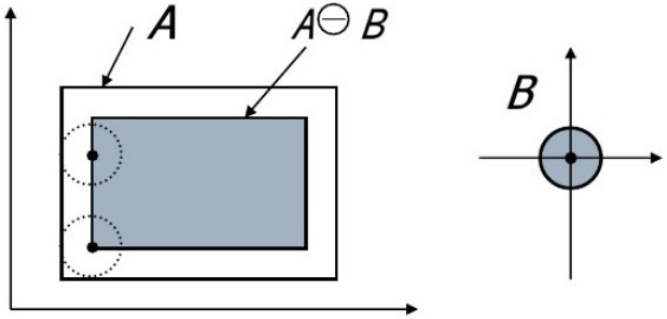
2.9 基于数学形态学的滤波方法

模板

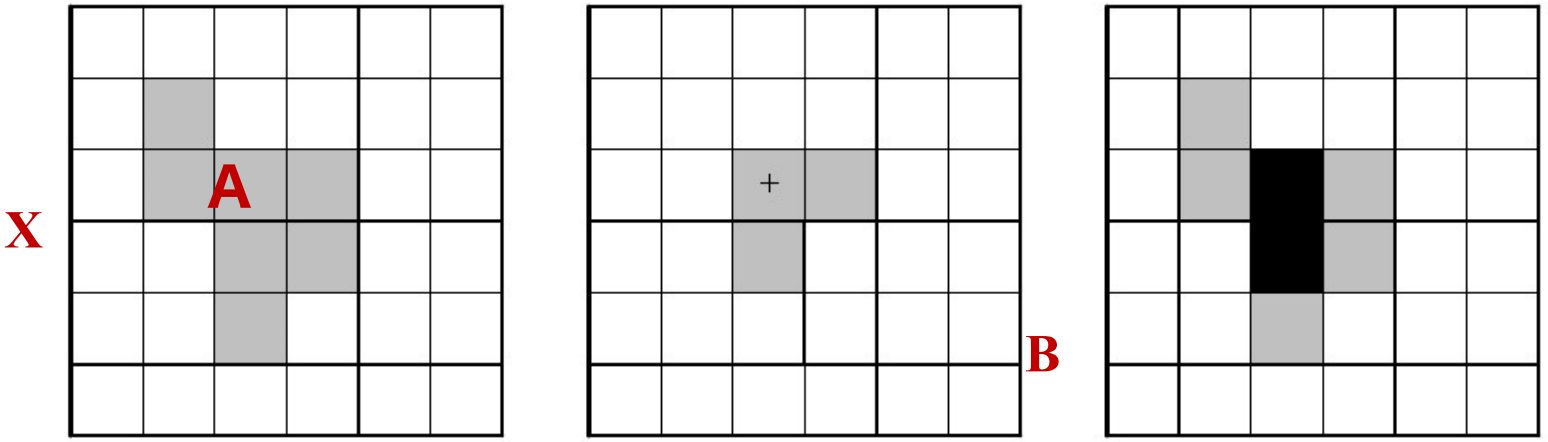
腐蚀运算：$A \ominus B = \{x : B + x \subset A\}$

x被滤波像素点

图像中的目标区域



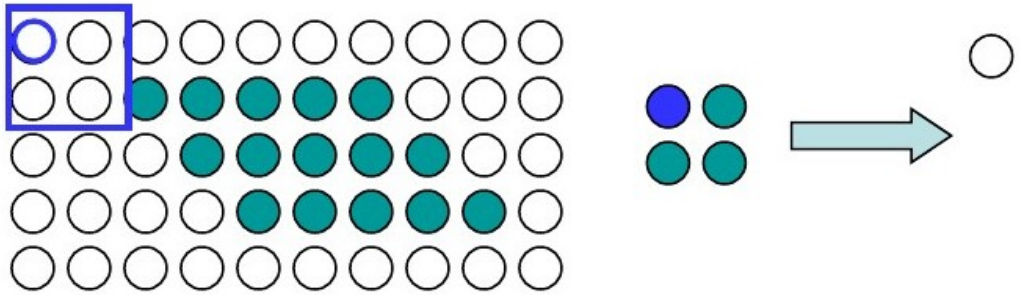
腐蚀过程：拿模板 B 的原点和输入图像 X 上的点一个一个对比，如果 B 上的所有为 1 的元素所覆盖的点都在目标 A 的范围内，则 B 原点所对应的点判断为属于目标 A，否则不属于。

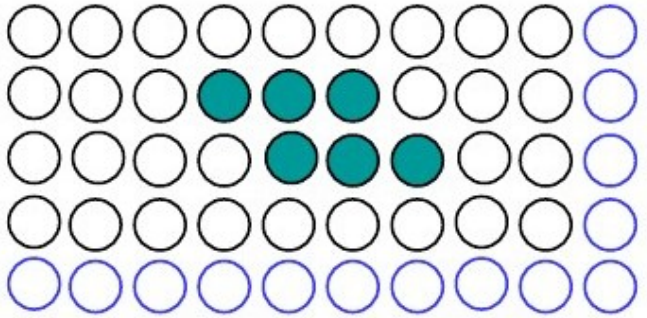


二、点云滤波

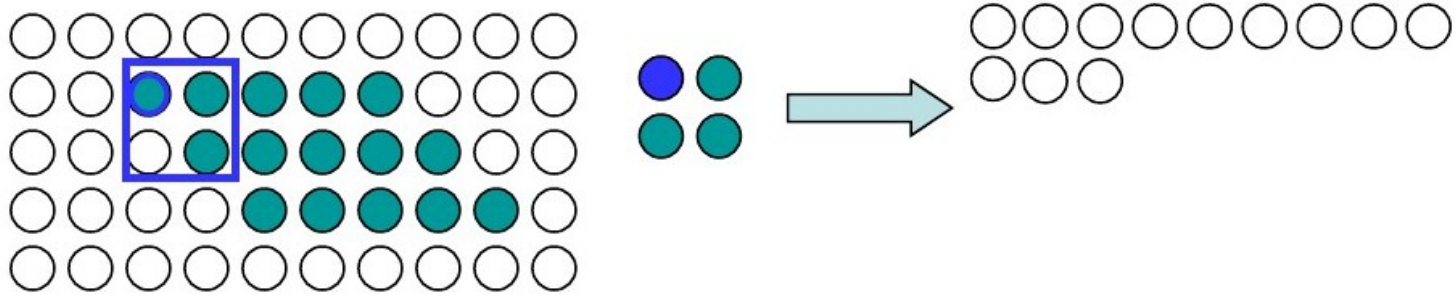
2.9 基于数学形态学的滤波方法

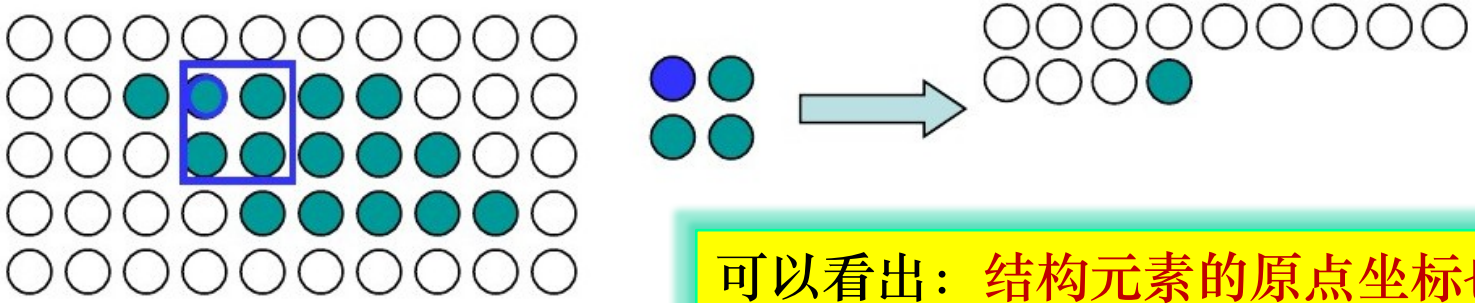
腐蚀运算：$A \ominus B = \{x : B + x \subset A\}$





最终结果



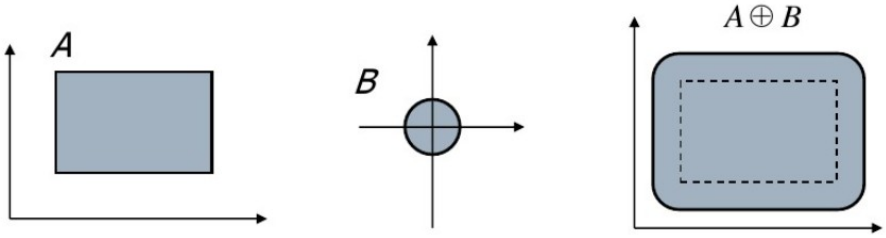


可以看出：结构元素的原点坐标也很重

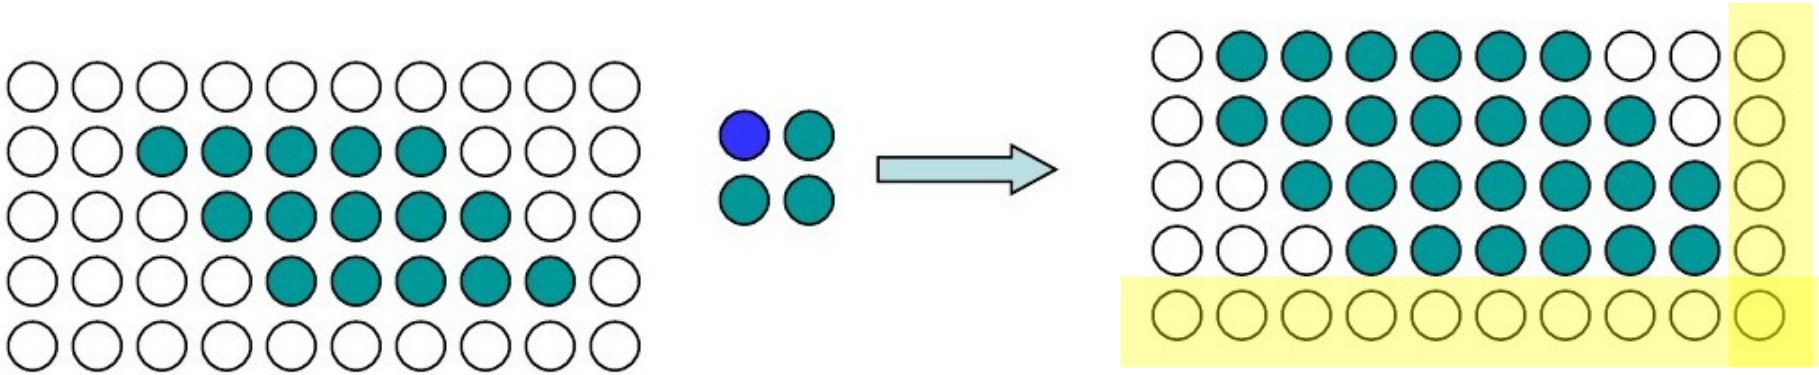
二、点云滤波

2.9 基于数学形态学的滤波方法

膨胀运算：$A \oplus B = [A^c \ominus (-B)]^c$



膨胀过程：拿模板 B 的原点和输入图像 X 上的点一个一个对比，如果 B 上有一个为 1 的元素所对应的图像点在目标 A 的范围内，则 B 原点所对应的点判断为属于目标 A，否则不属于。

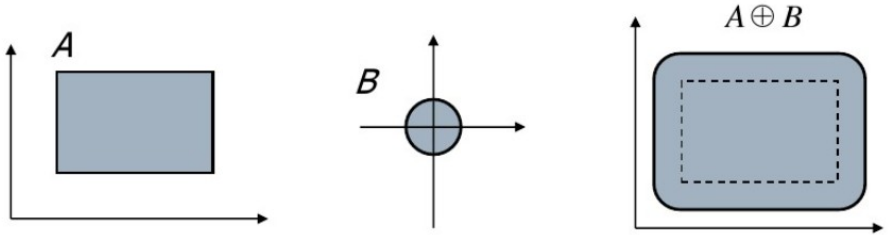


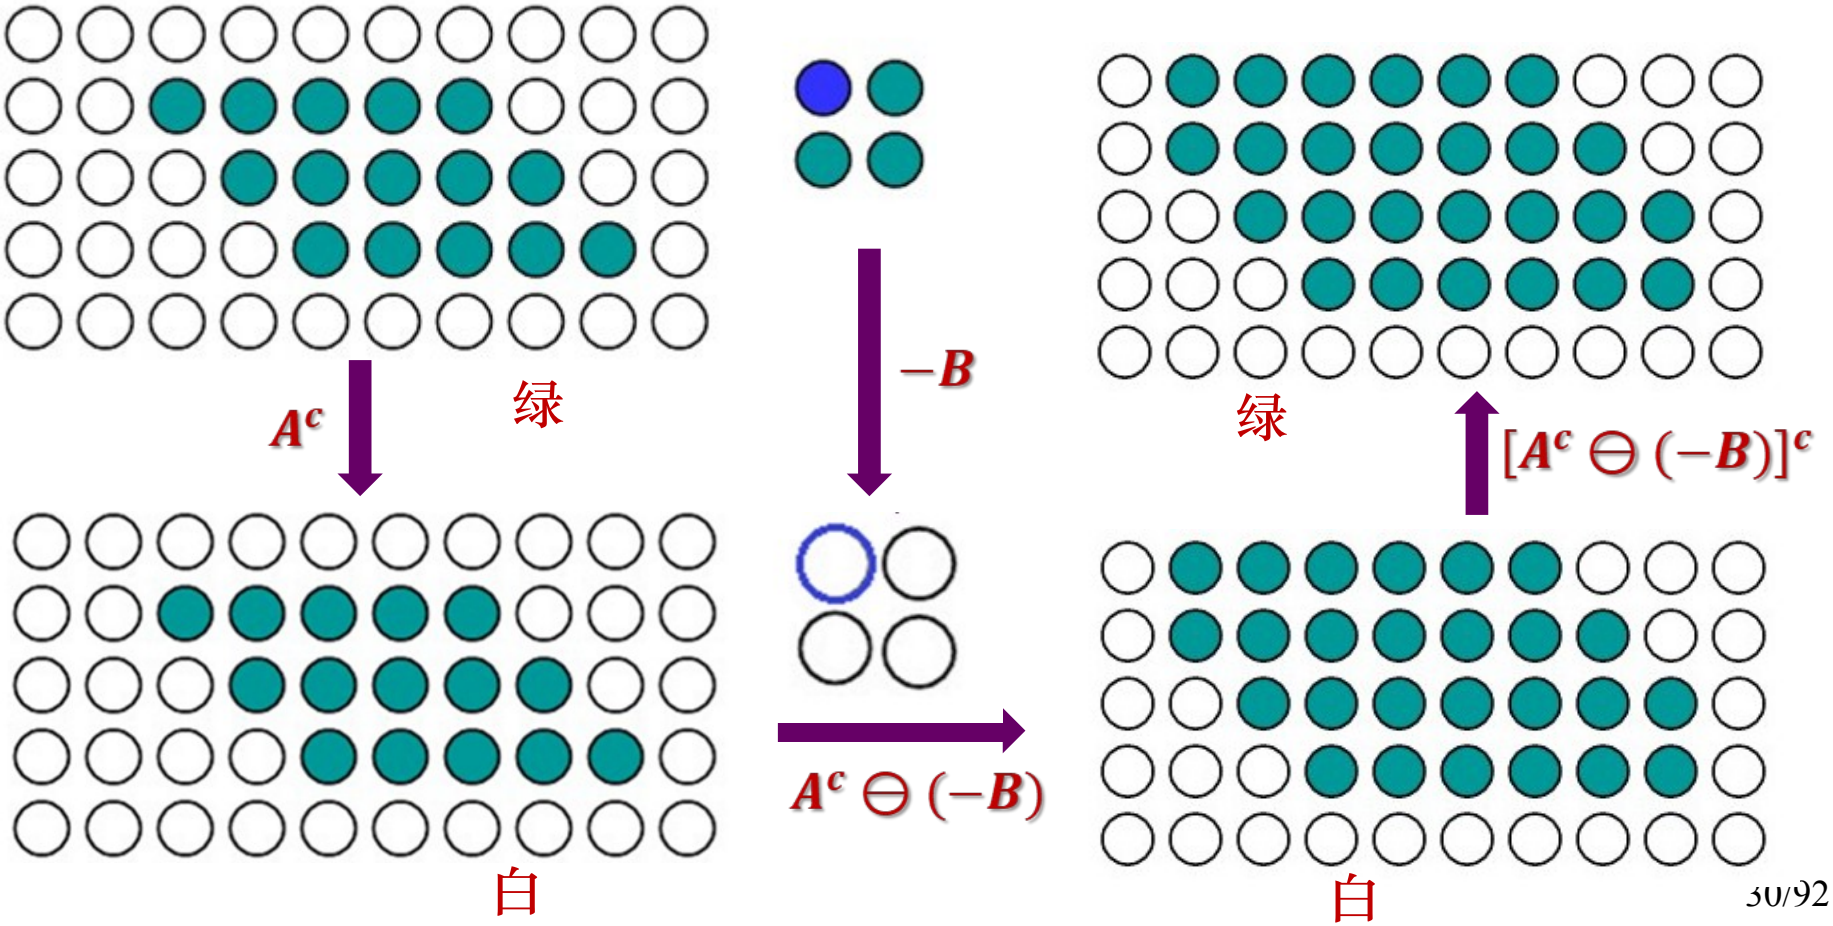
边缘不处理

二、点云滤波

2.9 基于数学形态学的滤波方法

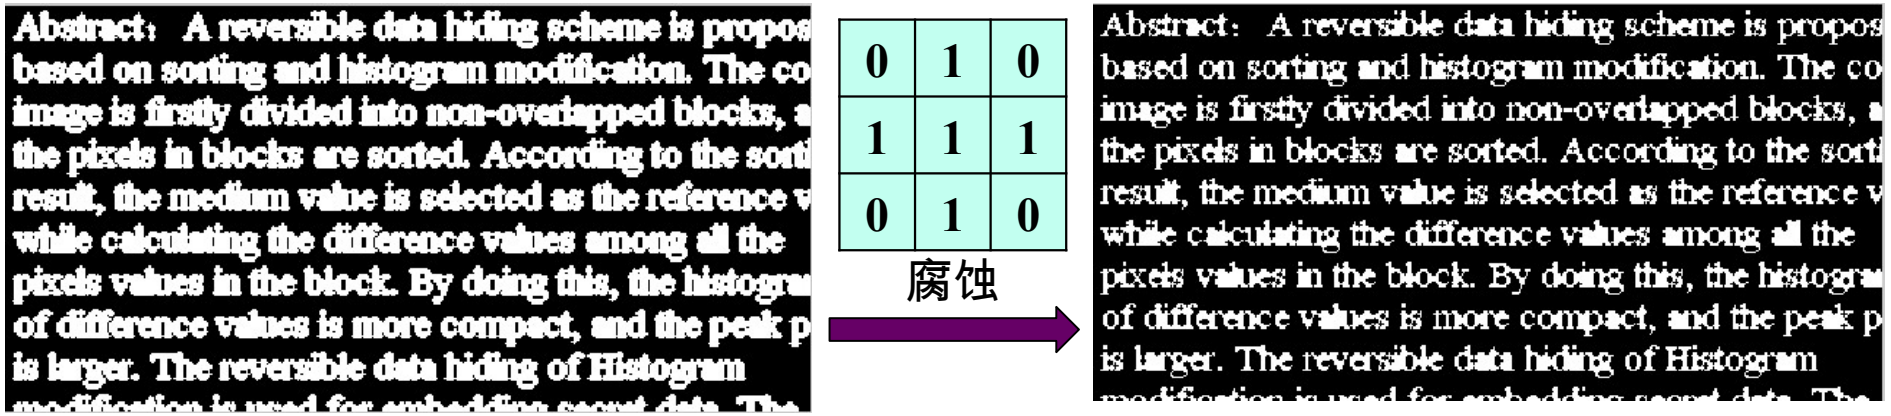
膨胀运算：$A \oplus B = [A^c \ominus (-B)]^c$

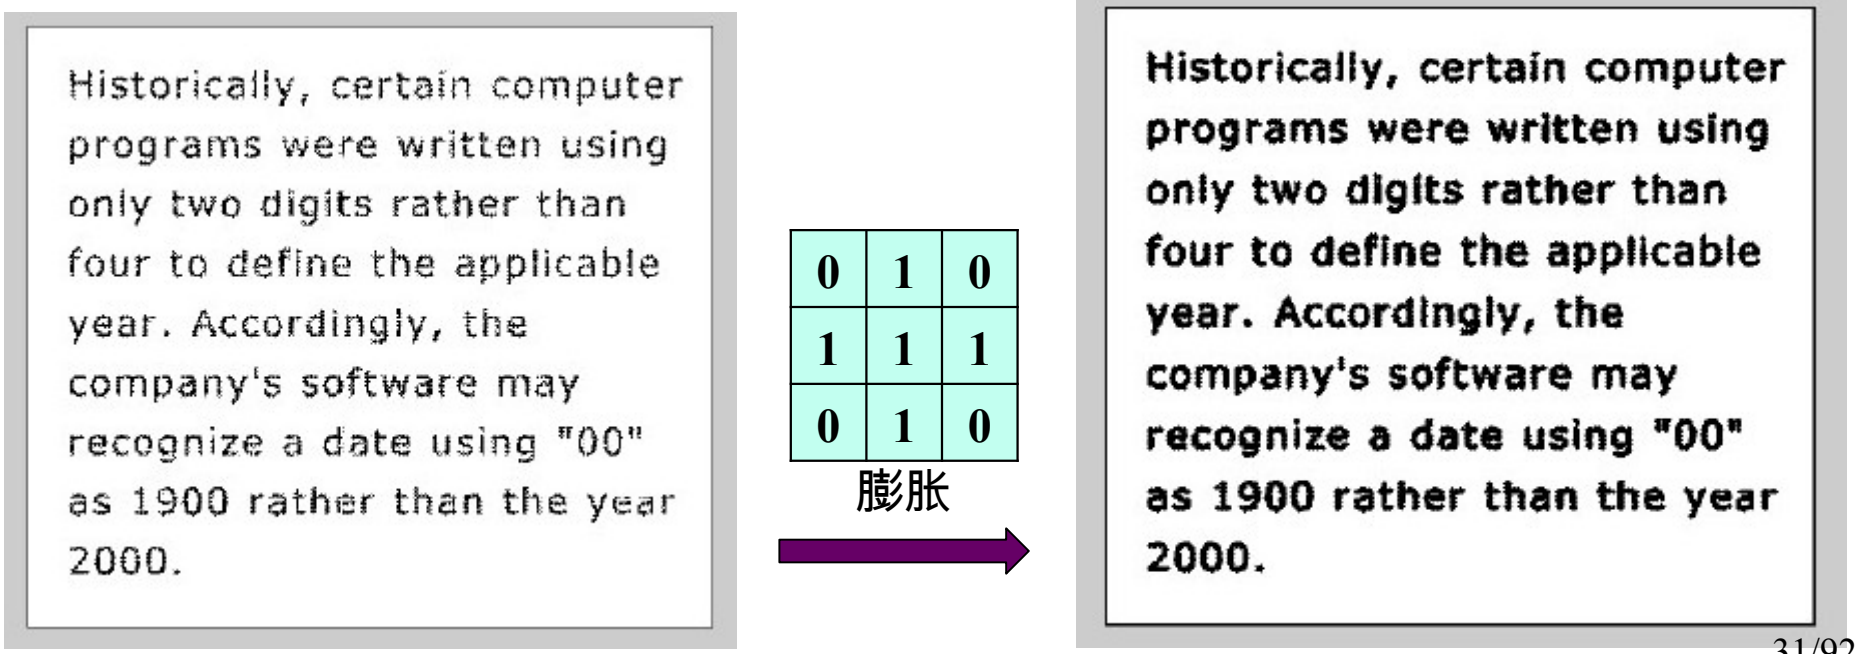




二、点云滤波

2.9 基于数学形态学的滤波方法



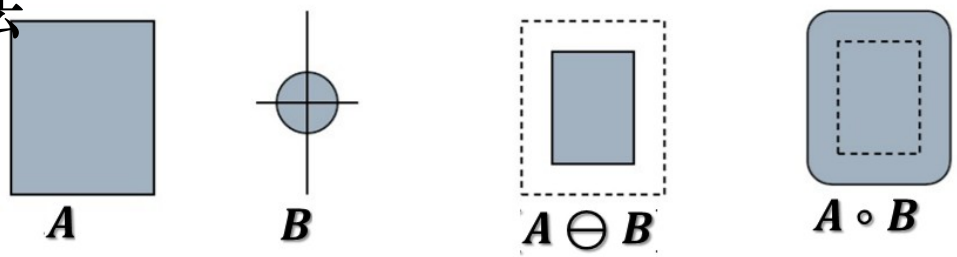


二、点云滤波

2.9 基于数学形态学的滤波方法

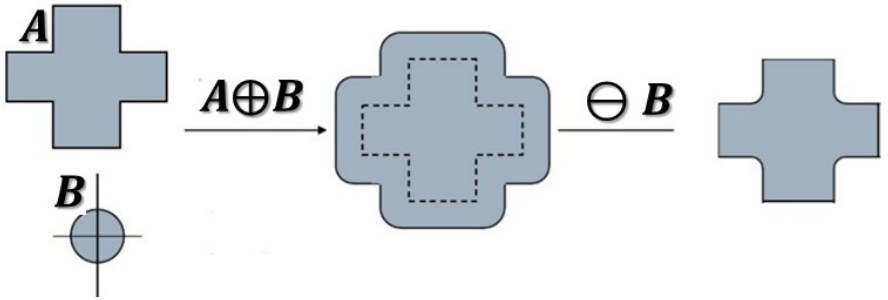
开运算：先腐蚀后膨胀

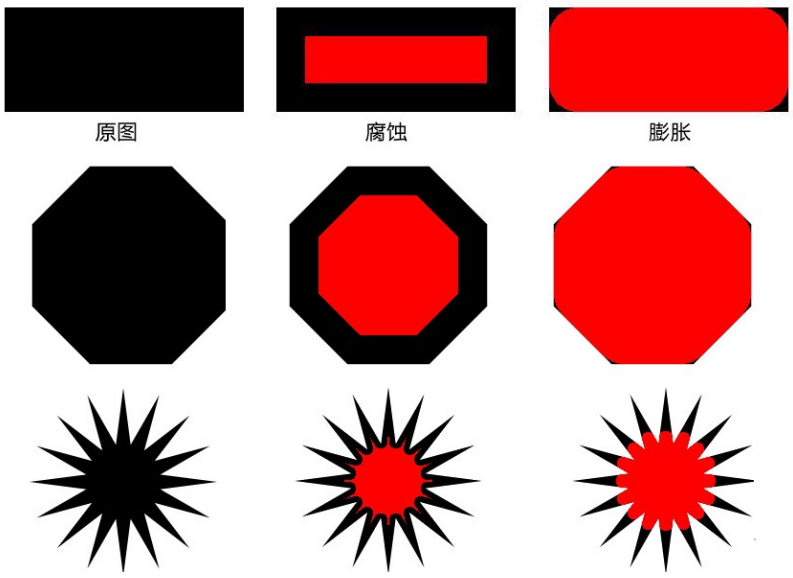
$$A \circ B = (A \ominus B) \oplus B$$

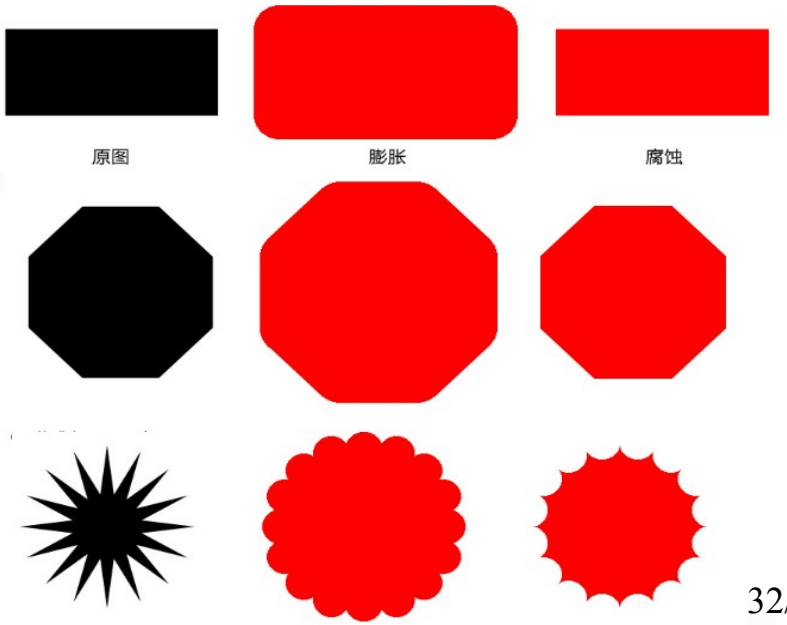


闭运算：先膨胀后腐蚀

$$A \bullet B = [A \oplus B] \ominus B$$







二、点云滤波

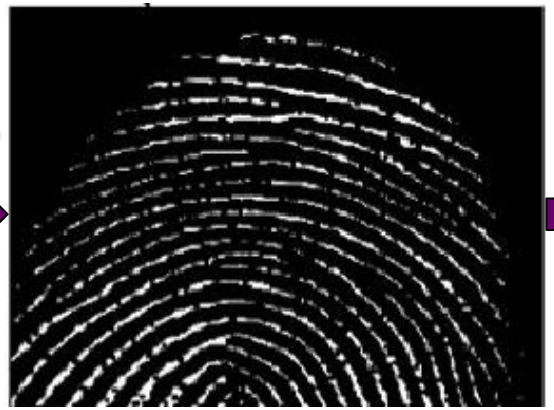
1	1	1
1	1	1
1	1	1

2.9 基于数学形态学的滤波方法

A



$A \ominus B$



噪声滤除，尺寸减小

$A \circ B = (A \ominus B) \oplus B$



尺寸复原，有间断

$(A \circ B) \oplus B$



尺寸扩大，间断修复

$(A \circ B) \bullet B = ((A \circ B) \oplus B) \ominus B$



尺寸复原

- 开运算作用：去除孤立小点、毛刺和小桥，总的位置和形状不变
- 闭运算作用：填平小孔，弥合小裂缝，总的位置和形状不变

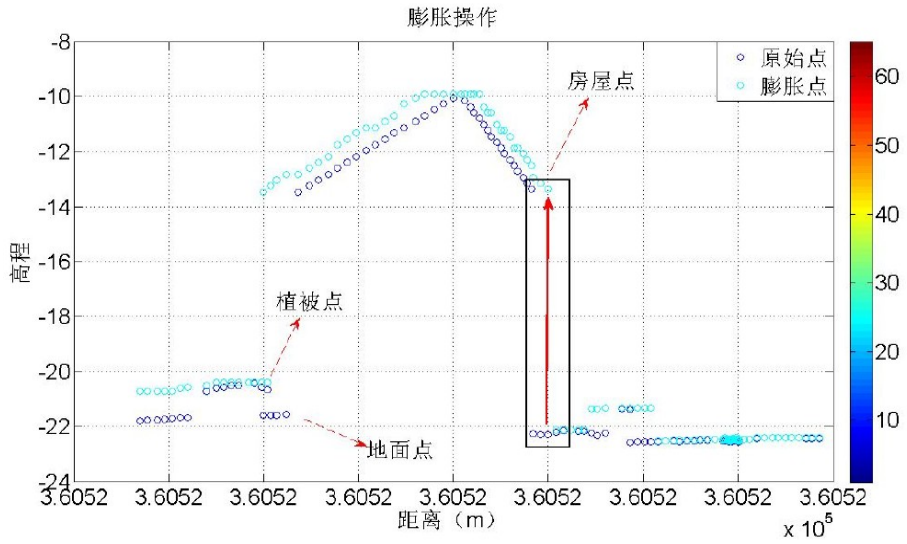
二、点云滤波

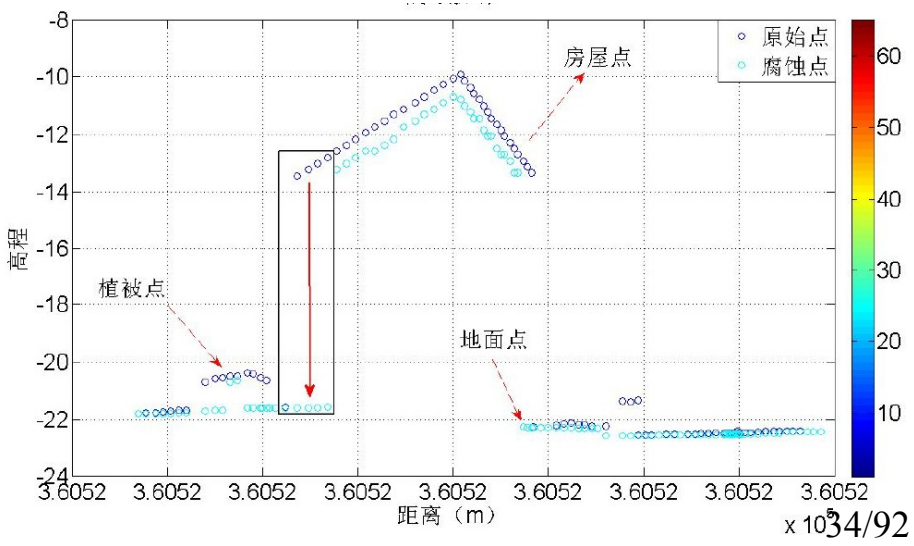
2.9 基于数学形态学的滤波方法

点云数据的数学形态学运算：假设三维点为$P(x_p, y_p, z_p)$，对该点的膨胀腐蚀等操作就是对其z值进行运算。膨胀和腐蚀分别定义为：

膨胀 $z_p = \max_{(x_s,y_s)\in W}(z_s)$　　腐蚀 $z_p = \min_{(x_s,y_s)\in W}(z_s)$

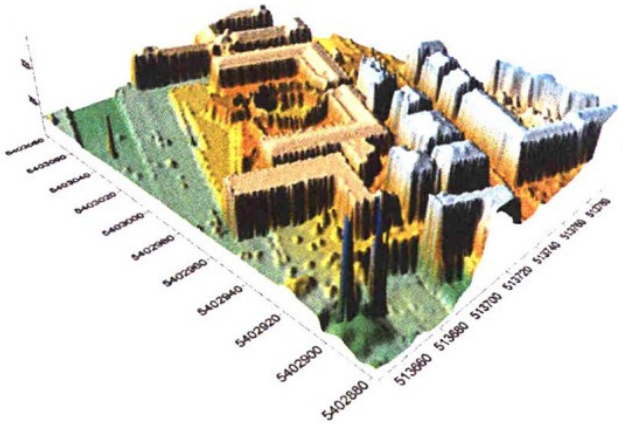
- **W** 为邻域窗口，窗口的形状可以是一维、二维方形或其它形状。
- 膨胀操作是高度提升为 邻域内的最高值；腐蚀将高度降低为邻域内的最低



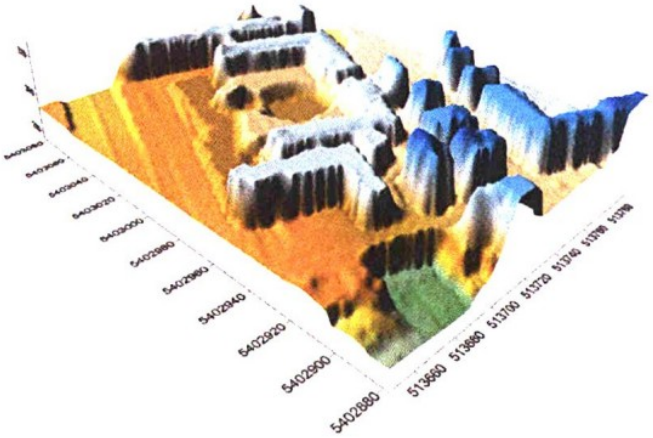


二、点云滤波

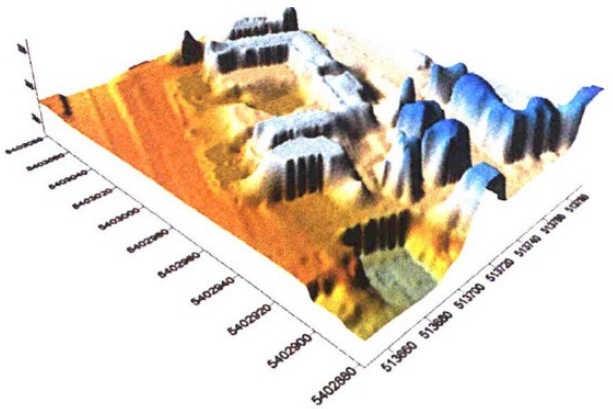
2.9 基于数学形态学的滤波方法



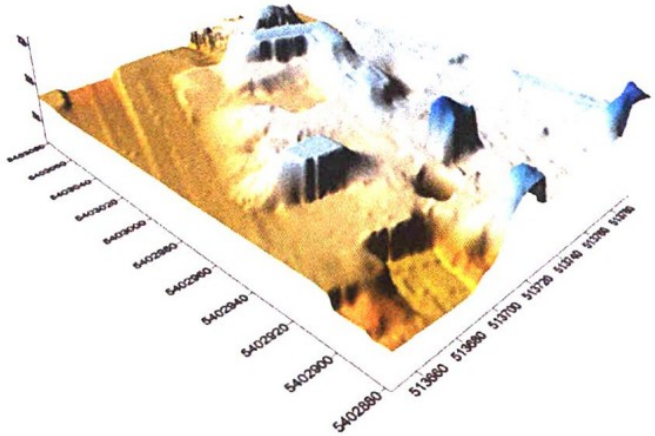
原始数据



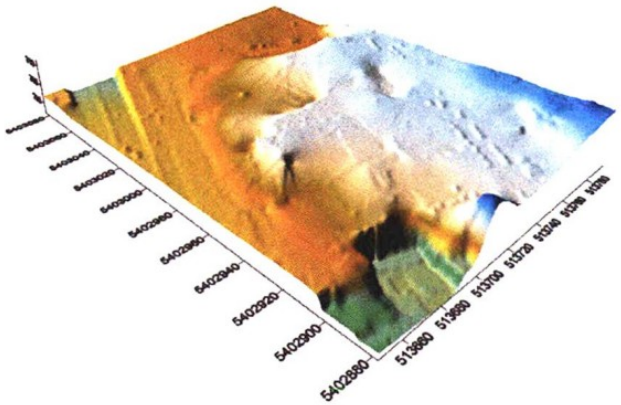
窗口尺寸： 5



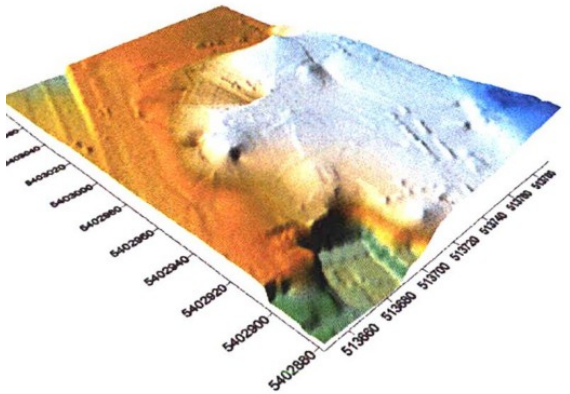
窗口尺寸： 9



窗口尺寸： 13



窗口尺寸： 17

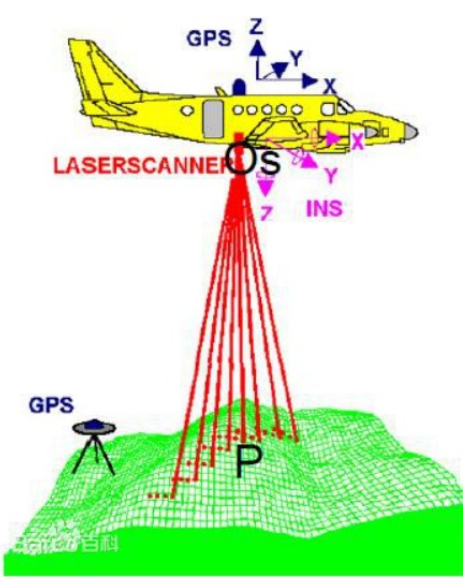


窗口尺寸： 21

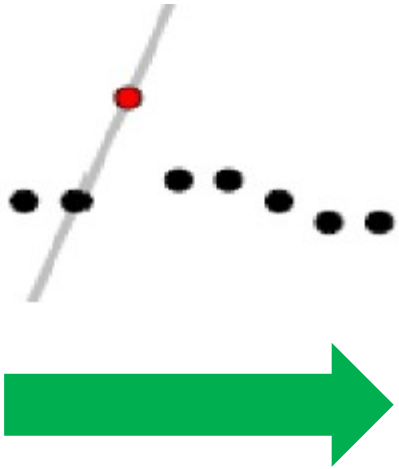
二、点云滤波

2.10 面向地形构建的 LIDAR 点云数据滤波

目的：通过机载激光雷达快速获取高精度三维地理数据，对这些点云数据进行滤波过程就是将 LIDAR 点云数据中的地面点和非地面点进行分离的过程。



机载
Lidar+GPS+INS

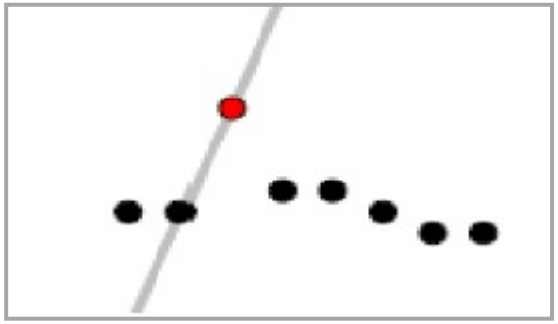




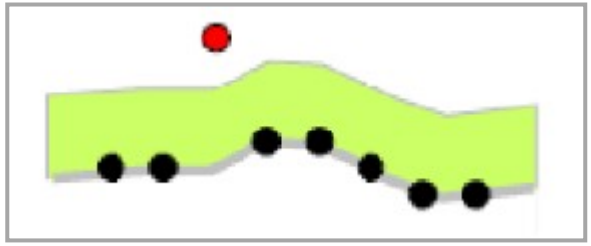
数字高程模型
（DEM： Digital Elevation Model）

二、点云滤波

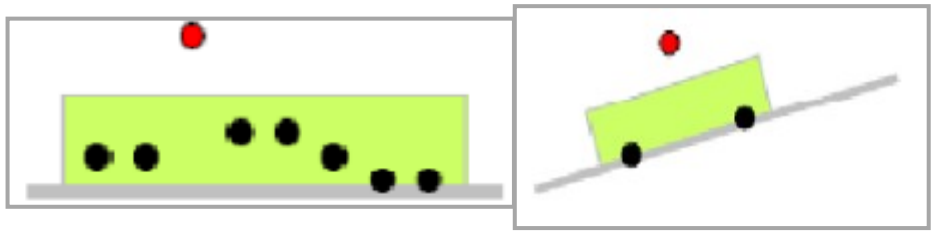
2.10 面向地形构建的 LIDAR 点云数据滤波



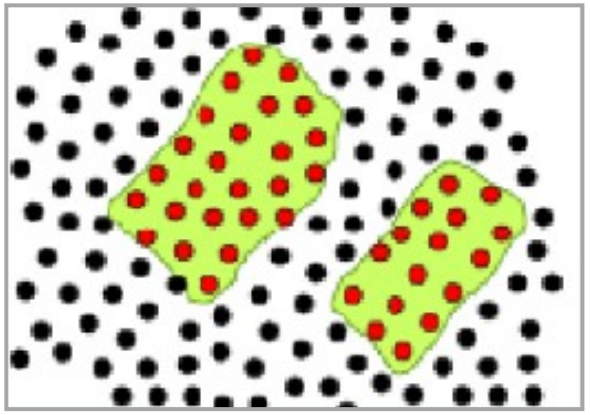
基于坡度理论的方法：认为地形表面平缓光滑，局部区域内地形发生急剧变化的可能性较小，通过比较两点间的高差值是否满足高差函数来判断点是否为地面点。



曲面拟合的方法



平面拟合的方法：利用窗口中的最低点拟合平面，滤除距离平面较远的点；调整窗口尺度



聚类与分割的方法

三、点云精简

概念与目的：原始数据量庞大，数据点密集，直接进行曲面重构或三角网格化，三角面片的数量巨大，增加计算时间；数据过细影响重构曲面的光滑性。以较少数量的点来逼近原始点云模型的过程就称为点云精简。

算法评估度量：

- 精度：依据精简数据重建所得表面与真实表面差别要尽可能小，保持原特征。
- 简度：精简后的三维点云数目尽可能少。
- 速度：精简过程时间短、速度快，

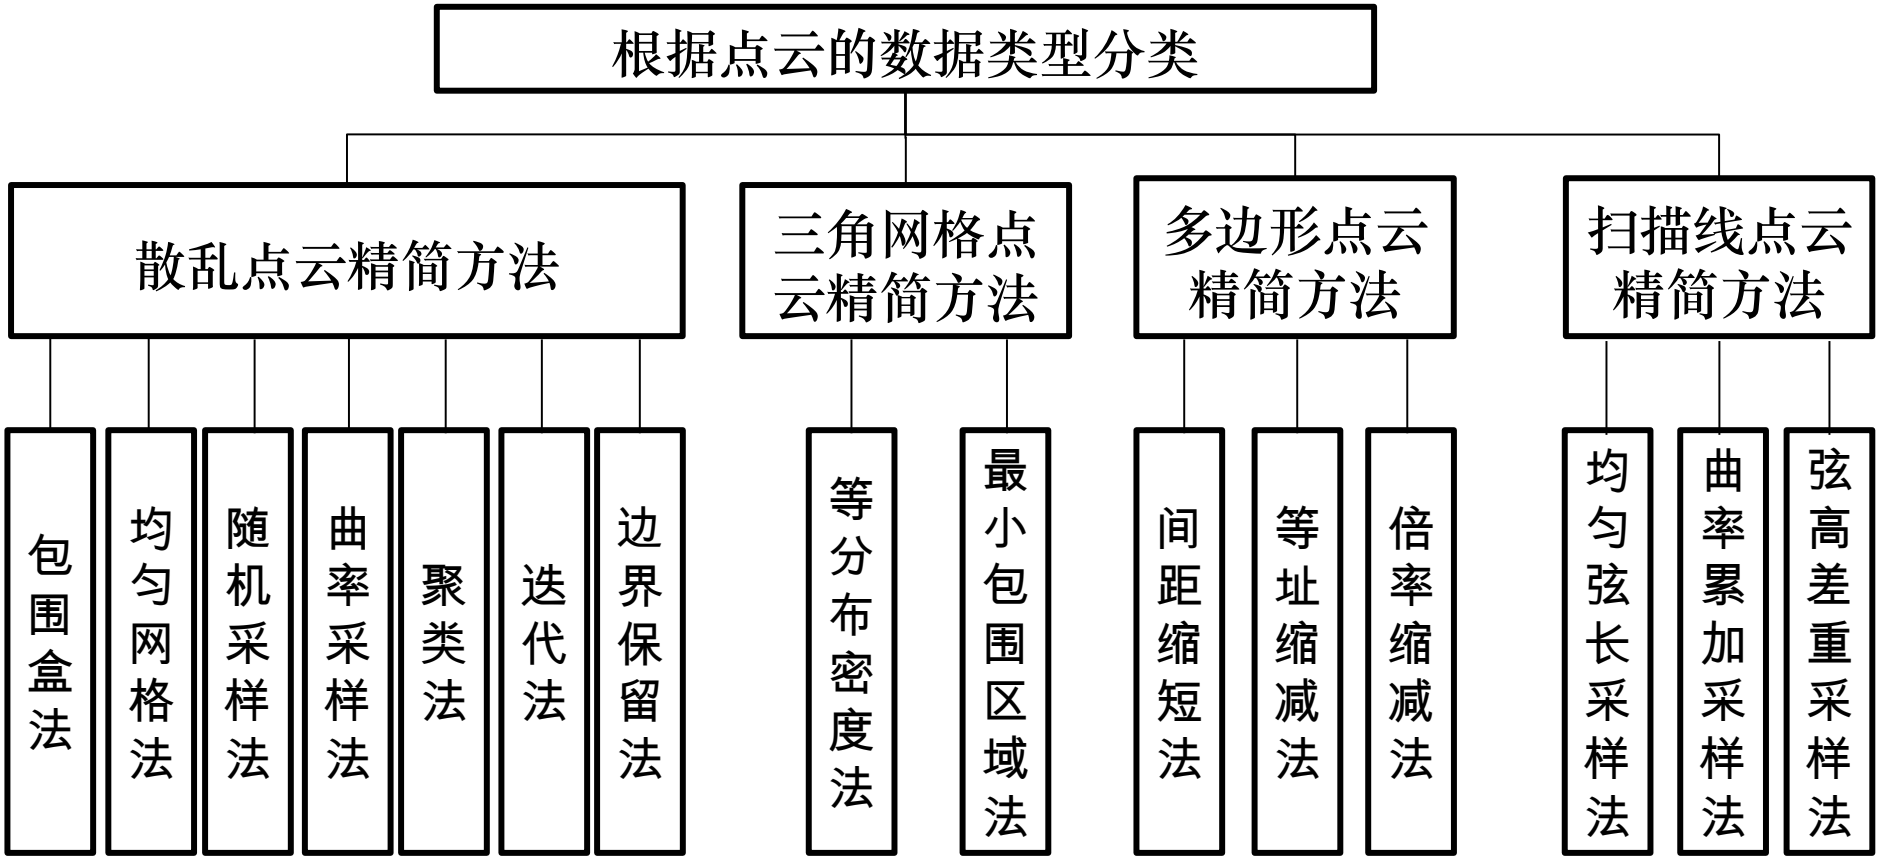
算法设计约束与思路：

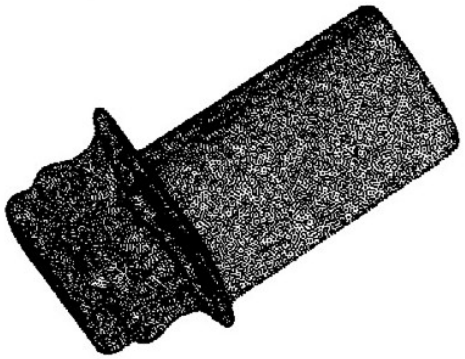
- 给定冗余误差阈值计算最小采样数分布；
- 给定目标采样点数据搜索最小误差分布。

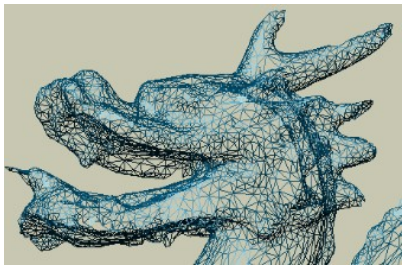


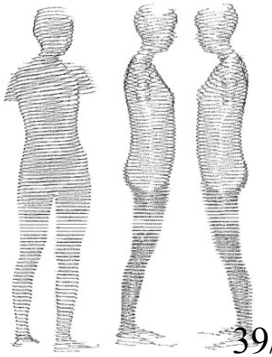


三、点云精简


根据点云的数据类型分类
散乱点云精简方法
三角网格点云精简方法
多边形点云精简方法
扫描线点云精简方法
包围盒法
均匀网格法
随机采样法
曲率采样法
聚类法
迭代法
边界保留法
等分布密度法
最小包围区域法
间距缩短法
等址缩减法
倍率缩减法
均匀弦长采样法
曲率累加采样法
弦高差重采样法



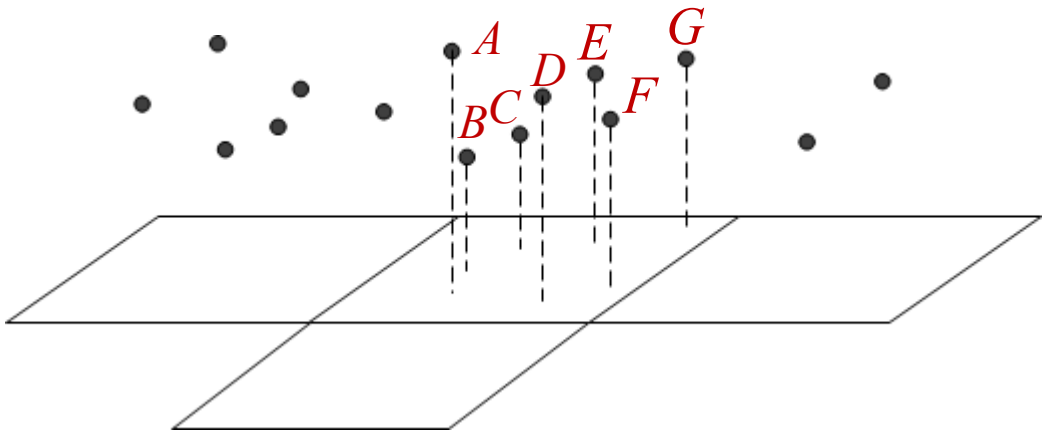




三、点云精简

3.1 均匀精简法

- 原理：首先把所得到的数据点进行均匀网格划分，然后从每个网格中提取样本点，网格中的其余点将被去除掉。
- 步骤：
  - ✓ 在垂直于扫描方向建立网格平面。将所有点投影至网格平面上，每个网格与对应的数据点匹配。
  - ✓ 每个网格中的点按照点到网格平面的距离远近排序，如果某个点位于各个点的中间，那么这个点就被选中保留。

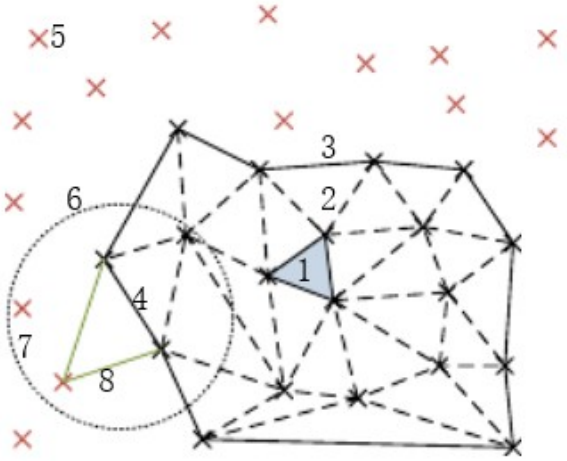


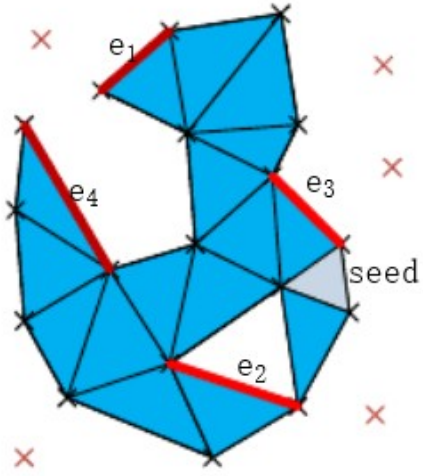
序号	数据点
1	B
2	C
3	F
4	D
5	E
6	G
7	A

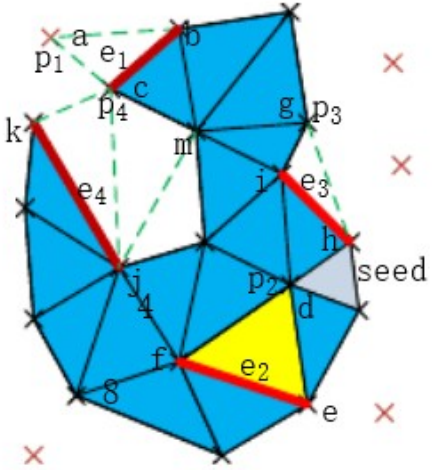
三、点云精简

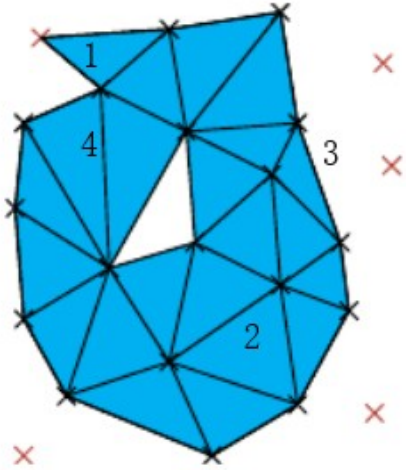
3.2 基于三角面片的散乱点云数据精简

- 基本思想：将扫描获取的数据点云直接三角网格化，比较数据点所在三角面片的邻近三角面片法向量，根据法向量相似性在平面或近似平面的较平坦区域用大的三角面片取代小的三角面片删除多余点，从而实现数据精简。



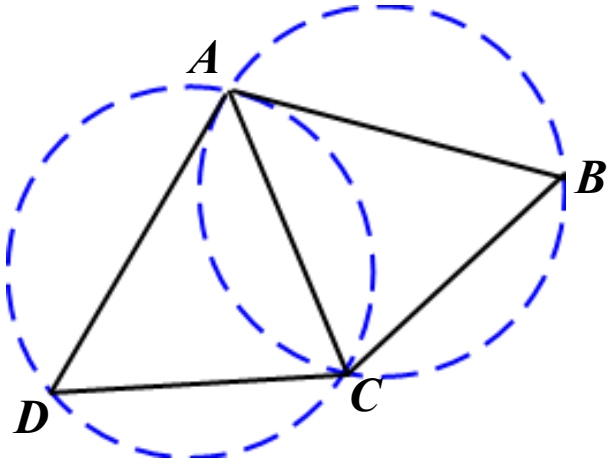






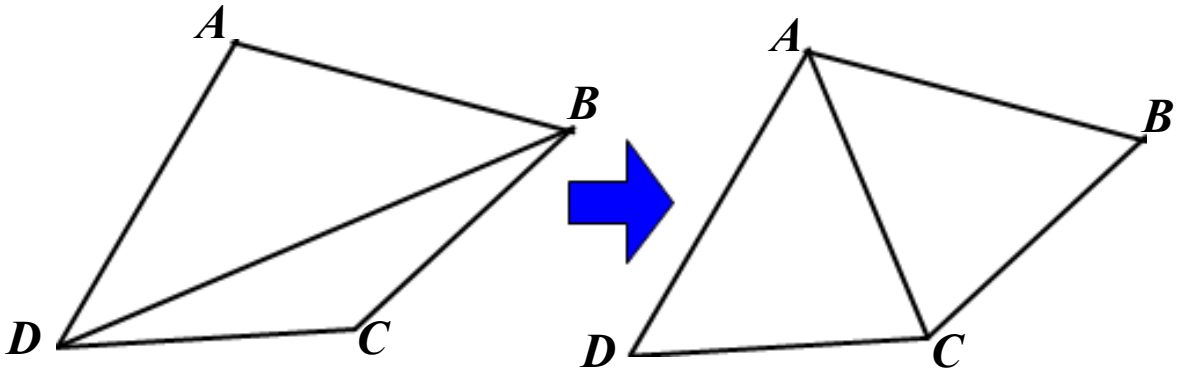
三、点云精简

3.2 基于三角面片的散乱点云数据精简



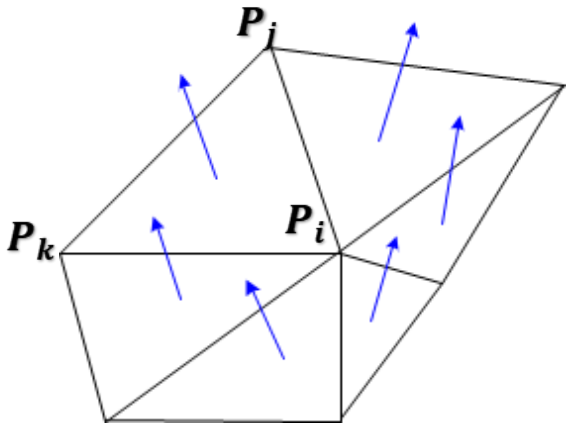
Delaunay 三角化准则：

- ✓ 空圆特性：在 Delaunay 三角形网中任一三角形的外接圆范围内不会有其它点存在。
- ✓ 最大化最小角特性：在散点集可能形成的三角化分中，Delaunay 三角剖分所形成的三角形的最小角最大。具体的说是指在两个相邻的三角形构成凸四边形的对角线，在相互交换后，六个内角的最小角不再增大。



三、点云精简

3.2 基于三角面片的散乱点云数据精简



✓ **三角形单位法矢量计算：** $\Delta P_i P_j P_k$

$$\vec{n}_{ijk} = \frac{\overrightarrow{P_iP_j} \times \overrightarrow{P_jP_k}}{\left\| \overrightarrow{P_iP_j} \times \overrightarrow{P_jP_k} \right\|}$$

平坦曲面上的点构成的三角网包含的信息量最少，即这些三角形的**法线向量的夹角越小**。如果以P_i为顶点的三角形有n个，两两之间的法线向量的夹角有$C^2{}_n$个，求这$C^2{}_n$**个夹角的最大值**，如果该最大值小于设定阈值，则该点P_i予以删除，否则保留。

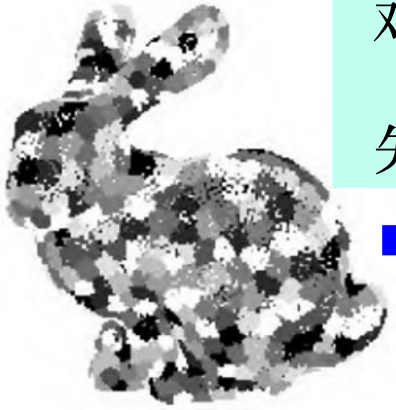


三、点云精简

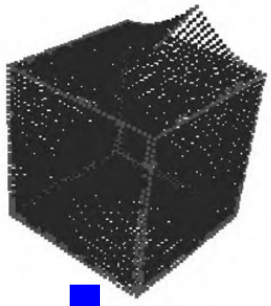
3.3 面向特征保持的点云数据精简



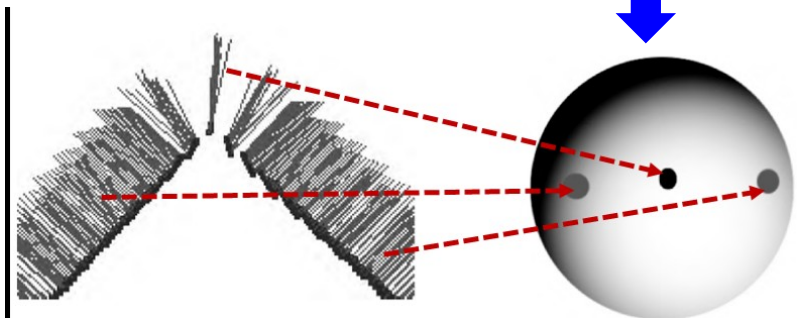
K 均值粗聚类



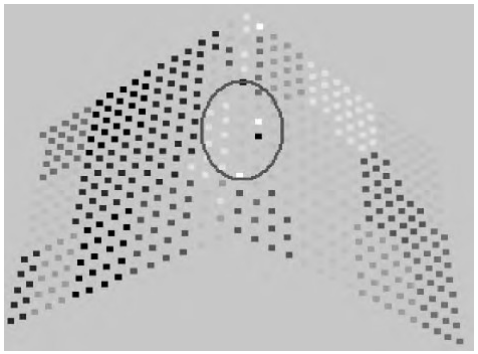
对每个聚类汇总的点云计算法矢，确定特征候选点



高斯球映射



在高斯球面上进行细聚类



三、点云精简

3.3 面向特征保持的点云数据精简

- 第 1 大步：利用 K 均值聚类法在空间域对点云全局聚类。

  Step1 ：选择初始化聚类中心；

  Step2 ：根据点云到各类中心的距离，每个点选择距离最近类作为类别标号；

  Step3 ：根据新的分类结果，计算同类中点云位置平均值作为新的聚类中心；

  Step4 ：重复步骤 2、3，直到类中心的位置不在发生变化。

基于 K-D 树的聚类中心初始化：保证点云聚类快速收敛，最好能均匀分布在模型各处。对点云数据构建 K-D 树，以 K-D 树的部分节点作为初始化聚类中心。



(a)原始点云

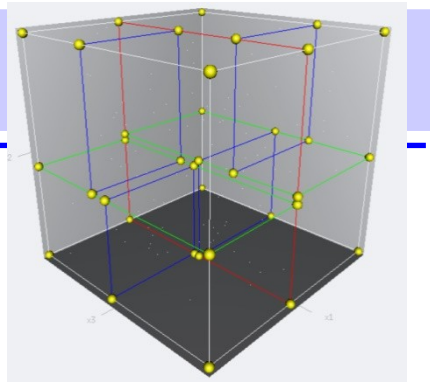


(b)K-d 树初始化聚类中心



(c)K 均值聚类结果

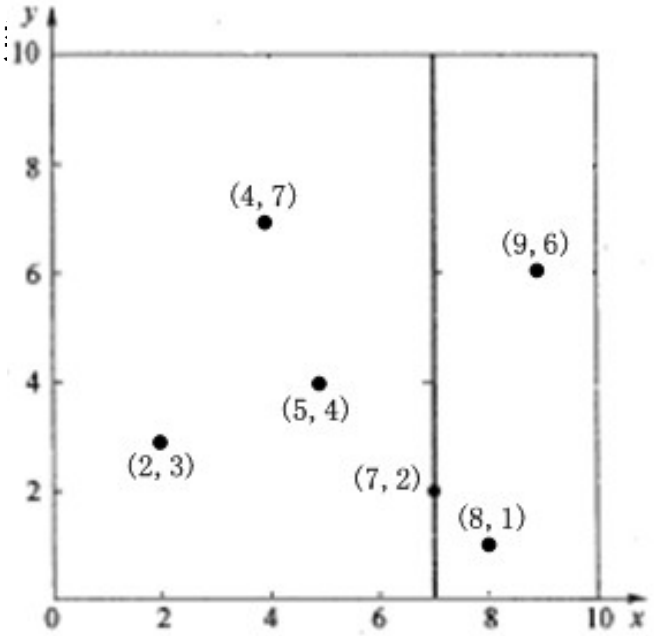
三、点云精简

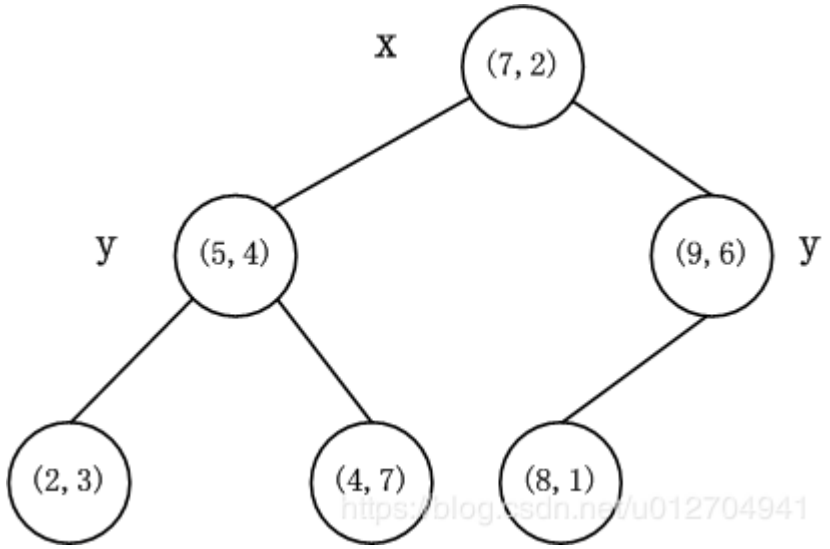


3.3 面向特征保持的点云数据精简

- 第 1 大步：利用K均值聚类法在空间域对点云全局聚类。

K-D 树：一种分割 k 维数据空间的数据结构，是二叉搜索树的扩展。在每个内部节点中，用一个 k-1 维与坐标轴平行的超平面将节点所表示的 k 维空间分成两部分，存储在子树中的点大约一半落入一侧，另一半落入另一侧。当一个节点中的点数少于给定的最大点数时，划分结束。超平面在 k 个方向上交替出现，每个超平面中至少包括一个。



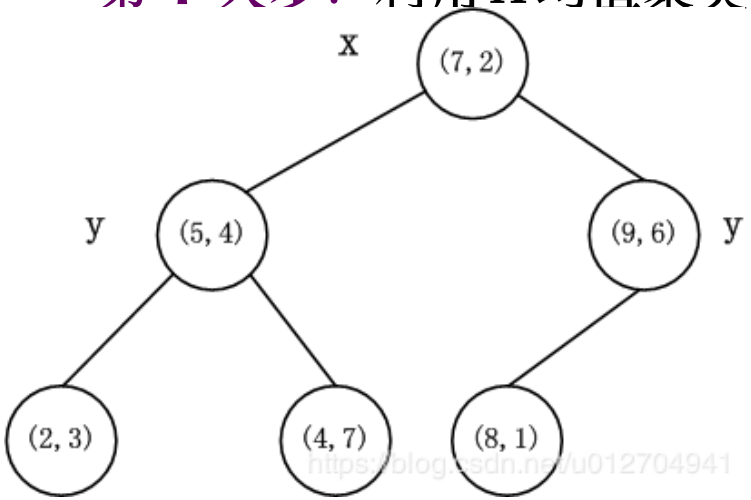


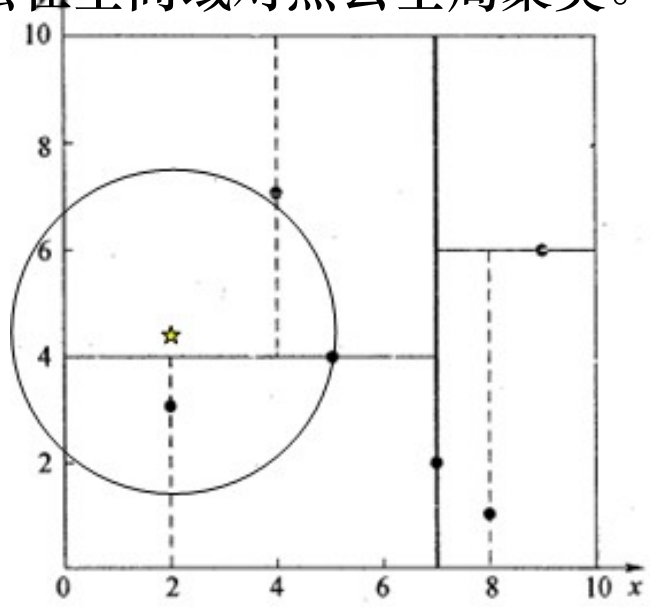
中位数划分

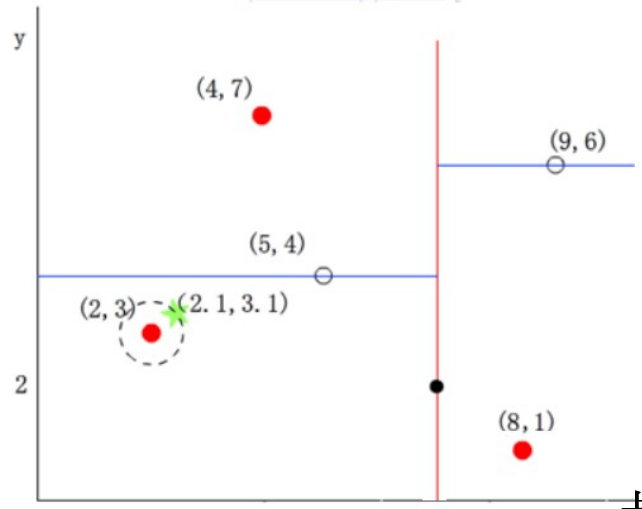
三、点云精简

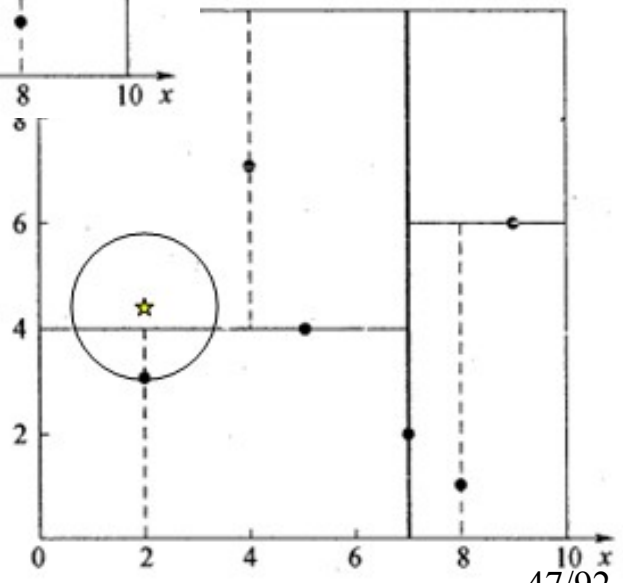
3.3 面向特征保持的点云数据精简

- 第 1 大步：利用K均值聚类法在空间域对点云全局聚类。









点的最近邻回溯搜索

3.3 面向特征保持的点云数据精简

- 第 2 大步：用主成分分析法估计点云法矢和候选特征点。遍历每个聚类，若类中包含特征点则将该类细分为多个子类，细分时将聚类映射到高斯球。

主成分分析

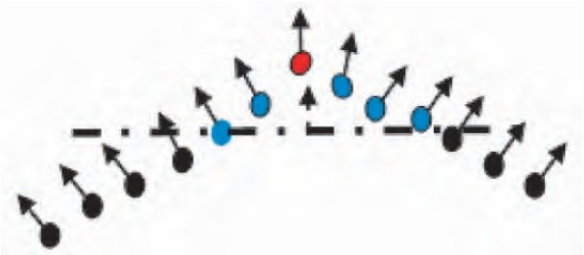
PCA：

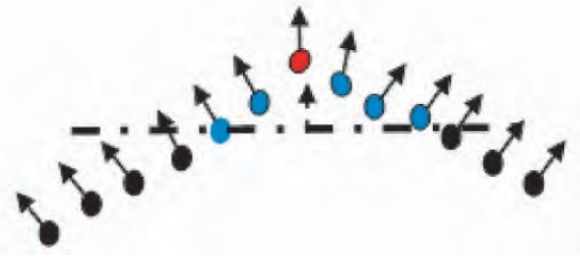
$$\mathbf{C} = \begin{bmatrix} (\boldsymbol{P_1} - \overline{\boldsymbol{P}})^{\mathrm{T}} \\ \cdots \\ (\boldsymbol{P_N} - \overline{\boldsymbol{P}})^{\mathrm{T}} \end{bmatrix}^{\mathrm{T}} \begin{bmatrix} (\boldsymbol{P_1} - \overline{\boldsymbol{P}})^{\mathrm{T}} \\ \cdots \\ (\boldsymbol{P_N} - \overline{\boldsymbol{P}})^{\mathrm{T}} \end{bmatrix}$$



$$\boldsymbol{\lambda} = \min(\boldsymbol{\lambda_1}, \boldsymbol{\lambda_2}, \boldsymbol{\lambda_3})$$

与之对应的特征矢量为平面法线矢量 n



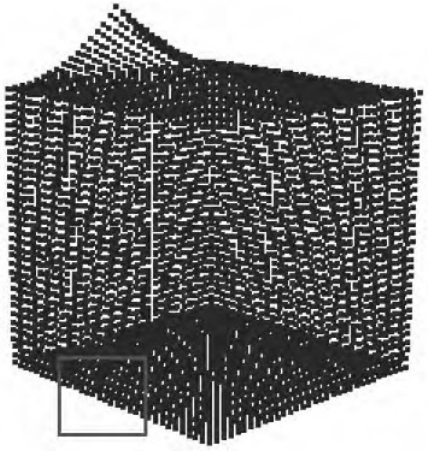


3.3 面向特征保持的点云数据精简

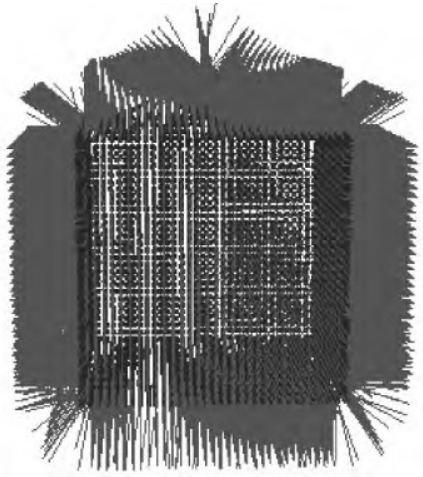
最小特征值λ_0表示了点沿着曲面法矢的变化情况，可利用各点的最小特征值来估计高曲率区域。

$$\omega_i = \frac{\lambda_{i0}}{\lambda_{i0} + \lambda_{i1} + \lambda_{i2}}$$

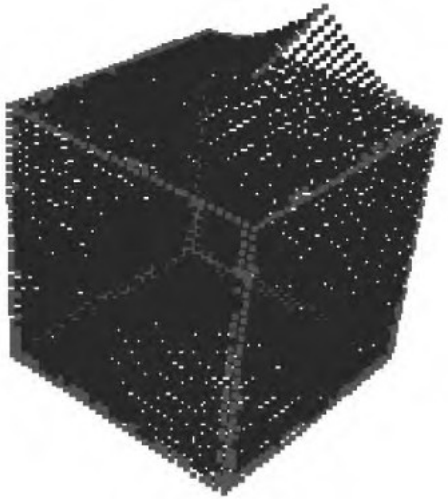
$\omega_i = 0$时，p_i为平面点；ω_i越大，曲面该点处越尖锐。 ω_i大于设定阈值，则p_i设为候选特征点



(a) Smooth-feature 模型



(b) 模型法矢方向



(c) 候选特征点

3.3 面向特征保持的点云数据精简

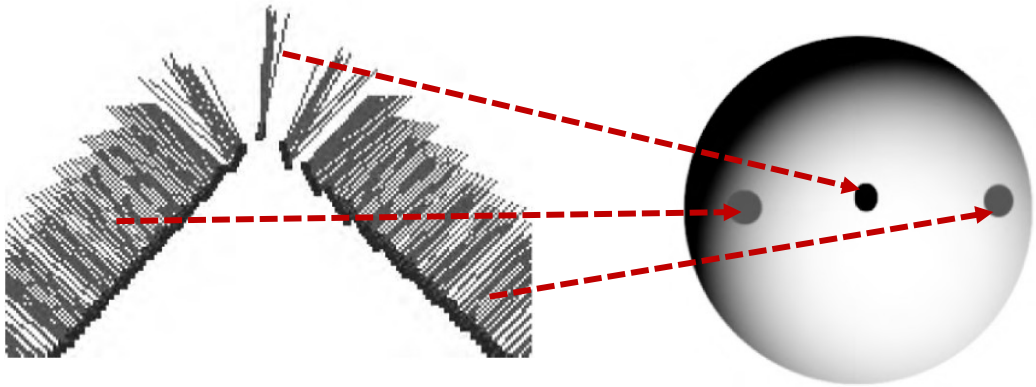
- 第 3 大步：遍历每个聚类，若含候选特征点（需细分）则该聚类映射到高斯球。

曲面的高斯映射：曲面每点的法向向量映射到一个单位球上，此球称为高斯球。

$$B = \{(x, y, z) \subset R^3 | x^2 + y^2 + z^2 = 1\}$$

映射过程：将法向矢量的起点平移至高斯参考球的球心，每个法向矢量会与高斯参考球的球面有一个交点，这个交点就称为法向矢量在高斯球上的高斯映像。

$$\vec{n} = [n_x, n_y, n_z]^T \Rightarrow x = n_x,\ y = n_y,\ z = n_z$$



- 平面的高斯图为高斯球上的一点
- 如果一连通曲面的高斯图为高斯球上的一点，则该曲面为平面。
- 估计的法矢总是存在误差，因此平面的高斯图为高斯球上的密集分布聚类

三、点云精简

3.3 面向特征保持的点云数据精简

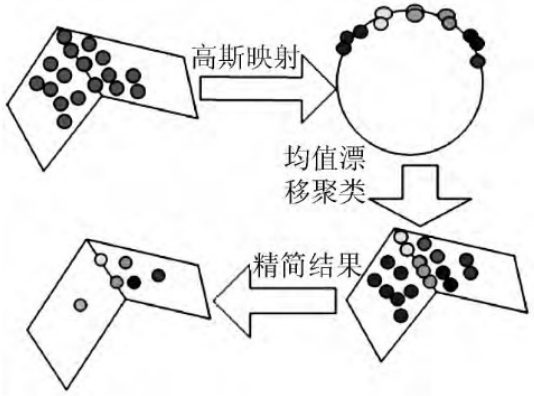
- 第 4 大步：用均值漂移算法对具有特征点的聚类的高斯图进行聚类细分。具有特征点的聚类包括多个平坦区域和特征点，多个平坦区域映射为高斯图上的多个聚类，特征点映射为独立的一个或者多个聚类。

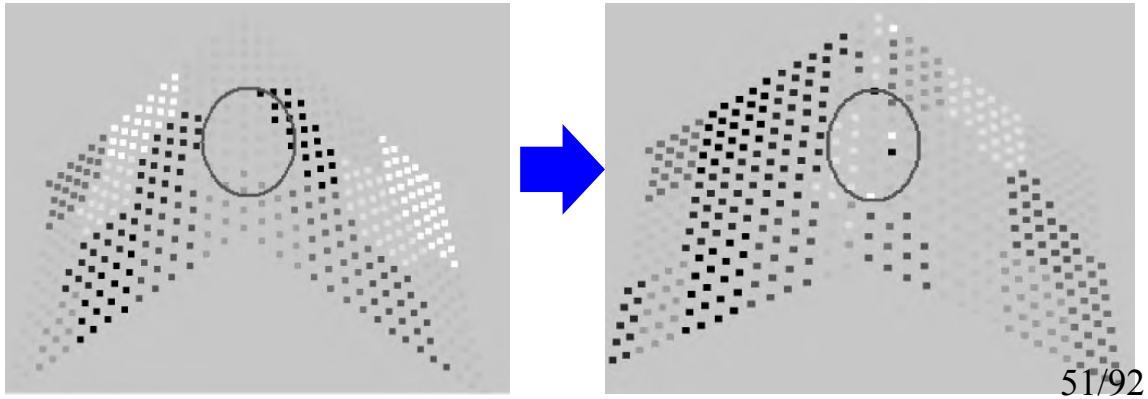
  ✓ 高斯球上的各子聚类对应为空间点云的子聚类。无法事先指定聚类细分数目，需要使用无参聚类算法对高斯图数据进行自动划分。

  ↓

  均值漂移算法（Mean-Shift）

  ✓ 高斯图上各聚类中心所对应的点云为局部曲面细分结果



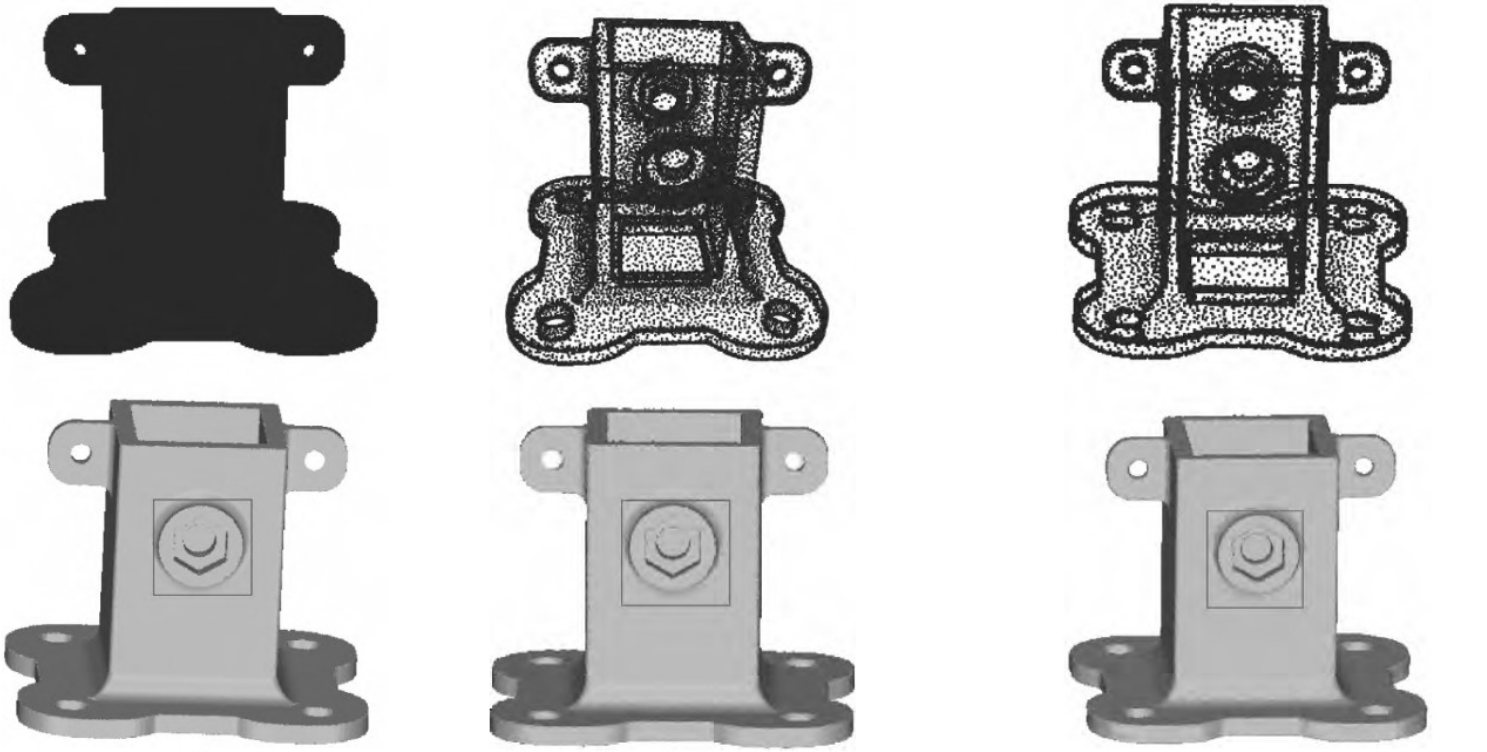


三、点云精简

3.3 面向特征保持的点云数据精简

点云

基于点云的三角化模型



(a)原始模型
(a)Original models

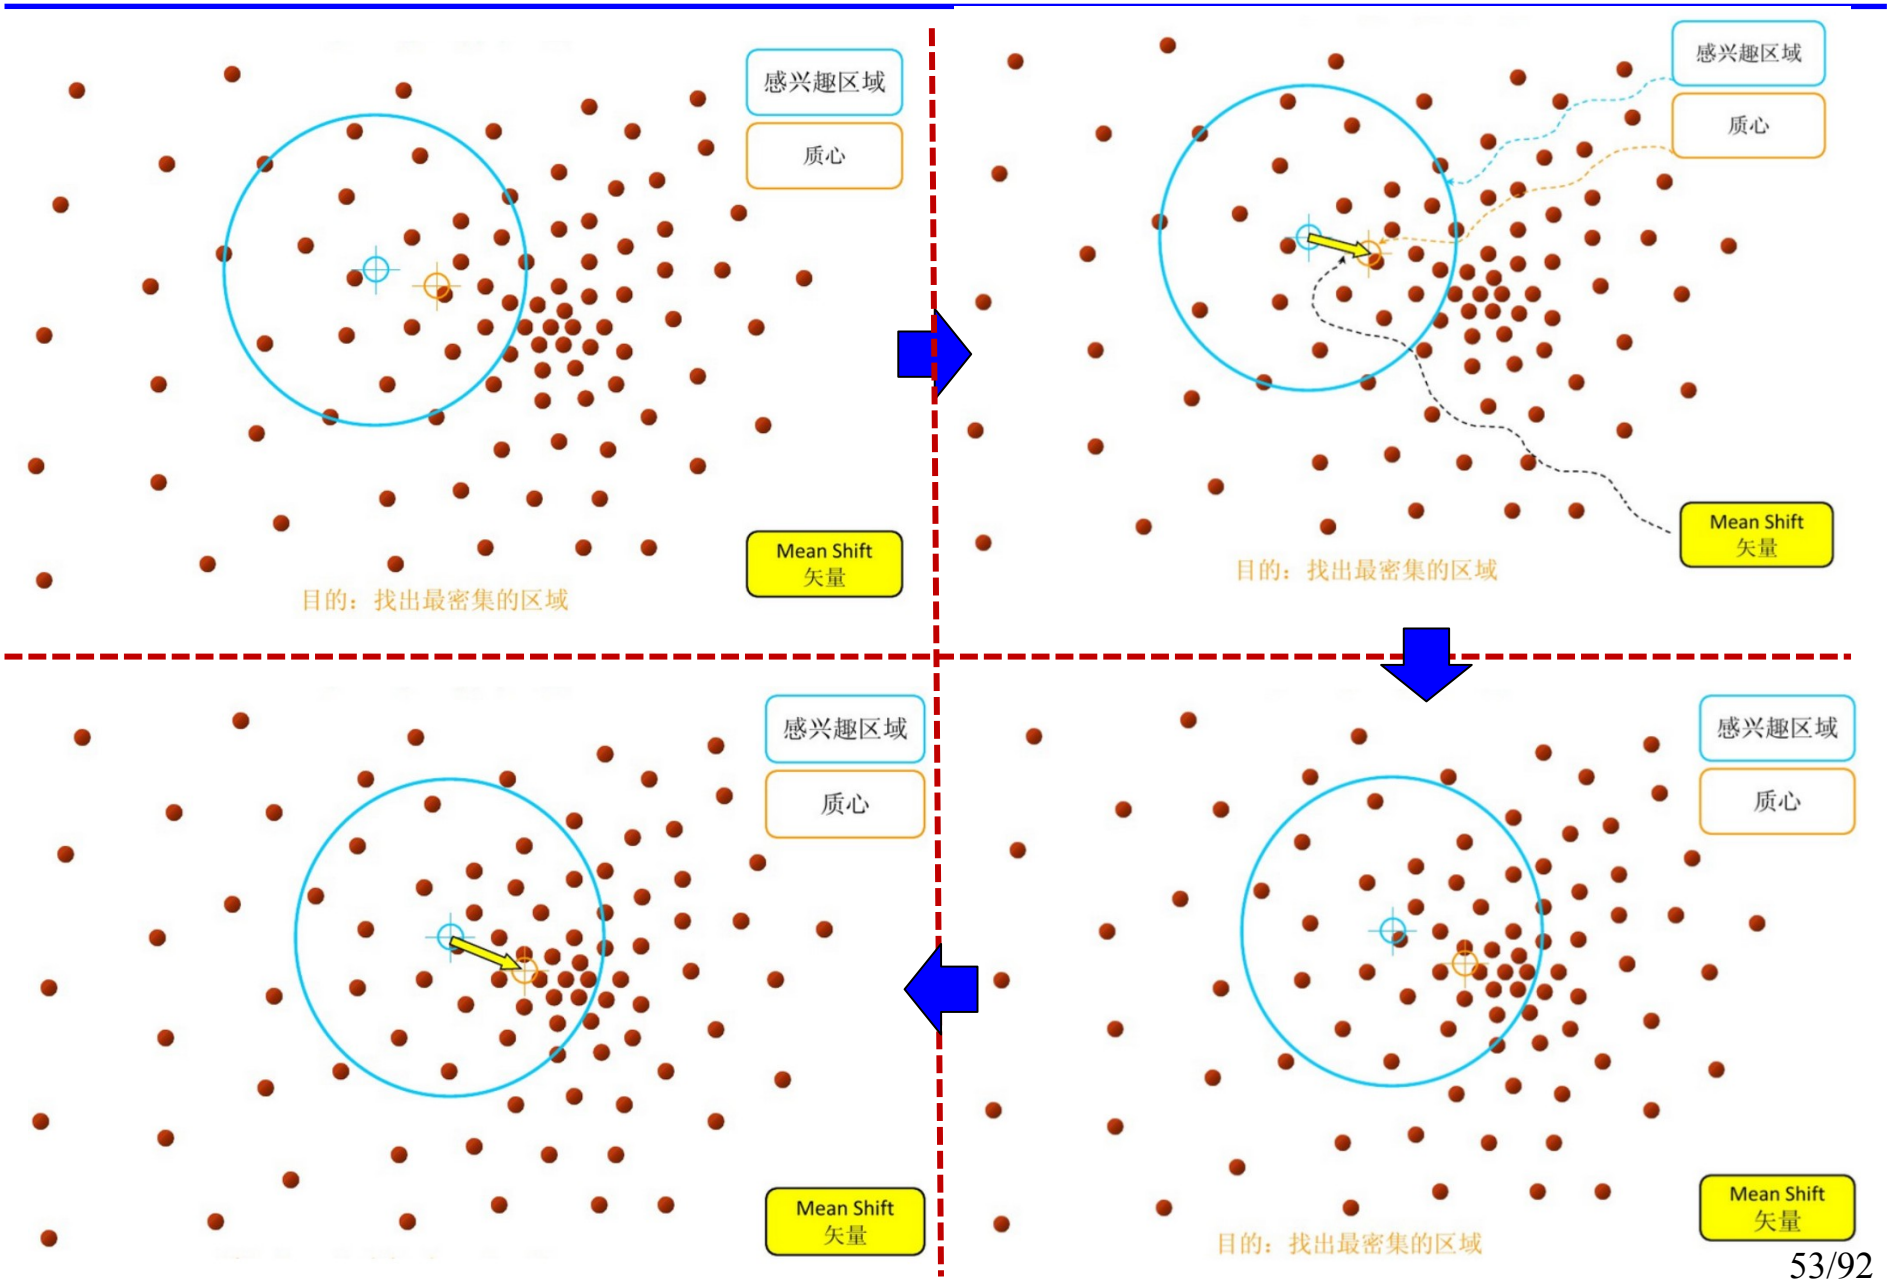
(b)点云数量精简到 41×10^3 时的结果
($\Delta_{max}=0.010, \Delta_{ave}=2.7\times10^{-4}$)

(c)点云数量精到 26×10^3 的结果
($\Delta_{max}=0.022, \Delta_{ave}=1.2\times10^{-3}$)

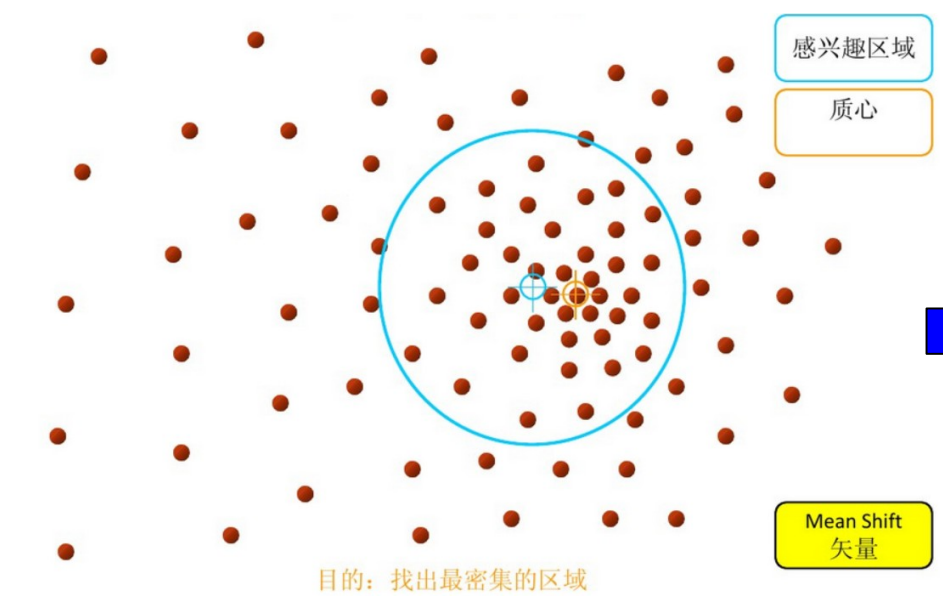
最大误差Δ_{max}：原始曲面S上采样点到精简点云曲面S’上投影点之间欧式距离的最大值

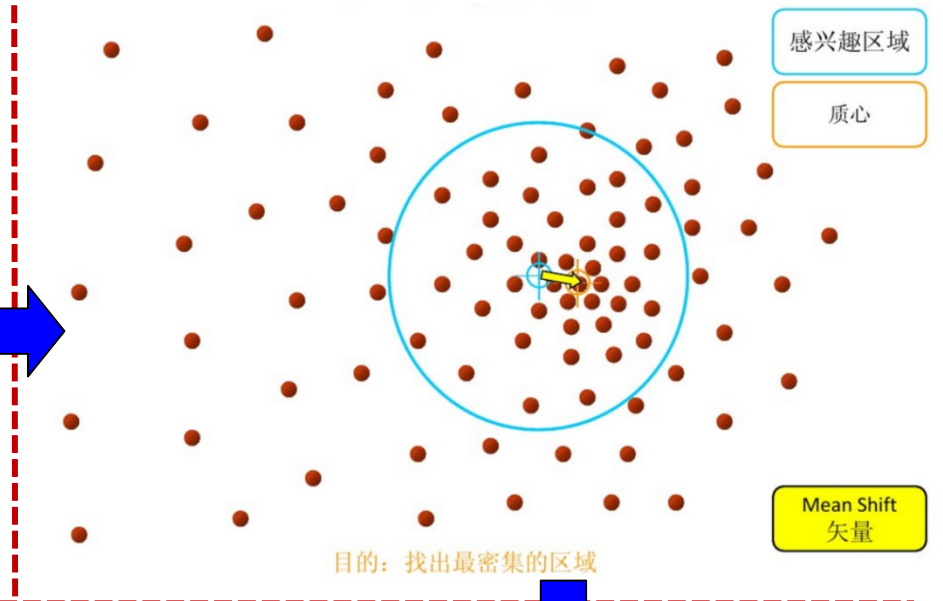
平均误差Δ_{ave}：原始曲面S上采样点到精简点云曲面S’上投影点之间欧式距离的平均值

均值漂移算法 -----Mean-shift 算法

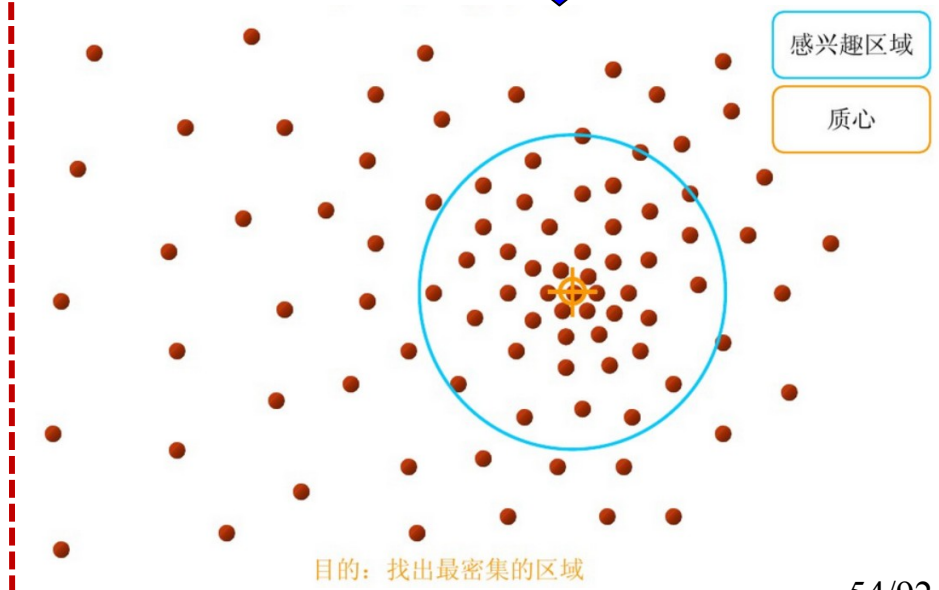


均值漂移算法 -----Mean-shift 算法





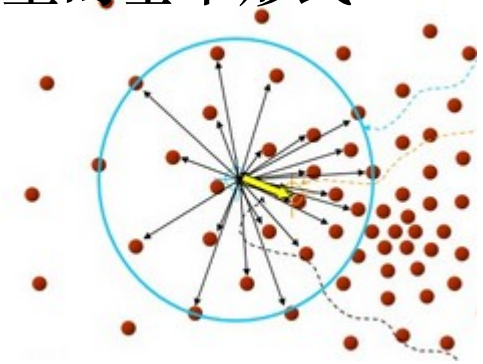
基本原理： **Mean-Shift** 是一个迭代步骤，即先算出当前点的偏移均值，将该点移动到此偏移均值，然后以此为新的起始点，继续移动，直到满足最终条件。



均值漂移算法 -----Mean-shift 算法

基本的 Mean Shift 向量形式：对于给定的 d 维空间 R_d 中的 n 个样本点 x_i，$i=1,\cdots,n$，则对于 x 点，其 Mean Shift 向量的基本形式为：

$$M_h(x) = \frac{1}{k}\sum_{x_i \in S_h}(x_i - x) = \frac{1}{k}\sum_{x_i \in S_h} x_i - x = \bar{x} - x$$



- S_h 是一个半径为 h 的高维球区域（前图中的蓝圆形区域），定义为：

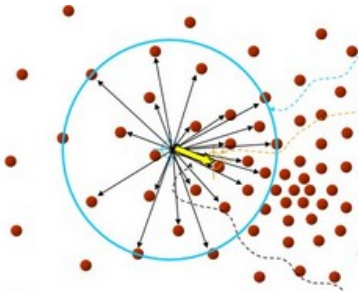
$$S_h(x) = \left(y \middle| (y-x)^T(y-x) \le h^2\right)$$

- 存在的问题：
  - 在 S_h 的区域内，每一个点对 x 的贡献是一样的。实际上每一个样本的重要程度也是不一样的。
  - 不一定完全收敛至高密度区域中心。

均值漂移算法 -----Mean-shift 算法

改进的 Mean Shift 向量形式：在基本的 Mean Shift 向量形式中增加核函数和样本权重，得到如下的改进的 Mean Shift 向量形式：

$$M_h(x) = \frac{1}{k}\sum_{x_i \in S_h}(x_i - x) \Rightarrow M_h(x) = \frac{\sum_{i=1}^{n} G_H(x_i - x)w(x_i)(x_i - x)}{\sum_{i=1}^{n} G_H(x_i - x)w(x_i)}$$



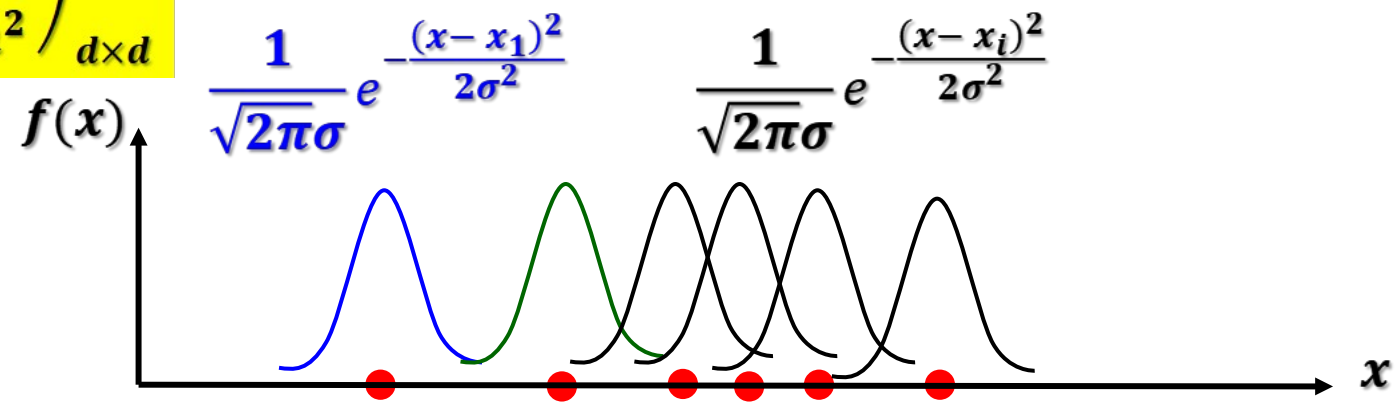
- $w(x_i) \geq 0$ 是每一个样本的权重。
- $G_H(x_i - x) = |H|^{-\frac{1}{2}} G\left(|H|^{-\frac{1}{2d}}(x_i - x)\right)$ 为单位核函数；
- H 是一个正定的对称$d \times d$ 矩阵，称为带宽矩阵，是一个对角阵。

$$M_h(x) = \frac{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right)w(x_i)(x_i - x)}{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right)w(x_i)} \Leftarrow H = \begin{pmatrix} h^2 & 0 & \cdots & 0 \\ 0 & h^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & h^2 \end{pmatrix}_{d \times d}$$

- Mean Shift向量$M_h(x)$是归一化的概率密度梯度

$$H=\begin{pmatrix} h^2 & 0 & \cdots & 0 \\ 0 & h^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & h^2 \end{pmatrix}_{d\times d}$$

算法 --- $G_H(x_i-x)=|H|^{-\frac{1}{2}}G\left(|H|^{-\frac{1}{2d}}(x_i-x)\right)$



一维 $$f(x)=\frac{1}{\sqrt{2\pi}\sigma}\sum_{i=1}^{n}e^{-\frac{(x-x_i)^2}{2\sigma^2}}=\frac{1}{\sigma}\sum_{i=1}^{n}\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{x-x_i}{\sigma}\right)^2}=\frac{1}{\sigma}\sum_{i=1}^{n}G\left(\frac{x-x_i}{\sigma}\right)$$

二维 $$f(x)=\frac{1}{2\pi\sigma^2}\sum_{i=1}^{n}e^{-\frac{(x_1-x_{i1})^2+(x_2-x_{i2})^2}{2\sigma^2}}=\frac{1}{\sigma^2}\sum_{i=1}^{n}\frac{1}{2\pi}e^{-\frac{1}{2}\left(\frac{\|x-x_i\|}{\sigma}\right)^2}=\frac{1}{\sigma^2}\sum_{i=1}^{n}G\left(\frac{x-x_i}{\sigma}\right.$$

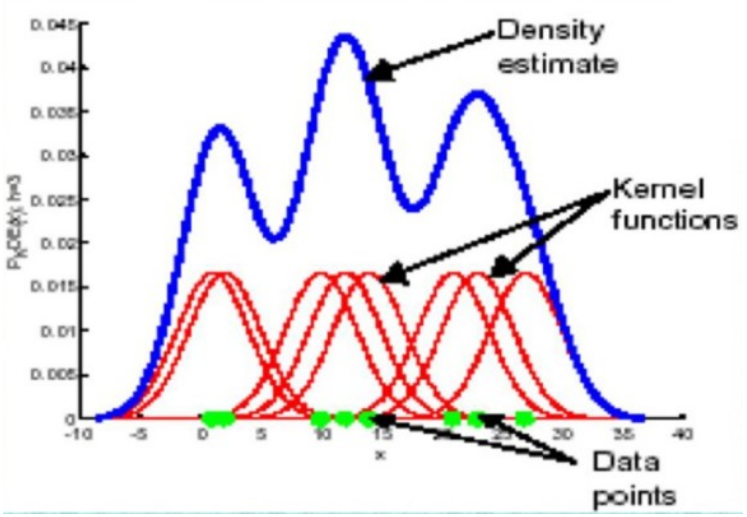
d维 $$f(x)=\frac{1}{\sigma^d}\sum_{i=1}^{n}\frac{1}{(2\pi)^{d/2}}e^{-\frac{1}{2}\left(\frac{\|x-x_i\|}{\sigma}\right)^2}=\frac{1}{\sigma^d}\sum_{i=1}^{n}G\left(\frac{x-x_i}{\sigma}\right)=\frac{1}{\sigma^d}\sum_{i=1}^{n}k\left(\left\|\frac{x-x_i}{\sigma}\right\|^2\right)$$

均值漂移算法 -----Mean-shift 算法

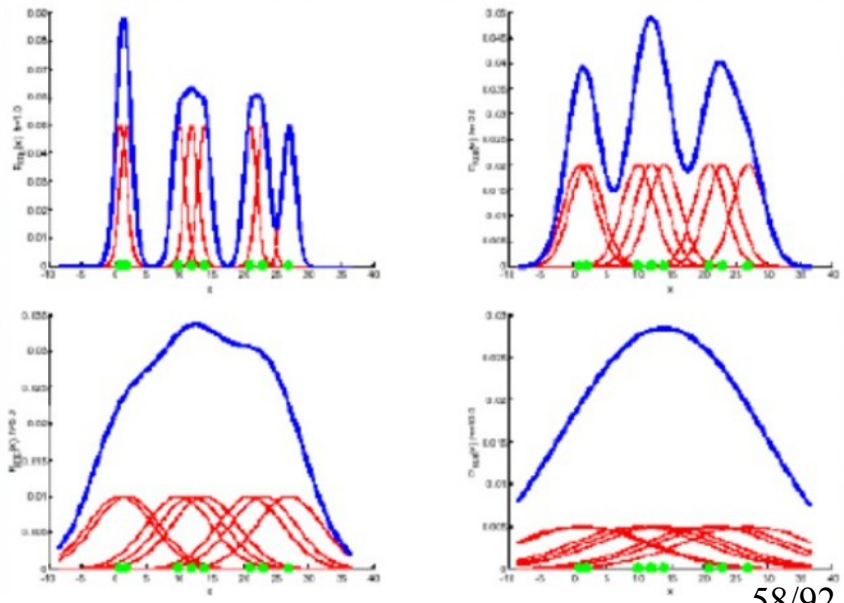
■ 概率密度梯度

核密度估计(Parzen窗估计)：概率论中用来估计未知的密度函数。对一个概率密度函数$f(x)$，已知d维空间中n个采样点$x_i, i = 1, \cdots, n$，$f(x)$的核函数估计为：

$$\hat{f}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right) w(x_i)}{h^d \sum_{i=1}^{n} w(x_i)}$$



- ✓ $w(x_i) \geq 0$ 是一个赋给采样点x_i 的**权重**
- ✓ $K(x)$ 是一个**核函数**
- ✓ h为核函数**窗口宽度**
  - h很大，变化缓慢，估计分辨率低。
  - h很小，变化迅速，估计统计变化大。



均值漂移

Mean Shift向量$M_h(x)$是归一化的概率密度梯度

■ 概率密度梯度

$$\hat{f}_K(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right) w(x_i)}{h^d \sum_{i=1}^{n} w(x_i)} = \frac{\sum_{i=1}^{n} k\left(\left\|\frac{x - x_i}{h}\right\|^2\right) w(x_i)}{h^d \sum_{i=1}^{n} w(x_i)}$$

$$\nabla \hat{f}_K(x) = \frac{-2\sum_{i=1}^{n} (x_i - x) k'\left(\left\|\frac{x - x_i}{h}\right\|^2\right) w(x_i)}{h^{d+2} \sum_{i=1}^{n} w(x_i)}$$

$$= \frac{2\sum_{i=1}^{n} G\left(\frac{x - x_i}{h}\right) w(x_i)(x_i - x)}{h^{d+2} \sum_{i=1}^{n} w(x_i)} \qquad G\left(\frac{x - x_i}{h}\right) = -k'\left(\left\|\frac{x - x_i}{h}\right\|^2\right)$$

$$= \frac{2}{h^2}\left[\frac{\sum_{i=1}^{n} G\left(\frac{x - x_i}{h}\right) w(x_i)}{h^d \sum_{i=1}^{n} w(x_i)}\right]\left[\frac{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i)(x_i - x)}{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i)}\right]$$

$\hat{f}_G(x)$

$$\nabla \hat{f}_K(x) = \frac{2}{h^2} \hat{f}_G(x) M_h(x)$$

Mean Shift向量$M_h(x)$，归一化的概率密度梯度

均值漂移算法 -----Mean-shift 算法

Mean Shift 向量修正：

$$M_h(x) = \frac{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i)(x_i - x)}{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i)}$$

$$= \frac{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i) x_i}{\sum_{i=1}^{n} G\left(\frac{x_i - x}{h}\right) w(x_i)} - x$$

$$= m_h(x) - x$$

mean shift 就是沿着密度上升的方向寻找同属一个簇的数据点

Mean Shift 步骤：

- ✓ 计算$m_h(x(k))$
- ✓ 令$x(k+1) = m_h(x(k))$
- ✓ 如果$\|x(k+1) - x(x)\| < \epsilon$，结束循环，否则，重复上述步骤

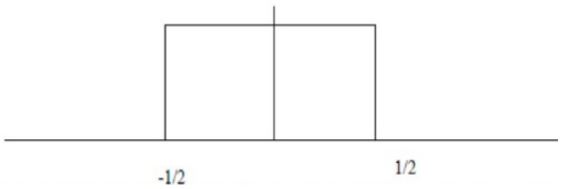
均值漂移算法 -----Mean-shift 算法

常用核函数：

$$x = (x_1, x_2, \cdots, x_d)^T \in R^d$$

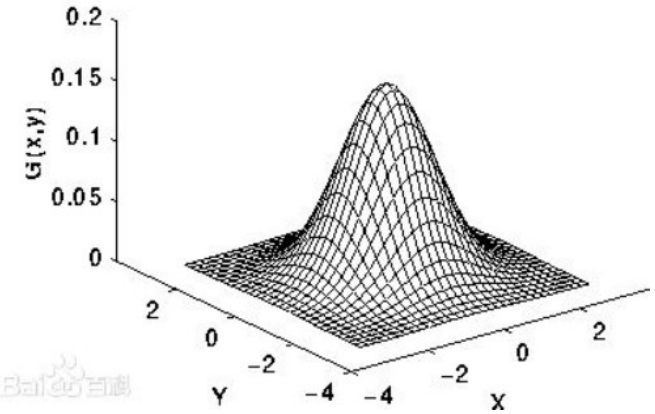
- 均匀核：

$$k(x) = \begin{cases} 1, & if |x_i| \le \frac{1}{2} \ for\ all\ i \\ 0 & else \end{cases}$$



- Gauss 核：

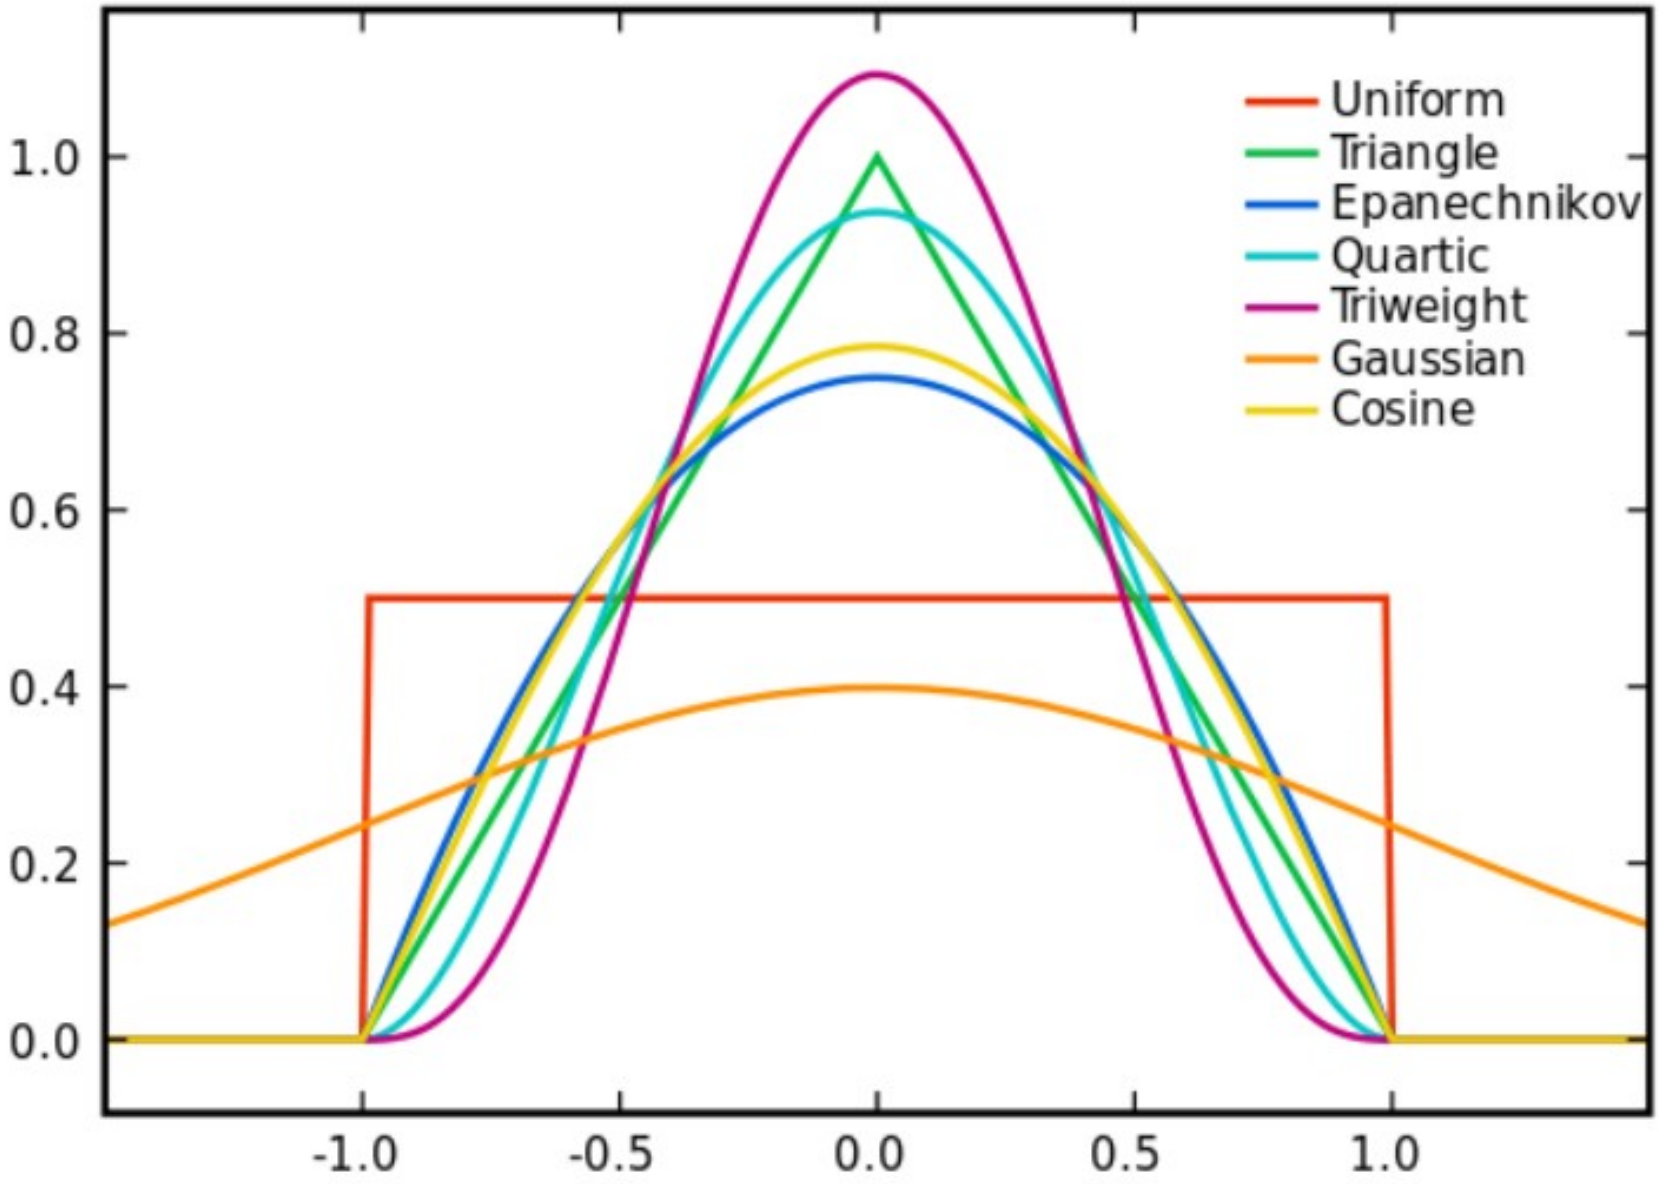
$$k(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\|x\|^2}{2}}$$



- Epanechnikov 核：

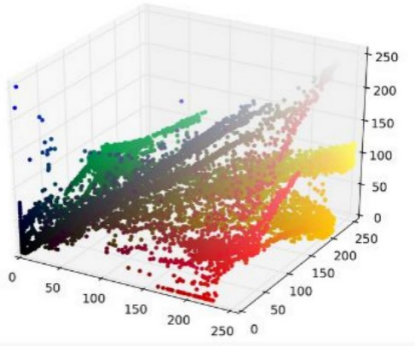
$$k(x) = \begin{cases} \frac{3}{4}(1 - x^2) & if |x_i| \le \frac{1}{2} \ for\ all\ i \\ 0 & else \end{cases}$$

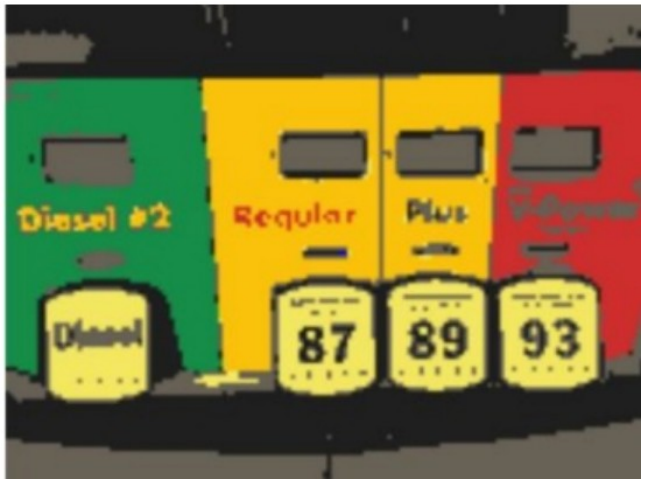
均值漂移算法 -----Mean-shift 算法



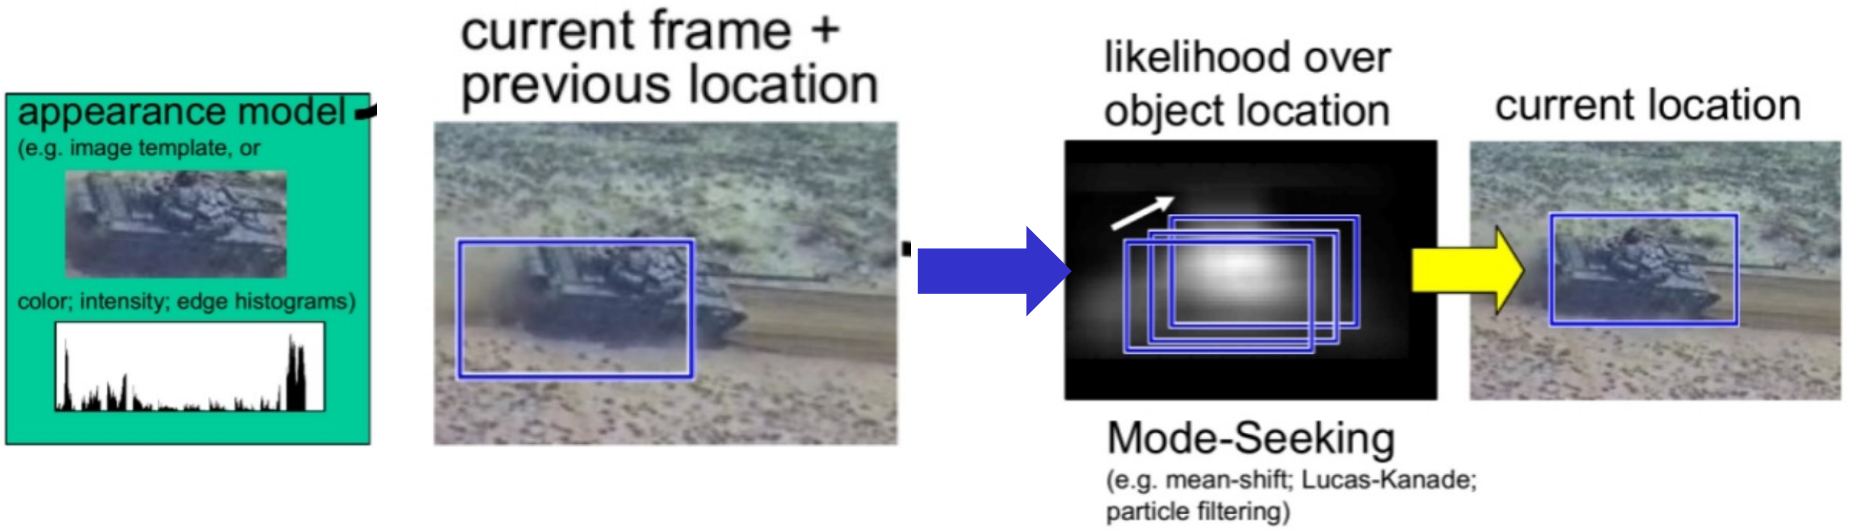
均值漂移算法 -----Mean-shift 算法







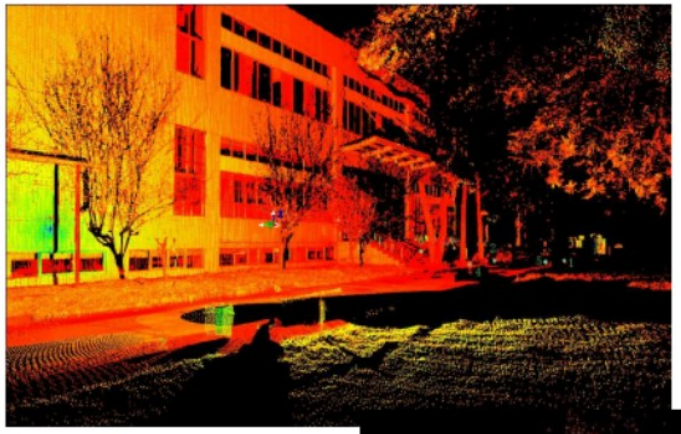
基于颜色的目标分割



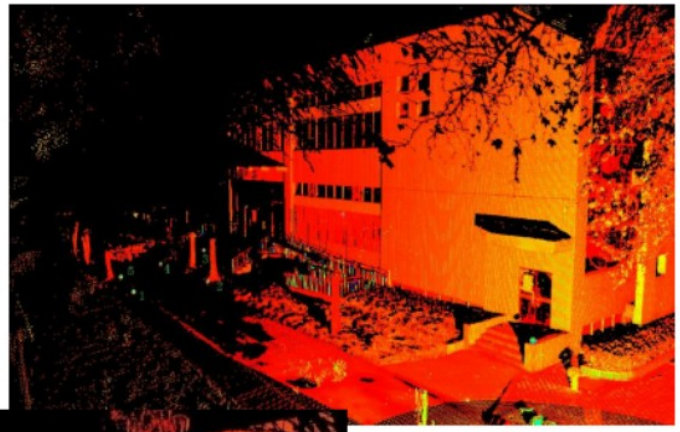
基于特征匹配的目标跟踪

四、点云配准

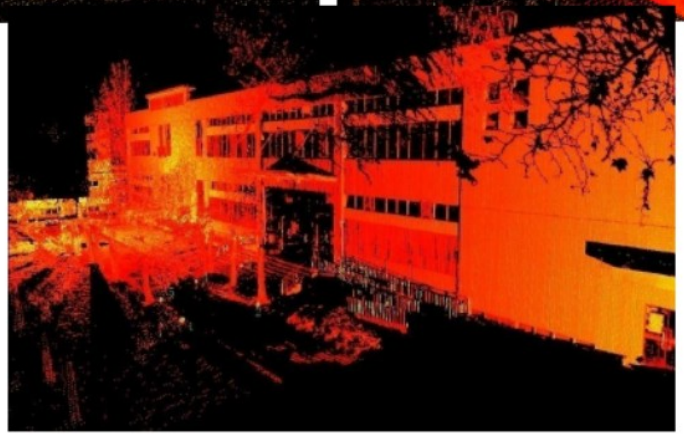
点云配准：将两个或两个以上坐标系中的三维点云数据转换至统一坐标系统中的数学计算过程。点云配准的实质就是空间坐标变换。空间坐标变换可以由三类参数唯一确定：尺度、旋转和平移。



第一站点云



第二站点云



配准结果

四、点云配准

■ 配准方法分类

- □ 按照配准算法所利用的信息，可分为：
  - ✓ 基于特征点的配准方法：根据靶标或者手工选取特征点进行配准（六参数法）
  - ✓ 基于整体迭代优化的配准方法：通过迭代计算两个点集最优匹配的几何变换（ICP 算法）
- □ 按自动化程度可以分为人工、半自动和全自动三种类型。

四、点云配准

■ 六参数法点云配准

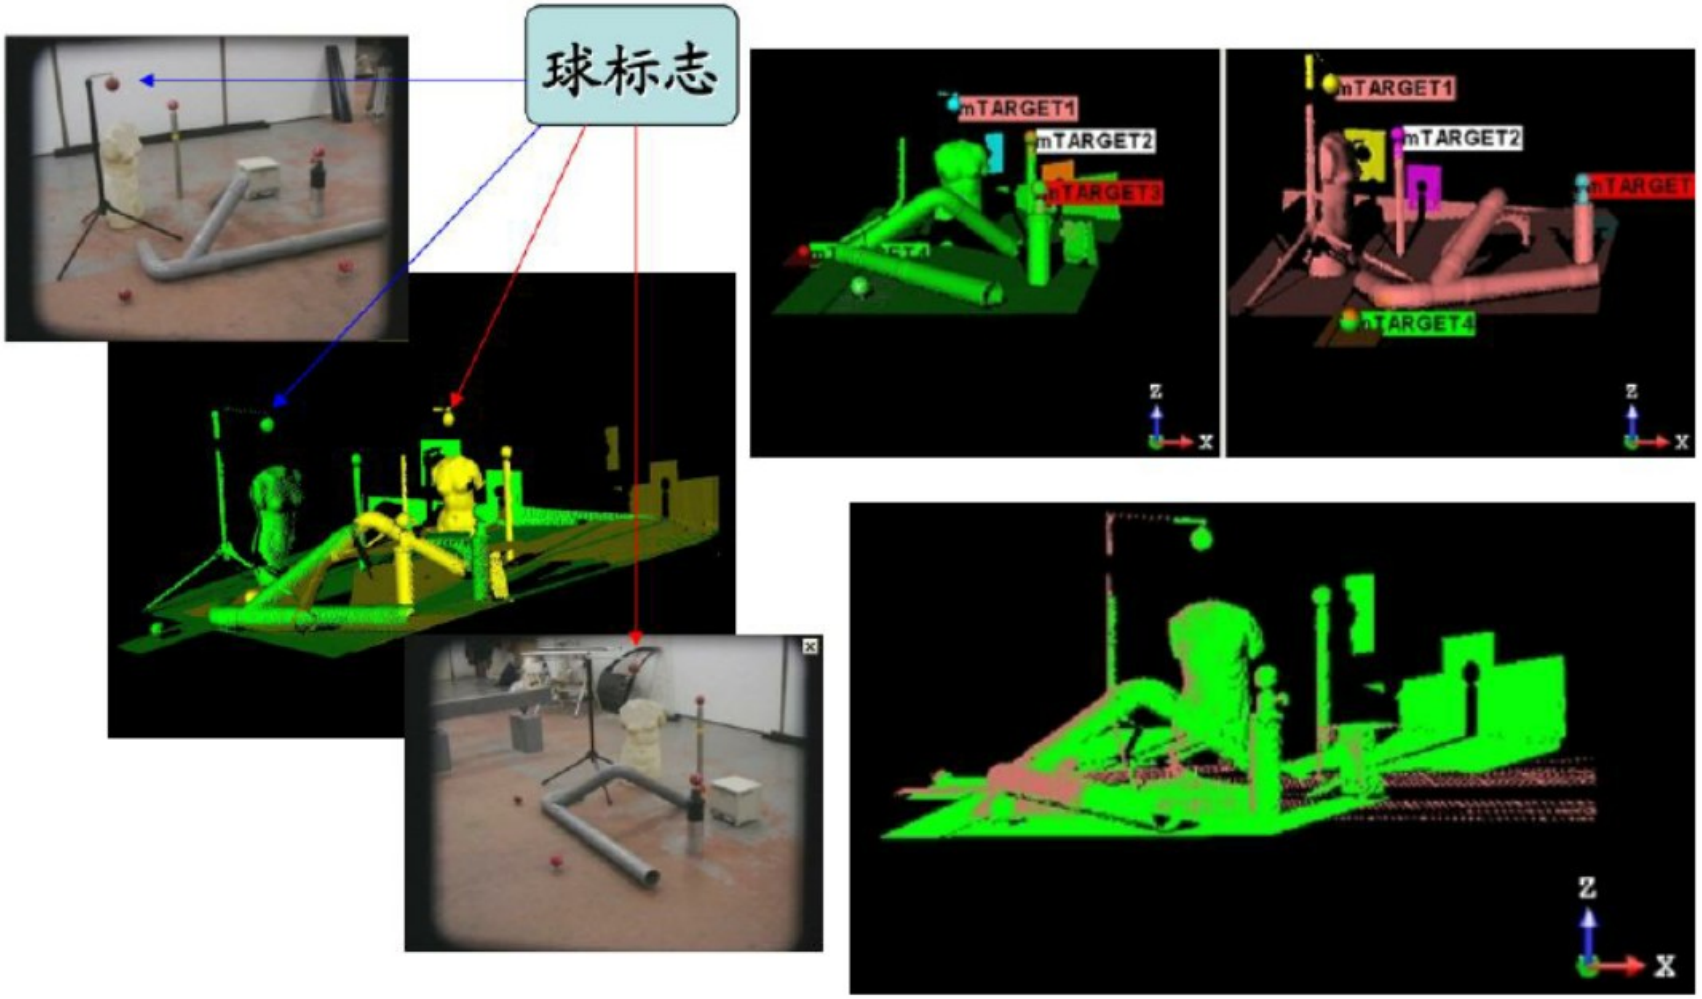
- 点云配准实质是空间坐标变换。空间坐标变换由三类参数确定：尺度、旋转和平移。点云配准前后相对大小没有发生改变，即不发生尺度变化，因此只需求解三个旋转参数和三个平移参数，所以称为六参数配准模型
- **设$p_c = (x_c, y_c, z_c)$表示一个自由坐标系下的点云坐标，$p_a = (x_a, y_a, z_a)$表示点在绝对坐标系下的坐标。两个点云坐标系坐标轴之间的夹角为α、β和γ，平移参数为Δx、Δy和Δz，则坐标变换关系为**

$$\begin{bmatrix} x_a \\ y_a \\ z_a \end{bmatrix} = R(\alpha, \beta, \gamma) \begin{bmatrix} x_c \\ y_c \\ z_c \end{bmatrix} + \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix}$$

- 至少需要 3 组点云数据，通过手动或者靶标提供。求解方程组。

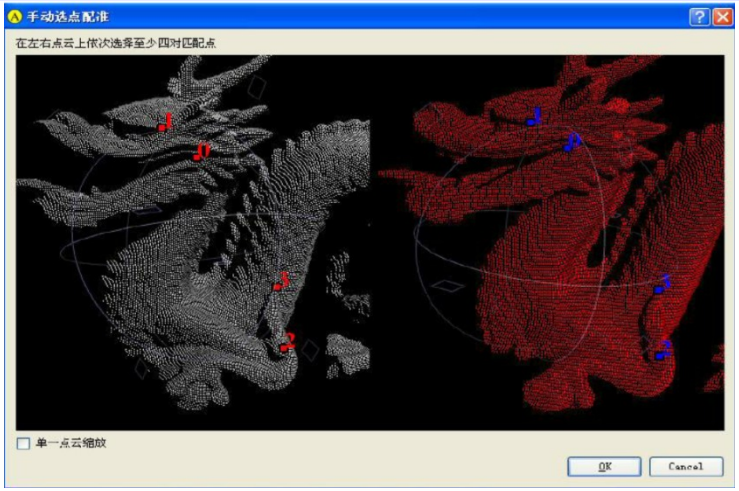
四、点云配准

- 六参数法点云配准 --- 靶标提供数据

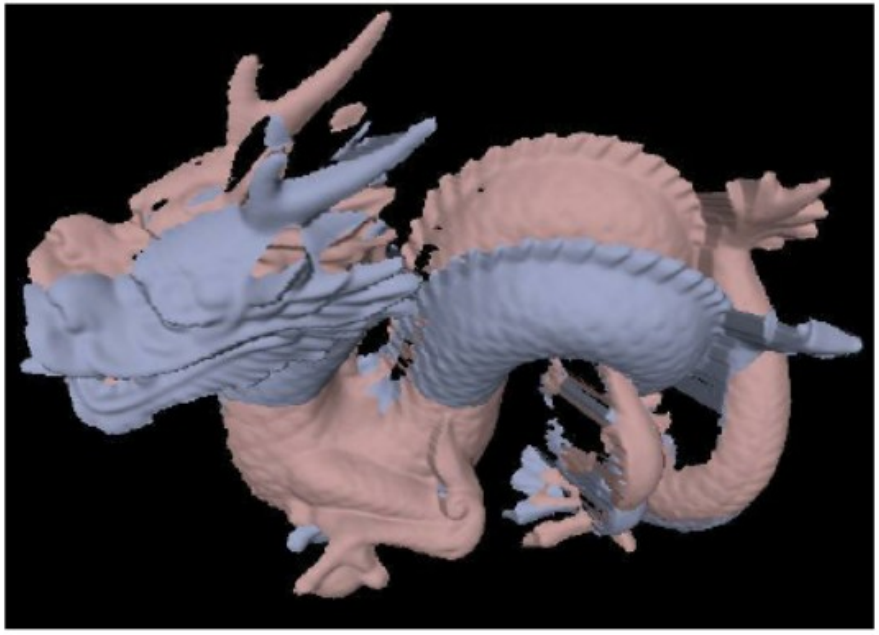


四、点云配准

- 六参数法点云配准 - 手动提供数据



配准前



配准后



四、点云配准

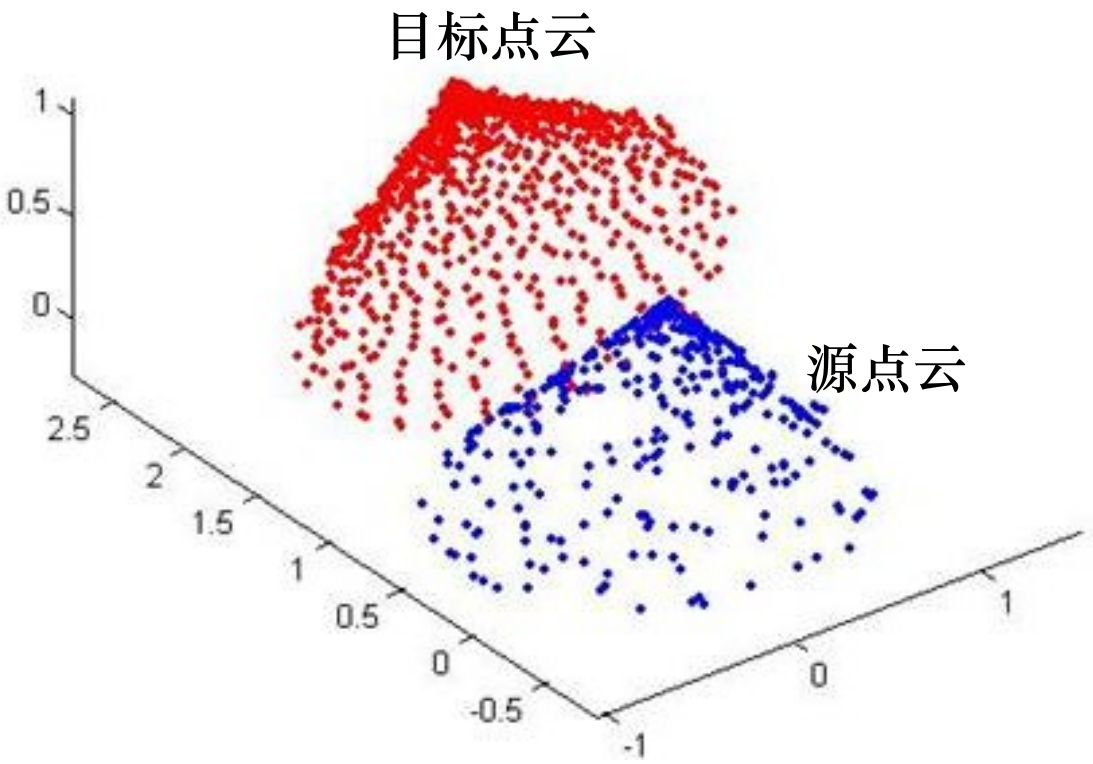
■ ICP 点云配准

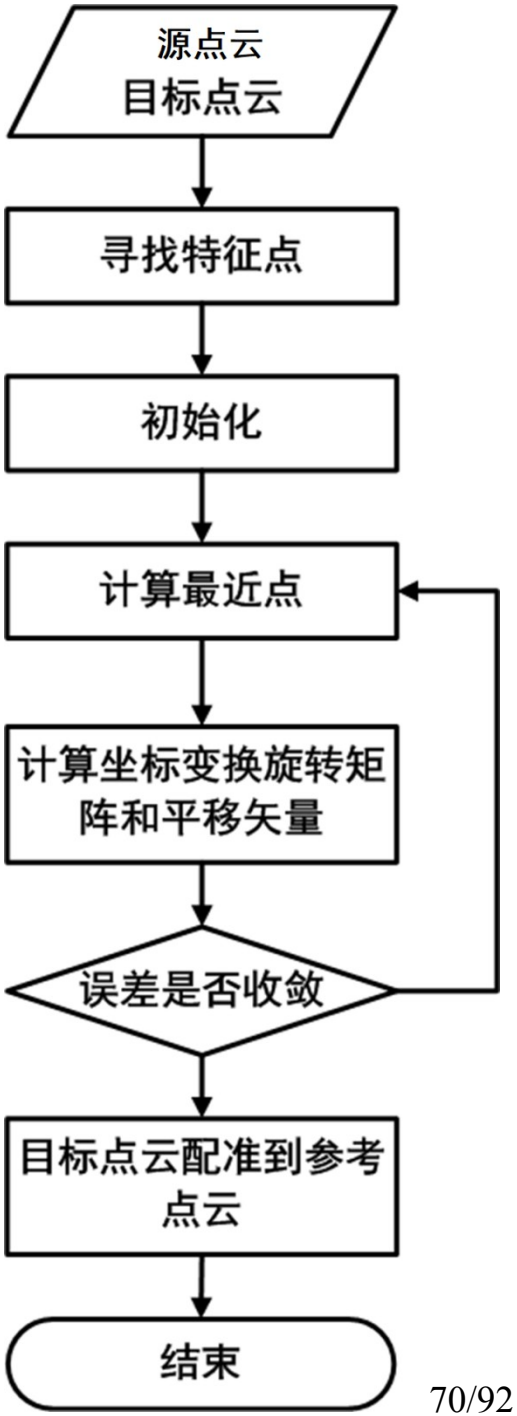
□ 迭代最近邻点配准算法（Iterative Closest Point Algorithm，ICP）：最为经典的数据配准算法。其特征在于，通过求取源点云和目标点云之间的对应点对，基于对应点对采用最小二乘构造旋转平移矩阵，并利用所求矩阵，将源点云变换到目标点云的坐标系下，估计变换后源点云与目标点云的误差函数，若误差函数值大于阈值，则迭代进行上述运算直到满足给定的误差要求。

- ✓ **Step1**：寻找目标点云的特征点及其与特征点最邻近的源点云中的点
- ✓ **Step2**：根据点之间的对应关系，利用最小二乘估计空间变换关系；
- ✓ **Step3**：利用估计出来的空间变换关系对源点云进行作用和变换，然后利用变换后数据进行 **Step1~Step3** 迭代，直至误差满足要求。

四、点云配准

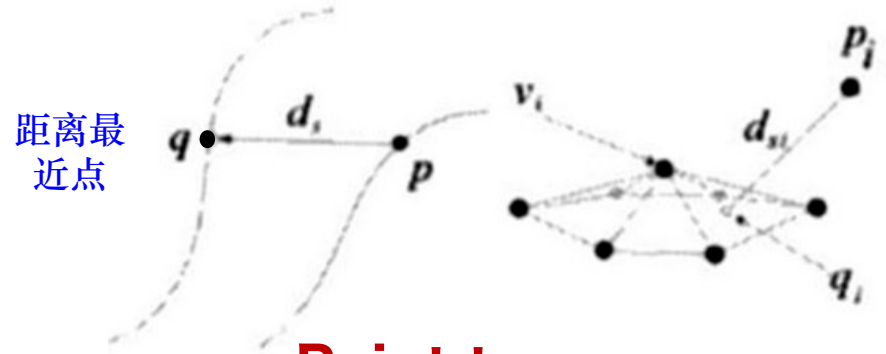
- ICP 匹配算法（ Iterative Closest Point



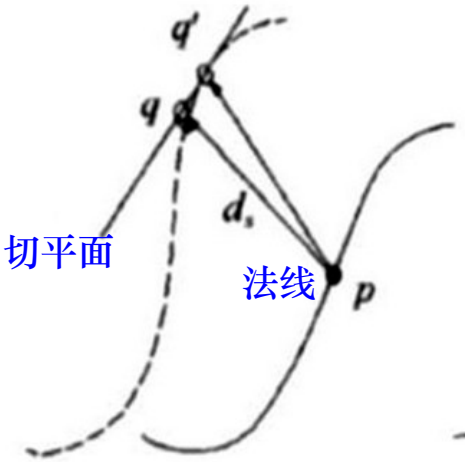


四、点云配准

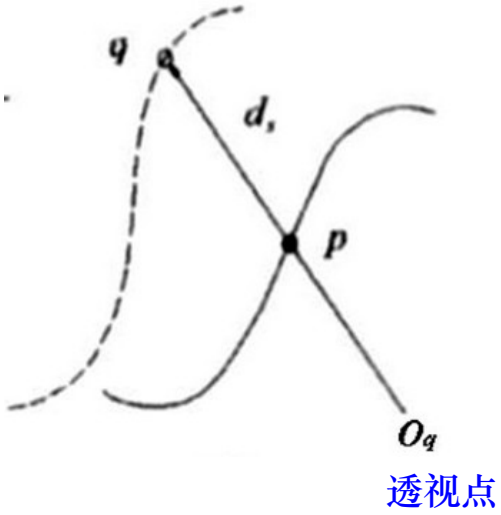
■ ICP 匹配算法（ Iterative Closest Point



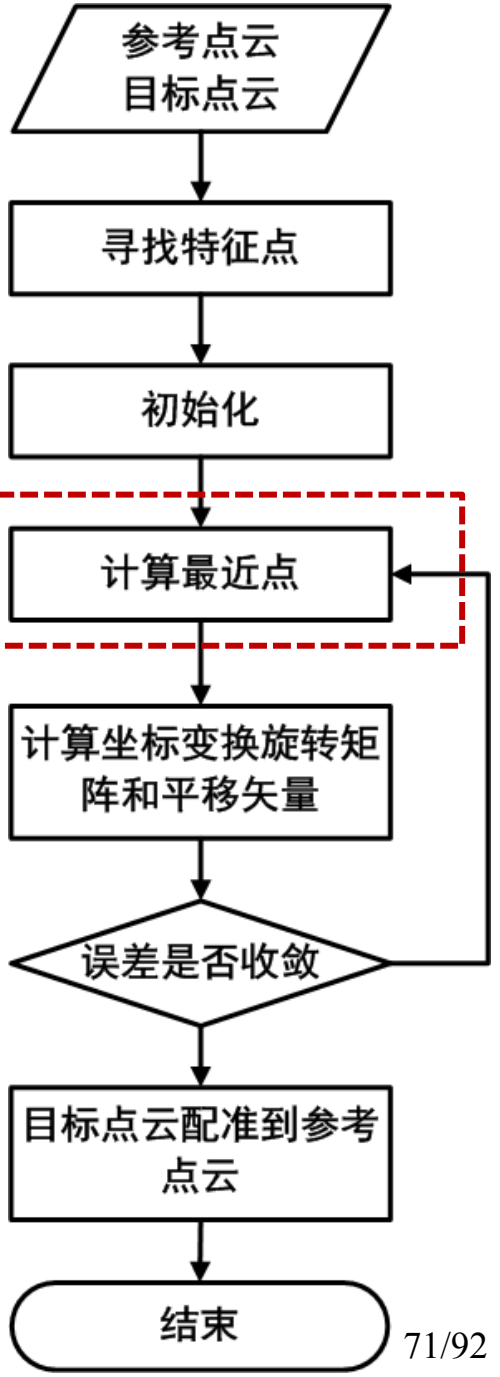
Point to Point



Point to Plane



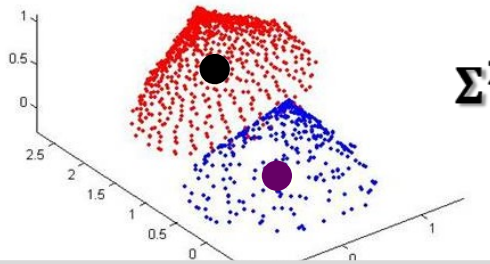
Point to Projection



四、点云配准

■ ICP 匹配算法（ Iterative Closest Point

问题描述：给定一组对应点Q_i和P_i，求取旋转矩阵R和平移矢量T，使得下面的目标函数值最小



$$\Sigma^2 = \sum_{i=1}^{N} \|Q_i - (RP_i + T)\|^2$$

求取两组点云的重心：

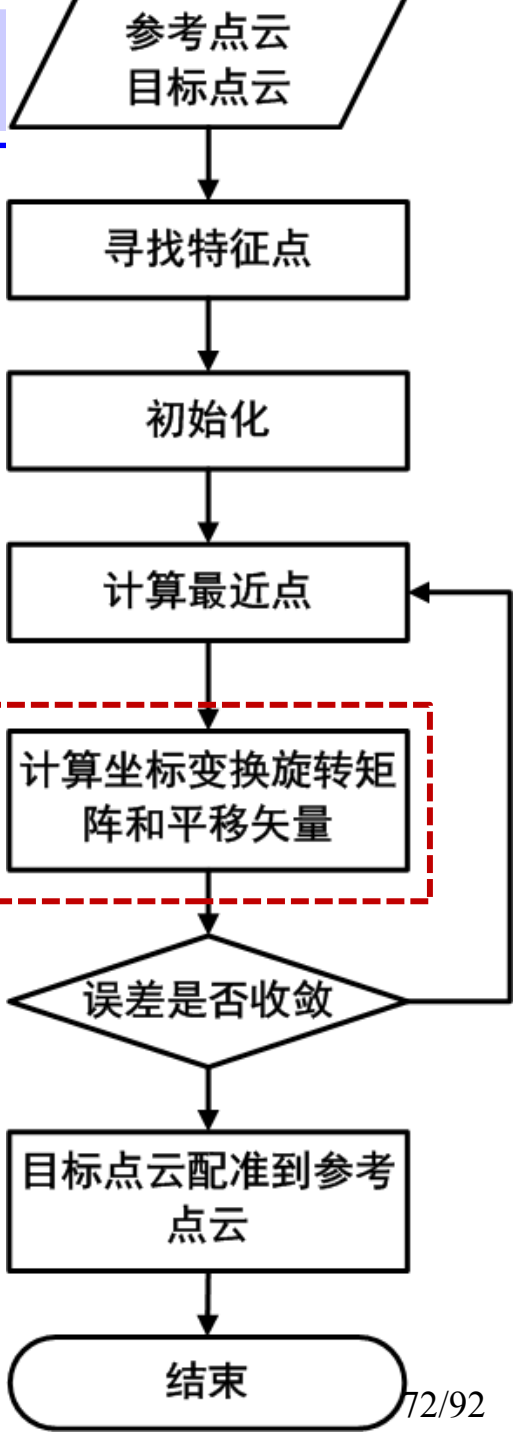
$$\overline{p} = \frac{1}{N}\sum_{i=1}^{N} P_i \qquad \overline{q} = \frac{1}{N}\sum_{i=1}^{N} Q_i$$

点云变换：

$$p_i' = P_i - \overline{p} \qquad q_i' = Q_i - \overline{q}$$

点云旋转平移后二者的重心重合：

$$\overline{q} = R\overline{p} + T$$



四、点云配准

■ ICP 匹配算法（ Iterative Closest Point ）

最小化函数推导：

$$\Sigma^2 = \sum_{i=1}^{N} \|Q_i - (RP_i + T)\|^2$$

$\bar{q} = R\bar{p} + T$

$p'_i = P_i - \bar{p}$

$q'_i = Q_i - \bar{q}$

$$\Sigma^2 = \sum_{i=1}^{N} \|q'_i - Rp'_i\|^2$$

$$= \sum_{i=1}^{N} (q'_i - Rp'_i)^T (q'_i - Rp'_i)$$

$$= \sum_{i=1}^{N} (q_i'^T q'_i + p_i'^T p'_i - 2q_i'^T Rp'_i)$$

$$\min_R \Sigma^2 \leftrightarrow \max_R \sum_{i=1}^{N} q_i'^T Rp'_i$$

$$= \max_R (Trace(\sum_{i=1}^{N} Rp'_i q_i'^T))$$

$$= \max_R (Trace(RH))$$

其中：$H = \sum_{i=1}^{N} p'_i q_i'^T$

四、点云配准

■ ICP 匹配算法（ Iterative Closest Point

$$\max_{R}(Trace(RH)) \qquad H=\sum_{i=1}^{N} p_i' q_i'^{T}$$

H 进行 SVD 分解：　$H = U\Lambda V^t$

令：　$R = VU^t$

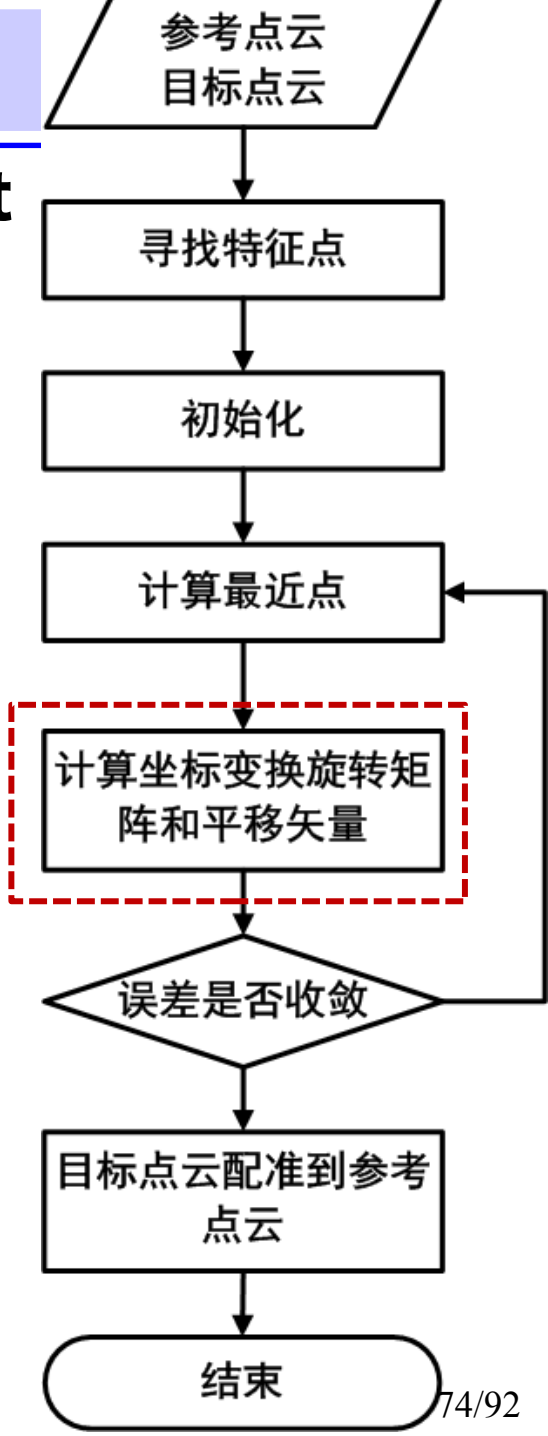
$$RH = VU^tU\Lambda V^t = V\Lambda V^t$$

根据施瓦茨不等式，对于任意正交矩阵 B，有：

$$Trace(RH) = \sum \lambda_i \geq Trace(BRH)$$

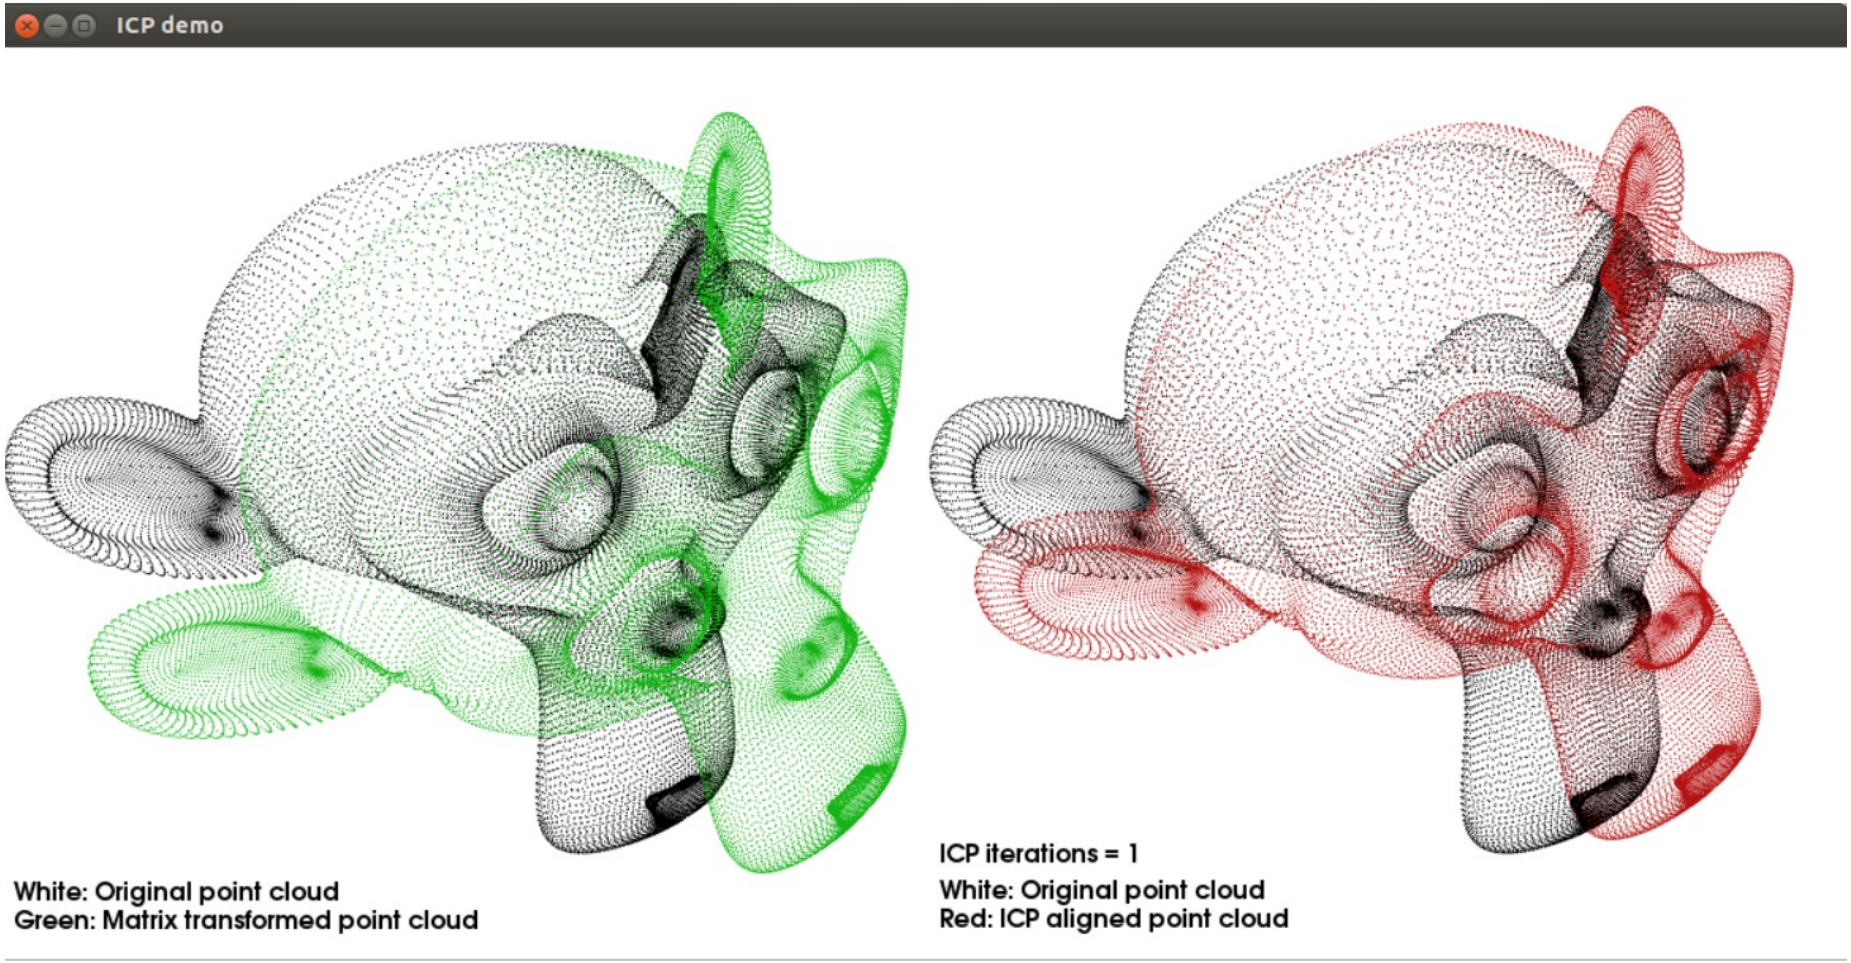
因此最终结果可确定为：　$R = VU^t$

$$T = \bar{q} - R\bar{p}$$



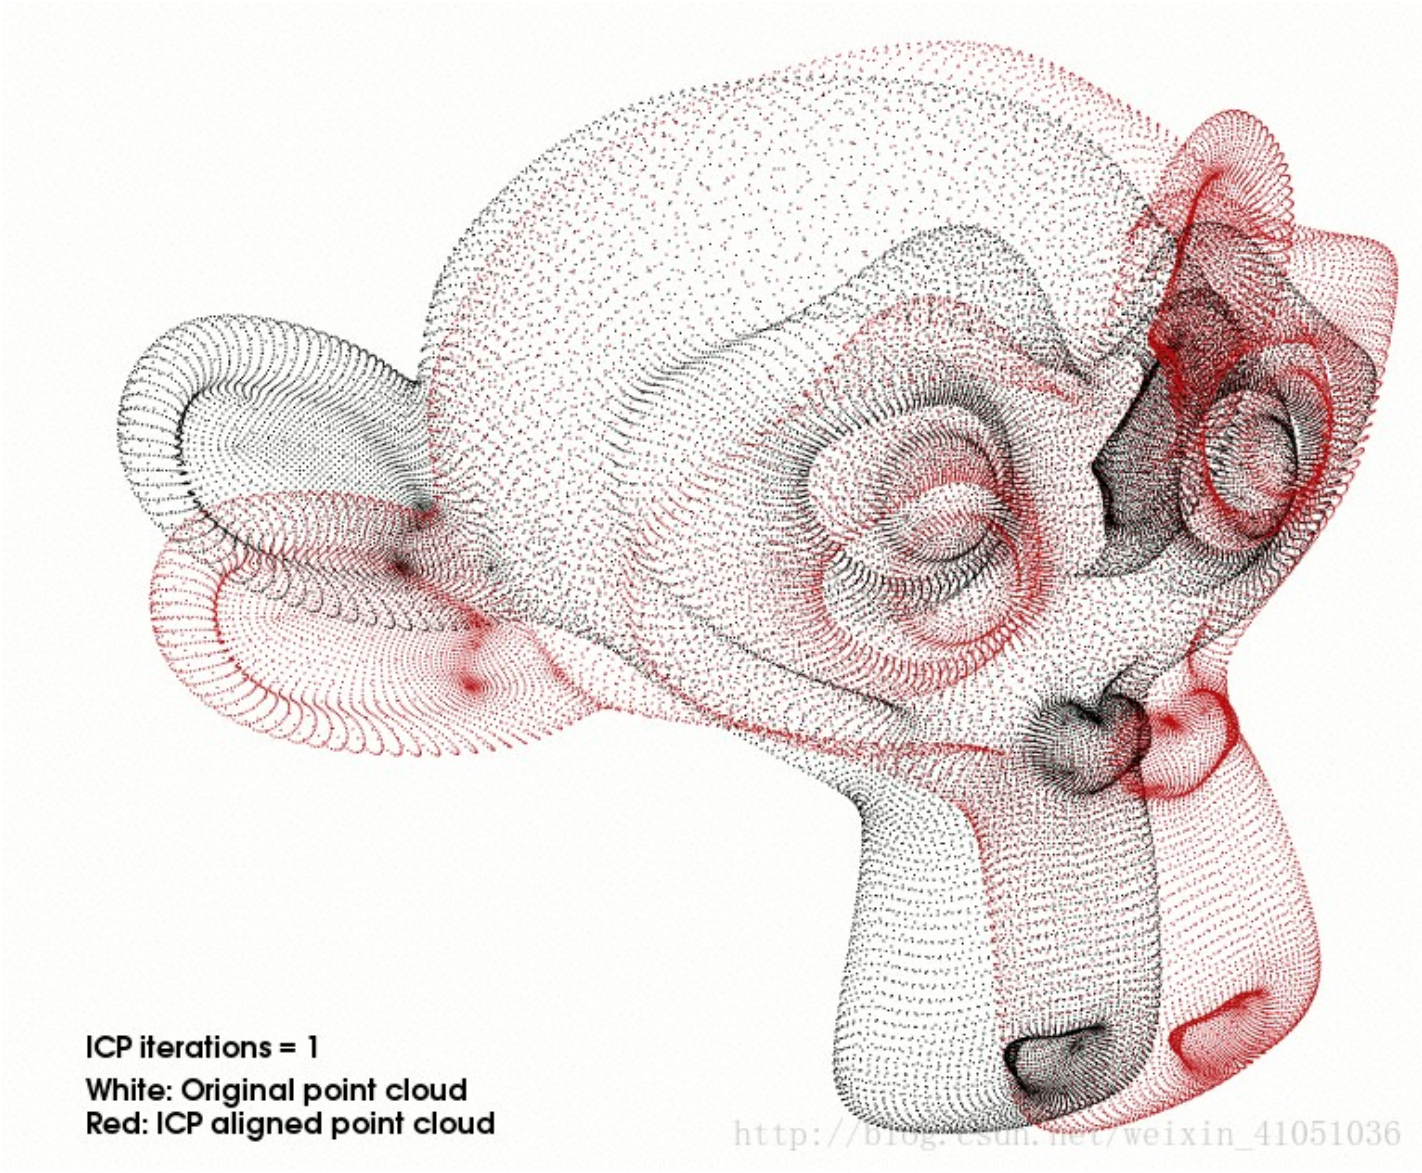
四、点云配准

■ ICP 匹配算法（ Iterative Closest Point ）



四、点云配准

- **ICP 匹配算法（ Iterative Closest Point ）**



http://blog.csdn.net/weixin_41051036

四、点云配准

■ ICP 匹配算法（ Iterative Closest Point ）

ICP 优缺点

- 能够实现点云自动化配准
- 全局配准保证配准可靠性
- 收敛效率及结果取决于初始迭代条件，即初始配准参数
- 点在目标点中的最近邻点耗时，导致效率较低

ICP 改进措施 ------ 大量工作可供参考

- 点云重采样
- 对应点搜索
- 对应点权重选择
- 误匹配点的去除
- 目标函数的选择

ICP 改进措施—点云重采样： 降低样本数量，提高配准效率

- 措施 1 ：对点云进行一致性采样：格网采样
- 措施 2 ：对点云进行随机采样
- 措施 3 ：对点云进行特征采样：对点云按法向量变化、曲率强度或颜色变化等信息进行特征采样，保留点云中的特征信息用于配准

四、点云配准

■ ICP 匹配算法（ Iterative Closest Point ）

ICP 改进措施—对应点搜索： 提高对应点的搜索效率

- 措施 1 ：建立空间索引提高搜索效率（ Kd-Tree 等 ）
- 措施 2 ：在距离约束上，增加颜色、强度、法向量等约束，提高最近点为同名点的可靠性。

ICP 改进措施—对应点权重选择： 考虑每对对应点的可靠性和搜索准确性对转换参数估计的影响，提高参数估计的可靠性

- 措施 1 ：常数权重值
- 措施 2 ：分配较小的权重值给较大的点到点距离匹配点对
- 措施 3 ：引入点对的法矢量信息来设置权重

四、点云配准

■ ICP 匹配算法（ Iterative Closest Point ）

ICP 改进措施—误匹配点的去除： 提剔除一定数量的误匹配点对，降低弱匹配点对或误匹配点对对参数估计的影响

- 措施 1 ：根据点对距离按比例或中误差阈值去除弱对应点对
- 措施 2 ：去除那些与邻域点对不一致的点对，如两组对应点对之间的距离差大于一定阈值，则认为二者不一致
- 措施 3 ：去除那些在点云边缘上的点对，边缘不稳定。

ICP 改进措施—目标函数的选择： 提高迭代收敛稳定性以及效率

- 措施 1 ：对应点对直接的距离平方和最小
- 措施 2 ：引入点对的颜色、强度或法向量差异作为约束
- 措施 3 ：每个源数据点到以其对应点及对应点法向量建立的局部平面的距离平方和最小。

五、点云分割

- 点云分割目的：将点云分为多个同质区域，分割在同一区域中的点云具有相似的性质。
- 点云分割难点：数据的冗余；点密度的不均匀性；在数据结构表示上缺乏明确统一的点云数据结构；



五、点云分割

■ 基于 **RANSAC** 的点云分割： **RANSAC**

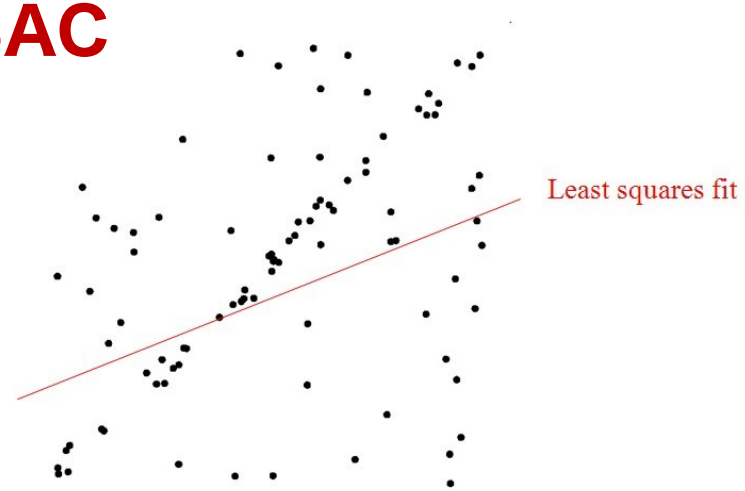
应用场合：复杂场景中物体可归结于简单的几何形状，可以用方程来描述的，或者说，可以用有限的参数来描述复杂的物体，如桌面墙面多半是大平面，桌上的罐子应该是圆柱体，长方体的盒子可能是牛奶等等。 **RanSaC** 算法可以很好的将此类物体分割出来。



五、点云分割

■ 基于 **RANSAC** 的点云分割： **RANSAC**

示例问题描述：直线拟合问题。噪音较大的数据集中提取直线模型（比方说只有 20% 的数据是符合模型的），最小二乘法就显得力不从心。



RANSAC(Random Sample Consensus，随机一致性采样) 采用迭代的方式从一组包含离群（噪声）的被观测数据中估算出数学模型的参数。

输入：

- 样本数据：既包含正确数据 **(inliers，可以被模型描述的数据)**，也包含异常数据 **(outliers，偏离正常范围很远、无法适应数学模型的数据)**，即噪声。
- 用于解释观测数据的参数化模型，并且在给定一组正确数据的情况下，存在

五、点云分割

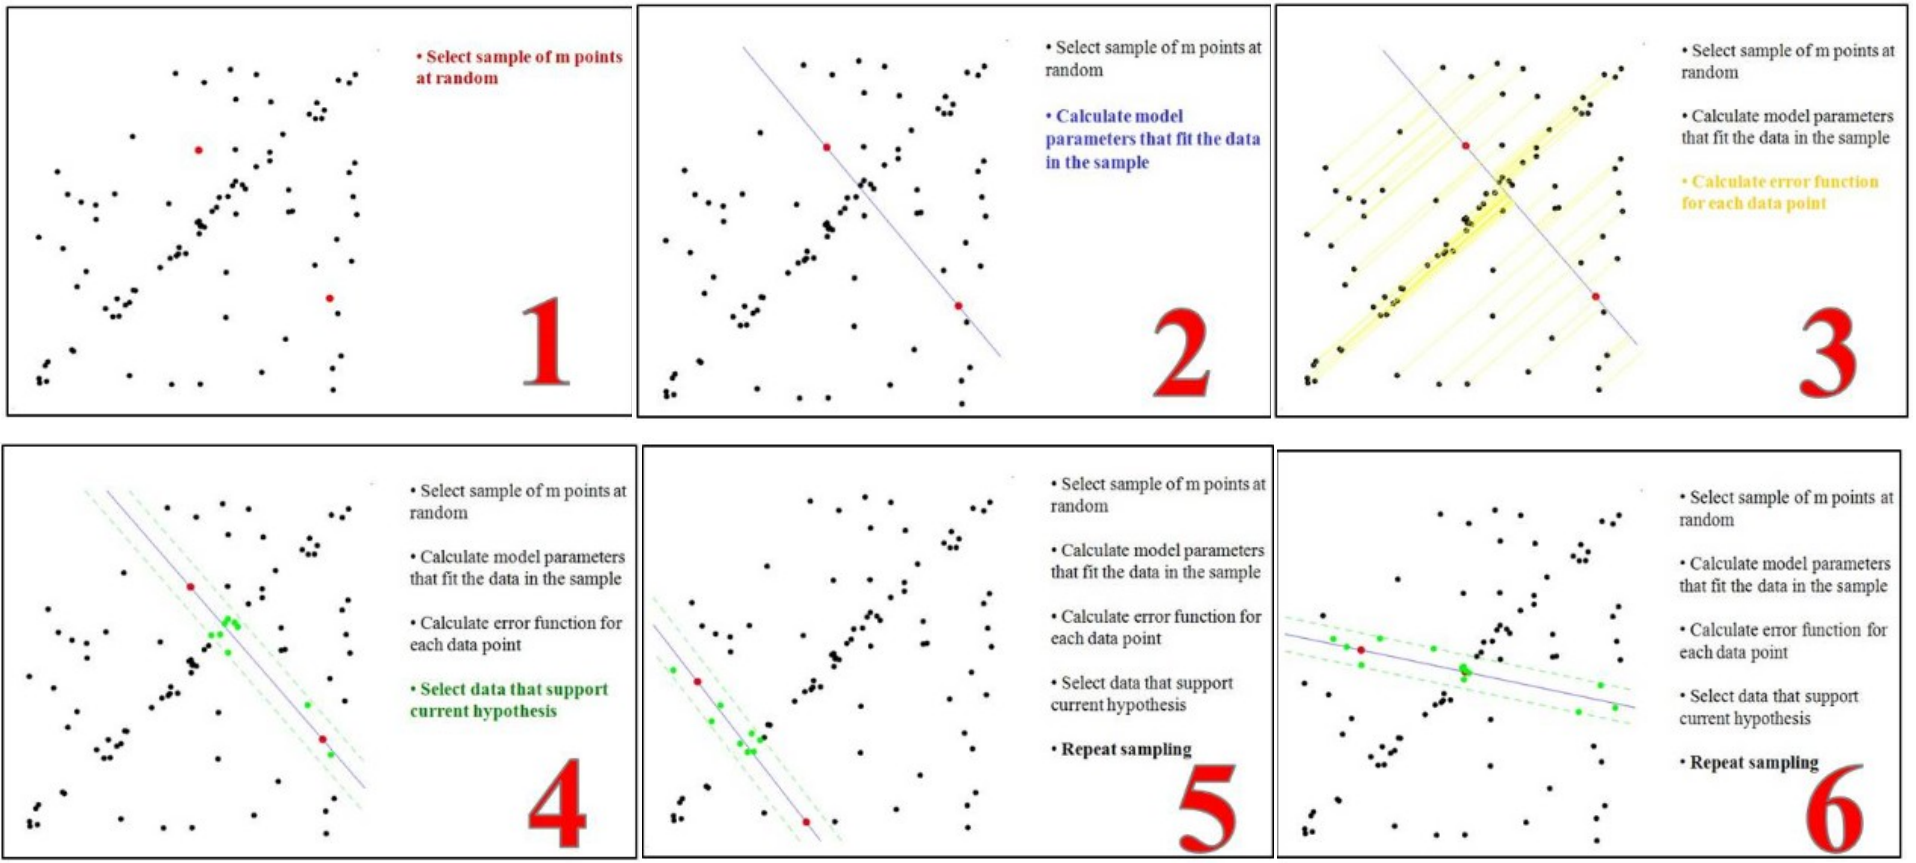
■ 基于 RANSAC 的点云分割： RANSAC

基本思想：

- 设样本集为 P，模型阶次为 n，集合 P 的样本数 #(P)>n。从 P 中随机抽取包含 n 个样本的 P 的子集 S，利用 S 中样本计算模型 M；
- 计算余集 SC=P\S 中的样本与模型 M 之间的误差，将误差小于某一设定阈值 t 的样本集以及 S 构成 S*。 S* 认为是内点集，它们构成 S 的一致集；
- 若 #(S*)≥N，认为得到正确的模型参数，并利用集 S*(内点 inliers) 采用最小二乘等方法重新计算新的模型 M*；
- 重新随机抽取新的 S，重复以上过程。
- 在完成一定的抽样次数后，若未找到一致集则算法失败，否则选取抽样后得到的最大一致集判断内外点，算法结束。

五、点云分割

■ 基于 RANSAC 的点云分割： RANSAC



在模型确定以及最大迭代次数允许的情况下， RANSAC 总是能找到最优解。经过实验，对于包含 80% 误差的数据集， RANSAC 的效果远优于直接的最小二乘法。

五、点云分割

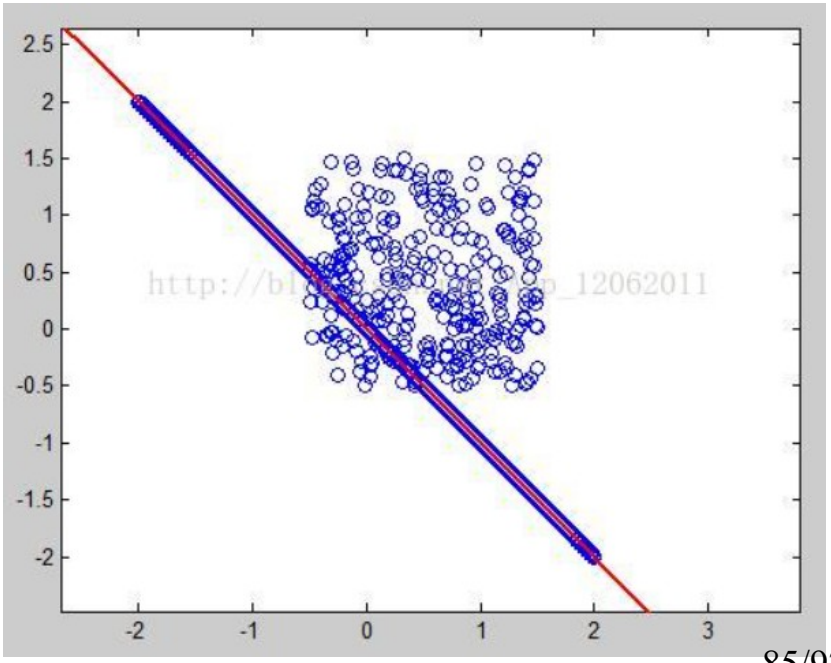
■ 基于 RANSAC 的点云分割： RANSAC

设数据集中的数据错误率为ε，最小抽样次数为M，模型参数计算需要的最小数据量为m，则至少取得一个良性取样子集的概率$P(P>\varepsilon)$满足如下关系：

$$P = 1 - (1 - (1 - \varepsilon)^m)^M$$

优化措施：

- 子集 S 的初始化问题：可以根据某些已知的样本特性采用特定的选取方案或有约束的随机选取来代替原来的完全随机选取。



五、点云分割

■ 基于 **RANSAC** 的点云分割：将 **RANSAC** 应用至分割

面片提取：

应用目标：三维点云数据中的面结构提取与分割

平面方程：$ax + by + cz = d$

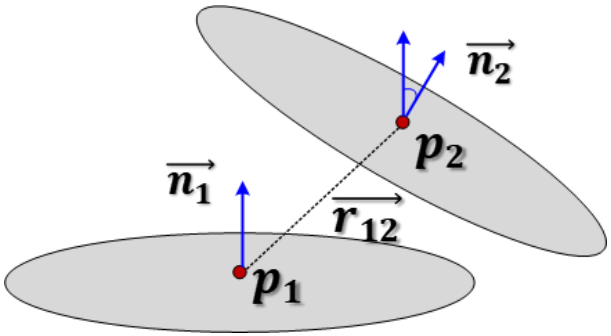
$$[x_i \quad y_i \quad z_i \quad 1]F = 0$$

$$F = [a \quad b \quad c \quad d]^T$$

3 个自由度
需要 3 个点

判断准则：$d(P, PL) = |ax + by + cz - d|$

面片合并：

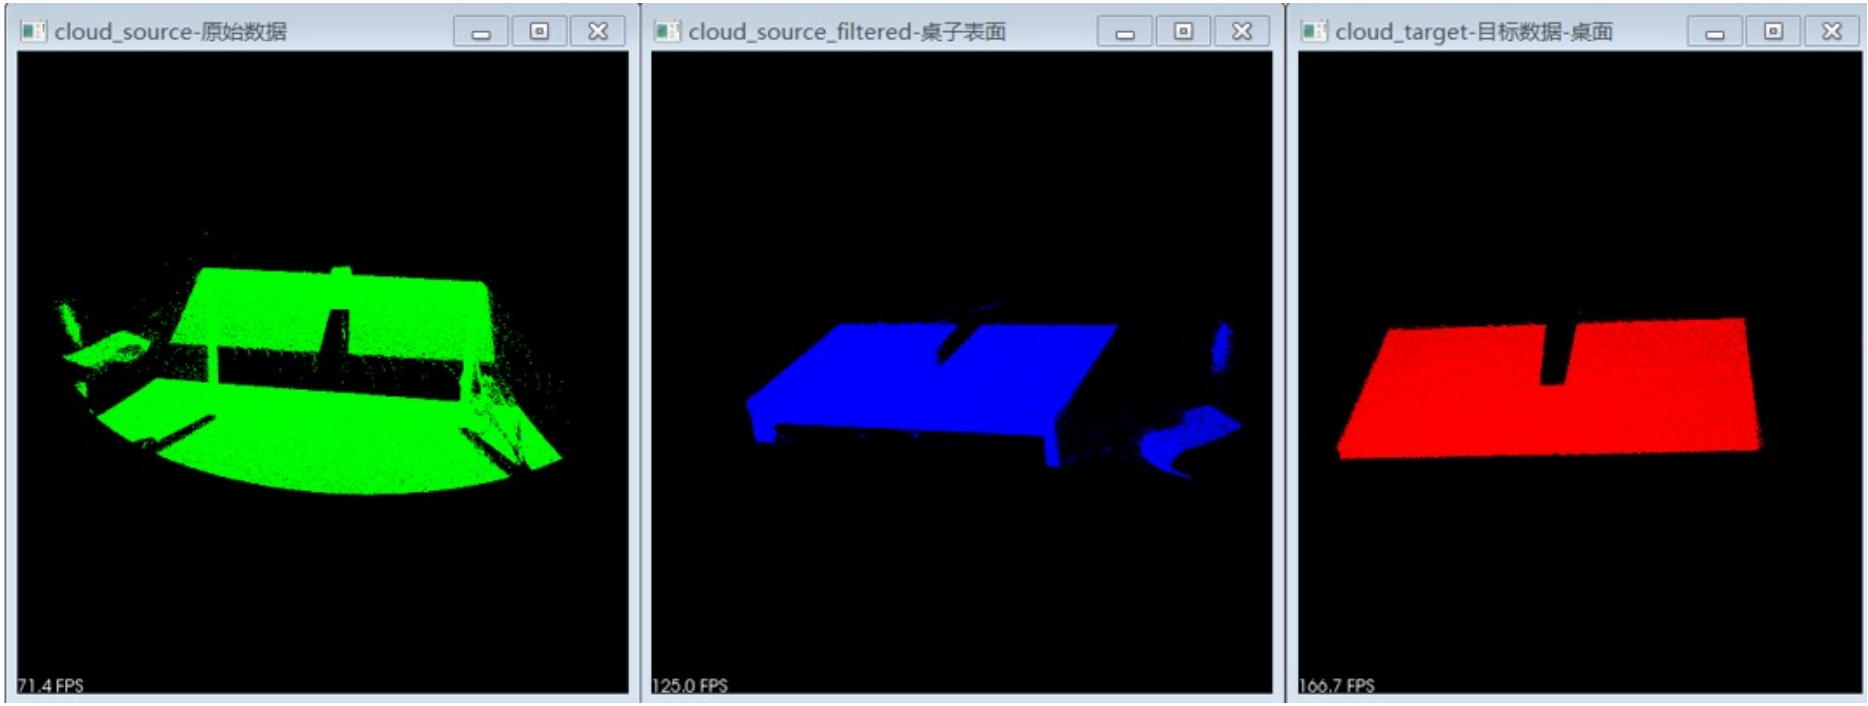


- 条件 1 ：面片之间的夹角（发现夹角）小于一定阈值 $\theta = \cos^{-1}(\overrightarrow{n_1} \cdot \overrightarrow{n_2})$
- 条件2：面片之间的距离d小于一定阈值

$$d = \max(|\overrightarrow{r_{12}} \cdot \overrightarrow{n_1}|, |\overrightarrow{r_{12}} \cdot \overrightarrow{n_2}|)$$

五、点云分割

- 基于 **RANSAC** 的点云分割：将 **RANSAC** 应用至分割

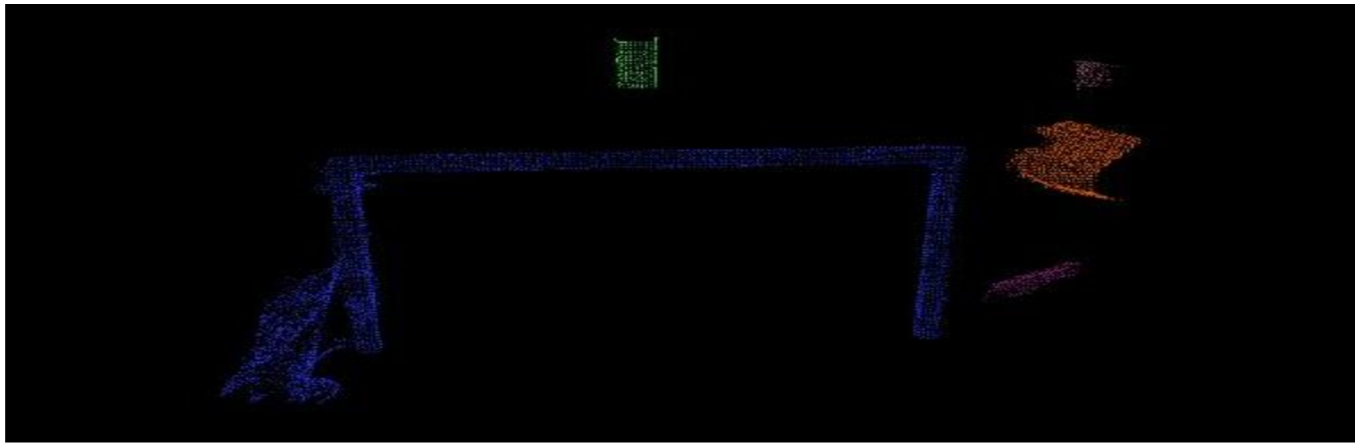


五、点云分割

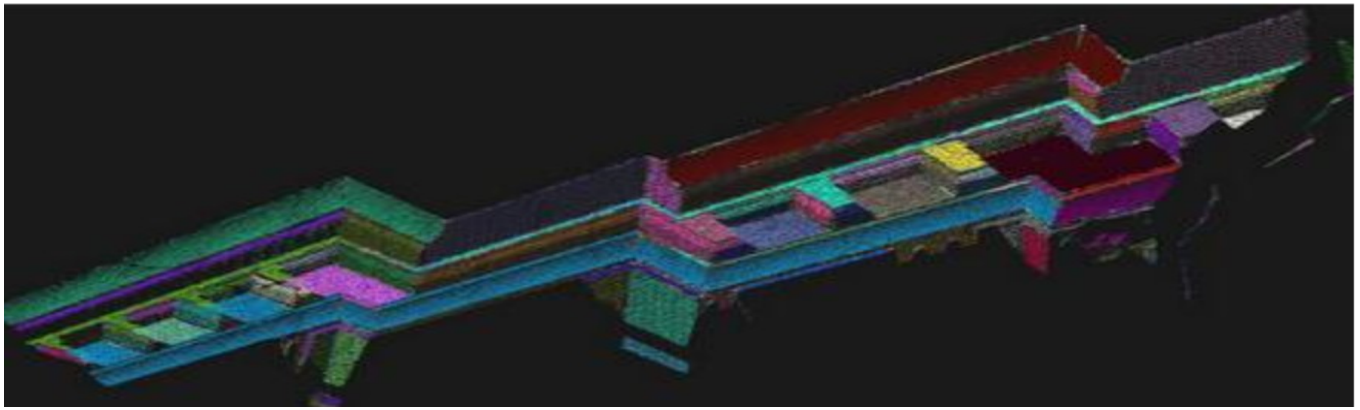
■ 基于邻近信息的点云分割

基本思路：利用 **K-d tree** 等树状结构组织点云数据，提供比较便利的邻近数据点判别机制；然后再用欧几里得法或区域生长法进行聚类分割。

欧几里得法

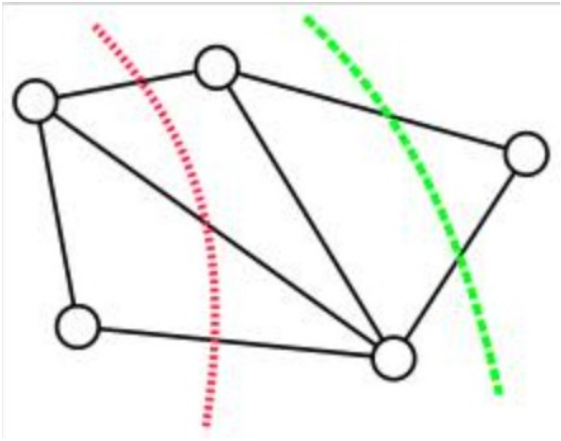


区域增长法



五、点云分割

■ 最小割法



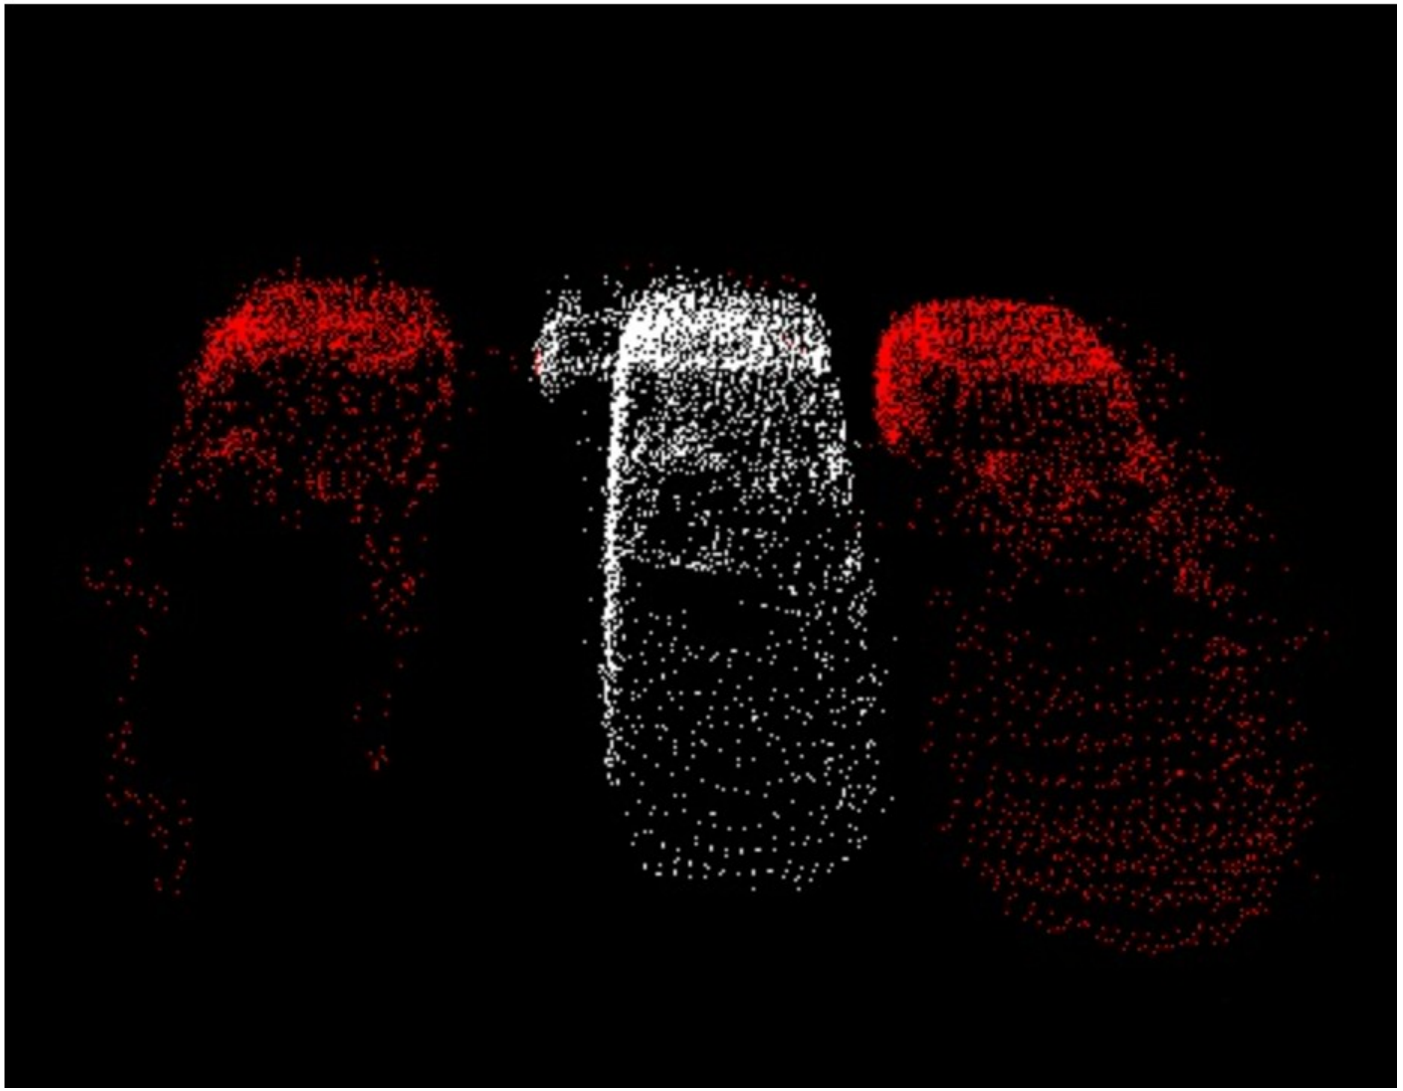
- 割：设 C_i 为网络 N 中一些弧的集合，若从 N 中删去 C_i 中的所有弧能使得从源点 V_s 到汇点 V_t 的路集为空集时，称 C_i 为 V_s 和 V_t 间的一个割。
- 最小割：图中所有的割中，边权值和最小的割为最小割。

如图中所示：如果要分开最左边的点和最右边的点，红绿两种割法都是可行的，但是红线跨过了三条线，绿线只跨过了两条。单从跨线数量上来论可以得出绿线这种切割方法更优的结论。

- 最小割求取问题是优化计算问题。

五、点云分割

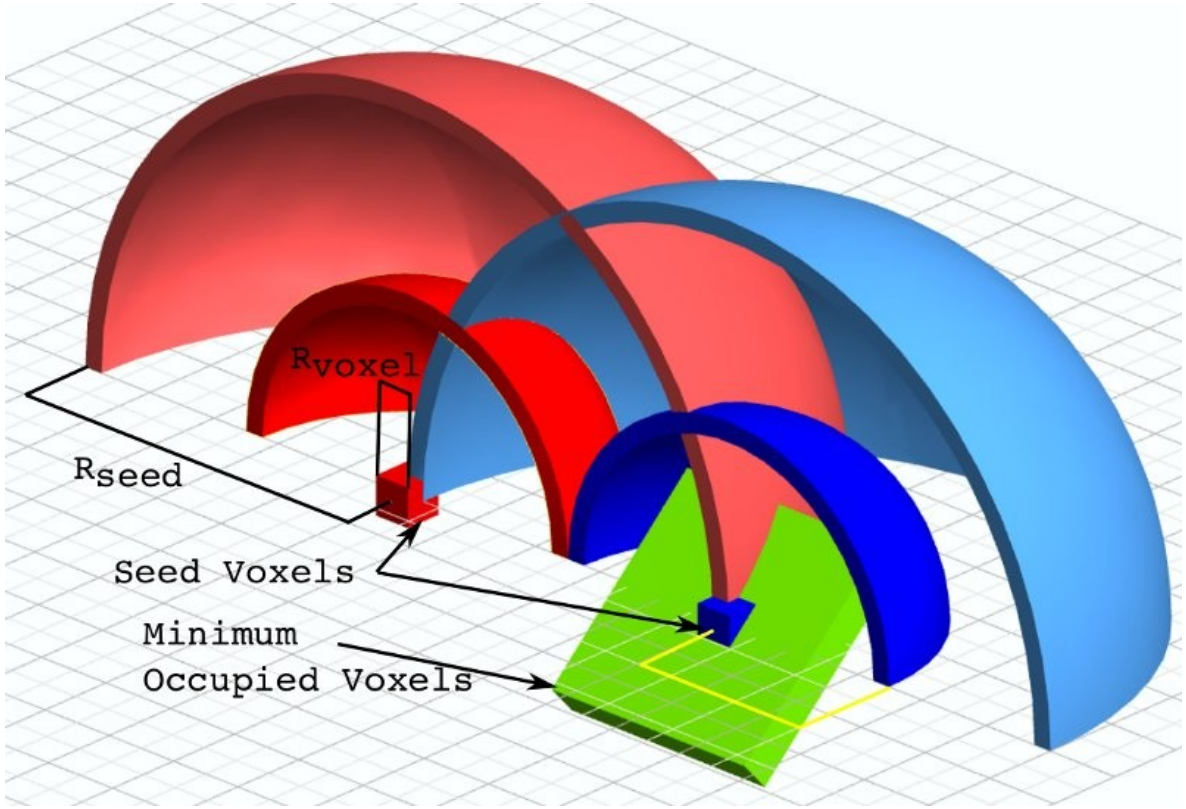
- 最小割法



五、点云分割

■ 基于超体聚类的点云分割

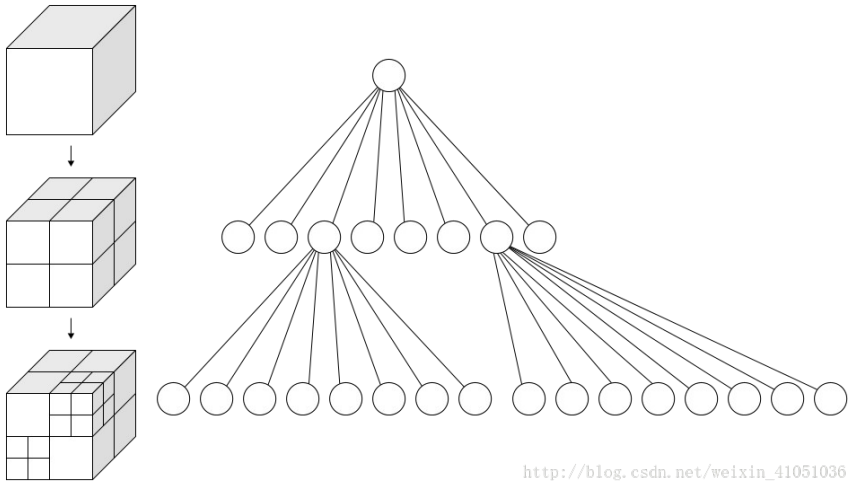
基本原理：超体聚类实际上是一种特殊的区域生长算法，其过程与盐溶液过饱和状态下的多晶核结晶类似，首先需要规律的布置区域生长“晶核(seed)”，所有晶核同时开始生长，最终填满整个空间，使物质具有晶体结



晶核在空间中实际上是均匀分布的，需要指定晶核距离（Rseed）和晶核尺寸（Rvoxel），以及最小晶粒（MOV），过小的晶粒需要融入最近的大晶粒。

五、点云分割

■ 基于超体聚类的点云分割

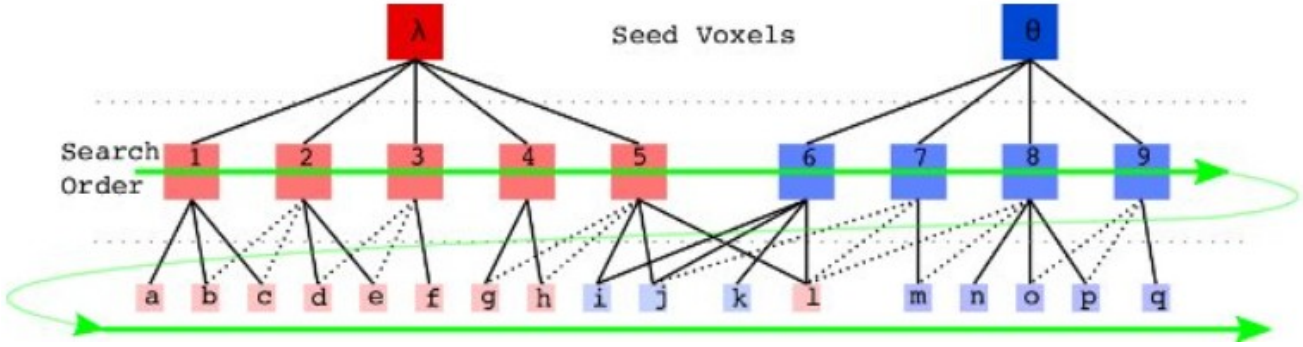


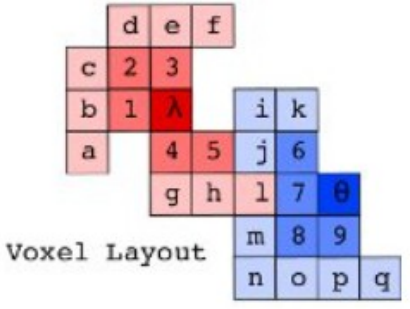
关键步骤：

- 空间划分。利用八叉树（octree）索引结构划分，按照一定宽度将其划分成空间上连续的点云体素。
- **聚类。寻找邻域中右式最小的体素，其中D_c表示颜色差异，D_s表示法线方向差异；D_n表示距离。**

$$D = \sqrt{w_c D_c^2 + \frac{w_s D_s^2}{3R_{seed}^2} + w_n D_n^2}$$

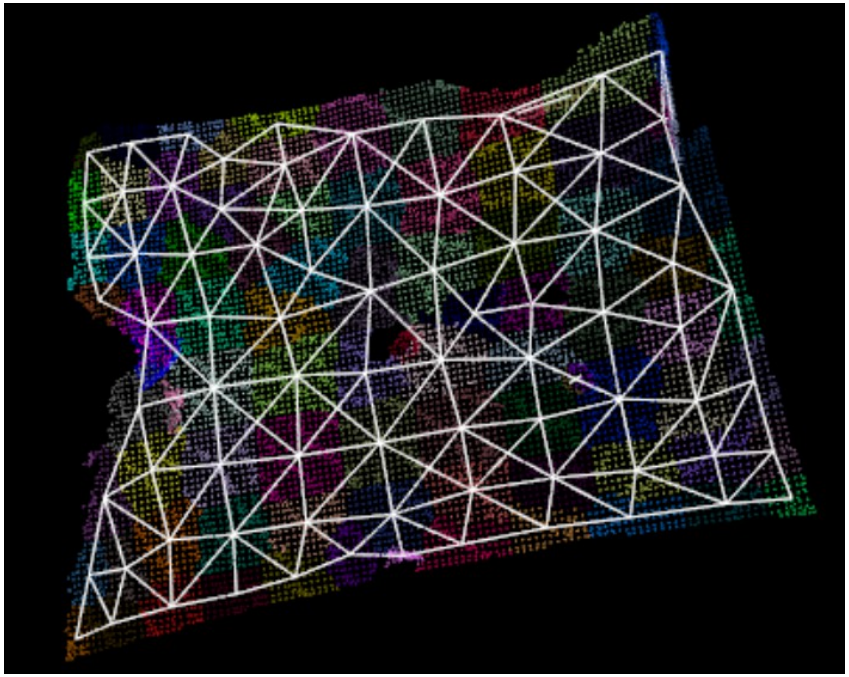
结晶过程：不是长完一个晶核再长下一个，而是所有晶核同时开始生长（虽然计算机计算时必然有先后，但从层次上来说是同时的）。

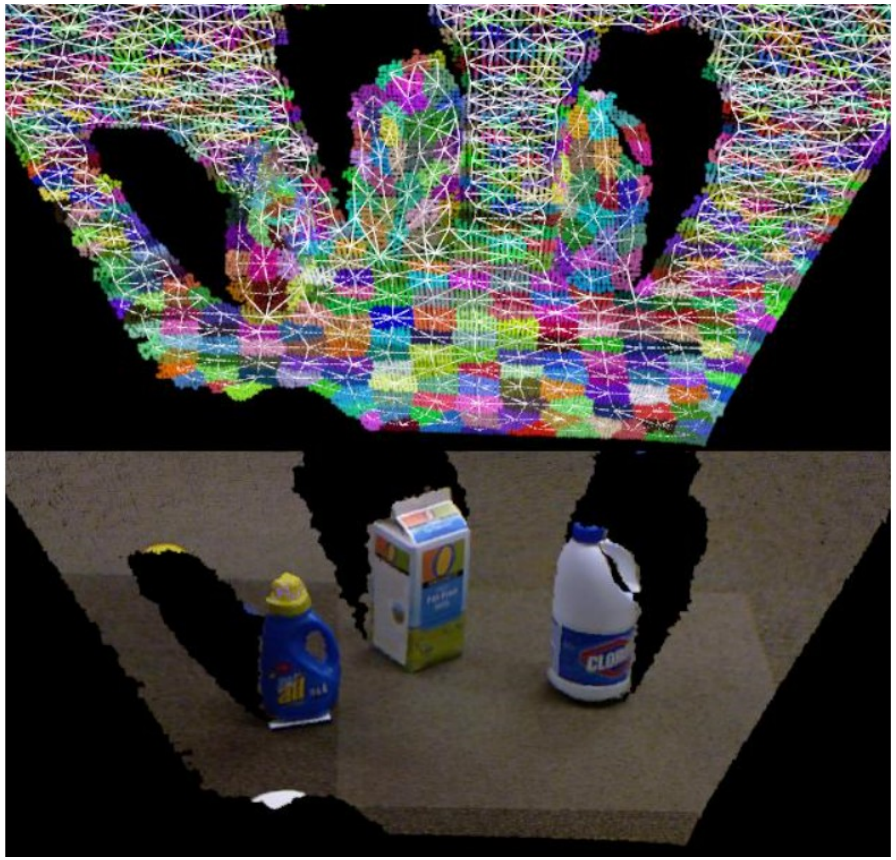




五、点云分割

- 基于超体聚类的点云分割



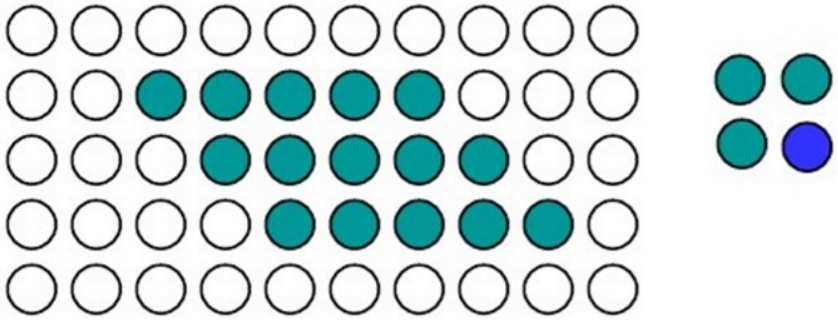


- 超体聚类作为一种过分割方法，在理想情况下是不会引入错误信息的，适合在此基础上再进行处理。

作业

1. 设二维平面某曲线上的5点：（-2,-1）（-1,1）（0,3）（1,5）（2,7），利用PCA方法求点（0,3）处该点的法线单位矢量。

2. 对图利用形态学方法进行腐蚀和膨胀处理（注：与课件中不同，模板原点位于右下角）。



3. 简述ICP配准思路和原理。

4. 设数据集中的数据错误率为0.5，模型需要拟合3个参数，利用RANSAC进行拟合时，如果要求至少取得一个良性取样子集的概率P为0.9，那么最少采样次数应该是多少？给出计算步骤。

THANK YOU

