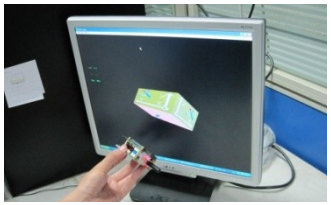
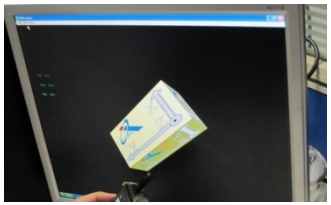
人工智能学院课程：《智能传感与信息处理》第 12~13 讲

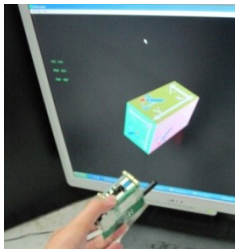
智能信息融合技术

中国科学院自动化研究所

刘希龙

一、信息融合概述




目标检测与跟踪

战场环境

传感器 → 目标探测跟踪

传感器 → 目标探测跟踪

传感器

传感器

武器系统

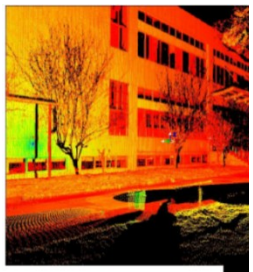
信息融合：对多传感器或多源信息进行协调优化和综合处理，产生新的有价值的信息，以得到更准确、可信的结论。

位置 类型 结构 数量 分布

多源 异质 大量 质差 对抗

目标检测与身份判别（机动）目标跟踪 数据关联与航迹融合

目标跟踪：就是利用传感器探测的目标信息来确定目标的位置和运动参数。


第一站点云


配准结果



一、信息融合概述

- 定义：利用计算机技术对按时序获得的若干传感器的观测信息在一定准则下加以自动分析和综合处理，以完成所需的决策和估计任务而进行的信息处理过程
  - 多传感器系统是信息融合的硬件基础
  - 多源信息是信息融合的加工对象
  - 协调优化和综合处理是信息融合的核心

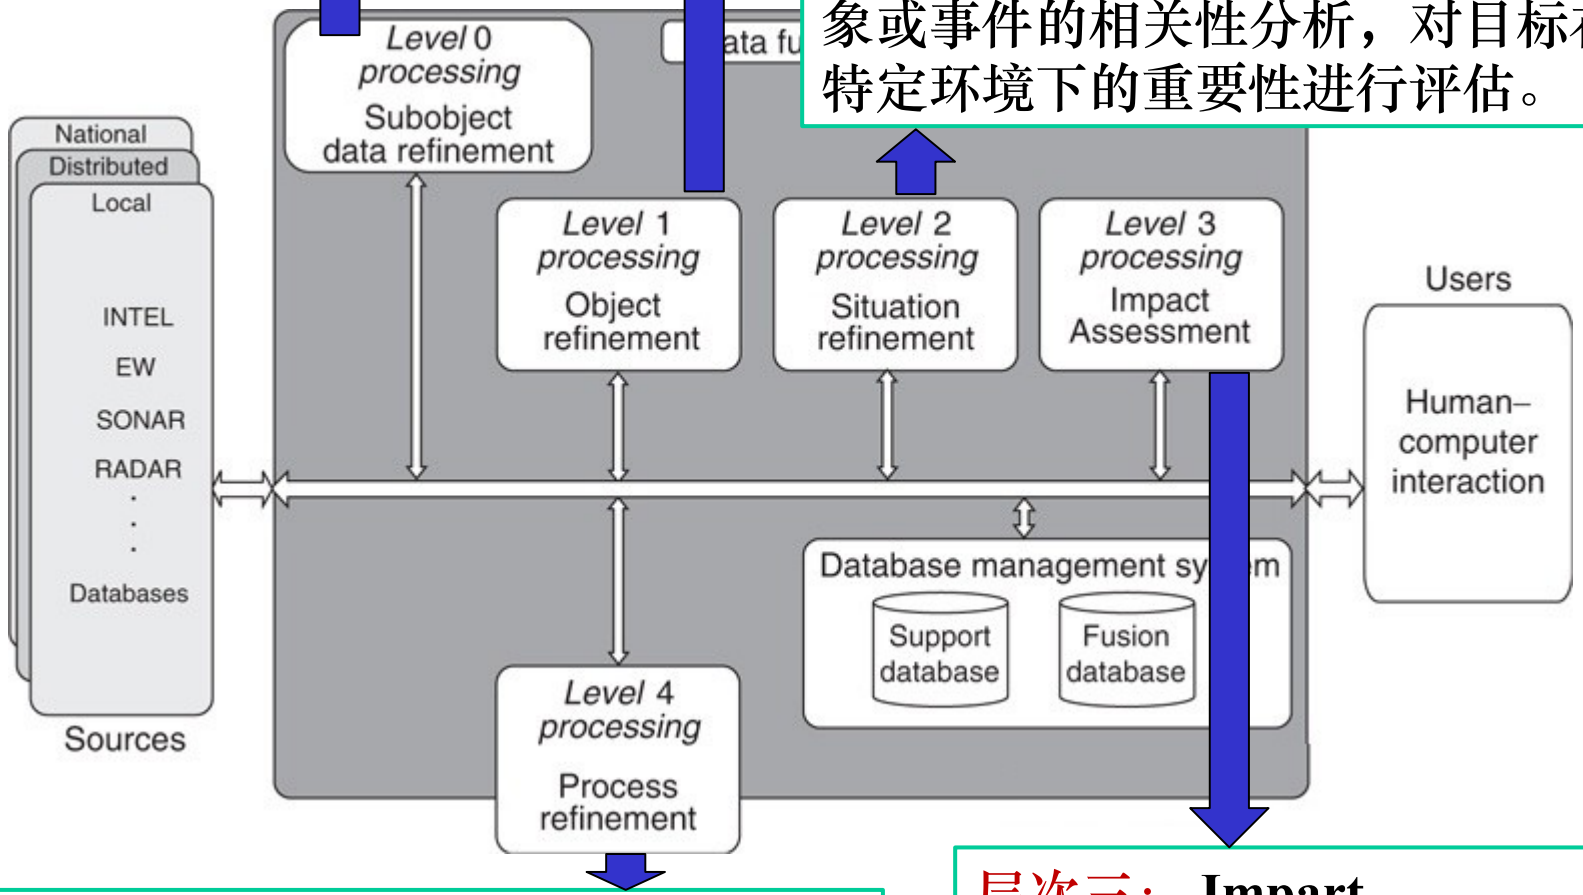
- 信息融合的基本原理是：通过对各种传感器及人工观测信息的合理支配与使用，将各种传感器在空间和时间上的互补与冗余信息依据某种优化准则或算法组合起来，产生对观测对象的一致性解释和描述

层次零： **Subobject refinement** 。预处理修正偏差，由图场者。

层次一： **Object refinement.** 数据关联分析，获得目标位置或属性，目标区分和目标追踪。

层次二： **Situation refinement** 。对象或事件的相关性分析，对目标在特定环境下的重要性进行评估。

美国国防部 JDL joint dir 数据融合模型



层次三： **Impart assessment** 。事件预测、威胁意图估计、己方部队的弱点以及后果分析。

层次四： **Process refinement.** 对融合过程进行评估并给用户提供建议，比如己方任务的优先度，以及可用资源的调配。

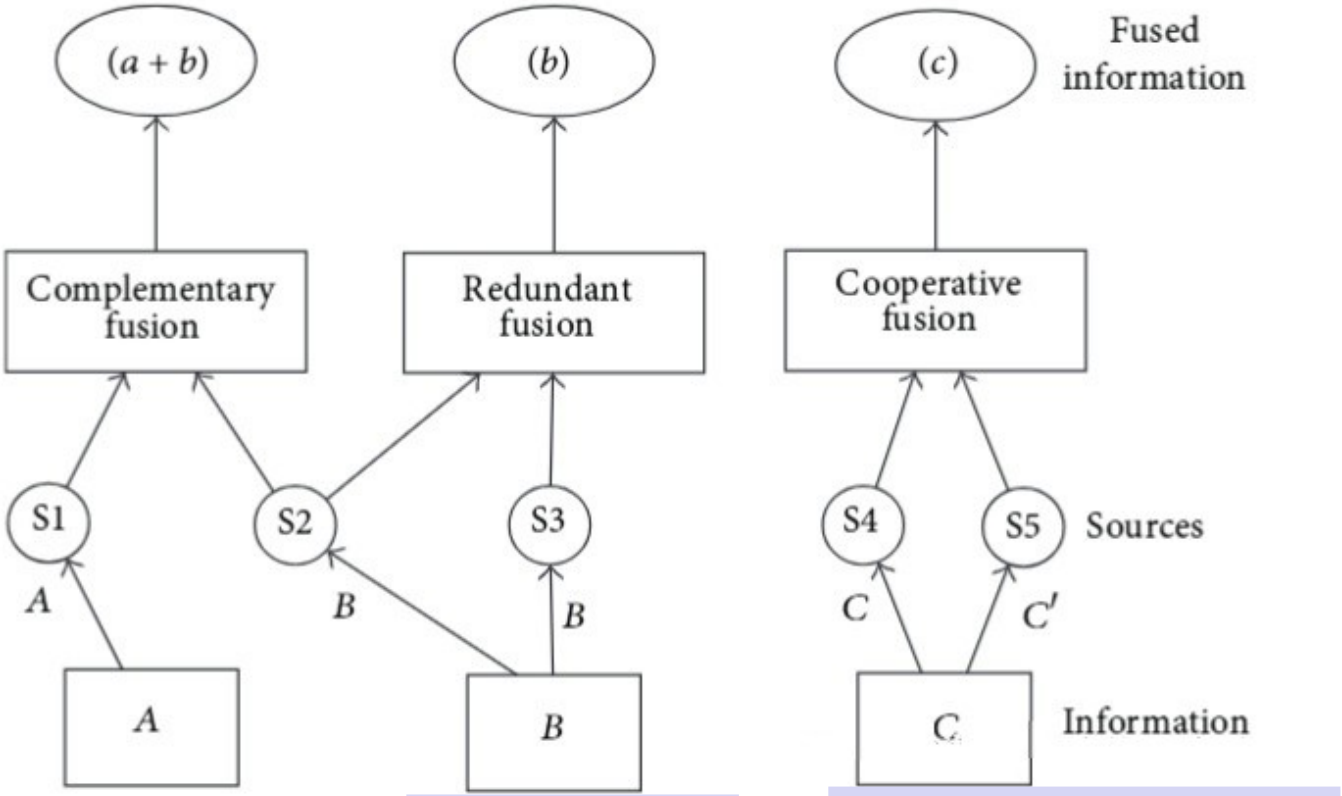
一、信息融合概述

根据输入数据的关系： **Durrant Whyte** 提出了以下分类准则：

互补型：输入数据代表同一场景的不同部分，融合获得更完整全局信息。

冗余型：多输入数据为同一目标的同类信息，融合增强可信度。

协作型：多输入数据组合成比原始信息更复杂的信息。



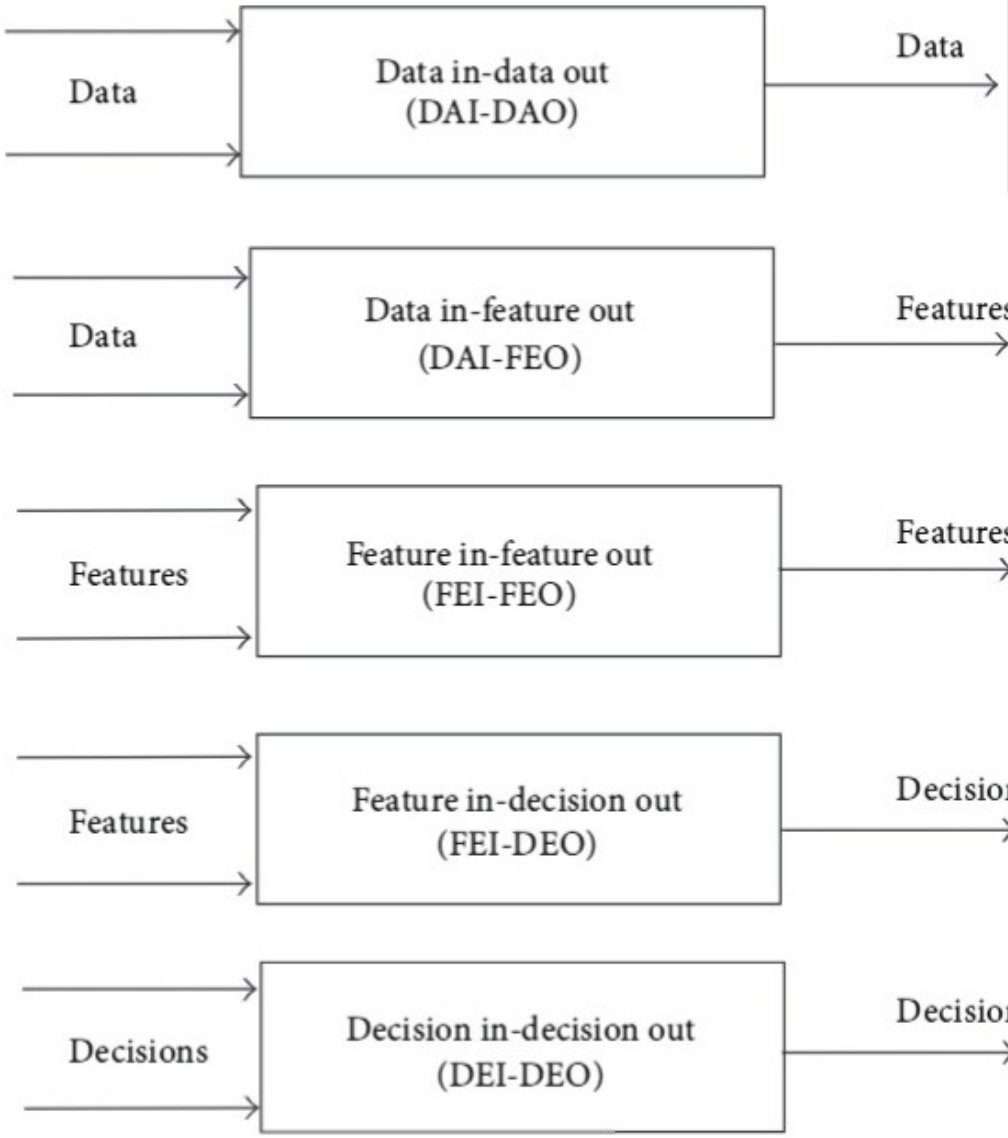
例：对同一目标不同方向进行观察

例：对相同区域重复观察

例：多模数据（如声音和视频）融合

一、信息融合概述

根据输入/输出数据类型：Dasarathy 提出的 5 个分类准则



数据进数据出（DAI-DAO）：基础数据融合方法，输出数据可信度更高或更准确。融合方法：信号与图像处理算法。

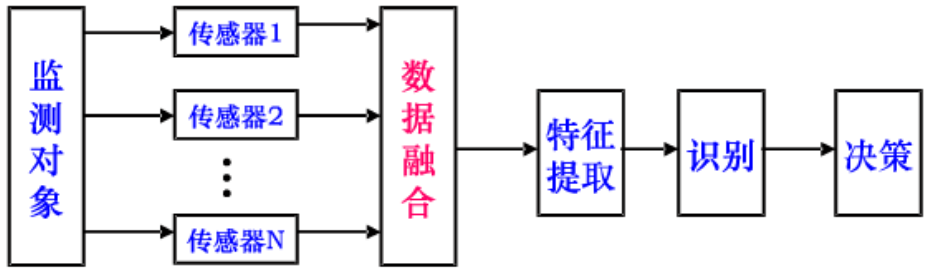
数据进特征出（DAI-FEO）：对原始数据进行特征提取。

特征进特征出（FEI-FEO）：对一组特征进行提高、改进或获得新的特征。被称为是特征融合。

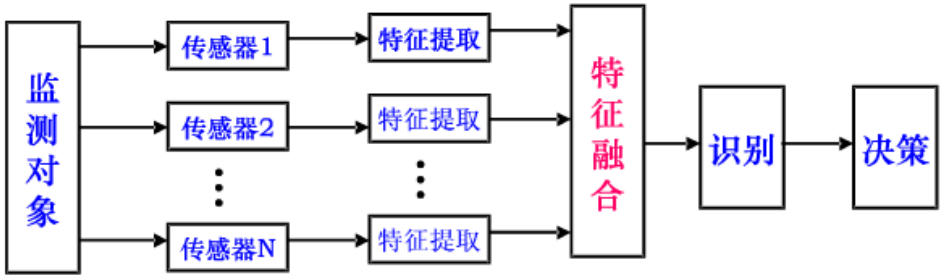
特征进决策出（FEI-DEO）：输入特征输出决策。决策分类系统。

决策进决策出（DEI-DEO）：决策融合，输入决策进行融合获得更好决策。

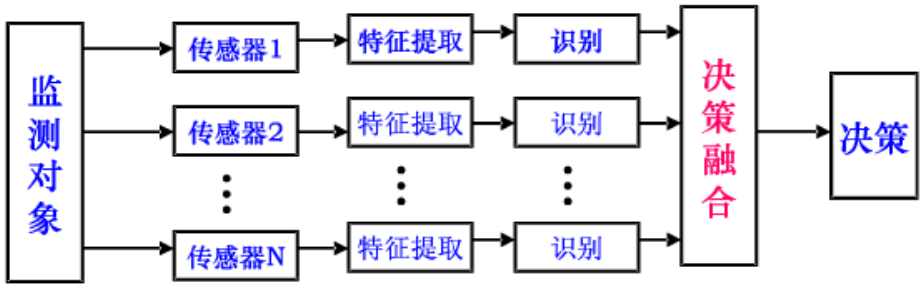
一、信息融合概述



数据级融合



特征级融合



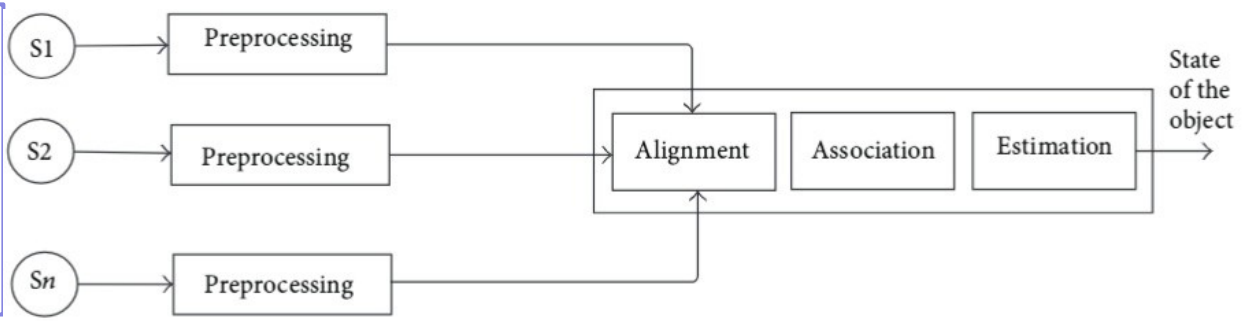
决策级融合

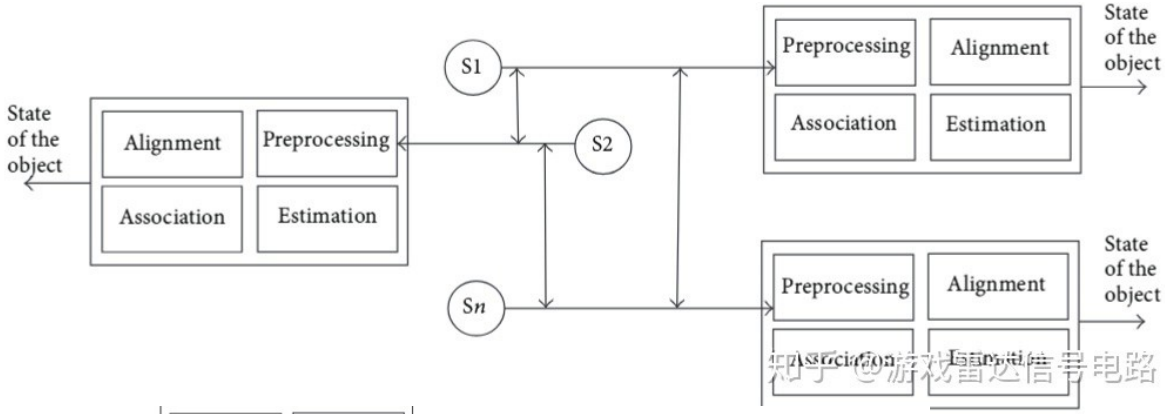
- 提高信息的全面性。比单一传感器获得有关周围环境更准确、全面的信息。
- 降低信息的不确定性。一组传感器采集的信息存在互补性，可以对单一传感器的不确定性和测量范围的局限性进行补偿
- 提高系统的可靠性。某个或几个传感器失效时，系统仍正常工作。

一、信息融合概述

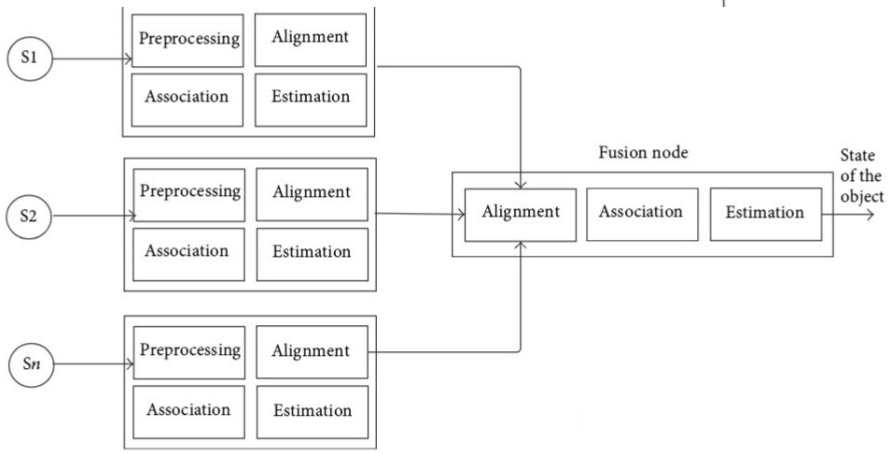
根据融合结构类型：

集中式结构：全部融合过程都在一个中央处理器上进行。理论最完美，存在数据传输带宽问题和数据同步问题。





分散式结构：融合节点为网络各个节点，都有处理能力，能对当前节点和周围节点信息进行融合。缺点为通信损耗，每个节点都需和其它节点进行通信；节点数增大，结构可拓展性较差。



分布式结构：每个数据来源节点单独处理，处理结果发送至融合节点，每个融合节点负责处理接收到的其他节点的信息。这种结构提供了更灵活的配置，可以只有一个融合节点，也可以有多个中间融合节点。

知乎 @游戏雷达信号电路

一、信息融合概述

- 融合方法
  - 加权平均
  - Kalman 滤波系列（EKF 和 UKF）
  - Bayes 估计理论
  - D-S 证据理论
  - 模糊推理
  - 神经网络

二、基于 Kalman 滤波的信息融合

背景介绍:

- Kalman，匈牙利数学家



- 卡尔曼滤波器源于他的博士论文和 1960 年发表的论文《A New Approach to Linear Filtering and Prediction Problems》，Journal of Basic Engineering Transactions , 1960 , 82 :35-45

  线性滤波与预测问题的新方法

- 卡尔曼将状态变量引入滤波理论，提出递推滤波算法，建立了后来被自动控制界称道的“卡尔曼滤波”

二、基于 Kalman 滤波的信息融合

Kalman 滤波：基本知识

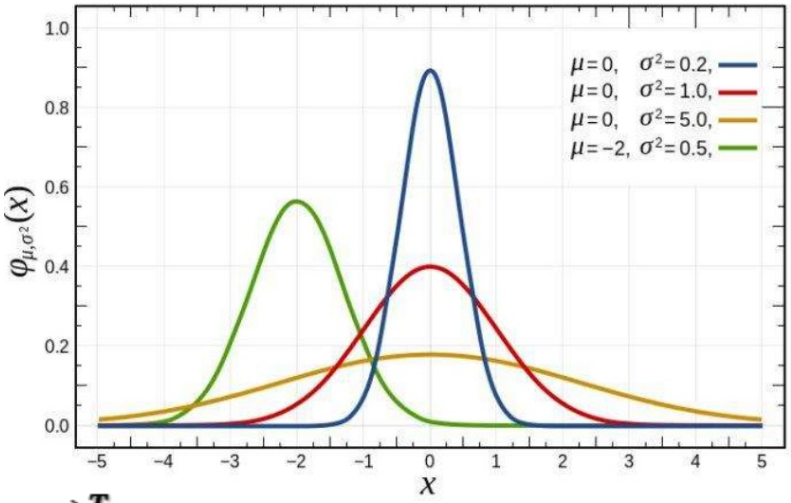
- 两个随机向量之间的协方差：

$$\Sigma = \mathrm{cov}(X, Y) = E\left((X-\mu)(Y-v)^T\right)$$

表示的两个变量之间的相关误差，当 Y=X 的时候就是方差

- 高斯分布：

$$p\left(x;\mu,\sigma^2\right) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



- 多元高斯分布：

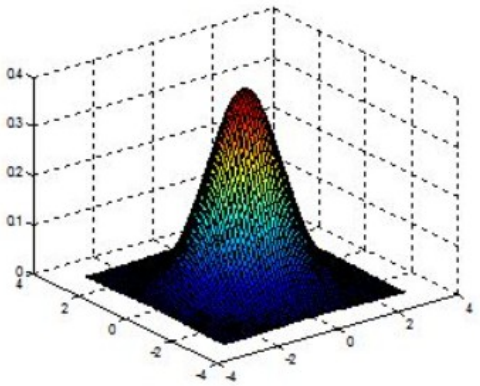
$$p(X;\mu,\Sigma) = \frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}} e^{-\frac{(X-\mu)^T\Sigma^{-1}(X-\mu)^T}{2}}$$

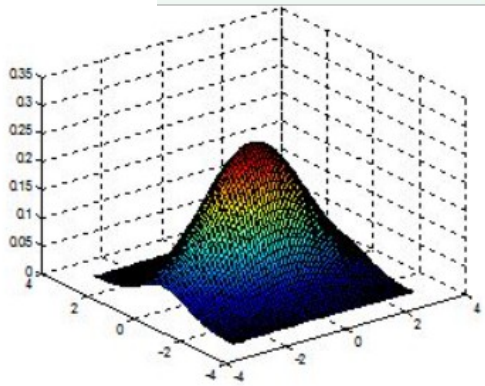
$$p(X;\mu,\Sigma) = \frac{1}{\left(\sqrt{2\pi}\right)^n \sigma_1\sigma_2\cdots\sigma_n} e^{-\left(\frac{(x_1-\mu_1)^2}{2{\sigma_1}^2}+\frac{(x_2-\mu_2)^2}{2{\sigma_2}^2}+\cdots+\frac{(x_n-\mu_n)^2}{2{\sigma_2}^2}\right)}$$

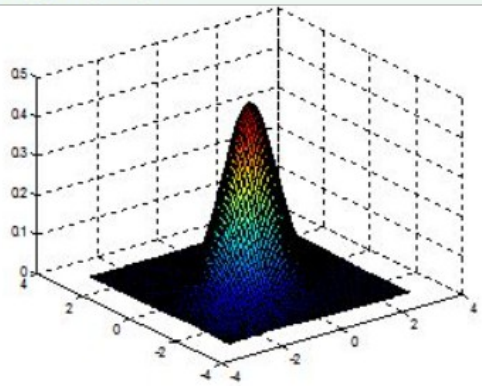
二、基于 Kalman 滤波的信息融合

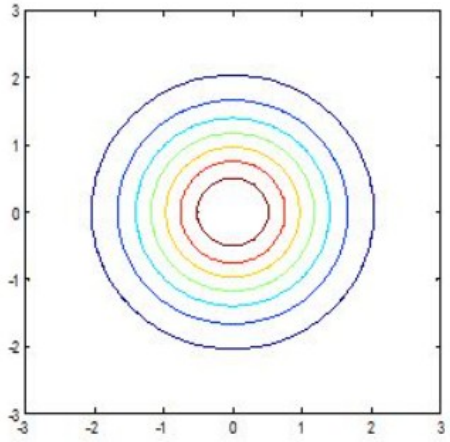
- **Kalman 滤波：** 基本知识

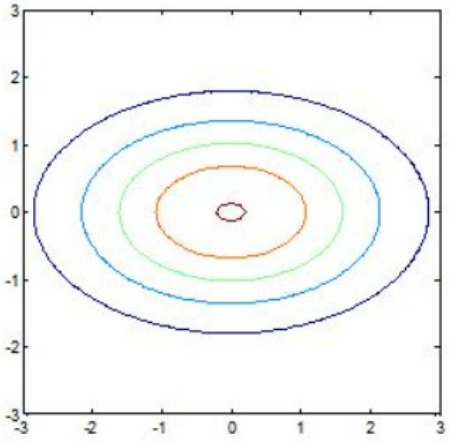
$$p(X;\mu,\Sigma)=\frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}}e^{-\frac{(X-\mu)^T\Sigma^{-1}(X-\mu)^T}{2}}$$

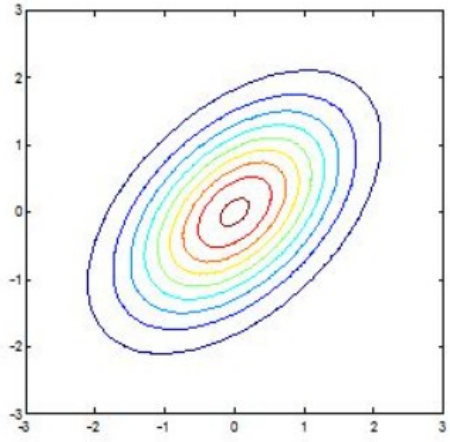












$$\Sigma=\begin{bmatrix}1.0 & 0\\ 0 & 1.0\end{bmatrix}$$

$$\mu=[0 \quad 0]^T$$

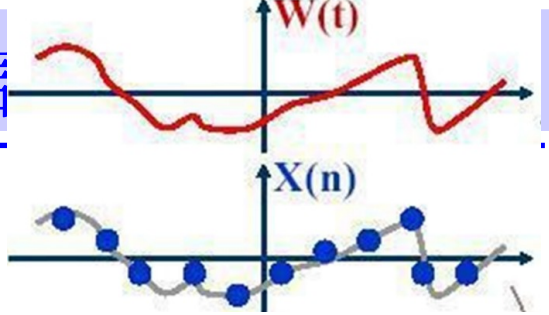
$$\Sigma=\begin{bmatrix}2.5 & 0\\ 0 & 1.0\end{bmatrix}$$

$$\mu=[0 \quad 0]^T$$

$$\Sigma=\begin{bmatrix}1.0 & 0.5\\ 0.5 & 1.0\end{bmatrix}$$

$$\mu=[0 \quad 0]^T$$

二、基于 Kalman 滤波的信



随机过程：随时间变化的随机变量$X(t)$

独立随机过程：任意时刻随机变量$X(t_1)$、$X(t_2)\cdots X(t_n)$都是相互独立的

平稳性：所有时刻的概率分布完全相同的随机过程，即随机过程的统计特性不随时间的推移而变化，称为平稳随机过程。

遍历性：对于平稳随机过程，统计平均值等于时间平均值。

平稳过程的功率谱密度：

$$S_X(\omega)=\lim_{T\to+\infty}\frac{1}{2T}E\{|F_X(\omega,T)|^2\}.$$



白噪声：

(1) 平稳过程$X(t)$均值为0，功率谱密度为正常数；

或（2）平稳过程$X(t)$均值为0，自相关函数为

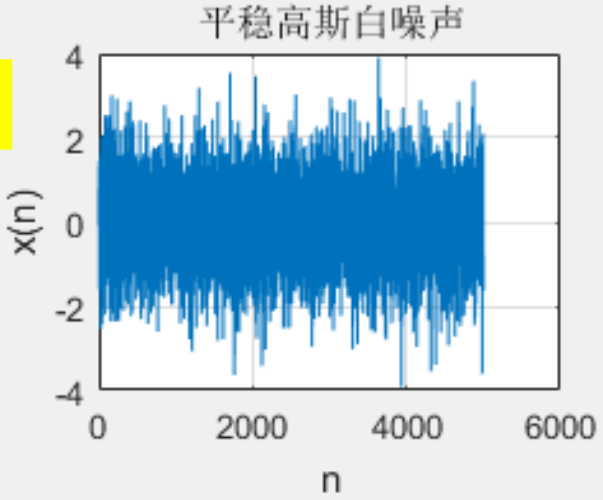
$$R(\tau)=E[X(t)X(t-\tau)]=\delta(\tau)$$

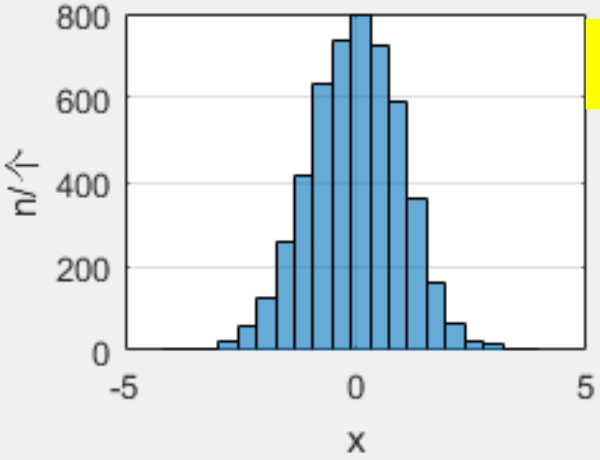
二、基于 Kalman 滤波的信息融合

□ Kalman 滤波：基本知识

高斯白噪声：瞬时值服从高斯分布的白噪声（零均值，谱密度均匀分布）

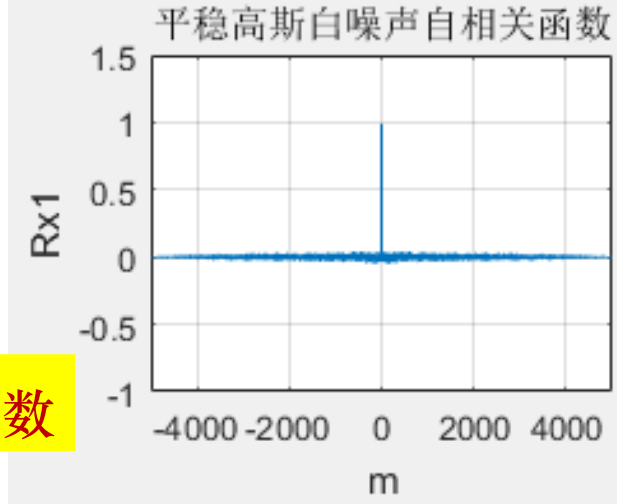
噪声数据

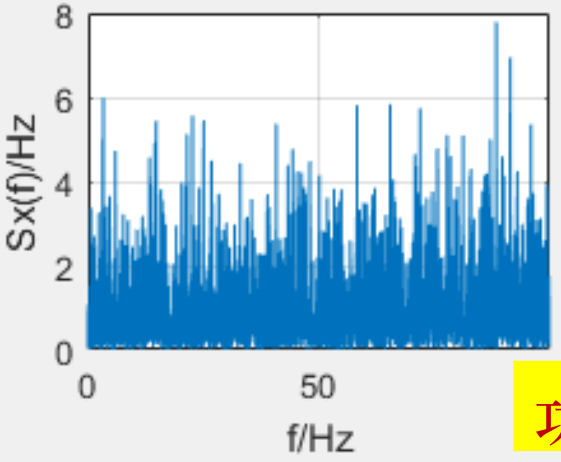




统计分布

自相关函数





功率谱密度

二、基于 Kalman 滤波的信息融合

Kalman 滤波：简单过程示例

传感器测 1 次：$X_A \sim N(\mu_A, {\sigma_A}^2)$

利用同一传感器的 2 次数据估计当前值：$\frac{X_{A1}+X_{A2}}{2} \sim N(\mu_A, \frac{{\sigma_A}^2}{2})$

两个传感器 A 和 B：$X_A \sim N(\mu_A, {\sigma_A}^2)$　　$X_B \sim N(\mu_B, {\sigma_B}^2)$

如何确定最终的测量估计值?

$$\hat{X} = kX_A + (1-k)X_B \qquad k \in [0,1]$$

$$\hat{X} \sim N\left(k\mu_A + (1-k)\mu_B, k^2{\sigma_A}^2 + (1-k)^2{\sigma_B}^2\right)$$

二、基于 Kalman 滤波的信息融合

Kalman 滤波：简单过程示例

$$\hat{X} \sim N\left(k\mu_A + (1-k)\mu_B, k^2\sigma_A{}^2 + (1-k)^2\sigma_B{}^2\right) \quad k \in [0,1]$$

如何选择 k？满足以上条件 且使得方差最小：

$$f(k) = k^2\sigma_A{}^2 + (1-k)^2\sigma_B{}^2$$

$$\frac{d}{dk}f(k) = 2k\sigma_A{}^2 - 2(1-k)\sigma_B{}^2 = 0 \Rightarrow k = \frac{\sigma_B{}^2}{\sigma_A{}^2 + \sigma_B{}^2}$$

$$\hat{X} \sim N\left(\frac{\sigma_B{}^2}{\sigma_A{}^2 + \sigma_B{}^2}\mu_A + \frac{\sigma_A{}^2}{\sigma_A{}^2 + \sigma_B{}^2}\mu_B, \frac{\sigma_A{}^2\sigma_B{}^2}{\sigma_A{}^2 + \sigma_B{}^2}\right)$$

二、基于 Kalman 滤波的信息融合

Kalman 滤波：简单过程

$$\hat{X}\sim N\left(\frac{\sigma_B^2}{\sigma_A^2+\sigma_B^2}\mu_A+\frac{\sigma_A^2}{\sigma_A^2+\sigma_B^2}\mu_B,\ \frac{\sigma_A^2\sigma_B^2}{\sigma_A^2+\sigma_B^2}\right)$$

$$\left(1-\frac{\sigma_A^2}{\sigma_A^2+\sigma_B^2}\right)\mu_A+\frac{\sigma_A^2}{\sigma_A^2+\sigma_B^2}\mu_B$$

$$=\mu_A+\frac{\sigma_A^2}{\sigma_A^2+\sigma_B^2}(\mu_B-\mu_A)$$

增益 Kg

新息

$$P(\hat{X})=\sigma_A^2\left(1-\frac{\sigma_A^2}{\sigma_A^2+\sigma_B^2}\right)$$

$$\hat{X}\sim N\left(\mu_A+K_g(\mu_B-\mu_A),\ (1-K_g)\sigma_A^2\right)$$

Kalman 滤波器把偏差递归，估算出最优温度值。按照上述预测、测量、更新的过程迭代，完成基于 Kalman 滤波的状态最优估

k-1 时刻温度最优估计值：23 计。 **k-1 时刻温度最优估计偏差：3 度**

度

相信短时间内温度恒定

自己预测的不确定性偏差为 4 度

预测值 **k 时刻温度预测：23 度** μ_A **预测偏差：$\sqrt{3^2+4^2}=5$度** σ_A

测量值 **温度计得到测量值：25** μ_B **温度计测量偏差为：4 度** σ_B

度

① 根据方差确定增益 $K_g=\frac{{\sigma_A}^2}{{\sigma_A}^2+{\sigma_B}^2}=\frac{5^2}{5^2+4^2}$

② 最优估计值：

新息

$$\mu_A(k+1)=\mu_A+K_g(\mu_B-\mu_A)=23+\frac{5^2}{5^2+4^2}\times(25-23)=24.56$$

③ k 时刻最优估计值的偏差：

$$\sigma_A(k+1)=\sigma_A\sqrt{(1-K_g)}=5\times\sqrt{(1-\frac{5^2}{5^2+4^2})}=2.35$$

二、基于 Kalman 滤波的信息融合

Kalman 滤波

Kalman 滤波器：是一种高效率利用线性系统状态方程，通过系统输入输出观测数据，对系统状态进行最优估计的算法。由于观测数据中包括系统中的噪声和干扰，所以最优估计也可看作是滤波过程。由于它便于计算机编程实现，所以它是目前引用最为广泛的滤波方法。

- 基本思想：采用信号与噪声的状态空间模型，利用前一时刻的估计值和现在时刻的观测值来更新对状态变量的估计，求出现在时刻的估计值，适合于实时处理和计算机运算

- 实质：由测量值重构系统的状态向量。以“预测 - 实测 - 修正”的顺序递推，根据测量值消除随机干扰，再现系统的状态

二、基于 Kalman 滤波的信息融合

Kalman 滤波：系统模型

条件 1：线性系统
条件 2：系统噪声和观测噪声为高斯白噪声
条件 3：观测噪声与系统噪声互不相关。

$$\begin{cases} X_k = AX_{k-1} + Bu_k + w_k & \text{系统状态方程} \quad w \sim N(0, Q) \\ z_k = HX_k + v_k & \text{观测方程} \quad v \sim N(0, R) \end{cases}$$

$$x_k = x_{k-1} + (\dot{x}_{k-1} \times \Delta t) + \frac{f_k}{2m}(\Delta t)^2$$

$$\dot{x}_k = \dot{x}_{k-1} + \frac{f_k}{m}\Delta t$$

$$X_k = \begin{bmatrix} x_k \\ \dot{x}_k \end{bmatrix} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_{k-1} \\ \dot{x}_{k-1} \end{bmatrix} + \begin{bmatrix} \frac{(\Delta t)^2}{2} \\ \Delta t \end{bmatrix} \frac{f_k}{m} \qquad z_k = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_k \\ \dot{x}_k \end{bmatrix}$$

Kalman滤波器目的：已知系统模型和测量模型、系统初始状态X_0，每个时刻的测量值z，求解状态X随着时间变化而产生的值。

二、基于 Kalman 滤波的信息融合

Kalman 滤波：系统模型

条件 1：线性系统
条件 2：系统噪声和观测噪声为高斯白噪声
条件 3：观测噪声与系统噪声互不相关

$$\begin{cases} X_k = AX_{k-1} + Bu_k + w_k \\ z_k = HX_k + v_k \end{cases}$$

系统噪声和观测噪声为高斯白噪声：$w_k \sim N(0, Q_k)$，$v \sim N(0, R_k)$，

不同时刻的系统噪声互不相关：

$$Q_{kl} = \mathrm{Cov}(w_k, w_l) = E\left(\begin{bmatrix} \omega_{k1} \\ \vdots \\ \omega_{kN} \end{bmatrix} [\omega_{l1} \quad \cdots \quad \omega_{lN}]^T \right) = Q_k \delta_{kl} = \begin{cases} Q_k, k = l \\ 0, k \neq l \end{cases}$$

不同时刻的观测噪声互不相关：

$$R_{kl} = \mathrm{Cov}(v_k, v_l) = E\left(\begin{bmatrix} v_{k1} \\ \vdots \\ v_{kN} \end{bmatrix} [v_{l1} \quad \cdots \quad v_{lN}]^T \right) = R_k \delta_{kl} = \begin{cases} R_k, k = l \\ 0, k \neq l \end{cases}$$

系统噪声与观测噪声互不相关：$\mathrm{Cov}(w_k, v_j) = 0, \ \forall k, l$

假设：$Q_k = Q = \mathrm{diag}[\sigma_{\omega 1}{}^2 \quad \cdots \quad \sigma_{\omega N}{}^2]$ $R_k = R = \mathrm{diag}[\sigma_{v1}{}^2 \quad \cdots \quad \sigma_{vN}{}^2]$

二、基于 Kalm

方程1： $\hat{X}_{k,k-1} = A\hat{X}_{k-1,k-1} + Bu_k$

方程2： $P_{k,k-1} = AP_{k-1,k-1}A^T + Q$

Kalman 滤波：状态预测

已知：

- 上一个时刻的状态更新值$\hat{X}_{k-1,k-1}$
- 上一个状态的更新值和真实值之间的误差$P_{k-1,k-1}$：

求解：

- 当前状态的预测值$\hat{X}_{k,k-1}$
- 当前状态的预测值和真实值之间的误差$P_{k,k-1}$：

预测状态：$\hat{X}_{k,k-1} = A\hat{X}_{k-1,k-1} + Bu_k$

$X_k = AX_{k-1} + Bu_k + w_k$

$$X_k - \hat{X}_{k,k-1} = AX_{k-1} + w_k - A\hat{X}_{k-1,k-1} = A\left(X_{k-1} - \hat{X}_{k-1,k-1}\right) + w_k$$

预测协方差矩阵：$P_{k,k-1} = E\left[\left(X_k - \hat{X}_{k,k-1}\right)\left(X_k - \hat{X}_{k,k-1}\right)^T\right]$

$$= E\left[\left(A\left(X_{k-1} - \hat{X}_{k-1,k-1}\right) + w_k\right)\left(A\left(X_{k-1} - \hat{X}_{k-1,k-1}\right) + w_k\right)^T\right]$$

$$= E\left[A\left(X_{k-1} - \hat{X}_{k-1,k-1}\right)\left(X_{k-1} - \hat{X}_{k-1,k-1}\right)^T A^T\right] + E\left[A\left(X_{k-1} - \hat{X}_{k-1,k-1}\right)w_k{}^T\right]$$
$$+ E\left[w_k\left(X_{k-1} - \hat{X}_{k-1,k-1}\right)^T A^T\right] + E[w_k w_k{}^T] = AP_{k-1,k-1}A^T + Q$$

二、基于 Kalman 滤波的信息融合

Kalman 滤波：状态更新

已知：

- 当前预测值$\hat{X}_{k,k-1}$和误差$P_{k,k-1}$
- 当前观测值z_k
- 观测模型$z_k = HX_k + v_k$

求解：

- 融合了预测值和观测值的更新值$\hat{X}_{k,k}$
- 由预测值的估计误差得到更新值得估计误差$P_{k,k}$：

Kalman 增益

利用反馈思想：$\hat{X}_{k,k} = \hat{X}_{k,k-1} + K_g\left(z_k - H\hat{X}_{k,k-1}\right)$ → 残差、新息

$$P_{k,k} = E\left[\left(X_k - \hat{X}_{k,k}\right)\left(X_k - \hat{X}_{k,k}\right)^T\right]$$

$$X_k - \hat{X}_{k,k} = X_k - \hat{X}_{k,k-1} - K_g z_k + K_g H\hat{X}_{k,k-1}$$

$$= X_k - \hat{X}_{k,k-1} - K_g HX_k - K_g v_k + K_g H\hat{X}_{k,k-1}$$

$$= \left(I - K_g H\right)X_k - \left(I - K_g H\right)\hat{X}_{k,k-1} - K_g v_k$$

$$= \left(I - K_g H\right)\left(X_k - \hat{X}_{k,k-1}\right) - K_g v_k$$

二、基于 Ka

方程3：$K_g = P_{k,k-1}H^T\left(HP_{k,k-1}H^T + R\right)^{-1}$

Kalman 滤波：计算增益

$$X_k - \hat{X}_{k,k} = (I - K_g H)(X_k - \hat{X}_{k,k-1}) - K_g v_k$$

$$P_{k,k} = E\left[(X_k - \hat{X}_{k,k})(X_k - \hat{X}_{k,k})^T\right]$$

$$= E\left[\left((I - K_g H)(X_k - \hat{X}_{k,k-1}) - K_g v_k\right)\left((I - K_g H)(X_k - \hat{X}_{k,k-1}) - K_g v_k\right)^T\right]$$

观测噪声与系统噪声独立

$$= (I - K_g H)E\left[(X_k - \hat{X}_{k,k-1})(X_k - \hat{X}_{k,k-1})^T\right](I - K_g H)^T + K_g E[v_k v_k{}^T]K_g{}^T$$

$$= (I - K_g H)P_{k,k-1}(I - K_g H)^T + K_g R K_g{}^T$$

$$= P_{k,k-1} - K_g H P_{k,k-1} - P_{k,k-1}H^T K_g{}^T + K_g H P_{k,k-1}H^T K_g{}^T + K_g R K_g{}^T$$

$$\frac{dP_{k,k}}{dK_g} = -2P_{k,k-1}H^T + 2K_g H P_{k,k-1}H^T + 2K_g R = 0$$

$$K_g = P_{k,k-1}H^T\left(HP_{k,k-1}H^T + R\right)^{-1}$$

二、基于 Ka

方程4：$\hat{X}_{k,k} = \hat{X}_{k,k-1} + K_g\left(z_k - H\hat{X}_{k,k-1}\right)$

Kalman 滤波：更新协方差

方程5：$P_{k,k} = \left(I - K_g H\right)P_{k,k-1}$

$$K_g = P_{k,k-1}H^T\left(HP_{k,k-1}H^T + R\right)^{-1}$$

$$P_{k,k} = P_{k,k-1} - K_g HP_{k,k-1} - P_{k,k-1}H^T K_g{}^T + K_g\left(HP_{k,k-1}H^T + R\right)K_g{}^T$$

$$= P_{k,k-1} - K_g HP_{k,k-1} - P_{k,k-1}H^T K_g{}^T + P_{k,k-1}H^T\left(HP_{k,k-1}H^T + R\right)^{-1}\left(HP_{k,k-1}H^T + R\right)K_g{}^T$$

$$= P_{k,k-1} - K_g HP_{k,k-1} - P_{k,k-1}H^T K_g{}^T + P_{k,k-1}H^T K_g{}^T$$

$$= P_{k,k-1} - K_g HP_{k,k-1}$$

$$= \left(I - K_g H\right)P_{k,k-1}$$

$$\hat{X} \sim N\left(\mu_A + K_g(\mu_B - \mu_A),\ (1 - K_g)\sigma_A{}^2\right)$$

二、基于 Kalman 滤波的信息融合

Kalman 滤波

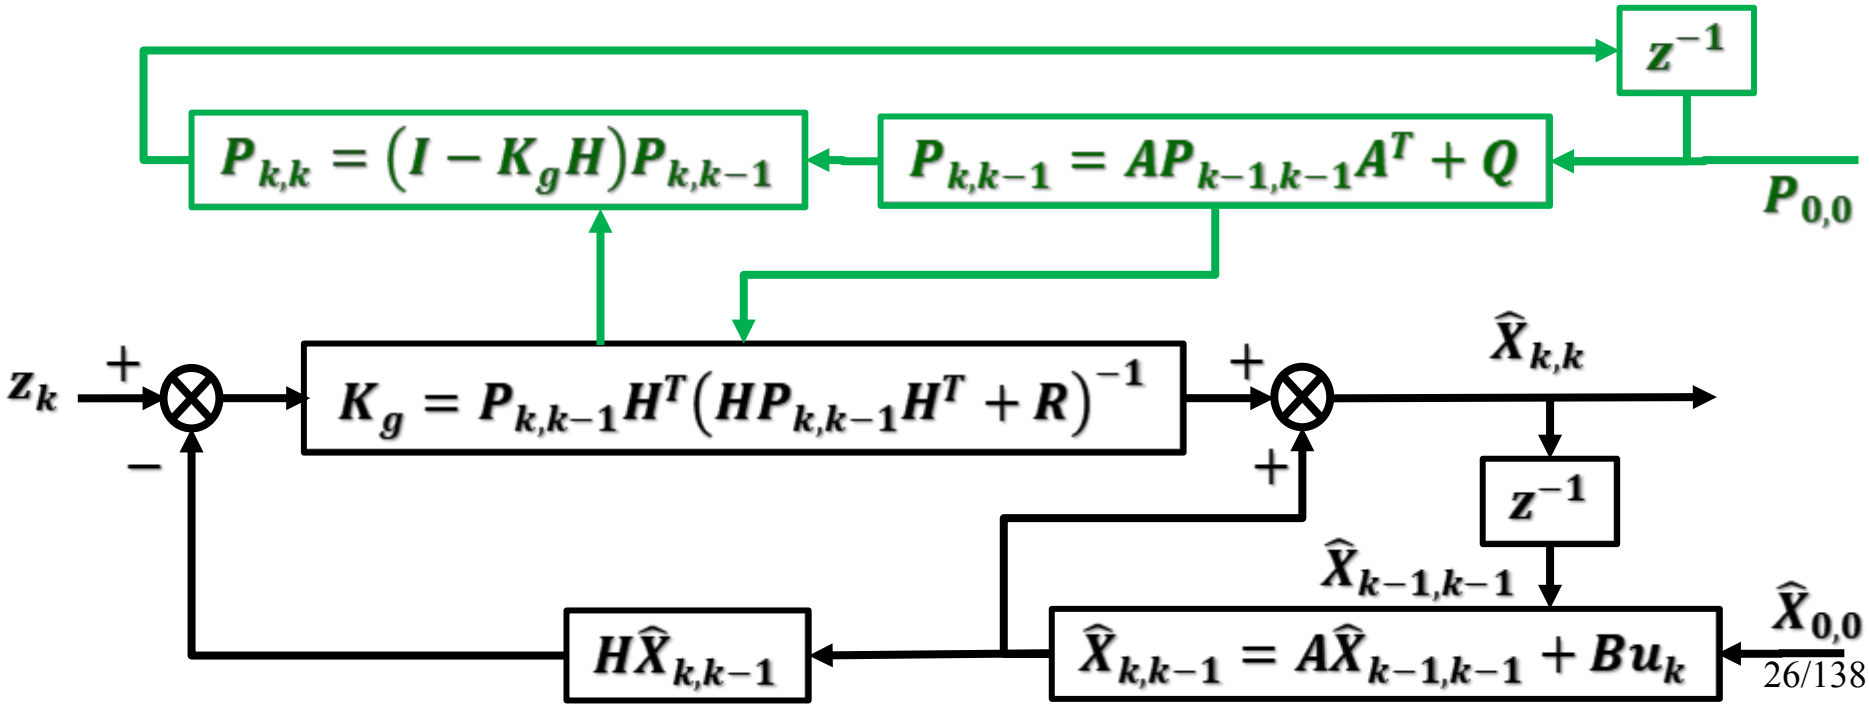
状态预测方程：$\hat{X}_{k,k-1} = A\hat{X}_{k-1,k-1} + Bu_k$

协方差预测方程：$P_{k,k-1} = AP_{k-1,k-1}A^T + Q$

增益计算方程：$K_g = P_{k,k-1}H^T\left(HP_{k,k-1}H^T + R\right)^{-1}$

状态更新方程：$\hat{X}_{k,k} = \hat{X}_{k,k-1} + K_g\left(z_k - H\hat{X}_{k,k-1}\right)$

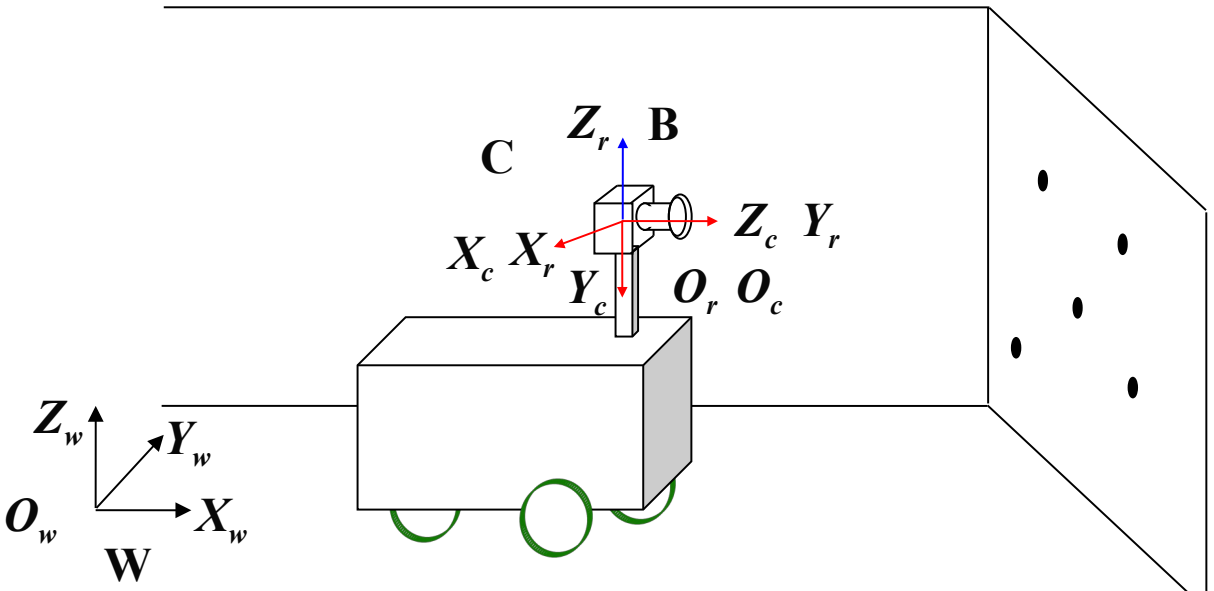
协方差更新方程：$P_{k,k} = \left(I - K_gH\right)P_{k,k-1}$



二、基于 Kalman 滤波的信息融合

示例 1：惯性与视觉定位融合仿真

- 室内移动机器人：工作于平整地面，两轮差动驱动。
- 惯性系统：一个加速度计，一个一维陀螺。
- 标记点： 5 个，在世界坐标系中位置已知。
- 摄像机：内参数已知。

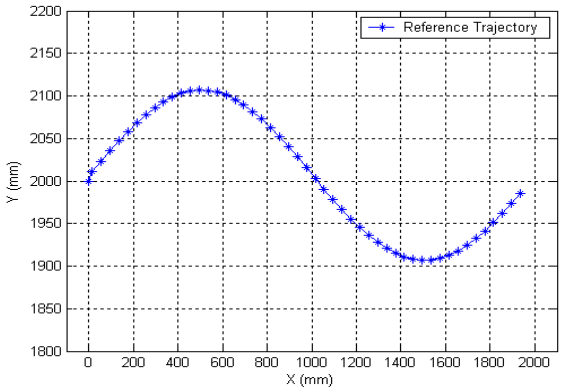


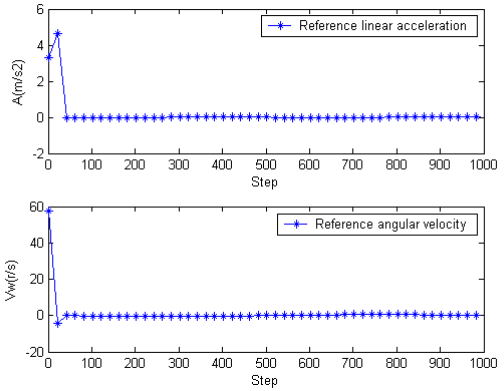
移动机器人仿真系统

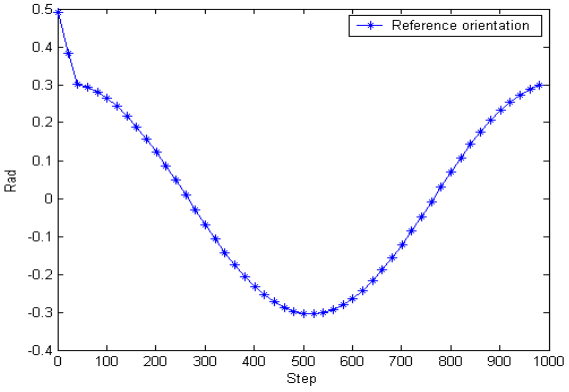
二、基于 Kalman 滤波的信息融合

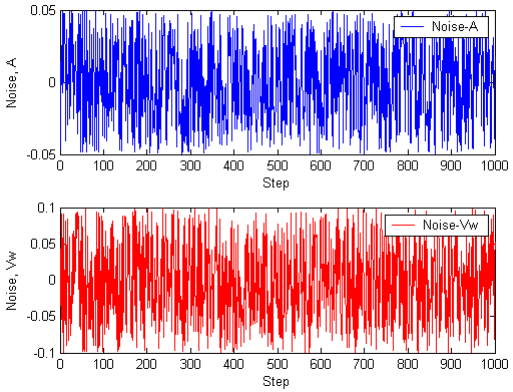
示例 1：仿真的测量数据生成

- 参考轨迹：正弦曲线。
- 惯性传感器数据：如加速度和角速度，根据参考轨迹的 **x(k)** 和 **y(k)** 计算产生。
- 测量值：在计算出的加速度和角速度值上增加零均值随机噪声和固定偏差，作为测量值。
- 图像坐标：根据 **x(k)**、**y(k)** 和 **(k)** 计算摄像机的位姿，结合摄像机内外参数和已知标记点坐标，产生标记点的图像坐标。









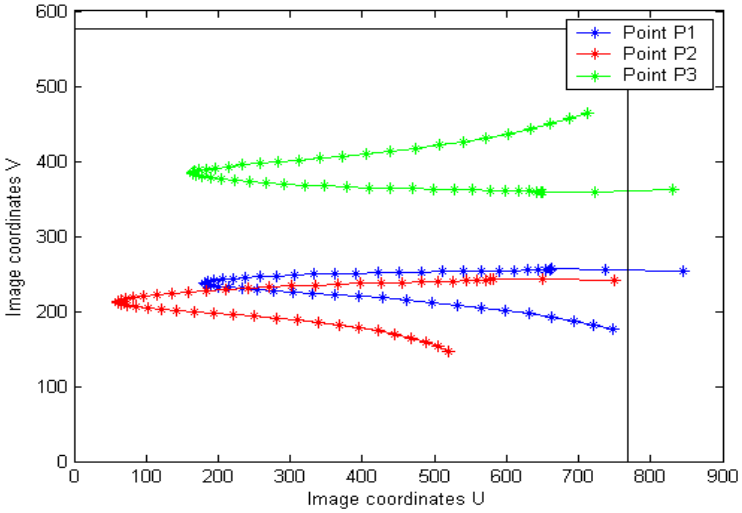
a: 加零均值噪声，方差 8.2831×10^{-4} m/s²，固定偏差 -0.01 m/s²

w: 加零均值噪声，方差 0.0035 rad/s，固定偏差 -0.02 rad/s

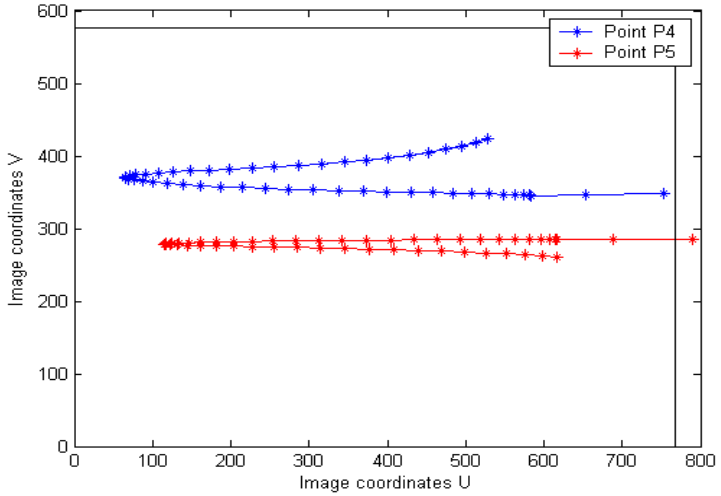
二、基于 Kalman 滤波的信息融合

示例 1：仿真的测量数据生成

$$M_{in} = \begin{bmatrix} 800 & 0 & 350 \\ 0 & 800 & 400 \\ 0 & 0 & 1 \end{bmatrix}$$



$$P = \begin{bmatrix} 3000 & 3000 & 3000 & 3000 & 3000 \\ 1810 & 2080 & 1850 & 2070 & 1960 \\ 650 & 700 & 300 & 340 & 550 \end{bmatrix}$$

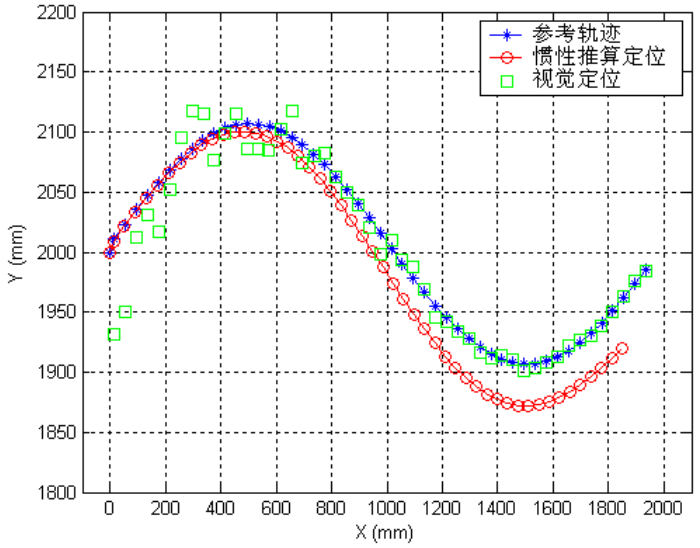


二、基于 Kalman 滤波的信息融合

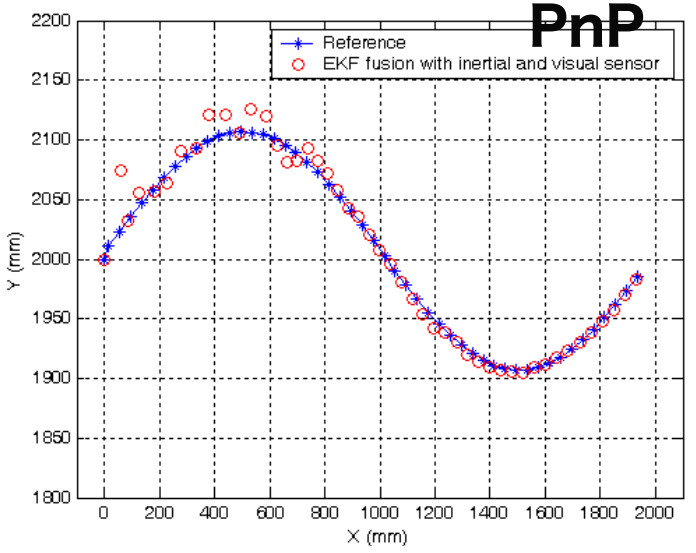
□ EKF 法融合结果

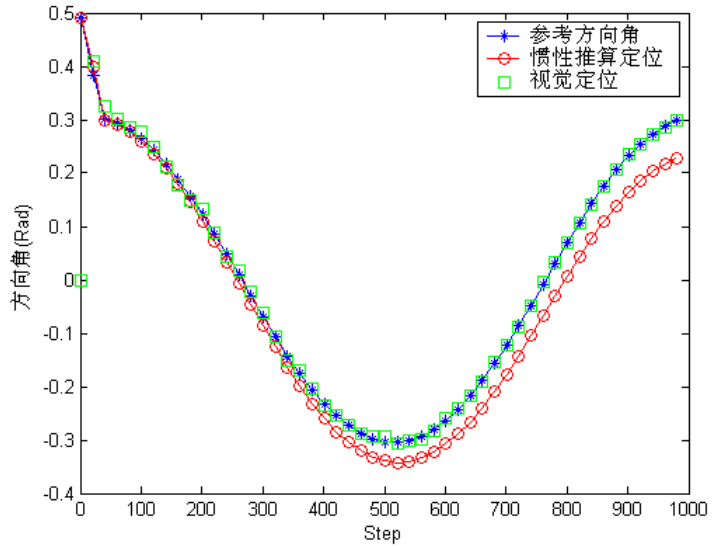
惯性：DR

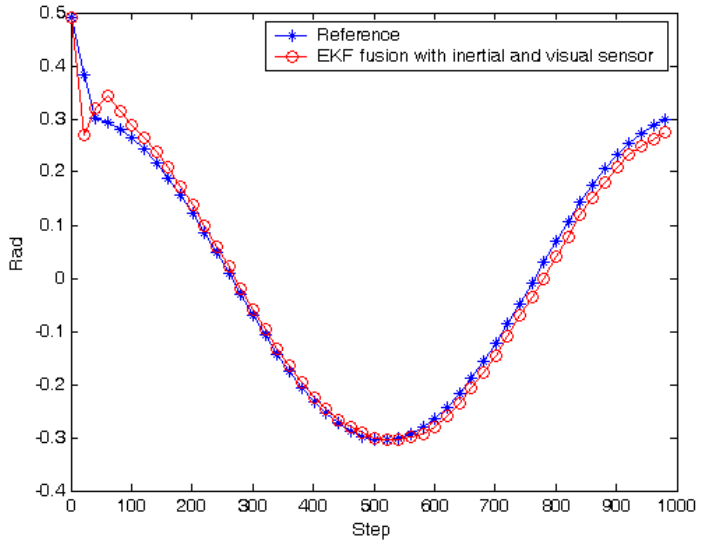
视　觉　：PnP



EKF







二、基于 Kalman 滤波的信息融合

思考

条件 1： 线性系统

条件 2： 系统噪声和观测噪声为高斯白噪声

条件 3： 观测噪声与系统噪声不相关。

思考 1： 系统方程和观测方程存在非线性怎么办?

思考 2： 系统噪声或观测噪声为非零均值的有色噪声怎么办?

$$\mathbf{v}_k = \mathbf{C}\mathbf{v}_{k-1} + \boldsymbol{\gamma},\ \ \boldsymbol{\gamma} \sim N(0, R)$$

三、基于 Bayes 的信息融合

3.1 基于贝叶斯 (Bayes) 估计的传感器融合

定理 设A_1，A_2，…，A_n为样本空间Ω的一个划分，且$P(A_i)>0$，$(i=1,2,\cdots,n)$，则对于任何一事件B $(P(B)>0)$，有

$$P(A_j|B)=\frac{P(A_j)P(B|A_j)}{\sum_{i=1}^{n}P(A_i)P(B|A_i)} \qquad j=1,2,\cdots,n$$

由条件概率的定义及全概率公式

$$P(A_j|B)=\frac{P(A_jB)}{P(B)}=\frac{P(A_j)P(B|A_j)}{P(B)} \qquad P(B)=\sum_{i=1}^{n}P(A_i)P(B|A_i)$$

$$P(A_j|B)=\frac{P(A_j)P(B|A_j)}{\sum_{i=1}^{n}P(A_i)P(B|A_i)}$$

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合

数学符号定义：

Z	传感器观测向量
X	状态向量
$P(Z=z\|X=x)$	传感器观测模型：实际状态为x时传感器输出为z的概率
$P(X=x)$	先验概率
$P(X=x\|Z=z)$	后验概率

根据 Bayes 公式：

$$P(X=x|Z=z)=\frac{P(Z=z|X=x)P(X=x)}{P(Z=z)}$$

$$=\frac{P(Z=z|X=x)P(X=x)}{\int P(Z=z|X=x)P(X=x)dx}$$

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合

两个传感器情况：两传感器独立 $P(X=x|Z_1=z_1,Z_2=z_2)$

$$\hat{x}=\underset{x}{\operatorname{argmax}}\,P(X=x|Z_1=z_1,Z_2=z_2)$$

$$=\underset{x}{\operatorname{argmax}}\,\frac{P(Z_1=z_1,Z_2=z_2|X=x)P(X=x)}{P(Z_1=z_1,Z_2=z_2)}$$

$$=\underset{x}{\operatorname{argmax}}\,P(Z_1=z_1|X=x)P(Z_2=z_2|X=x)P(X=x)$$

$$=\underset{x}{\operatorname{argmax}}\,P(Z_1=z_1|X=x)P(Z_2=z_2|X=x)$$

传感器模型 $P(Z_k=z_k|X=x)$：反应了传感器性能。利用数据统计特征：平均值和测量噪声方差，方差依赖于传感器的测量质量和运行参数。可采用高斯模型表示为：

$$P(Z_k=z_k|X=x)=\frac{1}{\sqrt{2\pi}\sigma_k}e^{-\frac{(z_k-x)^2}{2{\sigma_k}^2}}$$

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合

利用最大似然估计：

$$\hat{x} = \arg\max_{x} P(Z_1 = z_1 | X = x) P(Z_2 = z_2 | X = x)$$

$$L = P(Z_1 = z_1 | X = x) P(Z_2 = z_2 | X = x) = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{(z_1 - x)^2}{2{\sigma_1}^2} - \frac{(z_2 - x)^2}{2{\sigma_2}^2}}$$

$$\ln L = -\frac{(z_1 - x)^2}{2{\sigma_1}^2} - \frac{(z_2 - x)^2}{2{\sigma_2}^2} - \ln 2\pi\sigma_1\sigma_2$$

$$\frac{\partial}{\partial x} \ln L = \frac{z_1 - x}{{\sigma_1}^2} + \frac{z_2 - x}{{\sigma_2}^2} = 0$$

$$\hat{x} = \frac{{\sigma_2}^2}{{\sigma_1}^2 + {\sigma_2}^2} z_1 + \frac{{\sigma_1}^2}{{\sigma_1}^2 + {\sigma_2}^2} z_2$$

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合

$$\hat{x} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} z_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} z_2 = \frac{1}{r^2 + 1} z_1 + \frac{1}{1 + \frac{1}{r^2}} z_2$$

$$r = \frac{\sigma_1}{\sigma_2}$$ 标准方差比

由此可以看出：如果没有测量的先验信息，贝叶斯方法对 2 个传感器进行融合只根据二者之间的标准方差比进行加权平均。2 个高斯分布融合情况下，后验分布为联合高斯分布，均值为$\hat{x}$，标准偏差为：

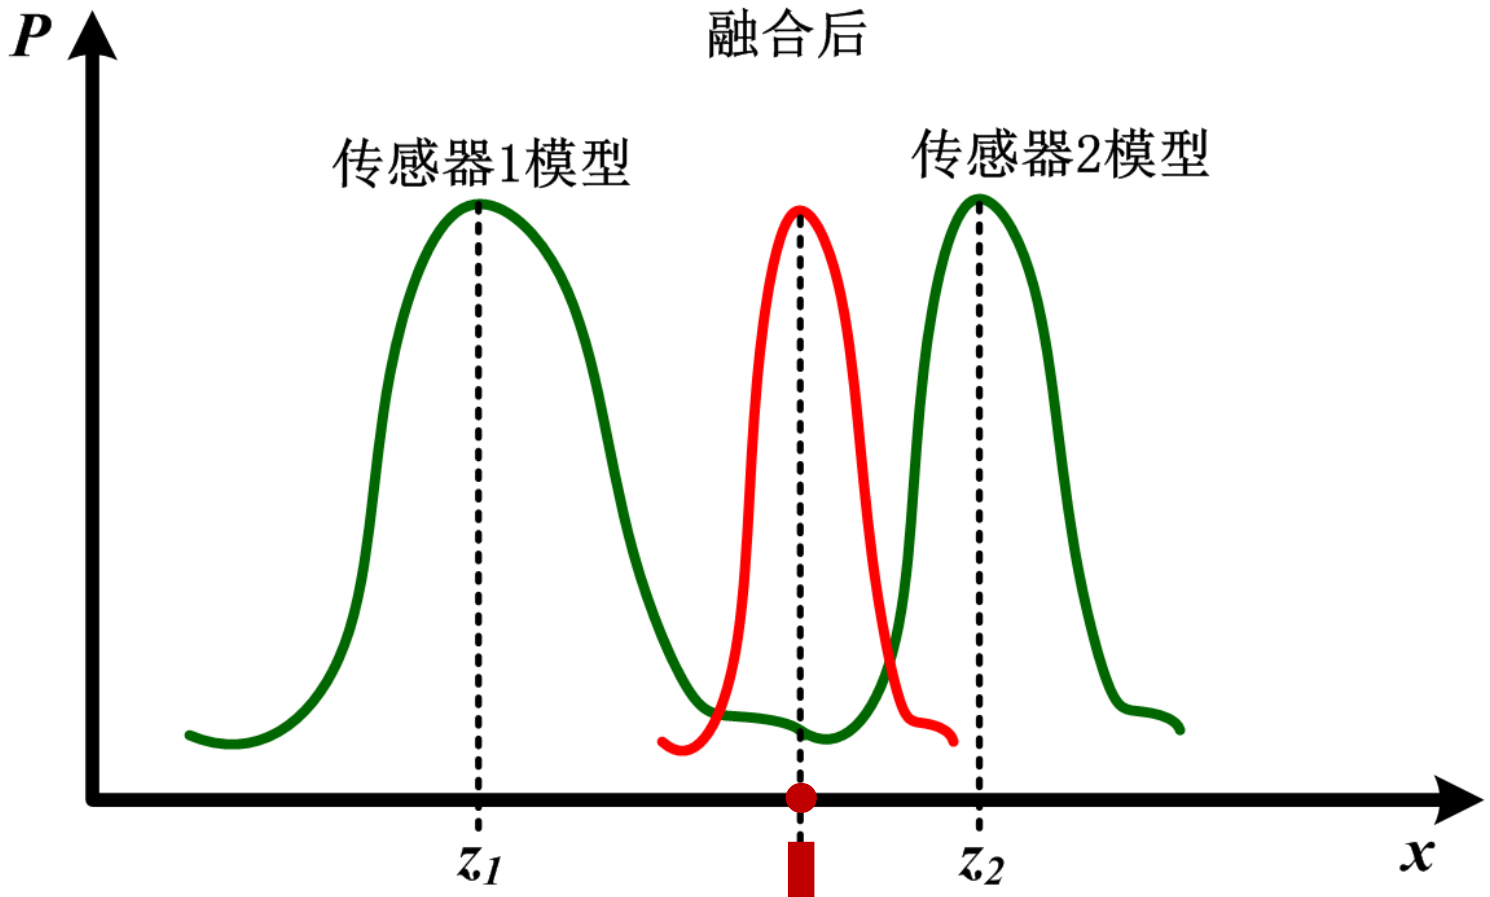
$$\sigma^2 = D(\hat{x}) = \left(\frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}\right)^2 \sigma_1^2 + \left(\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}\right)^2 \sigma_2^2$$

$$= \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

不确定性减小！

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合



$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

$$\hat{x} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} z_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} z_2$$

三、基于 Bayes 的信息融合

3.1 基于 Bayes 估计的传感器融合

$$\hat{x} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} z_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} z_2 \qquad \sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

$$= z_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}(z_2 - z_1) \qquad = \sigma_1^2 \left(1 - \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}\right)$$

$$= z_1 + k(z_2 - z_1) \qquad = \sigma_1^2 (1 - k)$$

利用z_1作为预测，z_2作为观测，$z_2 - z_1$为新息，k为新息增益，与Kalman滤波在本质上具有异曲同工之妙！

三、基于 Bayes 的信息融合

3.2 基于 Bayes 滤波的机器人融合定位

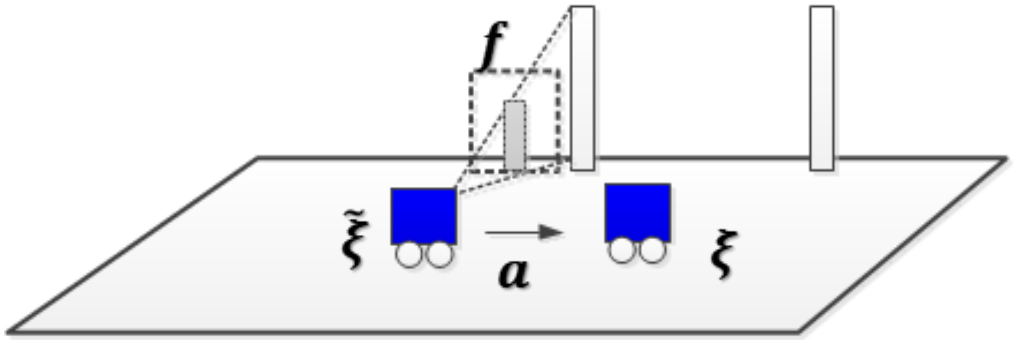
贝叶斯滤波：从贝叶斯理论的观点来看，状态估计问题（目标跟踪、信号滤波）就是根据之前一系列的**已有数据**$y_{1:k}$ **（后验知识）**递推地计算出当前状态x_k **的可信度**。这个可信度就是概率公式$p(x_k|y_{1:k})$，它需要通过预测和更新两个步骤进行递推计算：

- **预测过程**：利用系统模型(状态方程)预测状态先验概率密度，即通过已有的先验知识对未来的状态进行猜测，即$p(x_k|x_{k-1})$。
- **更新过程**：利用最新的测量值对先验概率密度进行修正，得到后验概率密度，也就是对之前的猜测进行修正$p(x_k|y_{1:k})$。

三、基于 Bayes 的信息融合

3.2 基于 Bayes 滤波的机器人融合定位

数学符号定义：



ξ 机器人位置

f 机器人观测特征

a 机器人动作

$Bel(\xi)$ 机器人在位置 的置信度

$P(\xi|\tilde{\xi},a)$ 状态转移概率：在执行动作a∈A后机器人由位置$\tilde{\xi}$转移到ξ 的概率

$P(f|\xi)$ 环境地图表征概率：在位置 处能够观测到特征 f 的概率

Sebastian Thrun, Bayesian Landmark Learning for Mobile Robot Localization, Machine Learning, vol.33, no.1, pp. 41-76, 1998. cited 181

三、基于 Bayes 的信息融合

3.2 基于 Bayes 滤波的机器人融合定位

融合定位问题描述：$Bel(\xi^{(t)}) = P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)}, f^{(t)})$

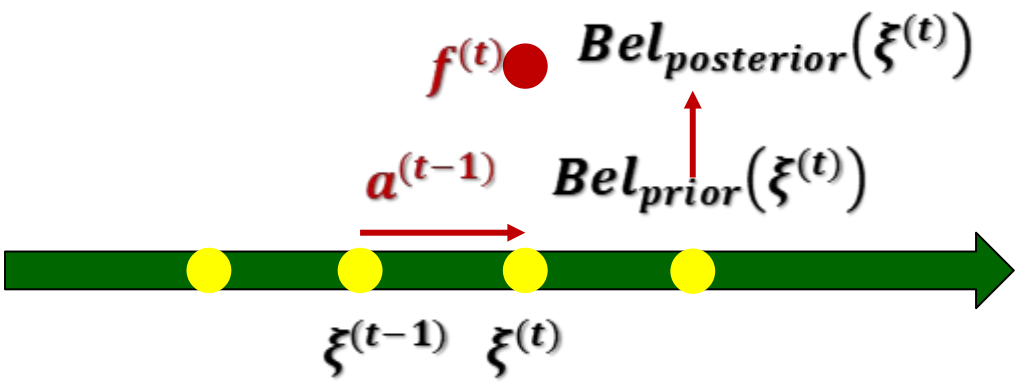
机器人在执行 t-1 个动作后，如何确定 t 时刻的定位先验概率？

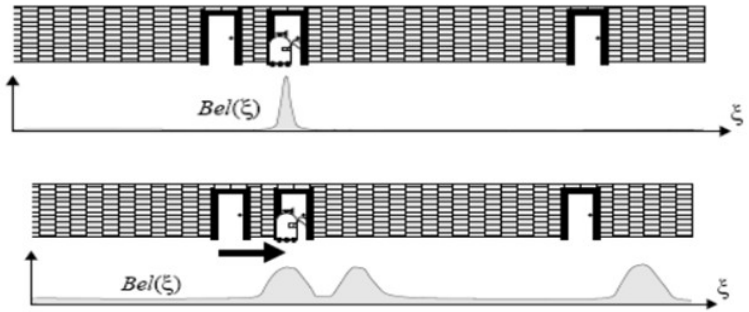
$$Bel_{prior}(\xi^{(t)}) = P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})$$

机器人在第 t 时刻观测数据后，如何更新其定位后验概率？

$$Bel_{posterior}(\xi^{(t)}) = P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)}, f^{(t)})$$

反复更新迭代





$$Bel_{posterior}(\xi^{(t)}) = \frac{P(f^{(t)}|\xi^{(t)})Bel_{prior}(\xi^{(t)})}{\int P(f^{(t)}|\xi^{(t)})Bel_{prior}(\xi^{(t)})d\xi^{(t)}}$$

3.2 基于Bayes滤波的机器人融合定位 $\xi^{(t)}$

在当前位置$\xi^{(t)}$得到传感器数据$f^{(t)}$后由先验概率更新$\xi^{(t)}$的后验概率:

$$Bel_{posterior}(\xi^{(t)}) = P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)}, f^{(t)})$$

$$= \frac{P(f^{(t)}|\xi^{(t)}, f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})}{P(f^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})}$$

传感器当前的测量值仅依赖于当前观测位置

项1：
$$P(f^{(t)}|\xi^{(t)}, f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)}) = P(f^{(t)}|\xi^{(t)})$$

项2：
$$Bel_{prior}(\xi^{(t)}) = P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})$$

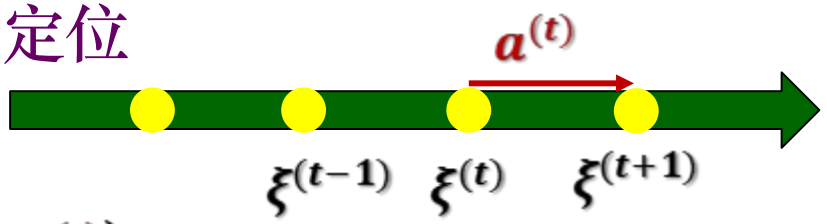
项3：
$$P(f^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})$$

$$= \int P(f^{(t)}|\xi^{(t)})P(\xi^{(t)}|f^{(1)}, a^{(1)}, f^{(2)}, a^{(2)}, \cdots, f^{(t-1)}, a^{(t-1)})d\xi^{(t)}$$

$$= \int P(f^{(t)}|\xi^{(t)})Bel_{prior}(\xi^{(t)})d\xi^{(t)}$$

三、基于 Bayes 的信息融合

3.2 基于 Bayes 滤波的机器人融合定位



执行动作后更新下一时刻的先验概率

$$Bel_{prior}\left(\xi^{(t+1)}\right) = P\left(\xi^{(t+1)}|f^{(1)},a^{(1)},\cdots,f^{(t)},a^{(t)}\right)$$

$$= \int P\left(\xi^{(t+1)},\xi^{(t)}|f^{(1)},a^{(1)},\cdots,f^{(t)},a^{(t)}\right)d\xi^{(t)}$$

$$= \int P\left(\xi^{(t+1)}|\xi^{(t)},f^{(1)},a^{(1)},\cdots,f^{(t)},a^{(t)}\right)P\left(\xi^{(t)}|f^{(1)},a^{(1)},\cdots,f^{(t)},a^{(t)}\right)d\xi^{(t)}$$

Markov过程：$\xi^{(t+1)}$只取决于$\xi^{(t)}$和$a^{(t)}$

$\xi^{(t)}$与动作$a^{(t)}$无关

$$Bel_{prior}\left(\xi^{(t+1)}\right) = \int P\left(\xi^{(t+1)}|\xi^{(t)},a^{(t)}\right)P\left(\xi^{(t)}|f^{(1)},a^{(1)},\cdots,f^{(t)}\right)d\xi^{(t)}$$

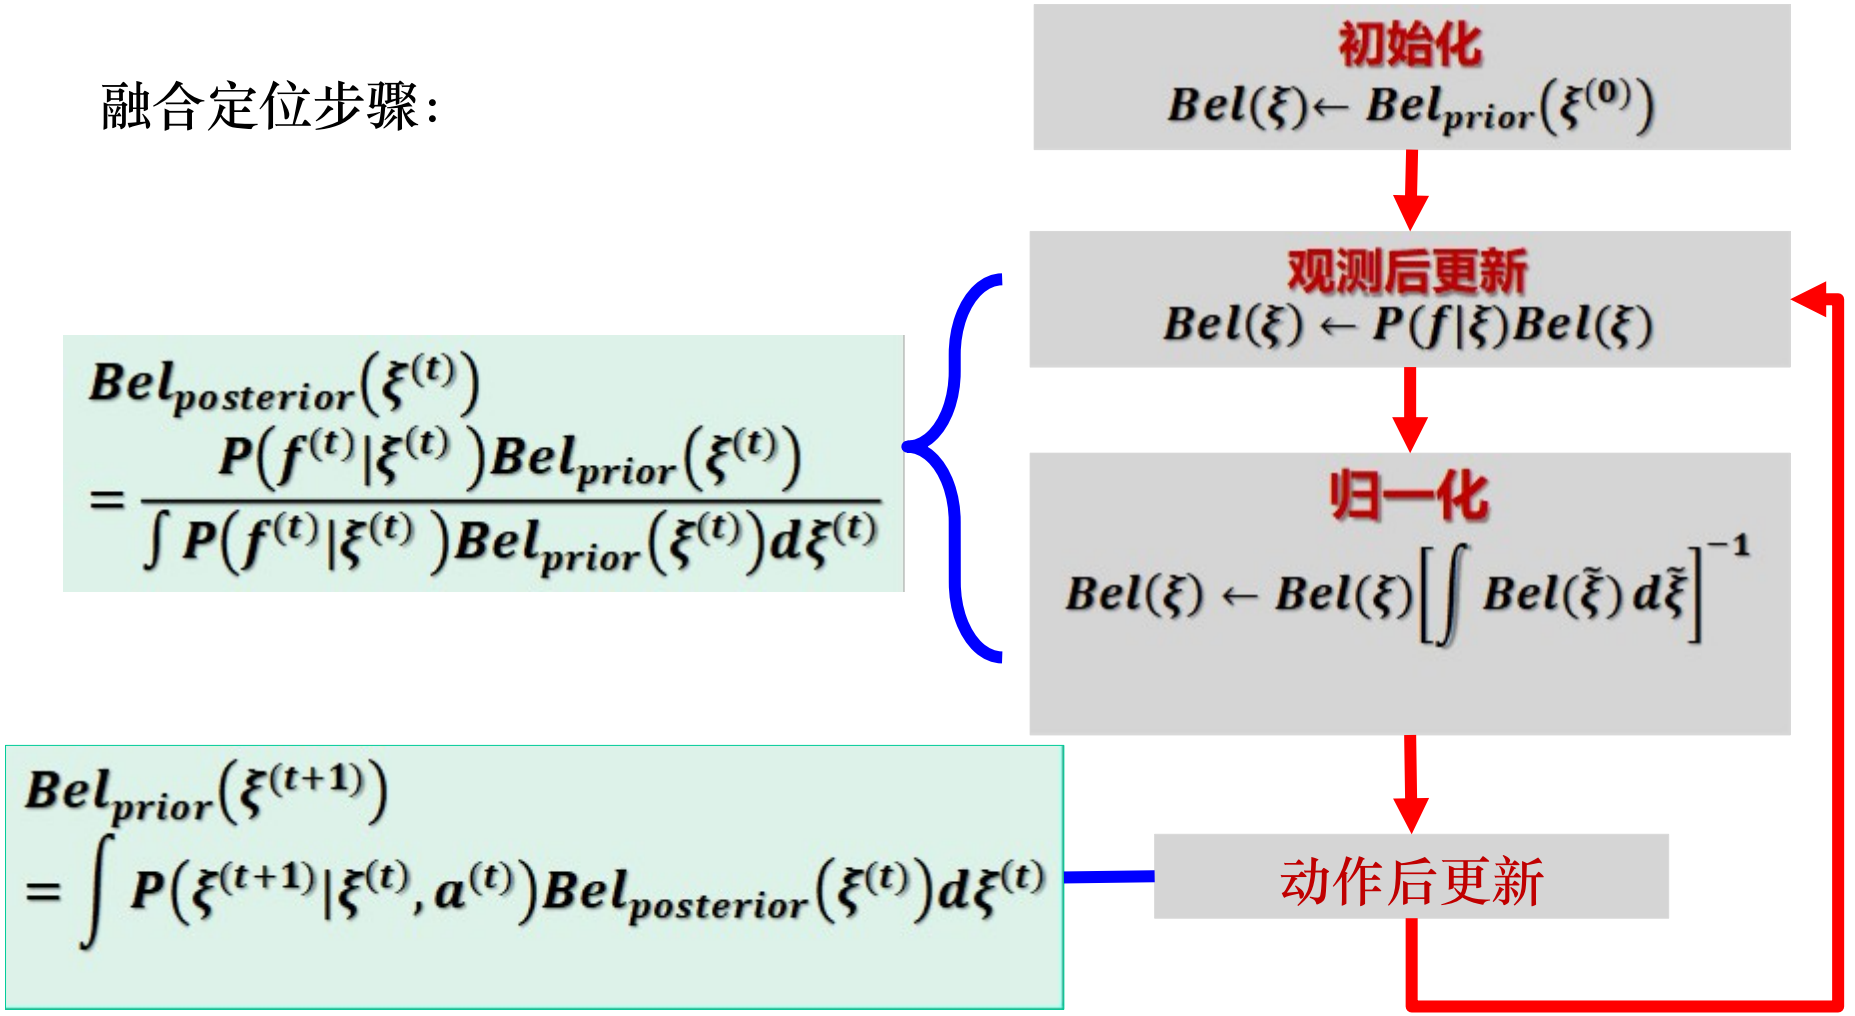
$$= \int P\left(\xi^{(t+1)}|\xi^{(t)},a^{(t)}\right)Bel_{posterior}\left(\xi^{(t)}\right)d\xi^{(t)}$$

$$Bel_{prior}\left(\xi^{(t+1)}\right) = \int P\left(\xi^{(t+1)}|\xi^{(t)},a^{(t)}\right)Bel_{posterior}\left(\xi^{(t)}\right)d\xi^{(t)}$$

三、基于 Bayes 的信息融合

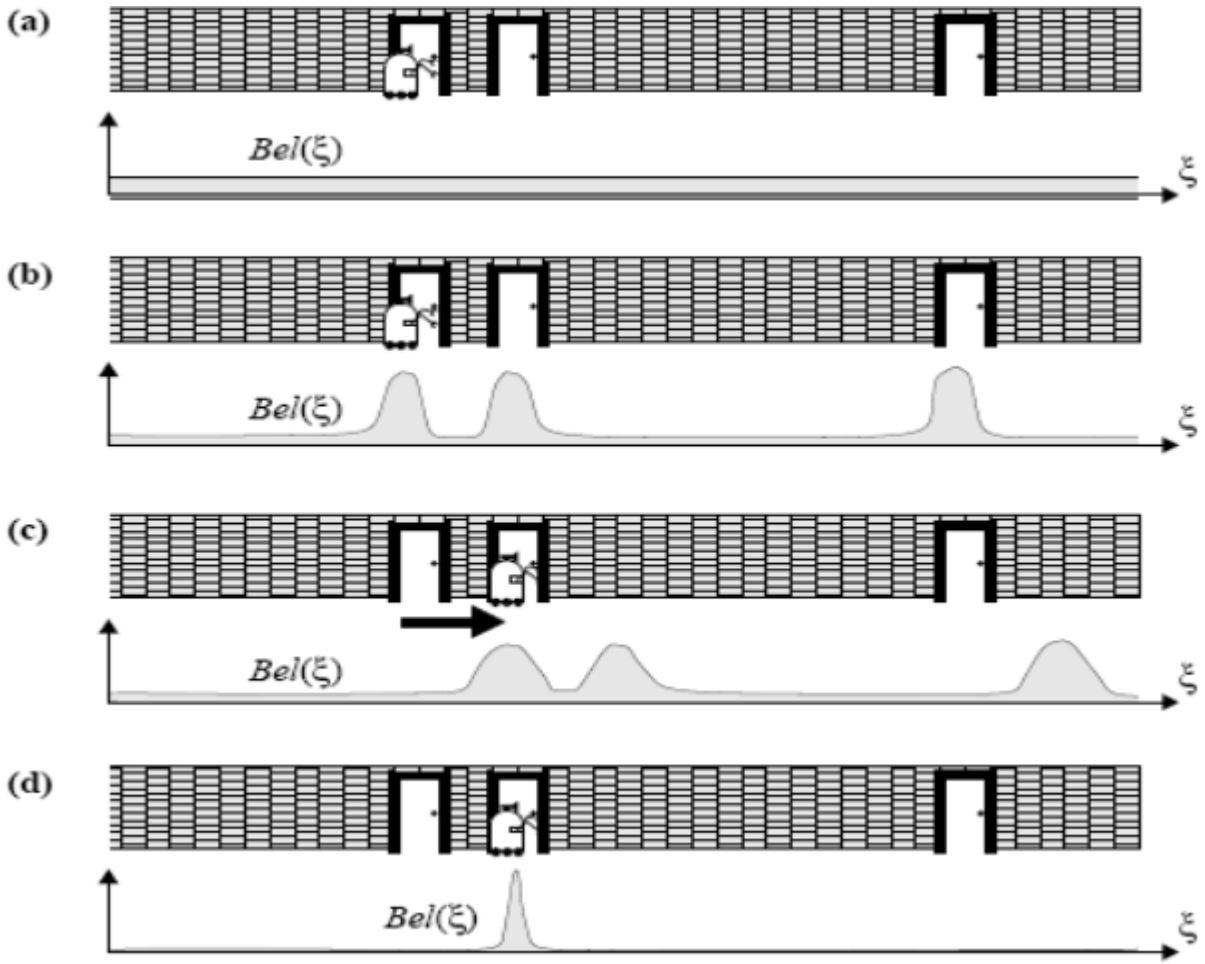
3.2 基于 Bayes 滤波的机器人融合定位

融合定位步骤：



三、基于 Bayes 的信息融合

3.2 基于 Bayes 滤波的机器人融合定位



初始情况：机器人一无所知，均匀分布

观测到第一个门：三个门附近位置的置信度提升

移动 1m：更新后位置置信度随动作而更新

观察到第 2 个门：更新后能够确定出哪个门，因此该门附近位置的置信度大幅提升

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）：通俗示例

1）初始化：提取跟踪目标特征：闻闻

贼衣服上的味道

2）搜索：放狗。

- 均匀放：即在整个空间中均匀撒粒子，将狗均匀放到城区里
- 在以前目标经常出现的附近按照高斯分布来放。

3）观测：每个狗闻闻所经过每个人的味道，计算相似度发给警务中心；

4）决策：中心根据所有狗测得的相似度和当前位置信息进行加权平均确定目标位置。

4）重采样：在相似度最高的狗那里放更多条狗，在相似度最低的狗那里少放狗，甚至撤回



相似度是
0.013



相似度是
0.005



相似度是
0.3





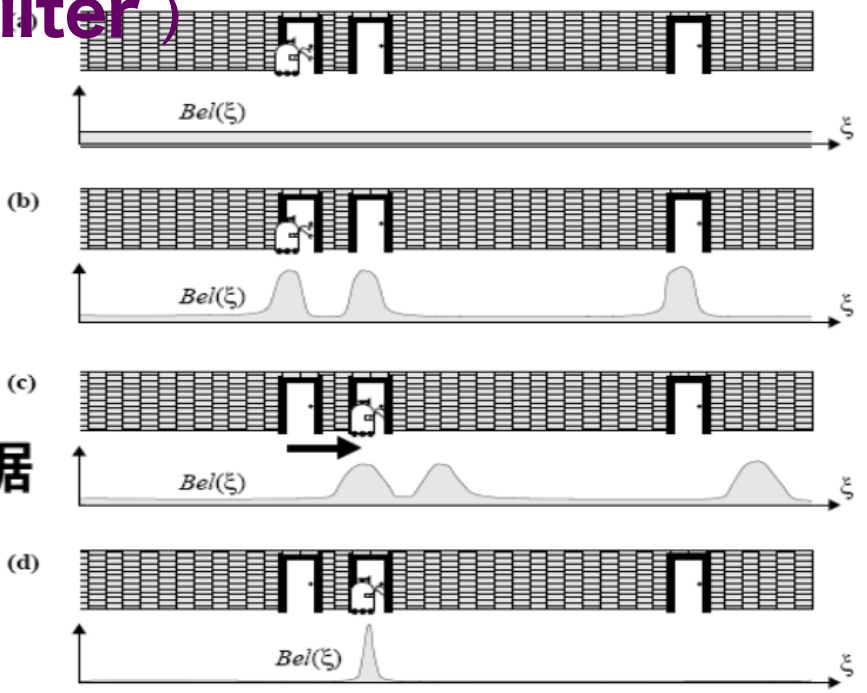
相似度是
0.02



相似度是
0.0002

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）



x_k：k时刻系统状态

y_k：k时刻观测数据

$X_k = x_{1:k}$：1到k时刻所有的系统状态数据

$Y_k = y_{1:k}$：1到k时刻所有的观测数据

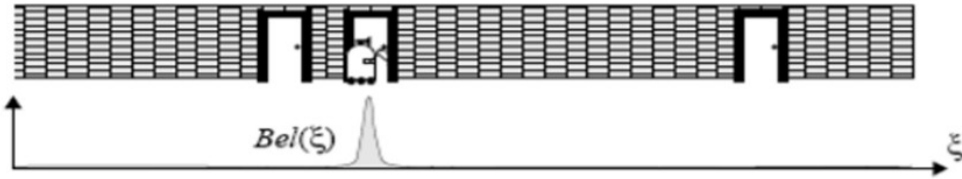
$f(x_k)$：关于k时刻系统状态的某个函数

$p(x_k|x_{k-1})$：系统状态转移概率

$p(y_k|x_k)$：观测模型，系统状态为x_k时观测量为y_k的概率

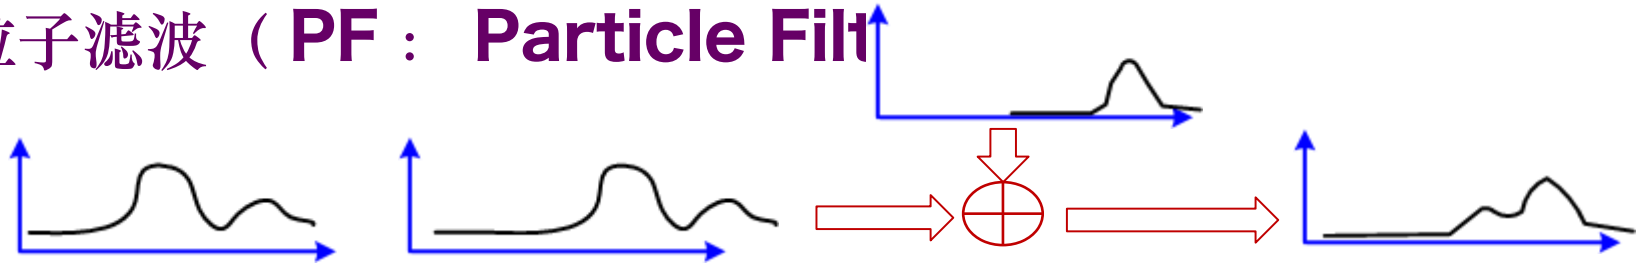
$p(x_k|y_{1:k})$：得到1到k时刻所有的观测数据后k时刻系统状态x_k的后验概率

三、基于 Bay



3.3 粒子滤波（PF： Particle Filt

- 目的



$p(x_{k-1}|y_{1:k-1})$ → $p(x_k|x_{1:k-1})$ → $p(y_k|x_{1:k})$ → $p(x_k|y_{1:k})$

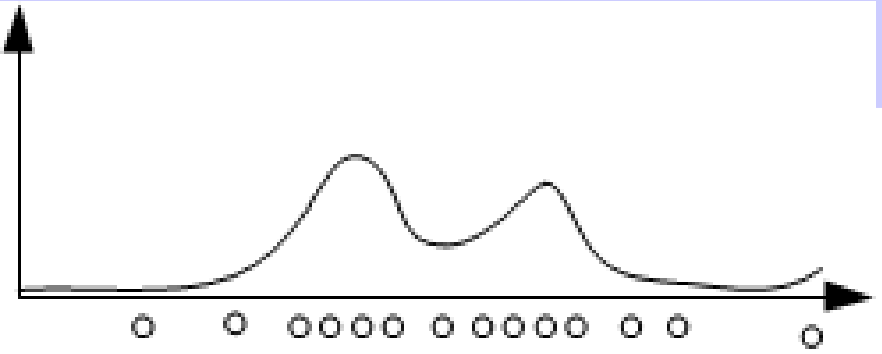
x_{k-1}后验　　x_k先验 状态转移　　观测到y_k　　x_k后验

得到一个确定的状态x_k估计，或者状态x_k某个函数$f(x_k)$的估计

$$\mathrm{E}[f(x_k)] = \int_a^b f(x_k)\, p(x_k|y_{1:k})\mathrm{d}x_k$$

积分难计算	$p(x_k\|y_{1:k})$不知道	粒子权重更新麻烦
蒙特卡洛采样	重要性采样	序贯采样
$\mathrm{E}[f(x_k)] = \frac{1}{N}\sum_{i=1}^{N} f(x_k^{(i)})$	$E[f(x_k)] = \sum_{i=1}^{N} \widetilde{W}_k(x_k^{(i)}) f(x_k^{(i)})$	$w_k^{(i)} = w_{k-1}^{(i)} p(y_k\|x_k^{(i)})$

三、基于 Baye



3.3 粒子滤波（PF： Particle F

□ 蒙特卡洛 (Monto Carlo) 采样

从后验概率分布$p(x_k|y_{1:k})$中采样得到N个样本（粒子）：$x_k^{(1)},\cdots,x_k^{(N)}$，利用这些样本去估计这个分布的某些函数$f(x_k)$的期望值

$$\mathrm{E}[f(x_k)] = \int_a^b f(x_k)\, p(x_k|y_{1:k})\mathrm{d}x_k$$

蒙特卡洛采样的基本思想：利用平均值代替积分求期望

$$\hat{p}(x_k|y_{1:k}) = \frac{1}{N}\sum_{i=1}^{N}\delta(x_k - x_k^{(i)})$$

$$\mathrm{E}[f(x_k)] \approx \int_a^b f(x_k)\, \hat{p}(x_k|y_{1:k})\mathrm{d}x_k$$

$$= \frac{1}{N}\sum_{i=1}^{N}\int_a^b f(x_k)\,\delta(x_k - x_k^{(i)})\mathrm{d}x_k = \frac{1}{N}\sum_{i=1}^{N} f(x_k^{(i)})$$

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

□ 重要性采样

问题： 后验概率分布$p(x_k|y_{1:k})$不知道，无法从后验概率分布中采样！

解决： 引入一个已知的**重要性概率密度分布**$q(x_k|y_{1:k})$进行采样

$$E[f(x_k)] = \int f(x_k)p(x_k|y_{1:k})dx_k = \int f(x_k)\frac{p(x_k|y_{1:k})}{q(x_k|y_{1:k})}q(x_k|y_{1:k})dx_k$$

$$= \int f(x_k)\frac{p(y_{1:k}|x_k)p(x_k)}{p(y_{1:k})q(x_k|y_{1:k})}q(x_k|y_{1:k})dx_k = \int f(x_k)\frac{W_k(x_k)}{p(y_{1:k})}q(x_k|y_{1:k})dx_k$$

$$= \frac{\int f(x_k)W_k(x_k)q(x_k|y_{1:k})dx_k}{\int p(y_{1:k}|x_k)p(x_k)dx_k}$$

$$W_k(x_k) = \frac{p(y_{1:k}|x_k)p(x_k)}{q(x_k|y_{1:k})} \propto \frac{p(x_k|y_{1:k})}{q(x_k|y_{1:k})}$$

$$= \frac{\int f(x_k)W_k(x_k)q(x_k|y_{1:k})dx_k}{\int W_k(x_k)q(x_k|y_{1:k})dx_k} = \frac{E_{q(x_k|y_{1:k})}[f(x_k)W_k(x_k)]}{E_{q(x_k|y_{1:k})}[W_k(x_k)]}$$

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

□ 重要性采样

$$E[f(x_k)] = \frac{E_{q(x_k|y_{1:k})}[f(x_k)W_k(x_k)]}{E_{q(x_k|y_{1:k})}[W_k(x_k)]}$$

积分利用蒙特卡洛通过采样进行计算：
采样所依赖的分布为：$q(x_k|y_{1:k})$

$$\widetilde{W}_k(x_k^{(i)}) = \frac{W_k(x_k^{(i)})}{\sum_{i=1}^{N} W_k(x_k^{(i)})}$$

$$E[f(x_k)] \approx \frac{\frac{1}{N}\sum_{i=1}^{N} W_k(x_k^{(i)}) f(x_k^{(i)})}{\frac{1}{N}\sum_{i=1}^{N} W_k(x_k^{(i)})} = \sum_{i=1}^{N} \widetilde{W}_k(x_k^{(i)}) f(x_k^{(i)})$$

$$E[f(x_k)] \approx \frac{1}{N}\sum_{i=1}^{N} f(x_k^{(i)})$$

- 粒子采样体现了分布$q(x_k|y_{1:k})$
- 所有粒子的加权和，粒子权重$\widetilde{W}_k(x_k^{(i)})$用于表明粒子的信任度。

三、基于 Bayes 的估

$$W_k(x_k) \propto \frac{p(x_k|y_{1:k})}{q(x_k|y_{1:k})}$$

3.3 粒子滤波（PF： Particle F

$$W_k(x_k) \propto \frac{p(x_{0:k}|y_{1:k})}{q(x_{0:k}|y_{1:k})} = \frac{p(X_k|Y_k)}{q(X_k|Y_k)}$$

- 序贯采样：利用迭代方式更新权重

假设重要性概率密度函数选择为$q(x_{0:k}|y_{1:k})$，即为过去所有时刻的状态后验，

利用Y_k表示$y_{1:k}$，X_k表示$x_{0:k}$

$$p(X_k|Y_k) = p(X_k|Y_{k-1}, y_k) = \frac{p(X_k, y_k|Y_{k-1})}{p(y_k|Y_{k-1})}$$

$$= \frac{p(y_k|X_k, Y_{k-1})p(X_k|Y_{k-1})}{p(y_k|Y_{k-1})}$$

$$= \frac{p(y_k|X_k, Y_{k-1})p(X_{k-1}, x_k|Y_{k-1})}{p(y_k|Y_{k-1})}$$

$$= \frac{p(y_k|X_k, Y_{k-1})p(x_k|X_{k-1}, Y_{k-1})p(X_{k-1}|Y_{k-1})}{p(y_k|Y_{k-1})}$$

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

- 序贯采样：利用迭代方式更新权重

k时刻的观测只取决于k时刻状态

$$p(y_k|X_k, Y_{k-1}) = p(y_k|X_k) = p(y_k|x_k)$$

Markov过程：k时刻状态只取决于k-1时刻状态：

$$p(x_k|X_{k-1}, Y_{k-1}) = p(x_k|X_{k-1}) = p(x_k|x_{k-1})$$

$$p(X_k|Y_k) = \frac{p(y_k|X_k, Y_{k-1})\,p(x_k|X_{k-1}, Y_{k-1})\,p(X_{k-1}|Y_{k-1})}{p(y_k|Y_{k-1})}$$

与状态无关，归一化因子

$$= \frac{p(y_k|x_k)\,p(x_k|x_{k-1})\,p(X_{k-1}|Y_{k-1})}{p(y_k|Y_{k-1})}$$

$$\propto p(y_k|x_k)\,p(x_k|x_{k-1})\,p(X_{k-1}|Y_{k-1})$$

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle F

$$W_k(x_k) \propto \frac{p(x_{0:k}|y_{1:k})}{q(x_{0:k}|y_{1:k})} = \frac{p(X_k|Y_k)}{q(X_k|Y_k)}$$

- 序贯采样：利用迭代方式更新权重

$$p(X_k|Y_k) \propto p(y_k|x_k)p(x_k|x_{k-1})p(X_{k-1}|Y_{k-1})$$

第 i 个粒子权重：

$$w_k^{(i)} \propto \frac{p(X_k^{(i)}|Y_k)}{q(X_k^{(i)}|Y_k)} = \frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})p(X_{k-1}^{(i)}|Y_{k-1})}{q(x_k^{(i)}|X_{k-1}^{(i)},Y_k)q(X_{k-1}^{(i)}|Y_{k-1})}$$

why not Y_k?

$$= w_{k-1}^{(i)} \frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{q(x_k^{(i)}|X_{k-1}^{(i)},Y_k)}$$

传感器观测模型

$$w_k^{(i)} = w_{k-1}^{(i)} \frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{q(x_k^{(i)}|X_{k-1}^{(i)},Y_k)}$$

系统模型：状态转移

自己选择的已知分布

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

□ 重要性概率密度分布$q(x_k|y_{1:k})$的选择

选取重要性函数准则是使重要性权重的方差最小。 Liu 等证明：

$$var_{q(x_k|X_{k-1},Y_k)}[w_k^{(i)}] = (w_{k-1}^{(i)})^2\left[\int\left(\frac{p(y_k|x_k)p(x_k|x_{k-1}^{(i)})}{q(x_k|X_{k-1}^{(i)},Y_k)}\right)^2 dx_k - p^2(y_k|x_{k-1}^{(i)})\right]$$

最优重要性函数 $q(x_k|X_{k-1},Y_k) = p(x_k|X_{k-1},Y_k)$

为

又回到引入重要性概率密度分布 q 的原点，后验概率 p 不知道啊

选择次优重要性函数：$q(x_k|X_{k-1},Y_k) = p(x_k|X_{k-1}) = p(x_k|x_{k-1})$

先验概率

系统模型决定

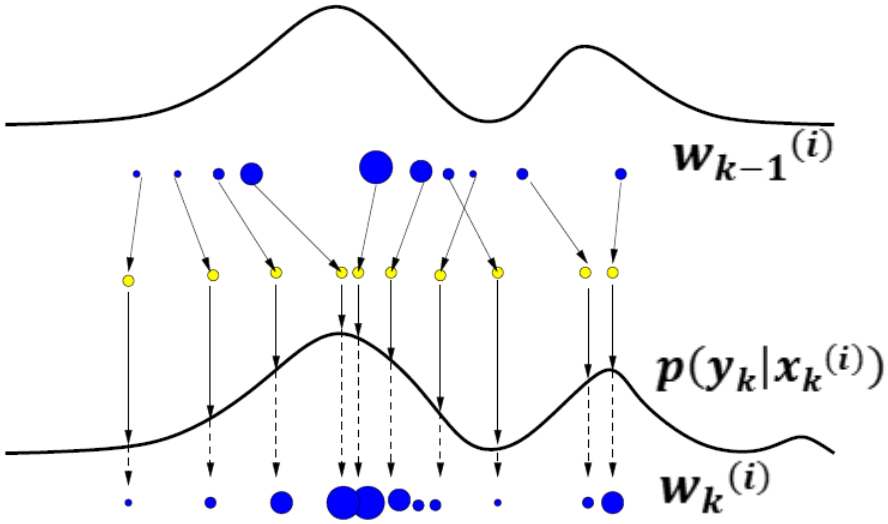
此时权重更新：$w_k^{(i)} = w_{k-1}^{(i)}\frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{q(x_k^{(i)}|X_{k-1}^{(i)},Y_k)} = w_{k-1}^{(i)}p(y_k|x_k^{(i)})$

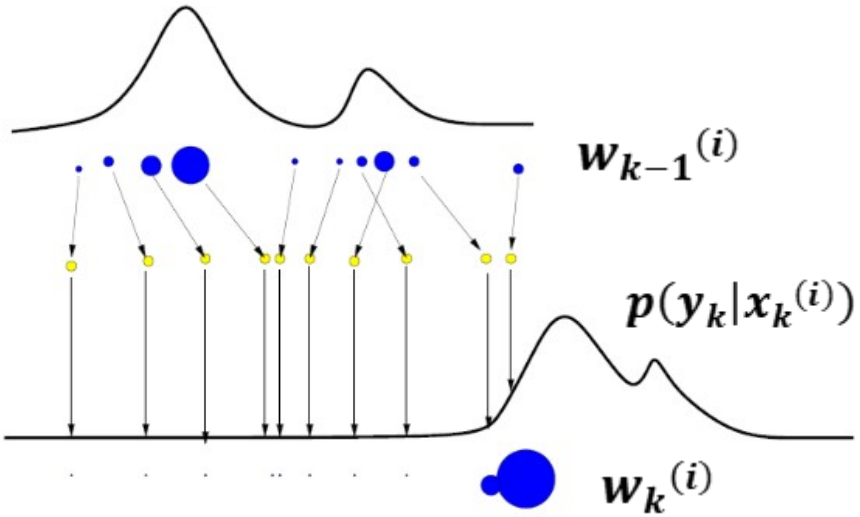
三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

- 重采样：解决粒子退化问题

粒子退化问题：几次迭代后，很多粒子权重都变得很小，粒子权值方差增大，状态空间中有效粒子数较少。大量计算浪费在对估计后验概率几乎无效的粒子上。





有效粒子评估：当有效粒子小于一定数量时需要进行重采样。

$$N_{eff} = \frac{N}{1 + var(w_k^{(i)})}$$

难计算

$$\hat{N}_{eff} \approx \frac{1}{\sum_{i=1}^{N} (w_k^{(i)})^2}$$

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）

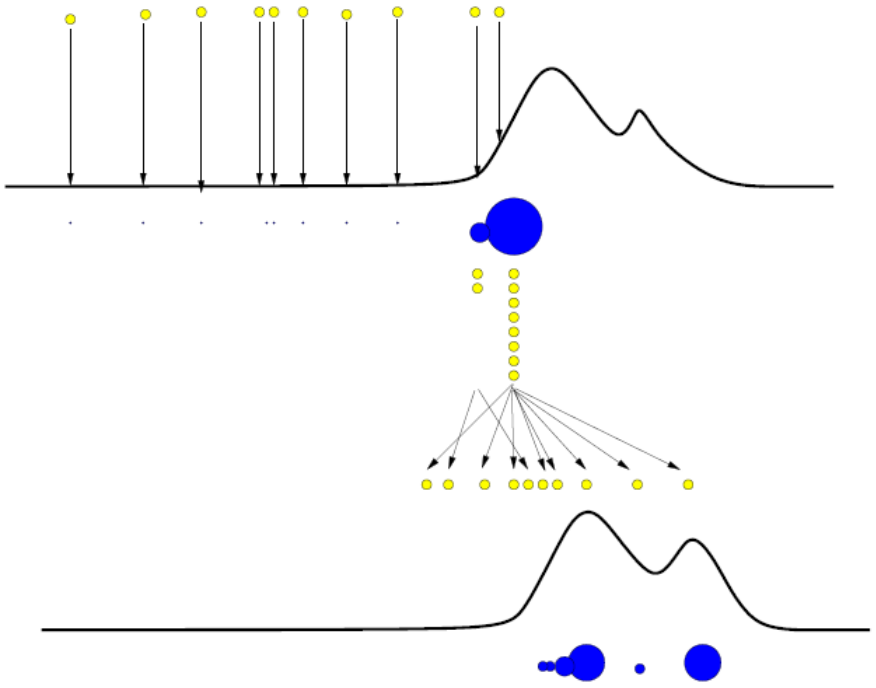
- 重采样：解决粒子退化问题

重采样策略：保持粒子数目不变，抛弃权重小的粒子，复制权重大的粒子，每个粒子复制数量根据自己权重所占的比例进行分配。

$$\tilde{p}(x_k|y_{1:k}) = \sum_{j=1}^{N} \frac{1}{N} \delta(x_k - x_k^{(j)})$$

粒子$x_k^{(i)}$被复制n_i次

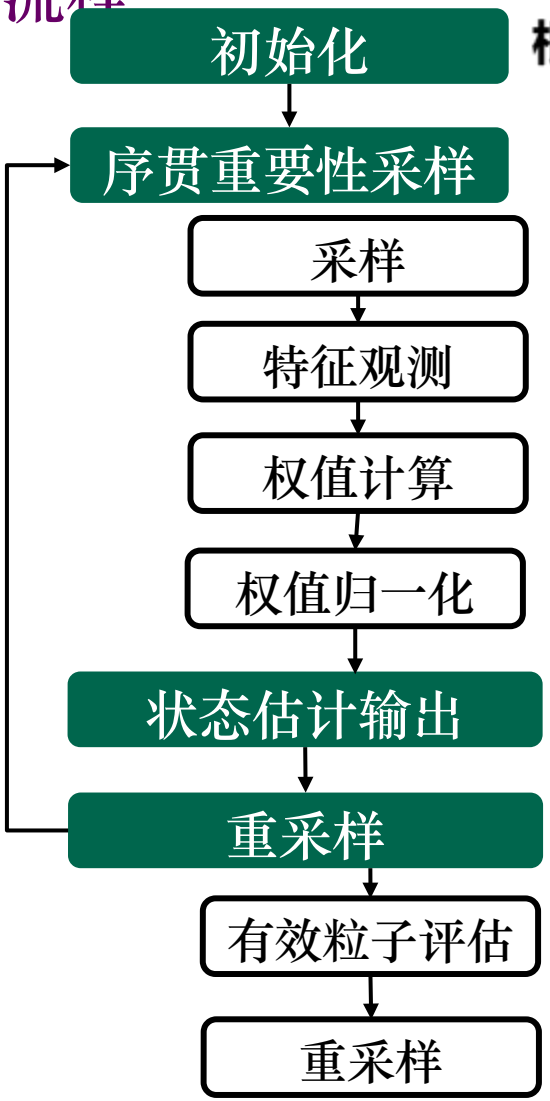
$$= \sum_{i=1}^{M} \frac{n_i}{N} \delta(x_k - x_k^{(i)})$$



重采样后的粒子权重：均为 1/N。

三、基于 Bayes 的信息融合

3.3 粒子滤波（PF： Particle Filter）：标准粒子滤波算法流程



根据先验$p(x_0)$建立初始粒子集$\{x_0^{(i)}, w_0^{(i)}\}_{i=1,\cdots N}$，$w_0^{(i)} = \frac{1}{N}$

根据$p(x_k^{(i)}|x_{k-1}^{(i)})$采样得到新的粒子集$\{x_k^{(i)}\}_{i=1,\cdots N}$

观测特征y_k，计算$p(y_k|x_k^{(i)})$

$$\tilde{w}_k^{(i)} = w_{k-1}^{(i)} p(y_k|x_k^{(i)})$$

$$w_k^{(i)} = \tilde{w}_k^{(i)} / \sum_{i=1}^{N} \tilde{w}_k^{(i)}$$

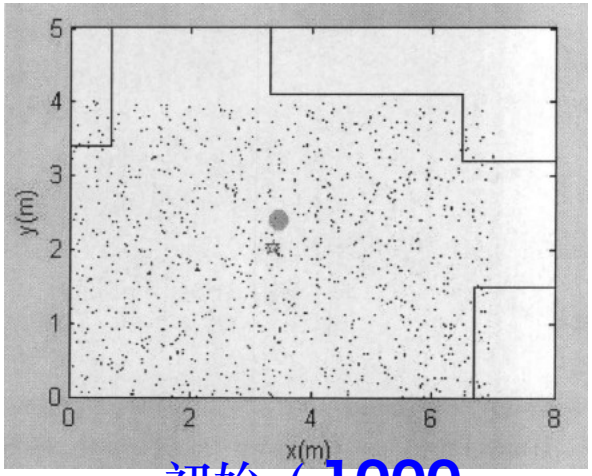
$$\hat{x}_k = \sum_{i=1}^{N} w_k^{(i)} x_k^{(i)}$$ → 输出

$$\hat{N}_{eff} \approx \frac{1}{\sum_{i=1}^{N} (w_k^{(i)})^2}$$

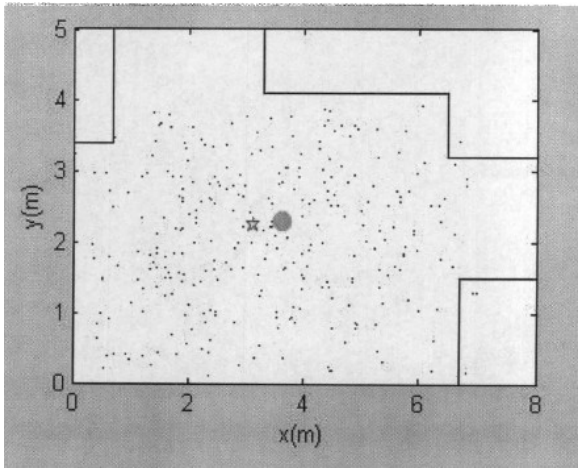
根据粒子权重$w_k^{(i)}$从粒子集$\{x_k^{(i)}, w_k^{(i)}\}_{i=1,\cdots N}$重新抽取N个粒子，建立新的粒子集$\{x_k^{(i)}, 1/N\}_{i=1,\cdots N}$

三、基于 Bayes 的信息融合

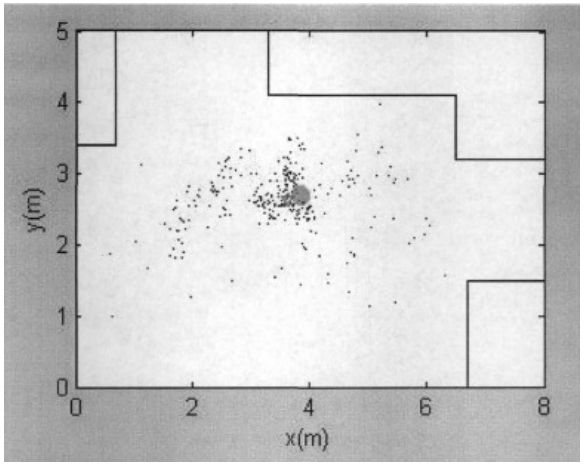
3.3 粒子滤波（PF： Particle Filter）



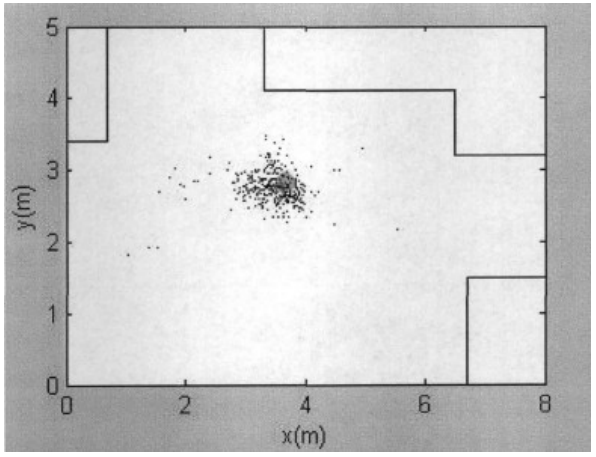
初始（1000个）



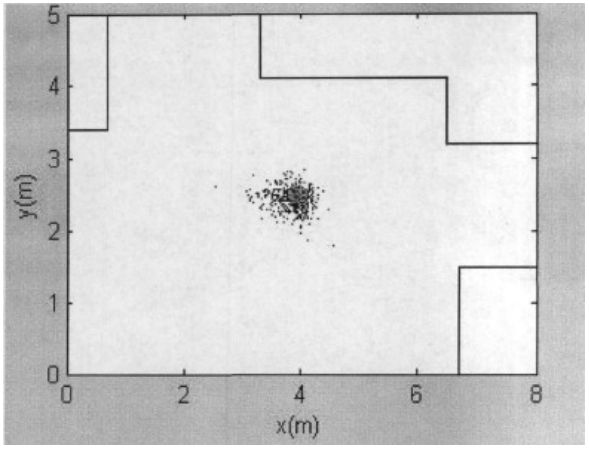
第 2 步



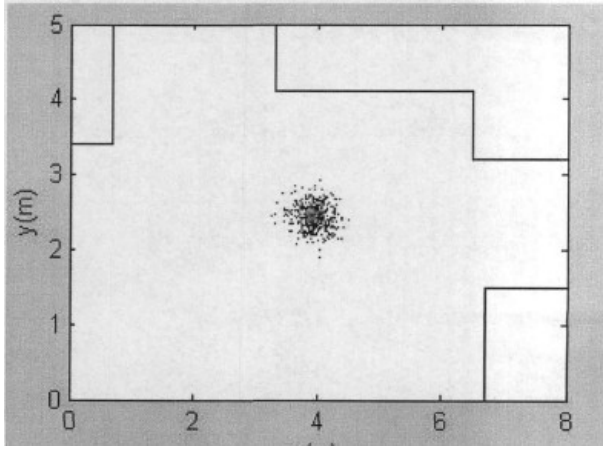
第 20 步



第 40 步



第 60 步



完成

四、基于 D-S 证据理论的信息融合

D-S 证据理论

- 诞生：源于 20 世纪 60 年代哈佛大学数学家 A.P.Dempster 在利用上、下限概率解决多值映射问题方面的研究工作，自 1967 年连续发表了一些论文，标志着证据理论的正式诞生。

- 形成： Dempster 的学生 G.Shafer 对证据理论做了进一步的发展，引入信任函数概念，形成了一套基于“证据”和“组合”来处理不确定性推理问题的数学方法，并与 1976 年出版了《证据的数学理论》，标志这证据理论正式成为一种处理不确定性问题的完整理论。

- 适用领域：信息融合、专家系统、情报分析、法律案件分析、多属性决策分析等等

四、基于 D-S 证据理论的信息融合

D-S 证据理论

基本概念： 设Ω是样本空间，Ω由一些互不相容的陈述构成，这些陈述的各种组合构成幂集2^{Ω}。Ω---辨识框架

例：$\{0,1\} \rightarrow \{\emptyset,\{0\},\{1\},\{0,1\}\}$

{1,2,3}
m({1})=0.1
m({2})=0.2
m({3})=0.1
m({1,2})=0.1
m({1,3})=0.1
m({2,3})=0.1
m({1,2,3})=0.1

定义1：基本概率分配函数M

$$M: 2^{\Omega} \rightarrow [0,1]$$

设函数为M满足下条条件的映射：

(1) 不可能事件的基本概率是0，即：$M(\emptyset)=0$；

(2) 2^{Ω}中全部元素的基本概率之和为1，即：$\sum_{A \subseteq 2^{\Omega}} M(A)=1$

称M是2^{Ω}上的概率分配函数，$M(A)$称为A的基本概率赋值，表示对A的信任程度

四、基于 D-S 证据理论的信息融合

D-S 证据理论

定义2：命题的信任函数Bel

对于任意假设而言，其信任度函数$Bel(A)$定义为A中全部子集对应的基本概率之和，即

$$Bel: 2^{\Omega} \to [0,1]$$

$$Bel(A) = \sum_{B \subseteq A} M(B), A \subseteq 2^{\Omega}$$

根据基本概率函数的定义，有：

$$Bel(\emptyset) = M(\emptyset) = 0$$

$$Bel(\Omega) = \sum_{B \subseteq \Omega} M(B) = 1$$

{1,2,3}
m({1})=0.1
m({2})=0.2
m({3})=0.1
m({1,2})=0.1
m({1,3})=0.1
m({2,3})=0.1
m({1,2,3})=0.1

Bel({1,2})=0.4

四、基于 D-S 证据理论的信息融合

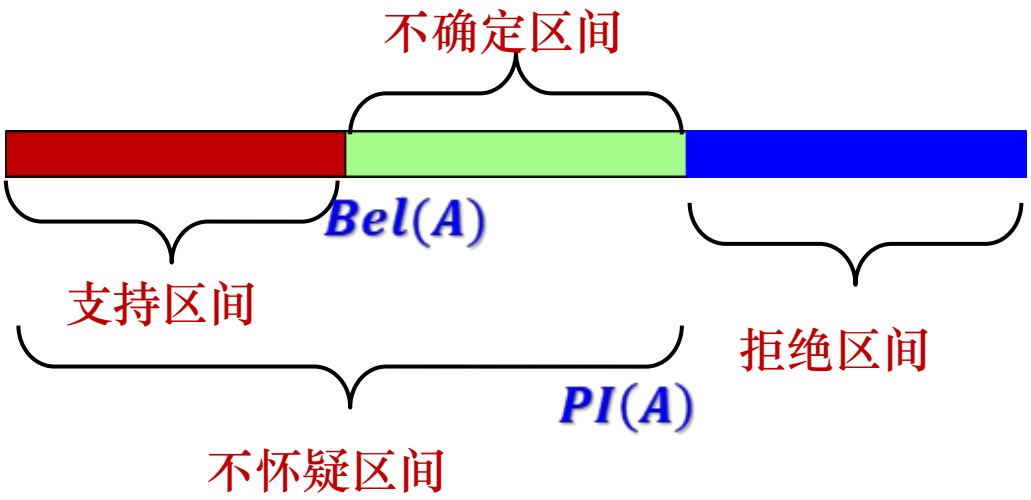
D-S 证据理论

定义2：命题的似然函数PI

$PI: 2^{\Omega} \to [0,1]$　　$PI(A) = 1 - Bel(\overline{A}), A \subseteq 2^{\Omega}$

PI函数为上限函数，表示对A非假的信任程度，即表示对A似乎可能成立的不确定度量。有

$$PI(A) \geq Bel(A)$$



{1,2,3}
m({1})=0.1
m({2})=0.2
m({3})=0.1
m({1,2})=0.1
m({1,3})=0.1
m({2,3})=0.1
m({1,2,3})=0.1

Bel({1,2})=0.4
PI({1,2})=1-Bel({3})=0.9

- 信任度是对假设信任程度的下限估计—悲观估计
- 似然度是对假设信任程度的上限估计—乐观估计

四、基于 D-S 证据理论的信息融合

D-S 证据理论

D-S证据理论的合成规则：设M_i和M_j是2^Ω上的两个概率分配函数，则其正交和$M_{ij} = M_i \oplus M_j$定义为：

$$M_{ij}(A_n) = \begin{cases} 0, & A_n = \emptyset \\ \dfrac{1}{c} \sum\limits_{\substack{\forall A_k^i, A_l^j \in 2^\Omega; \\ A_k^i \cap A_l^j = A_n}} M_i(A_k^i) M_j(A_l^j) & A_n \neq \emptyset \end{cases}$$

$$c = 1 - \sum_{\substack{\forall A_k^i, A_l^j \in 2^\Omega; \\ A_k^i \cap A_l^j = \emptyset}} M_i(A_k^i) M_j(A_l^j) = \sum_{\substack{\forall A_k^i, A_l^j \in 2^\Omega; \\ A_k^i \cap A_l^j \neq \emptyset}} M_i(A_k^i) M_j(A_l^j)$$

$$c = 1 - 0.5 \times 0.4 - 0.3 \times 0.4 = 0.68$$

m({1})=0.5	m({1})=0.3	m({1})=(0.5*0.3+0.5*0.3+0.3*0.1)/0.68=0.49
m({2})=0.4	m({2})=0.4	m({2})=(0.4*0.4+0.4*0.3+0.4*0.1)/0.68=0.47
m({1,2})=0.1	m({1,2})=0.3	m({1,2})=(0.1*0.3)/0.68=0.04

四、基于 D-S 证据理论的信息融合

D-S 证据理论

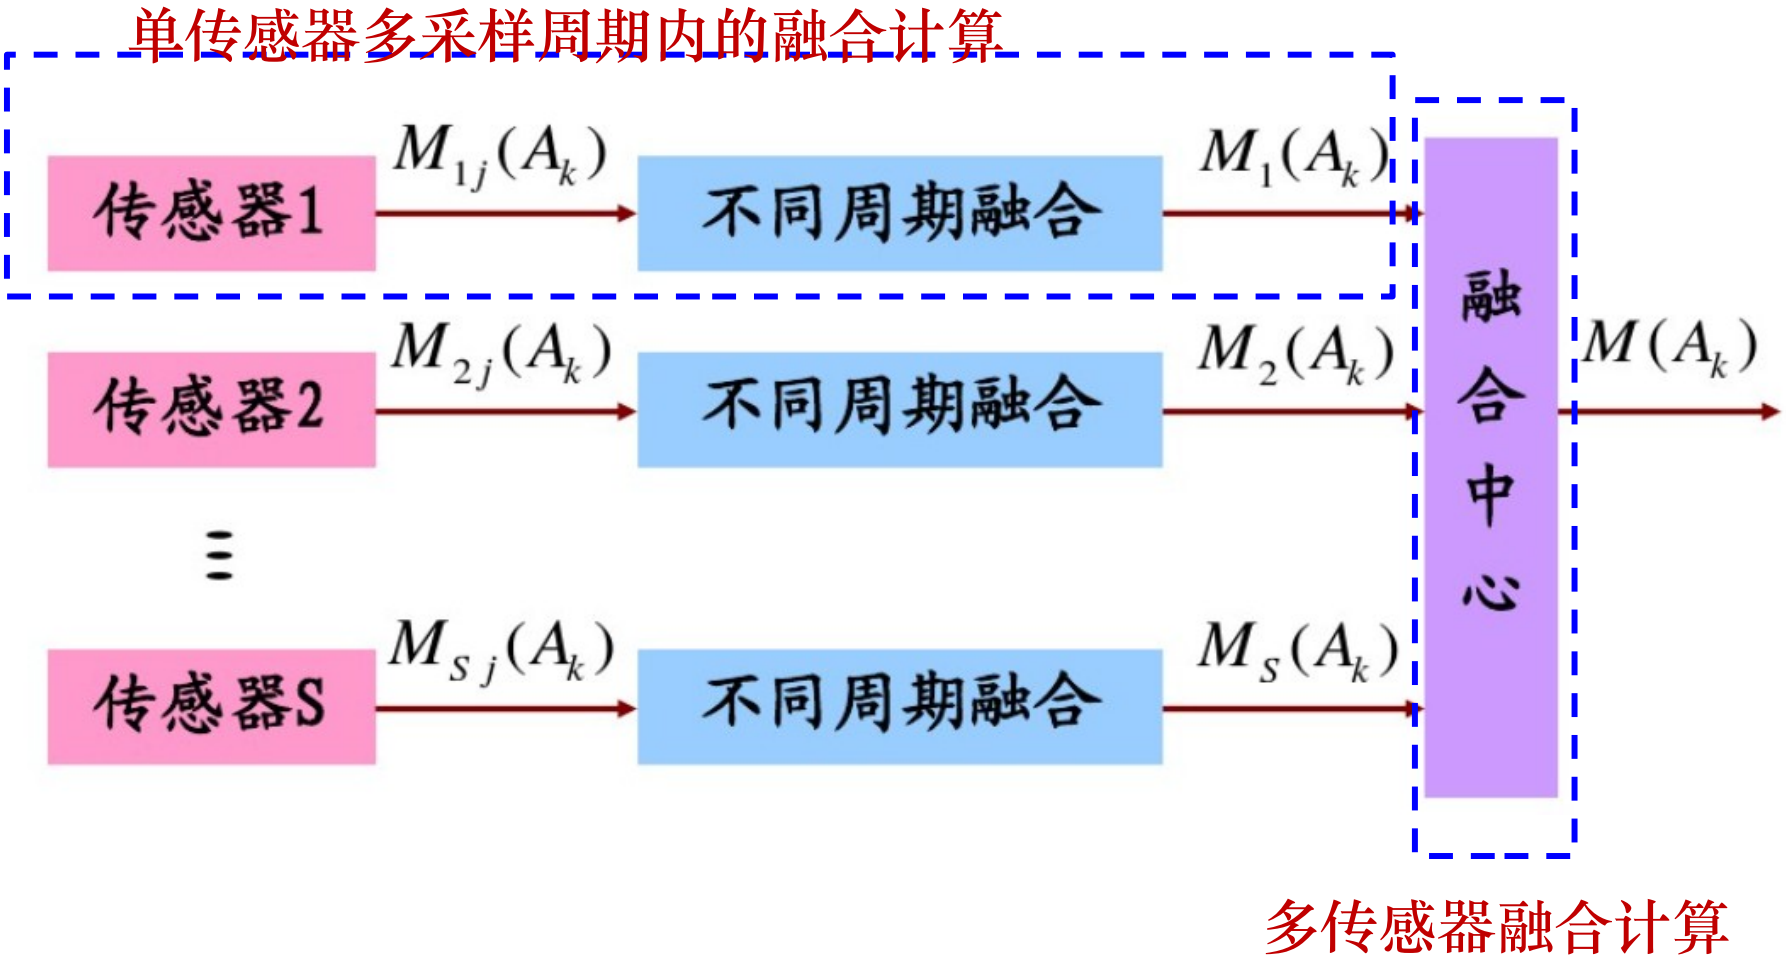
D-S 证据理论的合成规则：多个概率分配函数的正交和为：

$$M(A_k)=\begin{cases}0, & A_k=\emptyset\\ \dfrac{1}{c}\displaystyle\sum_{\cap A_i=A_k}\prod_{1\le i\le N}M_i(A_j^{\,i}) & A_k\neq\emptyset\end{cases}$$

$$c=1-\sum_{\cap A_i=\emptyset}\prod_{1\le i\le N}M_i\left(A_j^{\,i}\right)=\sum_{\cap A_i\neq\emptyset}\prod_{1\le i\le N}M_i(A_j^{\,i})$$

四、基于 D-S 证据理论的信息融合

D-S 证据理论



四、基于 D-S 证据理论的信息融合

D-S 证据理论：示例

假设空中目标含有 3 个属性（敌、我、不明）的 10 种机型（轰炸机、大型机、小型机和民航），利用 10 维向量表示，对目标采用中频雷达、 ESM 和 IFF 传感器探测。 19 个有意义的识别命题

序号	机型	向量表示	序号	含义	向量表示
1	我轰炸机	1000000000	11	我小型机	0011000000
2	我大型机	0100000000	12	敌小型机	0000001010
3	我小型机1	0010000000	13	敌轰炸机	0000100100
4	我小型机2	0001000000	14	轰炸机	1000100100
5	敌轰炸机1	0000100000	15	大型机	0100010000
6	敌大型机	0000010000	16	小型机	0011001010
7	敌小型机1	0000001000	17	敌	0000111110
8	敌轰炸机2	0000000100	18	我	1111000000
9	敌小型机2	0000000010	19	不明	1111111111
10	民航机	0000000001			

17

四、基于 D-S 证据理论的信息融合

D-S 证据理论：示例

3 种传感器每种测量两个周期：

中频雷达：

$$M_{11}(\{民航\},\{轰炸机\},\{不明\})=(0.3,0.4,0.3)$$
$$M_{12}(\{民航\},\{轰炸机\},\{不明\})=(0.3,0.5,0.2)$$

ESM（Electronic Support Measure）：

$$M_{21}(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=(0.4,0.3,0.2,0.1)$$

$$M_{22}(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=(0.4,0.4,0.1,0.1)$$

IFF(敌我识别系统)：

$$M_{31}(\{我\},\{不明\})=(0.6,0.4)$$
$$M_{32}(\{我\},\{不明\})=(0.4,0.6)$$

四、基于 D-S 证据理论的信息融合

D-S 证据理论：示例

$$M_{11}(\{民航\},\{轰炸机\},\{不明\})=(0.3,0.4,0.3)$$

$$M_{12}(\{民航\},\{轰炸机\},\{不明\})=(0.3,0.5,0.2)$$

中频雷达两个周期融合：

$$c_1=1-\{M_{11}(民航)M_{12}(轰炸机)+M_{11}(轰炸机)M_{12}(民航)\}$$

$$=1-(0.3\times0.5+0.4\times0.3)=0.73$$

$$\sum_{\cap A_j=民}\prod_{j=1,2}M_{1j}(A_j)=M_{11}(民)M_{12}(民)+M_{11}(民)M_{12}(不)+M_{11}(不)M_{12}(民)=0.24$$

$$\sum_{\cap A_j=轰}\prod_{j=1,2}M_{1j}(A_j)=M_{11}(轰)M_{12}(轰)+M_{11}(轰)M_{12}(不)+M_{11}(不)M_{12}(轰)=0.43$$

$$\sum_{\cap A_j=不}\prod_{j=1,2}M_{1j}(A_j)=M_{11}(不)M_{12}(不)=0.06$$

$$M_1(\{民航\},\{轰炸机\},\{不明\})=\frac{1}{0.73}(0.24,0.43,0.06)$$

$$=(0.32876,0.58904,0.0822)$$

四、基于 D-S 证据理论的信息融合

ESM 两个周期融合：

$$M_{21}(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=(0.4,0.3,0.2,0.1)$$

$$M_{22}(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=(0.4,0.4,0.1,0.1)$$

$$c_2=1-\left\{\begin{matrix}M_{21}(敌1)M_{22}(敌2)+M_{21}(敌1)M_{22}(我轰)+M_{21}(敌2)M_{22}(敌1)+\\ M_{21}(敌2)M_{22}(我轰)+M_{21}(我)M_{22}(敌1)+M_{21}(我轰)M_{22}(敌2)\end{matrix}\right\}$$

$$=1-(0.4\times0.4+0.4\times0.1+0.3\times0.4+0.3\times0.1+0.2\times0.4+0.2\times0.4)=0.49$$

$$\sum_{\cap A_j=敌1}\prod_{j=1,2}M_{2j}(A_j)=M_{21}(敌1)M_{22}(敌1)+M_{21}(敌1)M_{22}(不)+M_{21}(不)M_{22}(敌1)=0.24$$

$$\sum_{\cap A_j=敌2}\prod_{j=1,2}M_{2j}(A_j)=M_{21}(敌2)M_{22}(敌2)+M_{21}(敌2)M_{22}(不)+M_{21}(不)M_{22}(敌2)=0.19$$

$$\sum_{\cap A_j=我}\prod_{j=1,2}M_{2j}(A_j)=M_{21}(我)M_{22}(我)+M_{21}(我)M_{22}(不)+M_{21}(不)M_{22}(我)=0.05$$

$$\sum_{\cap A_j=不}\prod_{j=1,2}M_{2j}(A_j)=M_{21}(不)M_{22}(不)=0.01$$

$$M_2(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=\frac{1}{0.49}(0.24,0.19,0.05,0.01)$$

$$=(0.48979,0.38755,0.1025,0.020408)$$

四、基于 D-S 证据理论的信息融合

IFF 两个周期融合：

$$M_{31}(\{我\},\{不明\})=(0.6,0.4)$$

$$M_{32}(\{我\},\{不明\})=(0.4,0.6)$$

$$c_3=1$$

$$\sum_{\cap A_j=我}\prod_{j=1,2}M_{3j}(A_j)=M_{31}(我)M_{12}(我)+M_{31}(我)M_{12}(不)+M_{31}(不)M_{32}(我)=0.76$$

$$\sum_{\cap A_j=不}\prod_{j=1,2}M_{3j}(A_j)=M_{31}(不)M_{32}(不)=0.24$$

$$M_3(\{我\},\{不明\})=(0.76,0.24)$$

四、基于 D-S 证据理论的信息融合

3 个传感器的总体融合：

$$M_1(\{民航\},\{轰炸机\},\{不明\})=(0.329,0.589,0.082)$$

$$M_2(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\})=(0.490,0.388,0.103,0.0204)$$

$$M_3(\{我\},\{不明\})=(0.76,0.24)$$

$$C=1-\left\{\begin{array}{c} M_1(民)M_2(敌1)M_3(我)+M_1(民)M_2(敌1)M_3(不)+ \\ M_1(民)M_2(敌2)M_3(我)+M_1(民)M_2(敌2)M_3(不)+ \\ M_1(民)M_2(我轰)M_3(我)+M_1(民)M_2(我轰)M_3(不)+ \\ M_1(轰)M_2(敌1)M_3(我)+M_1(轰)M_2(敌2)M_3(我)+ \\ M_1(不)M_2(敌1)M_3(我)+M_1(不)M_2(敌2)M_3(我) \end{array}\right\}=0.23$$

$$M_A(\{民航\},\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{轰炸机\},\{我机\},\{不明\}) = (0.007, 0.343, 0.272, 0.316, 0.0125, 0.006, 0.0017)$$

$$M_1(\{民航\},\{轰炸机\},\{不明\}) = (0.329, 0.589, 0.082)$$

$$M_2(\{敌轰炸机1\},\{敌轰炸机2\},\{我轰炸机\},\{不明\}) = (0.490, 0.388, 0.103, 0.0204)$$

$$M_3(\{我\},\{不明\}) = (0.76, 0.24)$$

$$M(民) = \frac{M_1(民)M_2(不明)M_3(不明)}{C} = 0.007$$

$$M(敌1) = \frac{M_1(轰)M_2(敌1)M_3(不明) + M_1(不)M_2(敌1)M_3(不明)}{C} = 0.343$$

$$M(敌2) = \frac{M_1(轰)M_2(敌2)M_3(不明) + M_1(不)M_2(敌2)M_3(不明)}{C} = 0.272$$

$$M(我轰) = \frac{\begin{array}{l}M_1(轰)M_2(我轰)M_3(我) + M_1(轰)M_2(我轰)M_3(不) + \\ M_1(不)M_2(我轰)M_3(我) + M_1(不)M_2(我轰)M_3(不)\end{array}}{C} = 0.316$$

$$M(轰) = \frac{M_1(轰)M_2(不明)M_3(不明)}{C} = 0.0125$$

$$M(我) = \frac{M_1(不明)M_2(不明)M_3(我)}{C} = 0.006$$

$$M(不明) = \frac{M_1(不)M_2(不)M_3(不)}{C} = 0.0017$$

四、基于 D-S 证据理论的信息融合

3 个传感器的两两融合：

M_1({民航}, {轰炸机}, {不明}) = (0.32876, 0.58904, 0.0822)

M_2({敌轰炸机1}, {敌轰炸机2}, {我轰炸机}, {不明}) = (0.48979, 0.38755, 0.1025, 0.020408)





M_A({民航}, {敌轰炸机1}, {敌轰炸机2}, {我轰炸机}, {轰炸机}, {不明})

M_3({我}, {不明}) = (0.76, 0.24)





M({民航}, {敌轰炸机1}, {敌轰炸机2}, {我轰炸机}, {轰炸机}, {我机}, {不明})



结果与 3 个传感器一起融合是否一致？为什么？

四、基于 D-S 证据理论的信息融合

D-S 证据理论

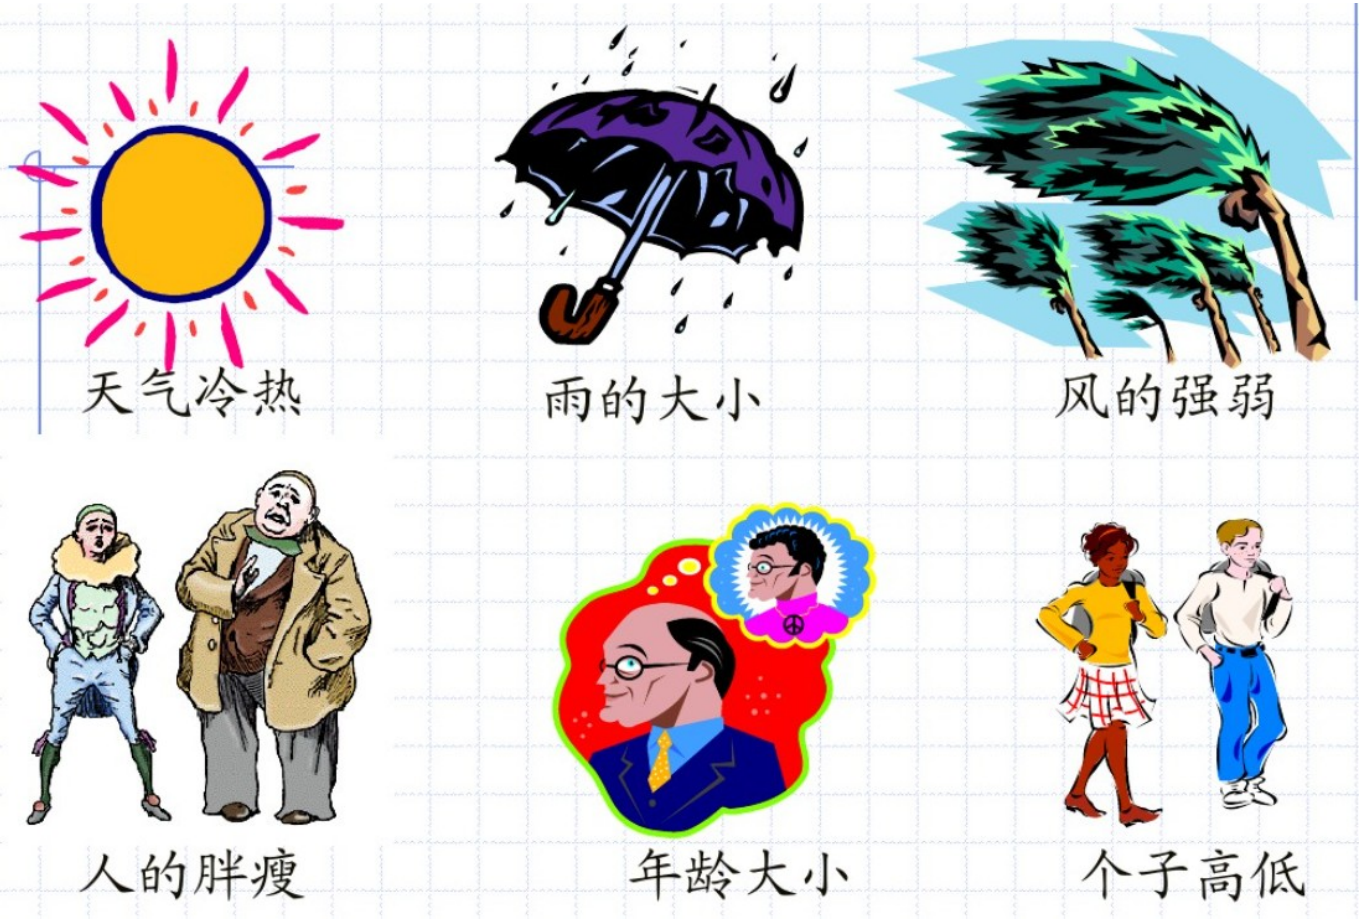
- 优势：

  满足比 Bayes 概率理论更弱的条件，即不需要知道先验概率。具有直接表达“不确定”和“不知道”的能力。

- 局限性：
  - ✓ 要求证据必须独立，这有时不易满足；
  - ✓ 证据合成规则没有坚固的理论支持，其合理性和有效性还存在较大的争议；
  - ✓ 计算上存在着潜在的组合爆炸问题。

五、基于模糊集的信息融合

模糊概念



模糊概念：从属于该概念到不属于该概念没有明显界限。利用数学方法研究模糊现象。

五、基于模糊集的信息融合

模糊集合概念

- 集合：把具有一定属性并且彼此可以明确识别的东西放在一起

学生 ={ 小学生，中学生，大学生，研究生 }

年青人={Human | P(Human) = $x, x \leq 35$}

- 论域：被讨论对象的全体组成的集合称为论域
- 集合表示清晰概念
  - ✓ 集合中元素具有互异性，即元素彼此相异，范围边界分明
  - ✓ 集合中元素具有确定性，一个元素 x 与集合 A 的关系是：要么 x 属于 A，要么不属于 A，二者必居其一。

实际生活中有些概念并非清晰概念，如鲜美的食物、美丽的景色、高个子、年轻人等等，对于这些概念，普通集合无能为力。

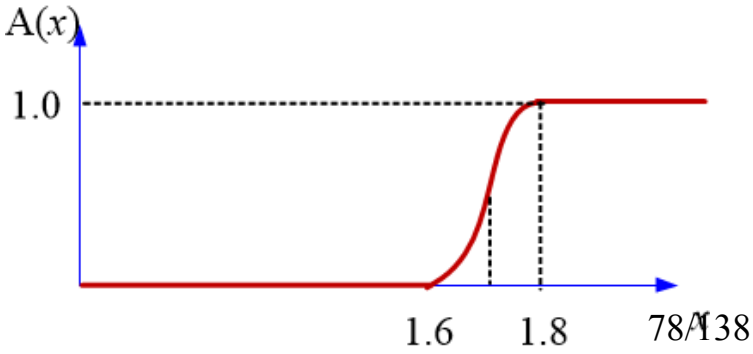
五、基于模糊集的信息融合

□ 模糊集合概念

定义：设U为论域，U在闭区间$[0,1]$上的任一映射$A: U \to [0,1]$称为U上的隶属函数。对于任意的$x \in U$，隶属函数值$A(x)$称为x对A的隶属度。A为论域U上的模糊集合。

例：用A表示“高个子男人”的模糊集合，假定身高1.80m以上的男人为高个子，1.60m以下的男人都不是高个子。用x表示男子身高，隶属函数可以为

$$A(x)=\begin{cases}0, & x<1.60\\ 2\left(\dfrac{x-1.60}{0.2}\right)^2, & 1.60\le x<1.70\\ 1-2\left(\dfrac{x-1.80}{0.2}\right)^2, & 1.70\le x<1.80\\ 1, & 1.80\le x\end{cases}$$



设$U=\{x_1=1.65m,\ x_2=1.70m,\ x_3=1.75m\}$

$$A=\frac{0.125}{x_1}+\frac{0.5}{x_2}+\frac{0.875}{x_3}$$

Zadeh 记号

五、基于模糊集的信息融合

模糊集合概念

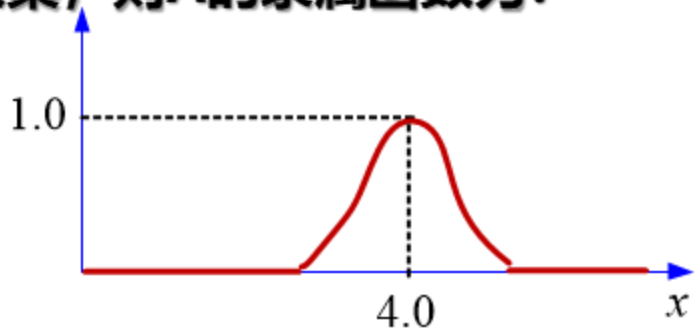
例：$U=\{1,2,3,4,5,6\}$，A表示“靠近4”的数集，则A可采不同方法表示为：

(1) $A=\{(1,\ 0),\ (2,\ 0.2),\ (3,\ 0.8),\ (4,\ 1.0),\ (5,\ 0.8),\ (6,\ 0.2)\}$

(2) $A=\dfrac{0}{1}+\dfrac{0.2}{2}+\dfrac{0.8}{3}+\dfrac{1}{4}+\dfrac{0.8}{5}+\dfrac{0.2}{6}$

例：设论域U为实数R，则A表示“靠近4”的数集，则A的隶属函数为：

$$A(x)=\begin{cases}e^{-k(x-4)^2}, & |x-4|\le\delta\\ 0, & |x-4|>\delta\end{cases}$$



隶属函数是刻画模糊集合的最基本概念；合理构造隶属函数是模糊数学应用的关键；虽然有一定的统计规律性，但实际上很难给出一个模糊集合隶属函数的唯一表达式，也不存在统一方法来构造隶属函数。

五、基于模糊集的信息融合

随机与模糊

随机性

- 事件本身具有明确含义
- 事件是否出现的不确定性
- [0,1] 上概率分布函数描述

模糊性

- 实物概念本身是模糊的
- 概念外延的模糊 --- 不确定性：模糊性
- [0,1] 上隶属函数描述

五、基于模糊集的信息融合

基于模糊集理论的传感器融合

设 m 个传感器对系统进行观测，传感器可信度模糊集合为 A；系统可能的决策有 n 个，对应的决策模糊集合为 B：

传感器本身性能所决定的可信度

$$A=\left\{\frac{a_1}{\text{传感器}1},\ \frac{a_2}{\text{传感器}2},\ \cdots,\ \frac{a_m}{\text{传感器}m}\right\}$$

最终决策

$$B=\left\{\frac{b_1}{\text{决策}1},\ \frac{b_2}{\text{决策}2},\ \cdots,\ \frac{b_n}{\text{决策}n}\right\}$$

设传感器i认为决策j的可能性为μ_{ij}，即传感器i对系统的判断结果是：

每个传感器根据当前数据判断出每个决策的可信度

$$\left\{\frac{\mu_{i1}}{\text{决策}1},\ \frac{\mu_{i2}}{\text{决策}2},\ \cdots,\ \frac{\mu_{in}}{\text{决策}n}\right\}$$

五、基于模糊集的信息融合

基于模糊集理论的传感器融合

则对 m 个传感器的决策结果进行融合

$$B = A \cdot R_{A\times B} = [a_1, a_2, \cdots, a_m] \begin{bmatrix} \mu_{11} & \mu_{12} & \cdots & \mu_{1n} \\ \mu_{21} & \mu_{22} & \cdots & \mu_{2n} \\ \vdots & \vdots & & \vdots \\ \mu_{m1} & \mu_{m2} & \cdots & \mu_{mn} \end{bmatrix}$$

决策1 … 决策n

上述关系定义为笛卡尔乘积。矩阵$R_{A\times B}$为描述模糊集合A与B之间关系的关系矩阵，其中

- ✓ **第i行表示第i个传感器对所有决策的支持程度；**
- ✓ **第j列表示所有传感器对第j个决策的支持程度。**

五、基于模糊集的信息融合

基于模糊集理论的传感器融合

例：某煤矿瓦斯监测，状态集合为{安全，危险}，传感器集合为{CH4传感器，温度传感器，CO传感器}，根据经验确定每种传感器对于状态判断的可信度

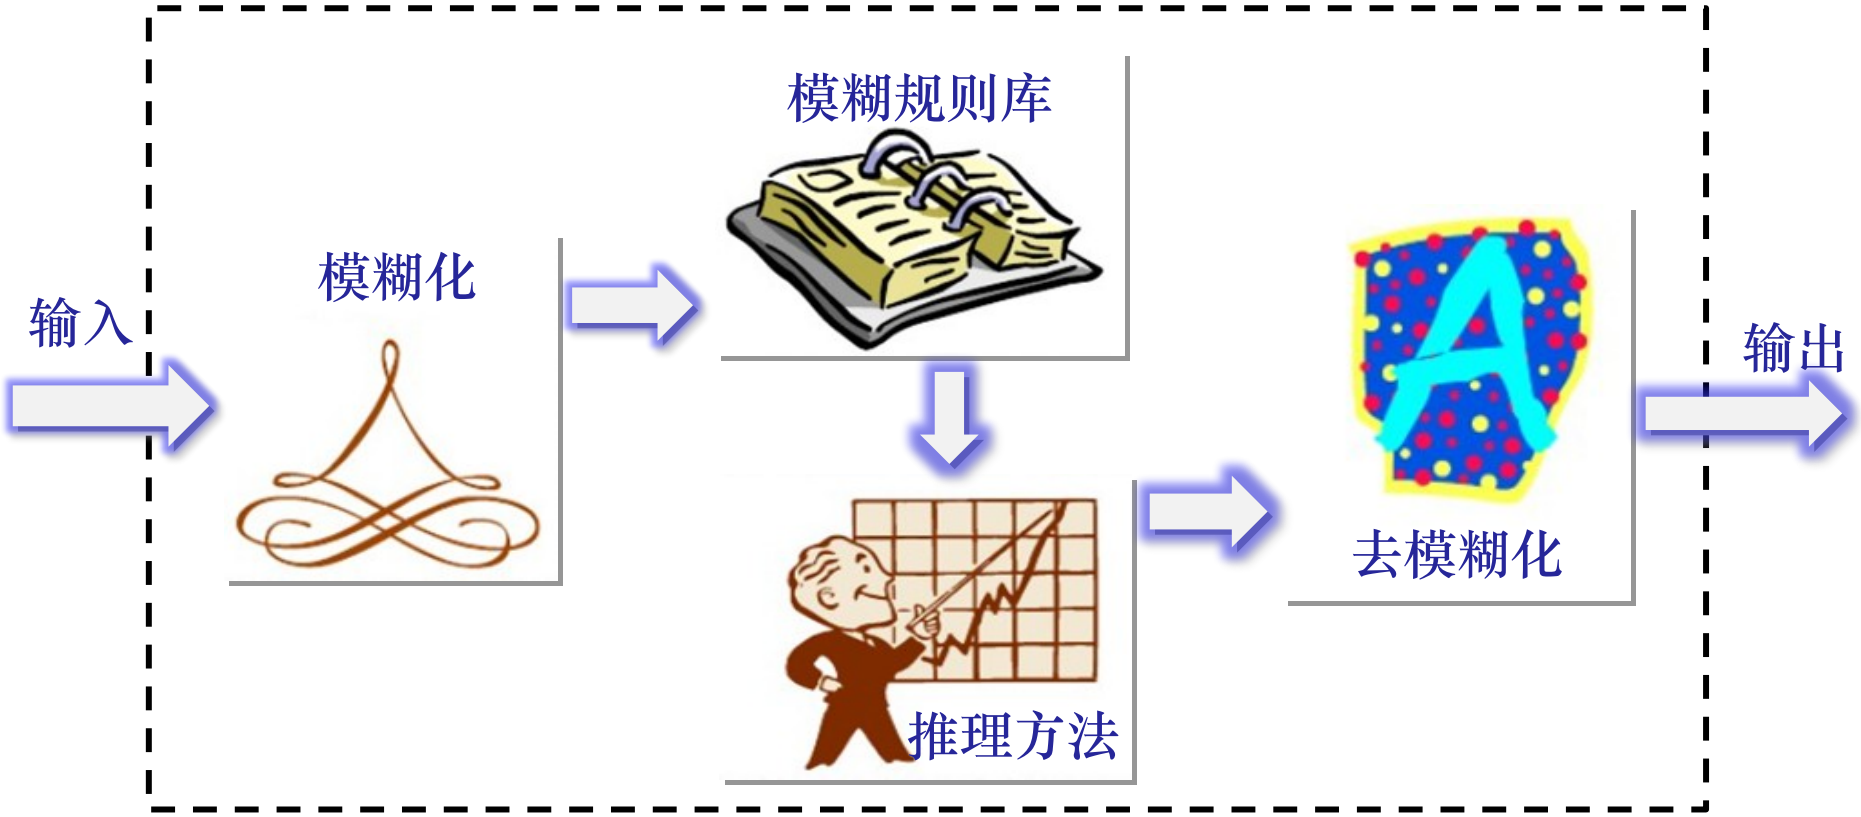
$$A=\left\{\frac{0.6}{\text{CH4传感器}},\ \frac{0.3}{\text{温度传感器}},\ \frac{0.1}{\text{CO传感器}}\right\}$$

$$\boldsymbol{B}=\boldsymbol{A}\cdot\boldsymbol{R}_{\boldsymbol{A}\times\boldsymbol{B}}=[0.6,0.3,0.1]\begin{matrix}\text{安全} & \text{危险}\\ \begin{bmatrix}0.38 & 0.62\\ 0.49 & 0.51\\ 0.70 & 0.30\end{bmatrix}\end{matrix}\begin{matrix}\\ \text{危险}\\ \text{不确定}\\ \text{安全}\end{matrix}$$

$$=[0.445\quad 0.555]\ \text{危险}$$

六、基于模糊推理的信息融合

模糊推理系统：以模糊集合理论和模糊推理为基础，具有处理模糊信息能力的系统。以模糊逻辑理论为主要计算工具，可以实现复杂的非线性映射关系，而且其输入输出都是精确数值，因此已经被广泛应用。



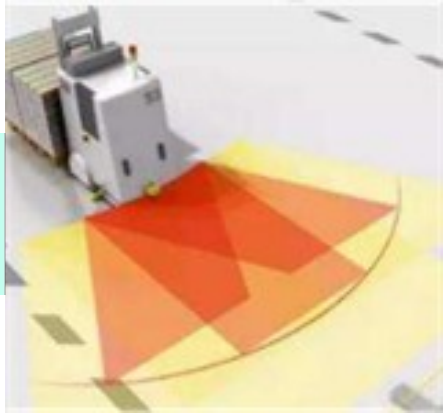
四个步骤：模糊化、模糊规则库、模糊推理方法、去模糊化。

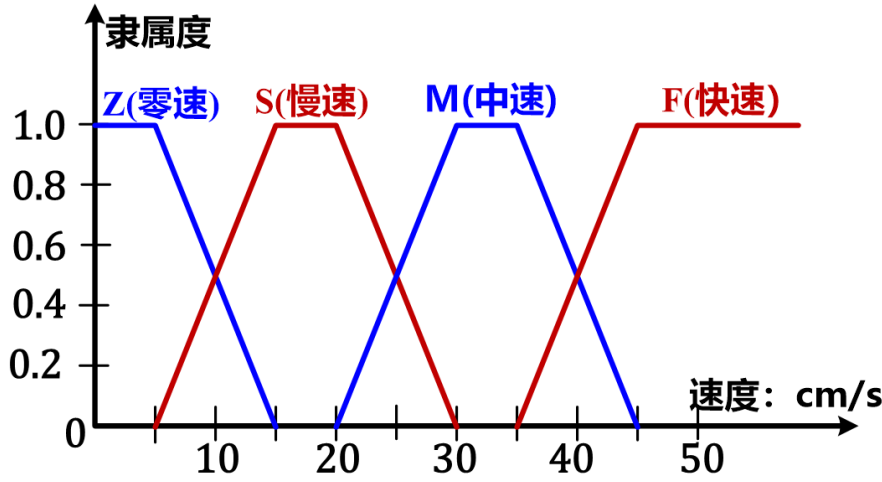
六、基于模糊推理的信息融合

- **模糊化**：将输入输出**定量数据**借助于**隶属度函数**转化为语义**模糊子集**

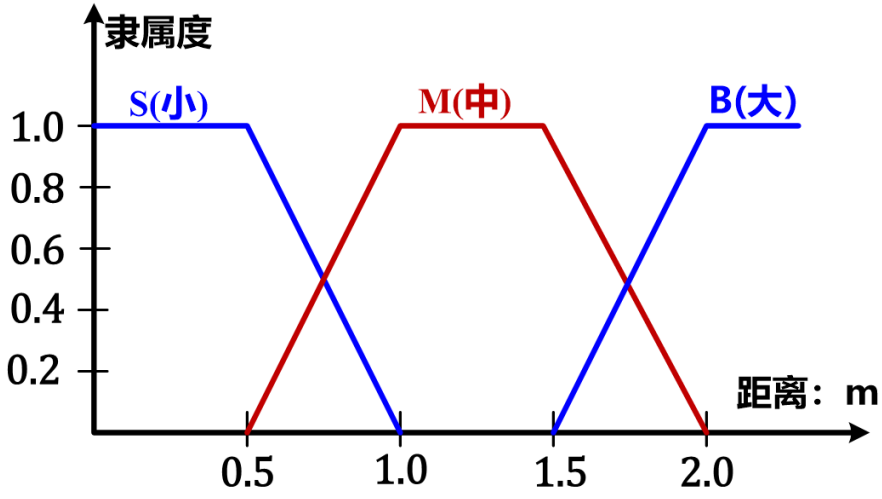
  - 模糊子集：语义表达
  - 隶属度函数

$$(v,\varphi) = f(D_L, D_F, D_R)$$

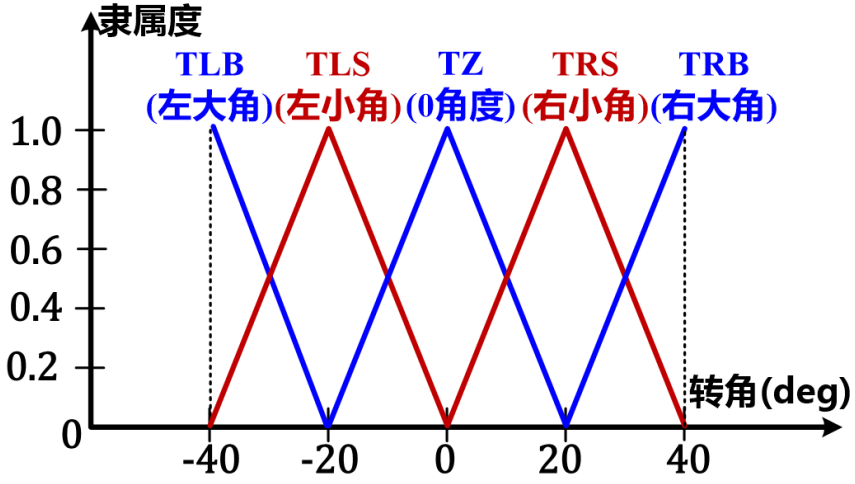




机器人运行速度



机器人前、左、右方向上的障碍物距离



机器人转弯角度

六、基于模糊推理的信息融合

- 模糊规则：避障行为控制器 If…Then…

避障模糊控制器规则表

规则号	D_L	D_F	D_R	v	ϕ	规则号	D_L	D_F	D_R	v	ϕ
1	S	S	S	Z	TRB or TLB	15	M	M	B	S	TRS
2	S	S	M	Z	TRS	16	M	B	S	M	TLS
3	S	S	B	Z	TRS	17	M	B	M	M	TZ
4	S	M	S	S	TRB or TLB	18	M	B	B	F	TRS
5	S	M	M	S	TRS	19	B	S	S	Z	TLB
6	S	M	B	S	TRS	20	B	S	M	Z	TLB
7	S	B	S	M	TZ	21	B	S	B	Z	TRB or TLB
8	S	B	M	M	TRS	22	B	M	S	S	TLS
9	S	B	B	F	TRS	23	B	M	M	S	TLS
10	M	S	S	Z	TLS	24	B	M	B	S	TRS or TLS
11	M	S	M	Z	TRB or TLB	25	B	B	S	F	TLS
12	M	S	B	Z	TRB	26	B	B	M	F	TLS
13	M	M	S	S	TLS	27	B	B	B	F	TZ
14	M	M	M	S	TRS or TLS						

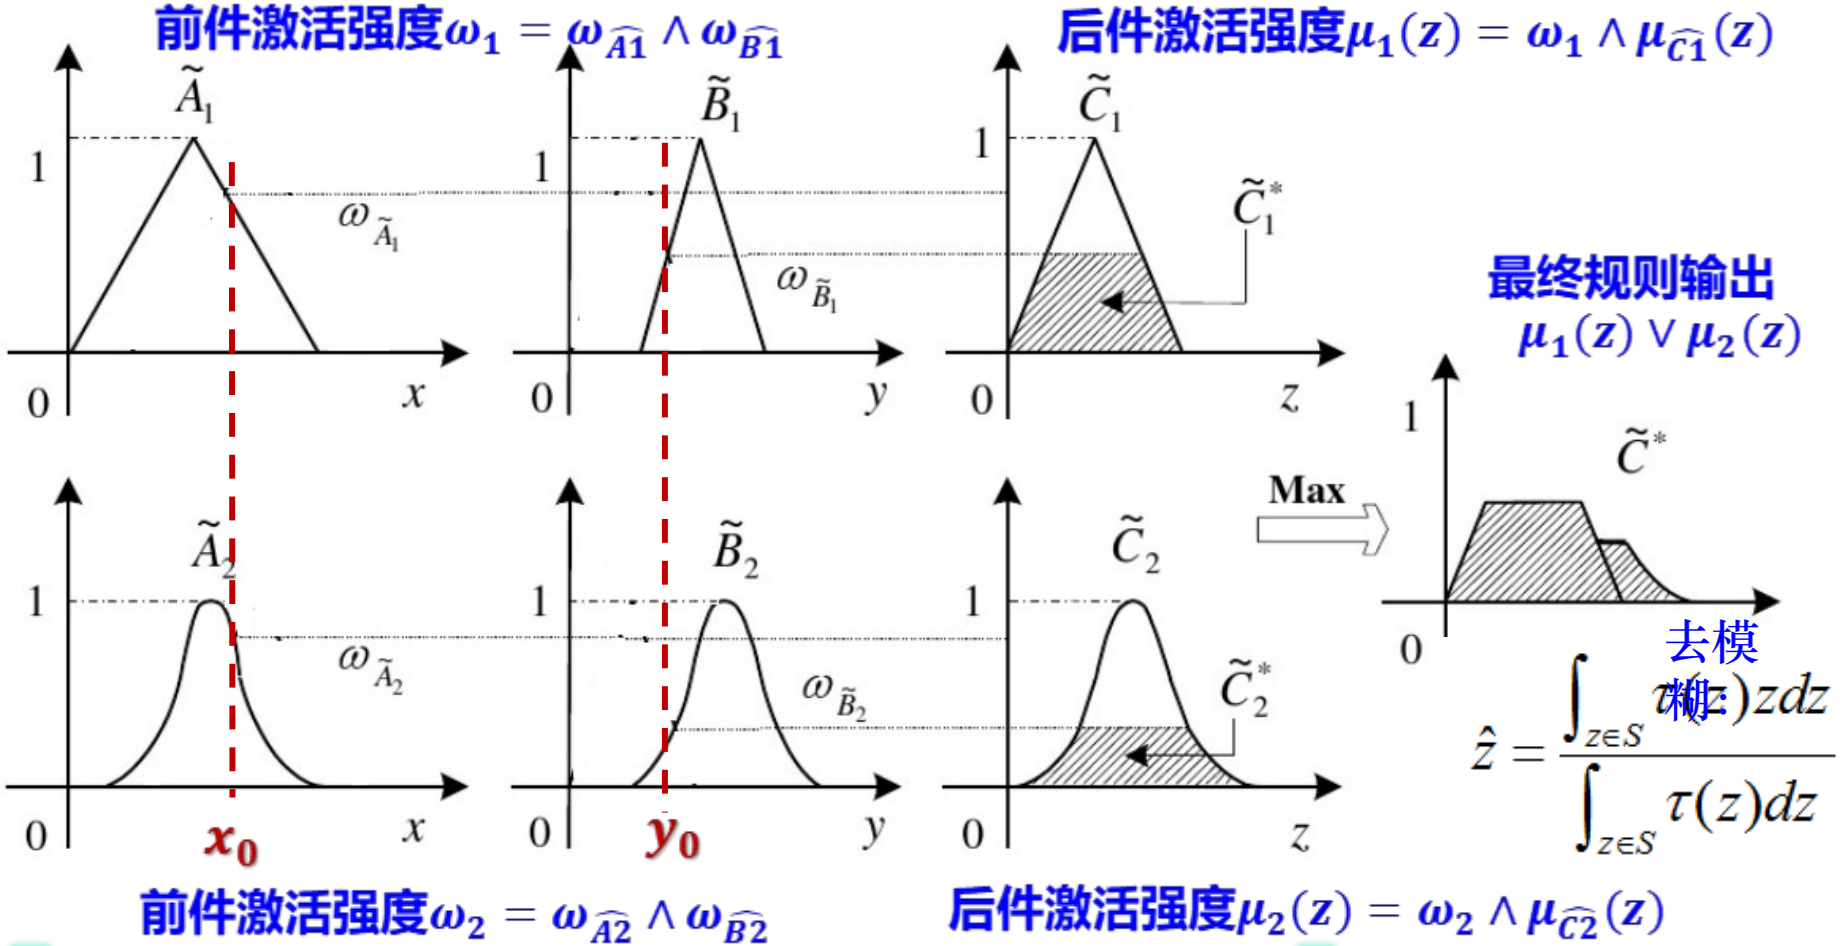
If D_L is M and D_F is S and D_R is B, 规则前件

Then v is Z and φ is TRB 规则后件

六、基于模糊推理的信息融合

模糊推理： Mamdani 方法

If x is A1 and y is B1, Then z is C1



If x is A2 and y is B2, Then z is C2

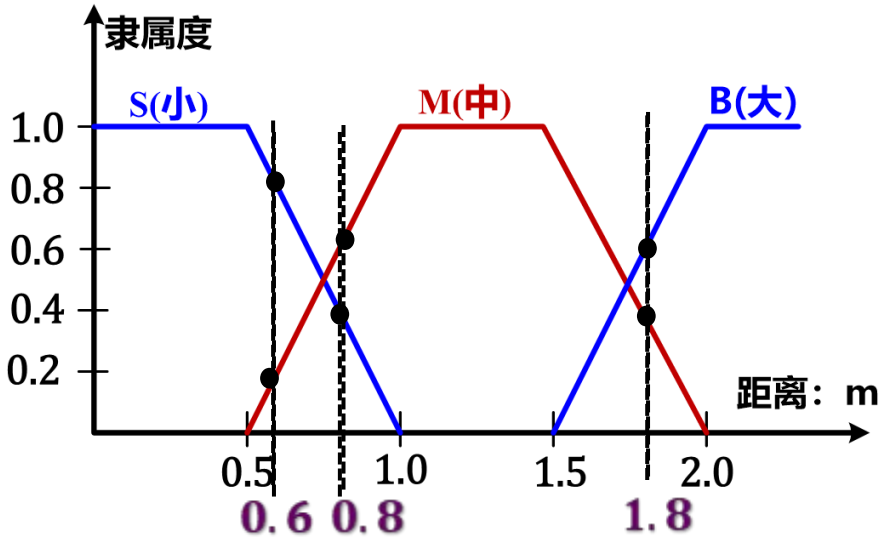
六、基于模糊推理的信息融合

□ 模糊推理： Mamdani 方法示例

左方距离：$D_L = 0.8\text{m}$

前方距离：$D_F = 0.6\text{m}$

右方距离：$D_R = 1.8\text{m}$



规则1：

$If\ D_L\ is\ S\ and\ D_F\ is\ S\ and\ D_R\ is\ B,\ Then\ v\ is\ Z\ and\ \varphi\ is\ TRS$

$\omega_{L1} = 0.4 \quad \omega_{F1} = 0.8 \quad \omega_{R1} = 0.6$

前件强度$\omega_1 = \omega_{L1} \wedge \omega_{F1} \wedge \omega_{R1} = 0.4$

规则2：

$If\ D_L\ is\ M\ and\ D_F\ is\ M\ and\ D_R\ is\ M,\ Then\ v\ is\ S\ and\ \varphi\ is\ TLS$

$\omega_{L2} = 0.6 \quad \omega_{F2} = 0.2 \quad \omega_{R2} = 0.4$

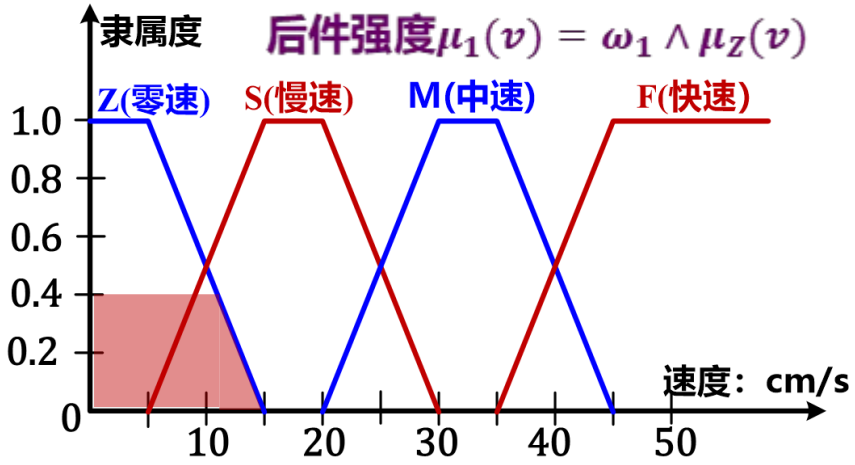
前件强度$\omega_2 = \omega_{L2} \wedge \omega_{F2} \wedge \omega_{R2} = 0.2$

六、基于模糊推理的信息融合

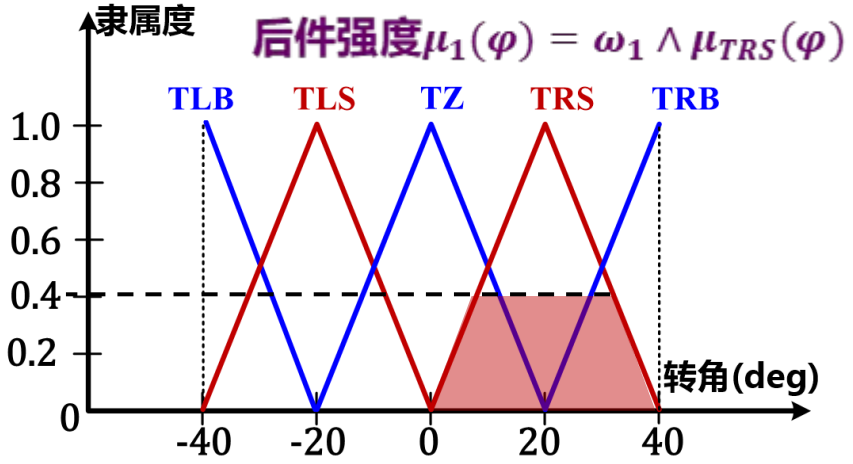
模糊推理： Mamdani 方法示例

规则 1

前件强度$\omega_1 = 0.4$

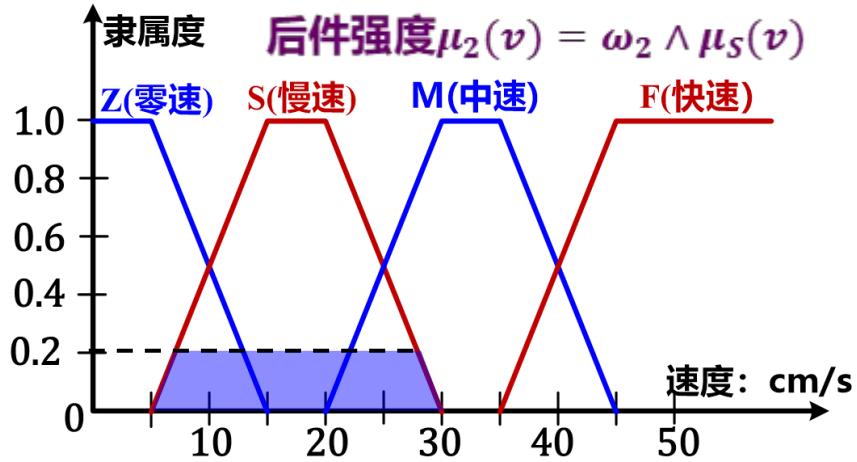


Then v is Z and φ is TRS

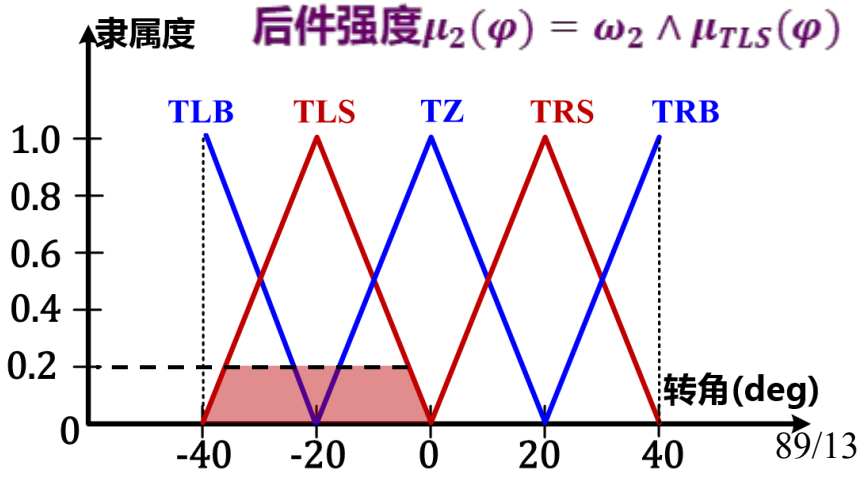


规则 2

前件强度$\omega_2 = 0.2$



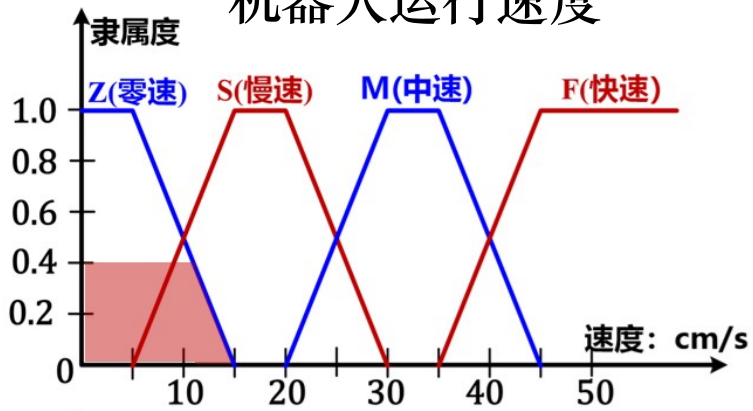
Then v is S and φ is TLS

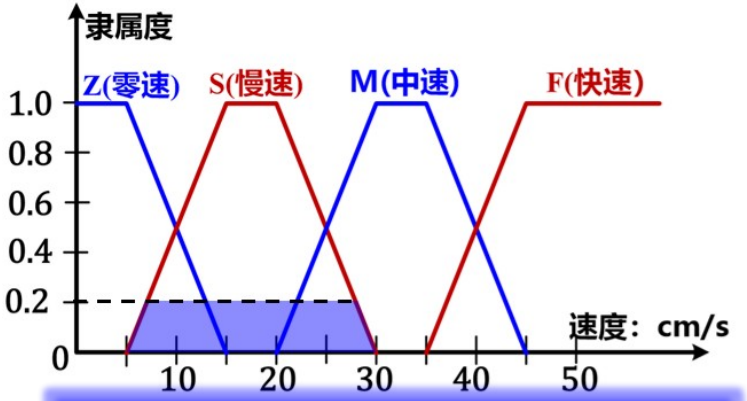


六、基于模糊推理的信息融合

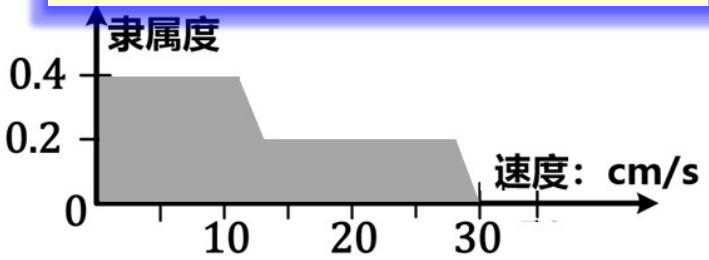
模糊推理： Mamdani 方法示例

机器人运行速度

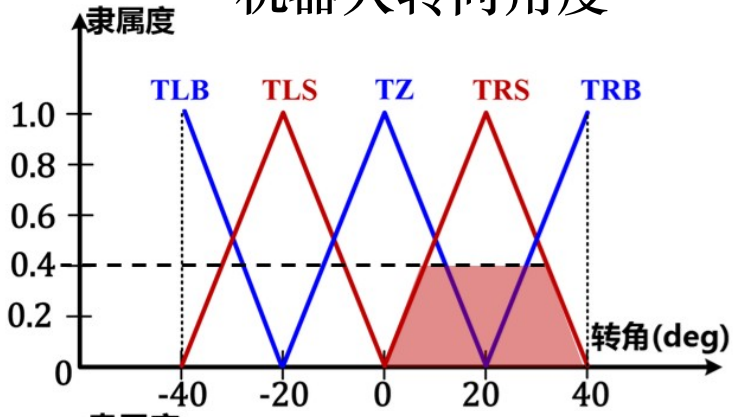


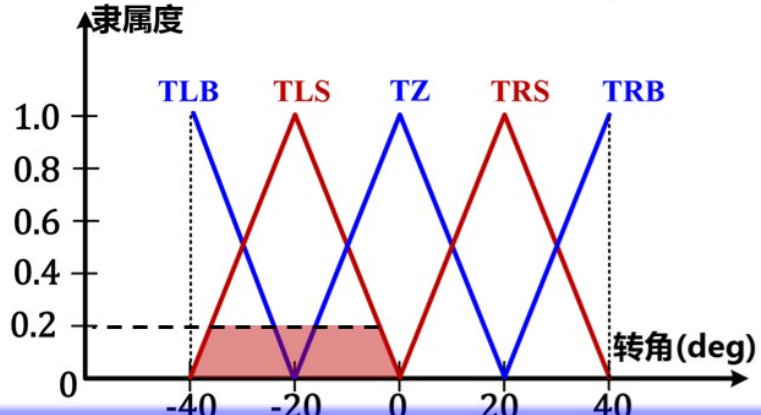


$$\mu(v) = \mu_1(v) \vee \mu_2(v)$$

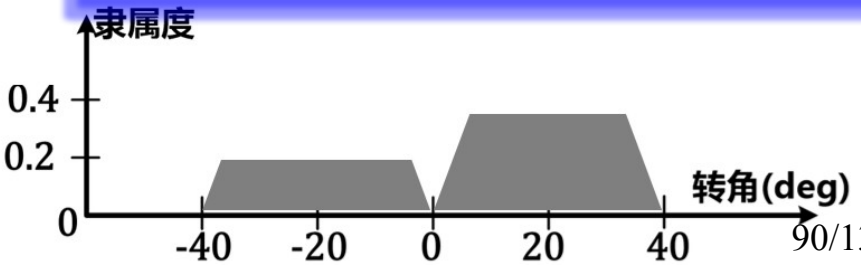


机器人转向角度





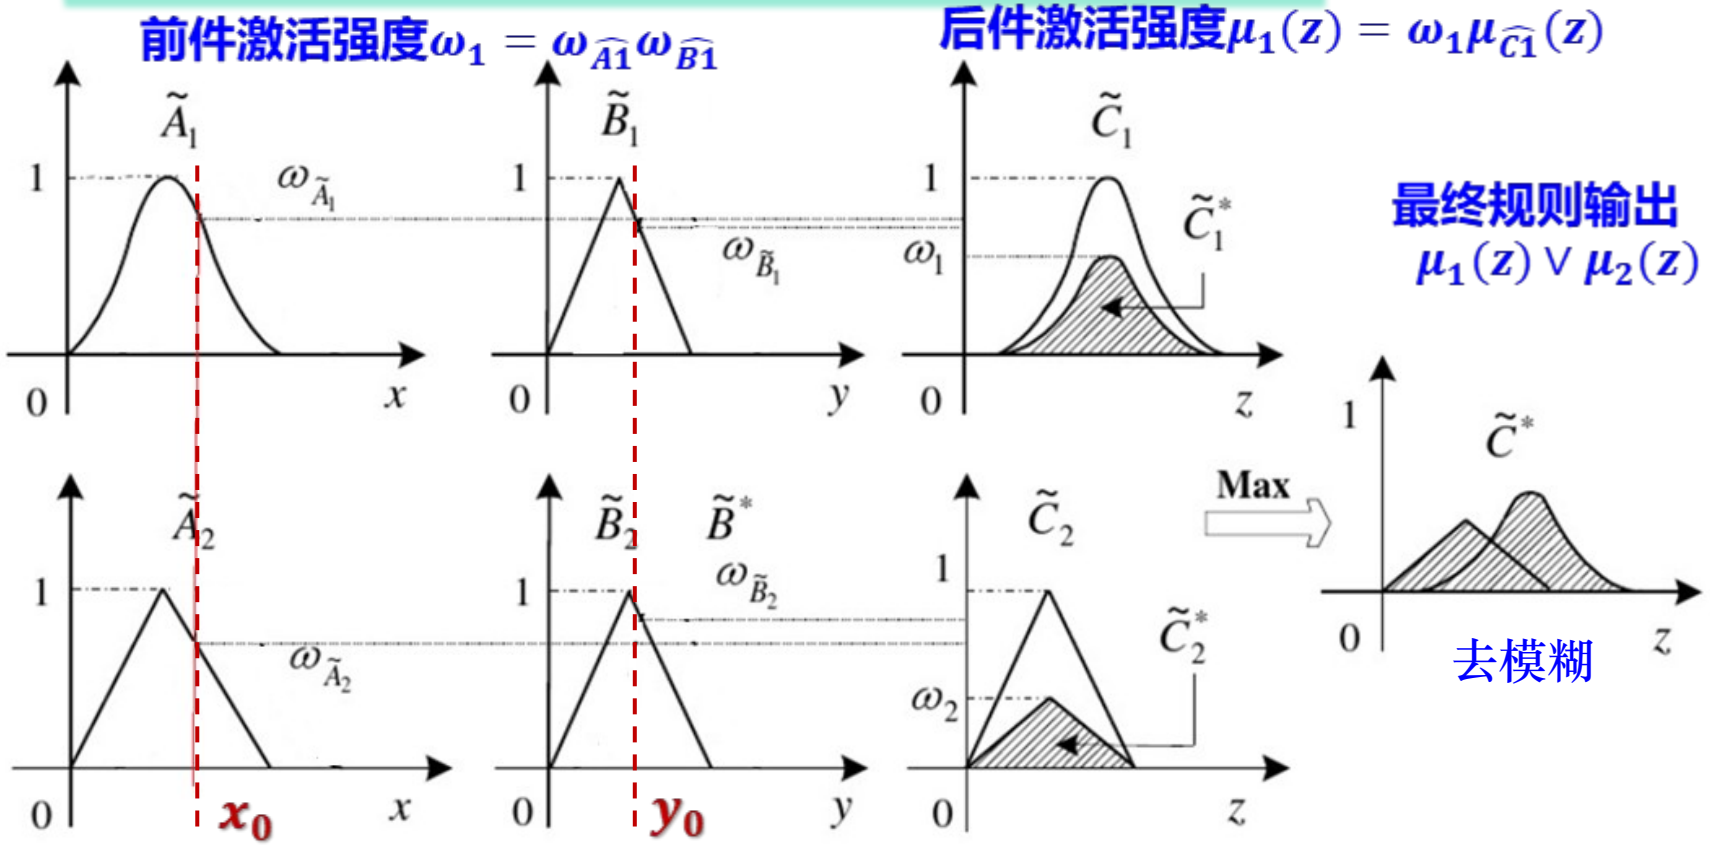
$$\mu(\varphi) = \mu_1(\varphi) \vee \mu_2(\varphi)$$



六、基于模糊推理的信息融合

- 模糊推理： Larsen 方法

If x is A1 and y is B1, Then z is C1

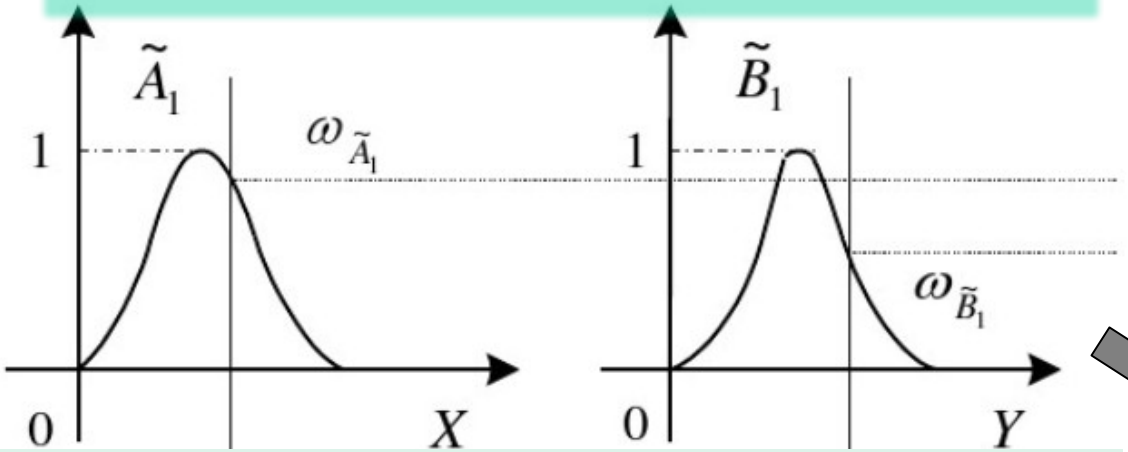


If x is A2 and y is B2, Then z is C2

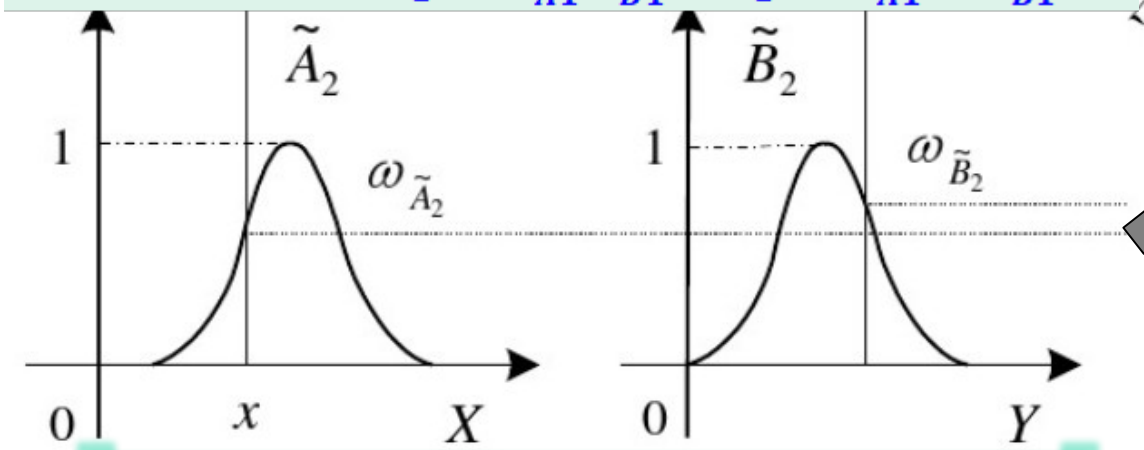
六、基于模糊推理的信息融合

- 模糊推理： T-S （Takagi-Sugeno）方法

If x is A1 and y is B1, Then $z = f_1(x,y)$



前件激活强度$\omega_1 = \omega_{\widehat{A1}}\omega_{\widehat{B1}}$或$\omega_1 = \omega_{\widehat{A1}} \wedge \omega_{\widehat{B1}}$



If x is A2 and y is B2, Then $z = f_2(x,y)$

每条规则的输出表达为输入 x 和 y 的清晰函数

$$z_1 = p_1x + q_1y + r_1$$

ω_1

$$z = \frac{\omega_1 z_1 + \omega_2 z_2}{\omega_1 + \omega_2}$$

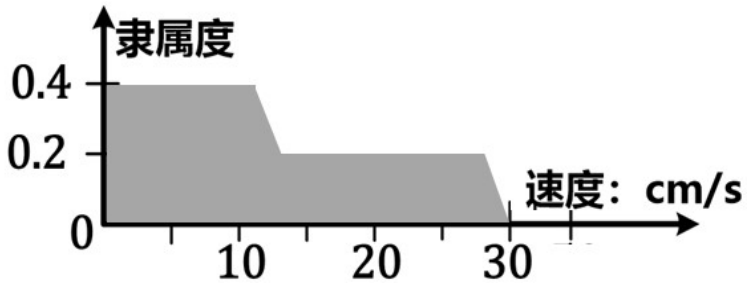
利用前件激活强度进行加权

ω_2

$$z_2 = p_2x + q_2y + r_2$$

六、基于模糊推理的信息融合

去模糊方法



模糊推理结果是模糊集合或者隶属函数。在实际应用中通常需要输出一确定值，根据推理结果隶属度计算输出单值的过程称为去模糊（解模糊）过程，也叫清晰化计算。

- 重心法：隶属度函数曲线与横轴围城区域的重心

$$Z_{COA}=\frac{\int_Z z\mu(z)dz}{\int_Z \mu(z)dz}$$

- 面积等分法：左右两侧隶属度函数区域的面积相等

$$\int_{\alpha}^{Z_{BOA}}\mu(z)dz=\int_{Z_{BOA}}^{\beta}\mu(z)dz$$

$$\alpha=\min\{z|z\in Z\}$$

$$\beta=\max\{z|z\in Z\}$$

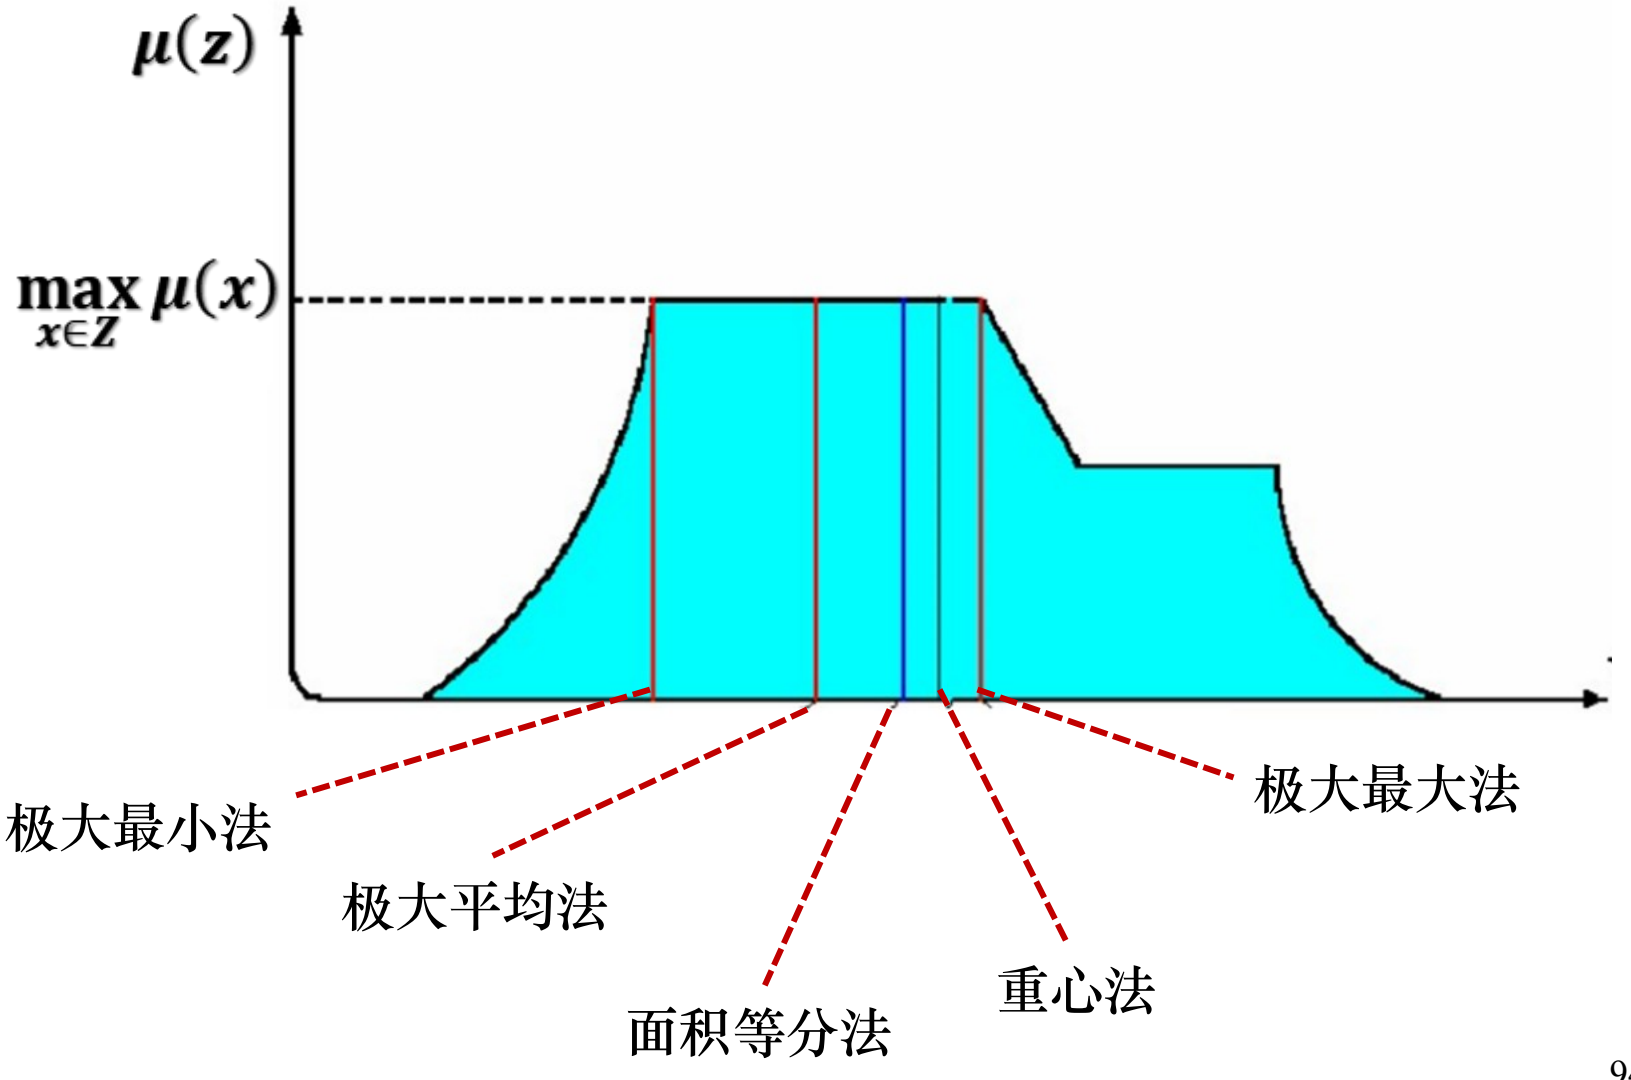
- 极大平均法：隶属度极大值区域的平均值

$$Z_{MoM}=\frac{\int_{Z'} zdz}{\int_{Z'} dz}\qquad Z'=\left\{z\middle|\mu(z)=\max_{x\in Z}\mu(x)\right\}$$

- 极大最大法
- 极大最小法

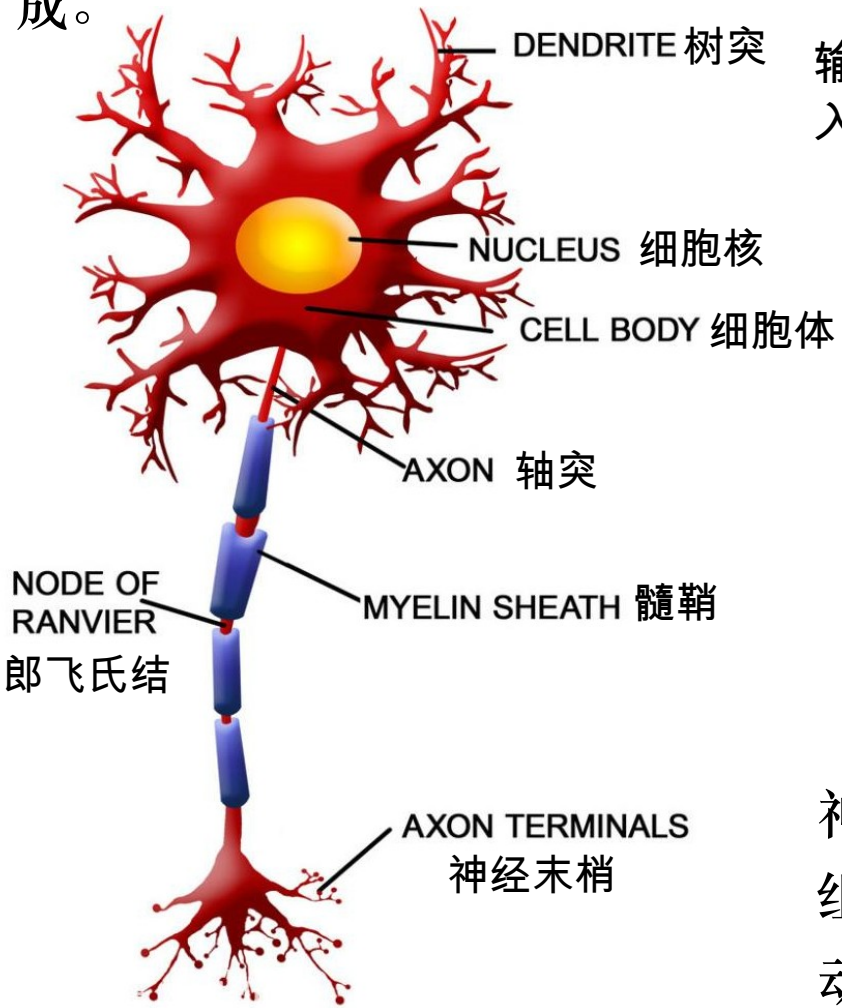
六、基于模糊推理的信息融合

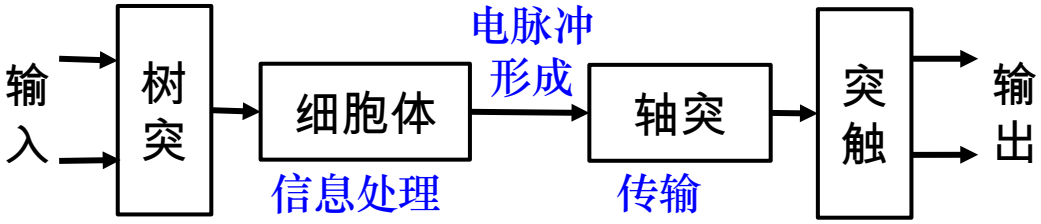
去模糊方法



七、基于神经网络的信息融合

神经元（神经细胞）：神经系统最基本的结构和功能单位，人脑约有百亿个神经元组成，神经元互连成为神经网络。主要由细胞体、树突、轴突和突触组成。





- 信息传递：用传导兴奋的方式沿突起作远距离传送；以电传导或化学传递的方式跨细胞传递。
- 信息处理
- 信息存储

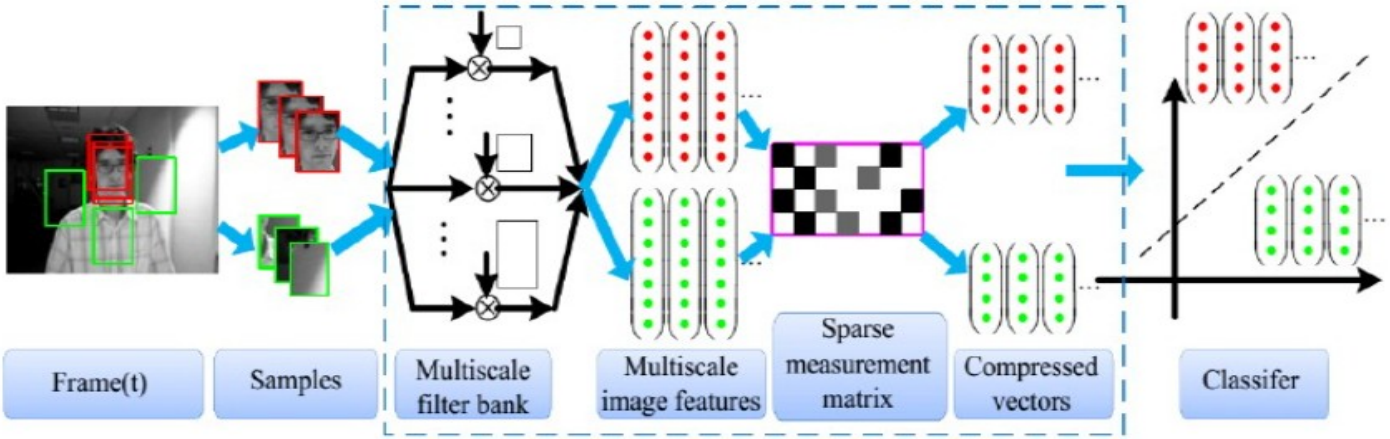
神经元通过突触连接，使数目众多的神经元组成比其他系统复杂得多的神经系统。由此动物能对环境变化做出快速整合性反应。

七、基于神经网络的信息融合

神经网络概述

人工神经网络（**Artificial Neural Network**，简称 **ANN**）是由具有适应性的简单单元组成的广泛并行互连的网络，试图模拟生物神经系统对真实世界物体所作出的交互反应。神经网络结构和工作机理基本上以人脑的组织结构和活动规律为背景，反应了人脑的某些基本特征，但并不是对人脑部分的真实再现，可以说人工神经网络是利用人工的方式对生物神经网络的模拟。

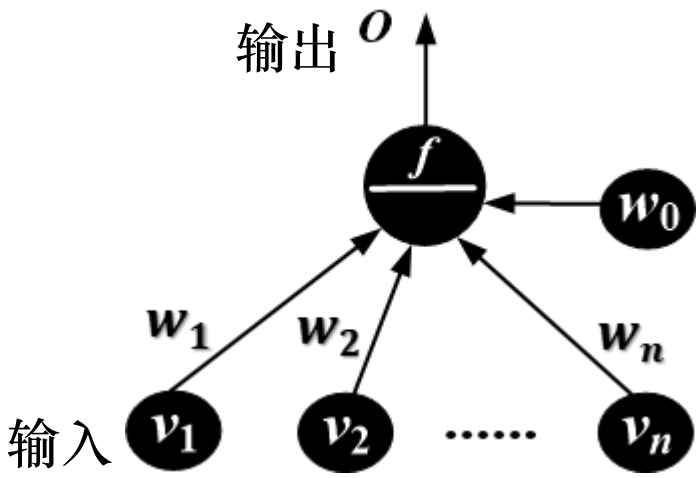
- 大脑神经网络是由神经元经突触与树突连接起来形成；
- 人工神经网络由基本处理单元及其互连方法决定。



七、基于神经网络的信息融合

神经网络概述

- 处理单元：单神经元 M-P 模型，感知器，基本模型 + 激活函数



(1) 从输入端接收输入信号v_i;

(2) 根据连接权值w_i，求所有输入的加权和

$$\sigma = \sum_{i=1}^{n} w_i v_i + w_0$$

(3) 非线性激活函数转换，获得输出o:

$$o = f(\sigma)$$

七、基于神经网络的信息融合

☐ 神经网络概述

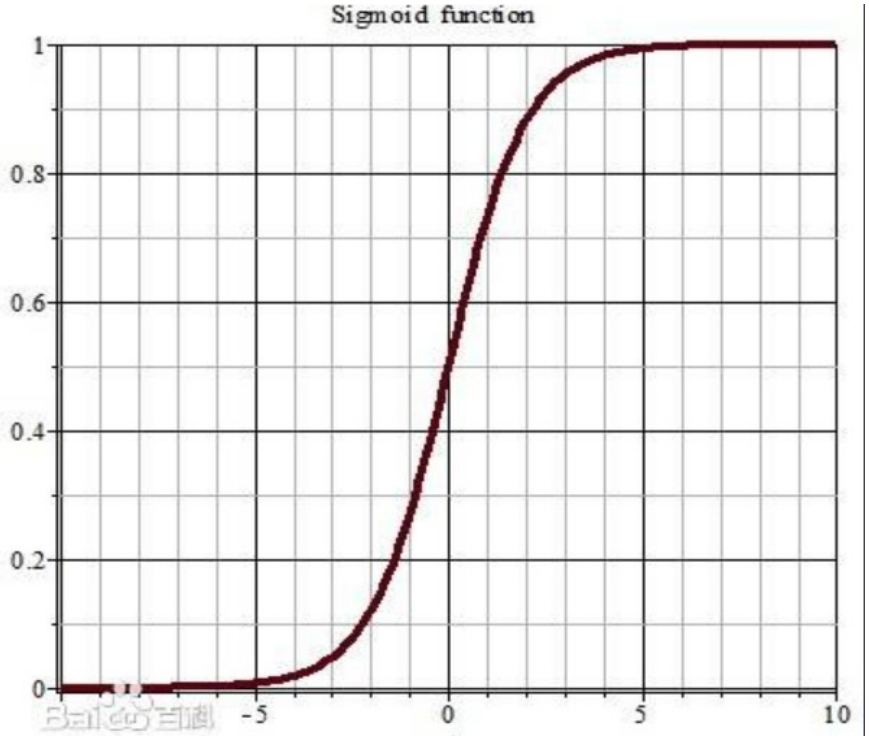
激活函数：非线性，实现阶跃功能，保证连续可微，常采用 **Sigmod** 函数

$$o = \begin{cases} 1, \sigma \geq 0 \\ 0, \sigma < 0 \end{cases}$$

Sigmod 函数
S 函数

$$o = \frac{1}{1 + e^{-\sigma}}$$

$$o' = \frac{e^{-\sigma}}{(1 + e^{-\sigma})^2} = o(1 - o)$$



七、基于神经网络的信息融合

神经网络概述

感知器训练：有监督学习，逐步地将样本输入到网络中，根据输出结果和理想输出之间的差别来调整网络中的权矩阵。

训练输入：一组样本(x_i, y_i)，x_i为样本输入矢量，y_i为样本期望输出（指导信号）

(1) 用适当的小伪随机数初始化矩阵W;

(2) 初始化：精度控制参数ε、学习率α、精度控制变量$d = \varepsilon + 1$;

(3) while $d > \varepsilon$ do

$d = 0$

for 每个样本(x_i, y_i) do

(a) 输入样本$x_i = [x_{i1}, x_{i2}, \cdots, x_{in}]^{\mathrm{T}}$

(b) **计算$o_i = f(W^T x_i)$**

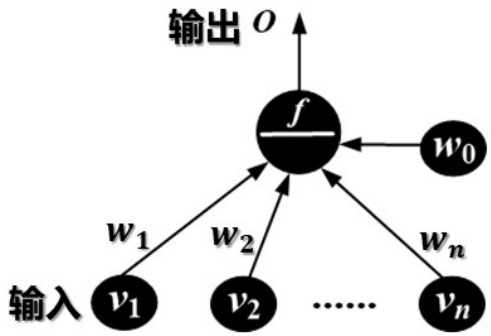
(c) 修改权值向量

for $j = 1, \cdots n$

$$w_j = w_j + \alpha(y_i - o_i)x_{ij}$$

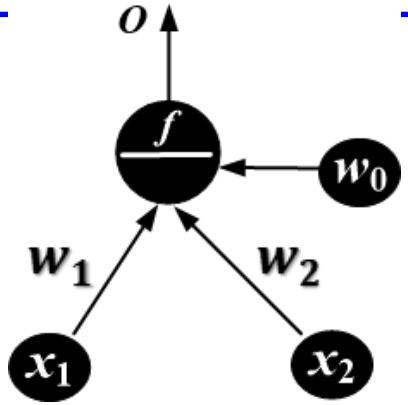
(d) 计算累积误差

$$d = d + (y_i - o_i)$$



七、基于神经网络的信息融合

神经网络概述



感知器举例：在简单感知器上利用误差学习算法实现表 1 所示真值表。

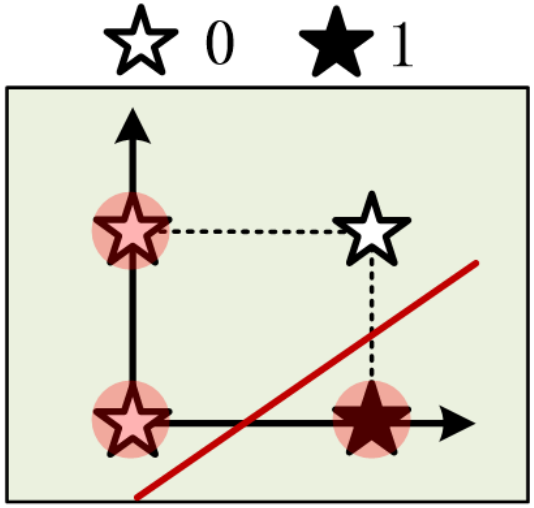
设置初始化参数$w_1(0) = 0.2$，$w_2(0) = -0.5$，$w_0(0) = -0.1$。在初始参数条件下，网络实际输出如表2所示，可以看出：有3个输入样本相应的输出都与期望的输出不符，即产生了误差。此时简单感知器产生的样本划分线为：

表 1

x_1	x_1	x_1
0	0	1
0	1	1
1	0	0
1	1	0

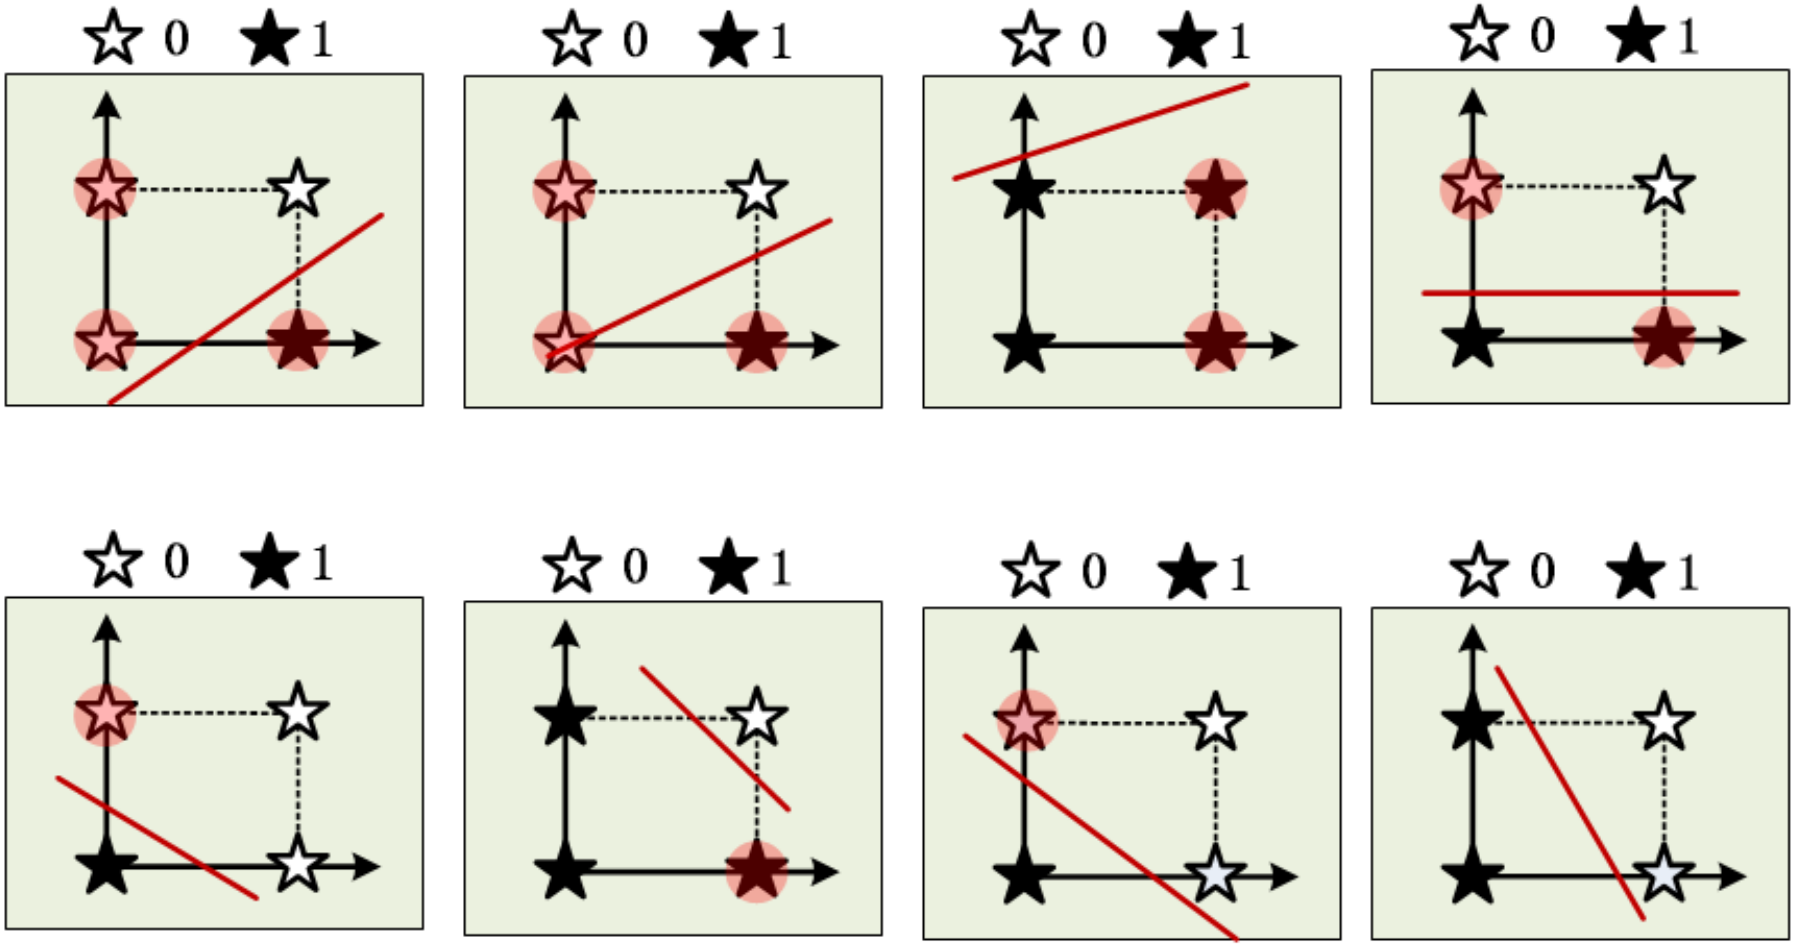
表 2

x_1	x_1	x_1
0	0	0
0	1	0
1	0	1
1	1	0



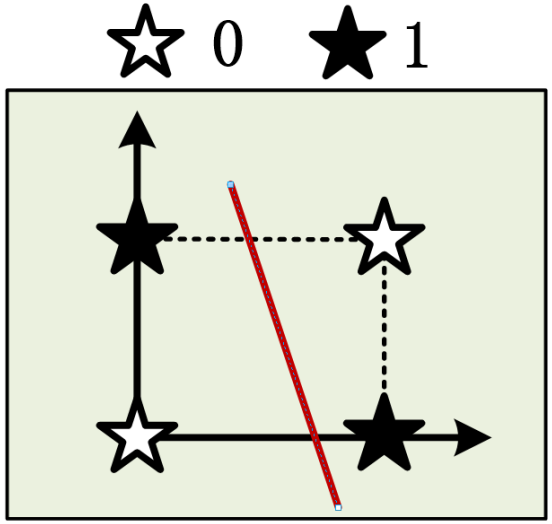
七、基于神经网络的信息融合

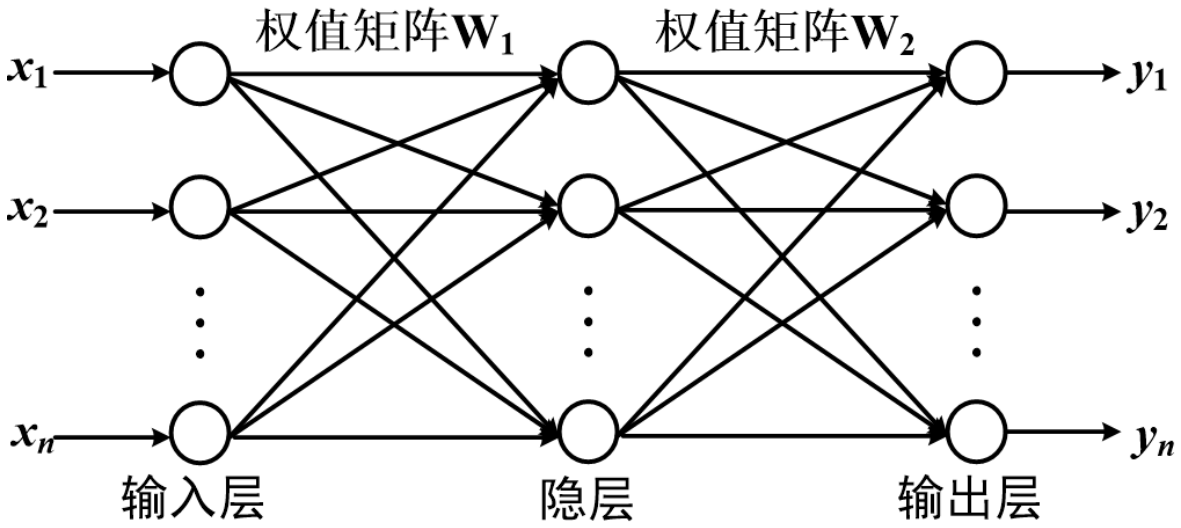
神经网络概述



七、基于神经网络的信息融合

神经网络概述



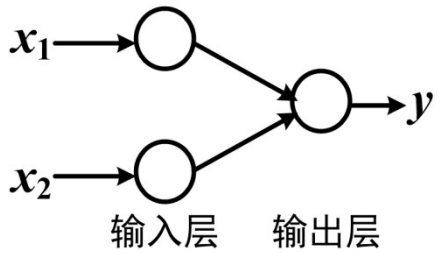
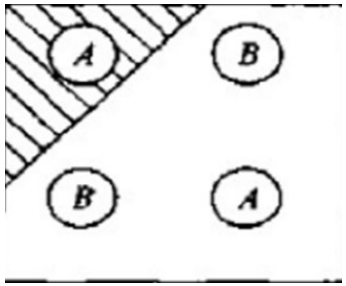
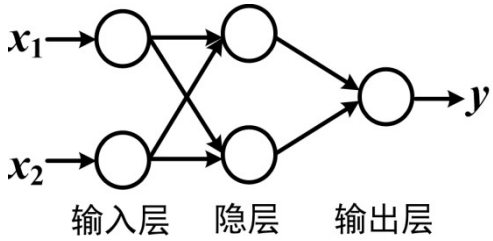
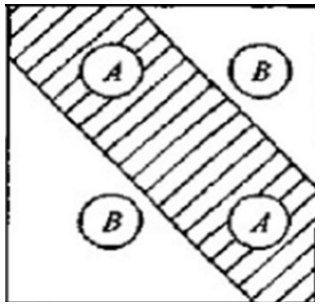
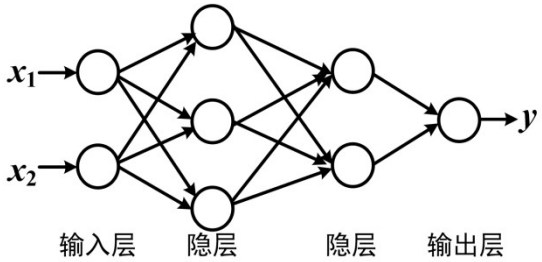
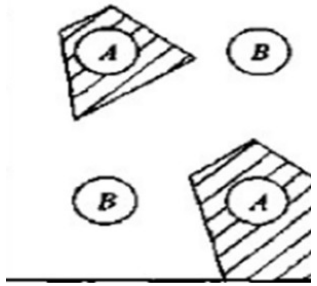


线性不可分问题：异或运算

多层感知机：**BP** 网络

七、基于神经网络的信息融合

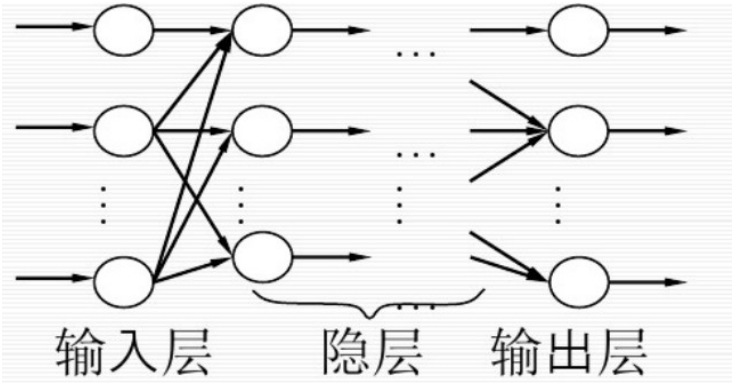
神经网络概述

结构	决策区域类型	区域形状	异或问题
	由一个超平面分成两个		
	开凸区域或闭凸区域		
	任意形状（其复杂度由单元数目确定）		

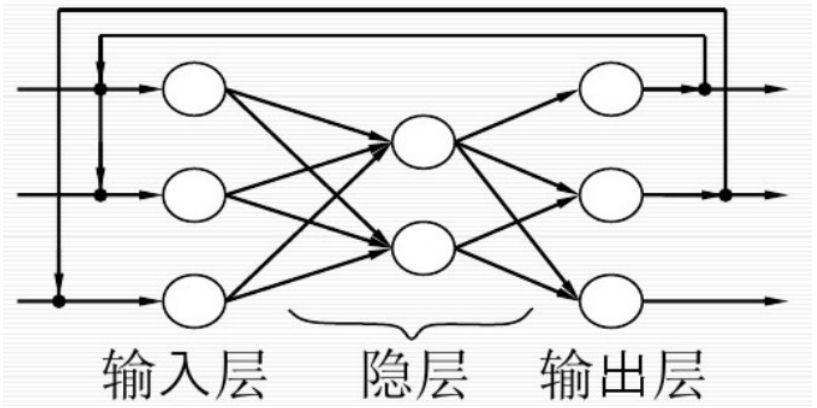
七、基于神经网络的信息融合

☐ 神经网络概述

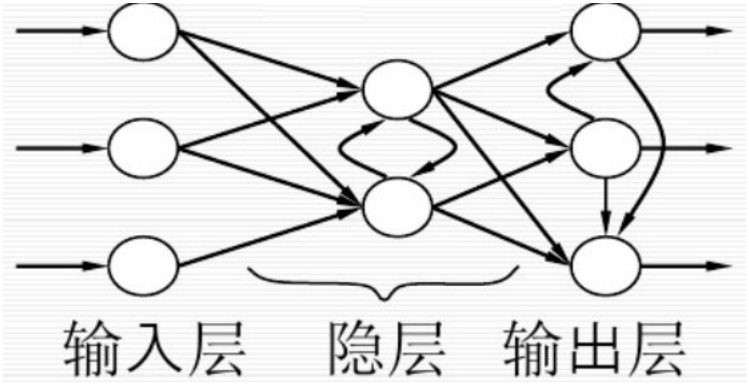
网络连接：前馈与反馈



前向网络



反馈网络



层内互连网络

七、基于神经网络的信息融合

神经网络概述

网络训练：根据样本调整权值，使网络输出满足给定要求

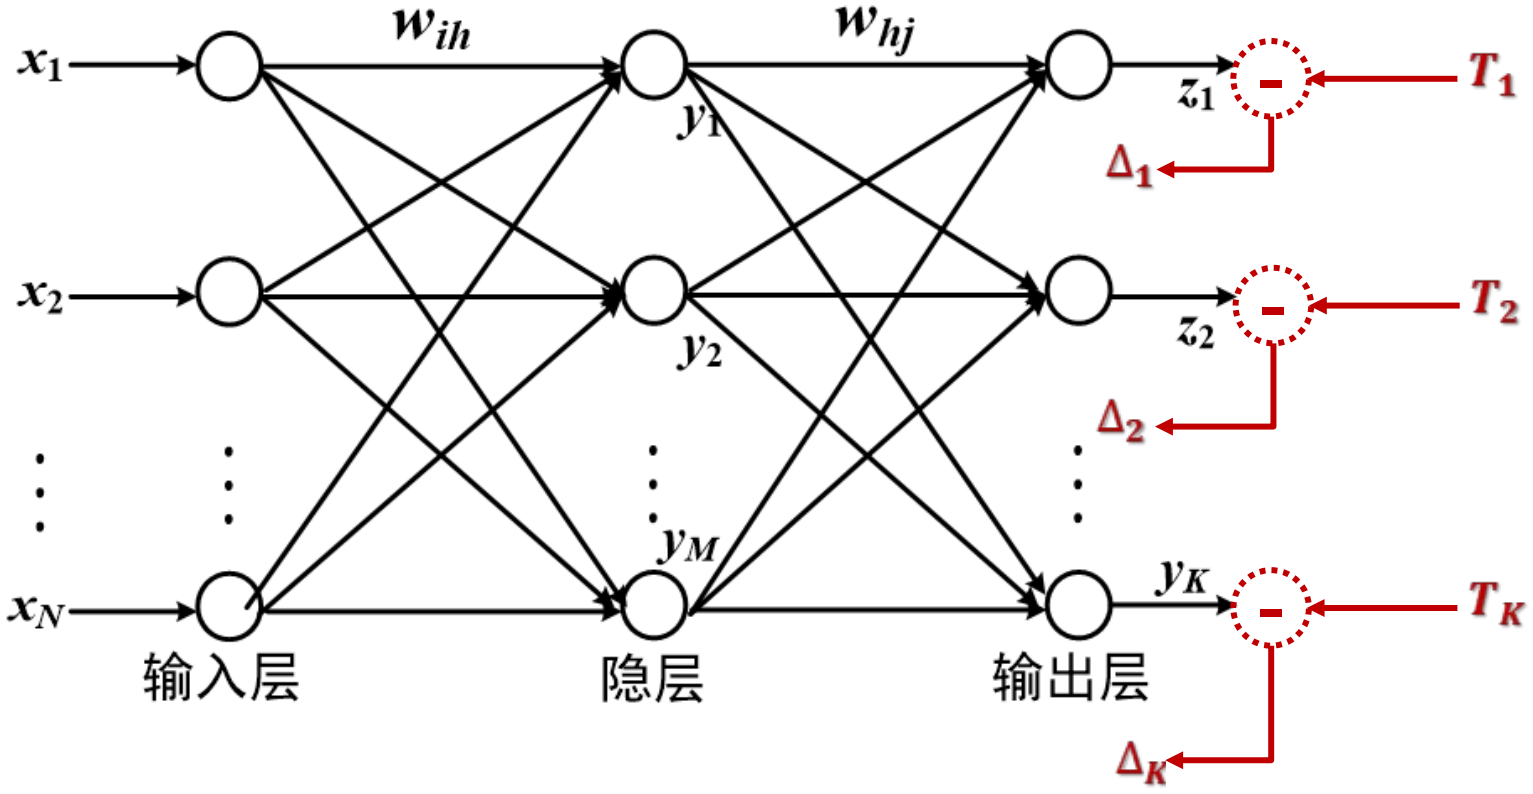
训练模式：

- 监督学习（有导师学习）：根据期望与实际的网络输出之间的差调整神经元连接的强度或权值。有输入有期望。
- 无监督学习（无导师学习）：自动地适应连接权值，以便按相似特征把输入模式分组聚类。有输入无期望。
- 强化学习：不需要老师给出目标输出，采用一个“评论员”来评价与给定输入相对应的神经网络输出的优良程度。尝试性学习。

发展：弱监督、半监督等等

七、基于神经网络的信息融合

BP 网络



- 激活函数：必须处处可导，使用 S 函数

$$o = \frac{1}{1+e^{-\sigma}} \qquad \sigma = \sum_{i=1}^{n} w_i v_i + s$$

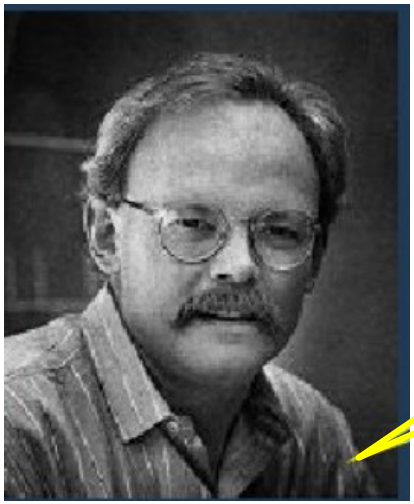
七、基于神经网络的信息融合

BP 网络

- Rumelhart， McClelland 于 1985 年提出了 BP 网络的误差反向后传 BP(Back Propagation) 学习算法



David Rumelhart

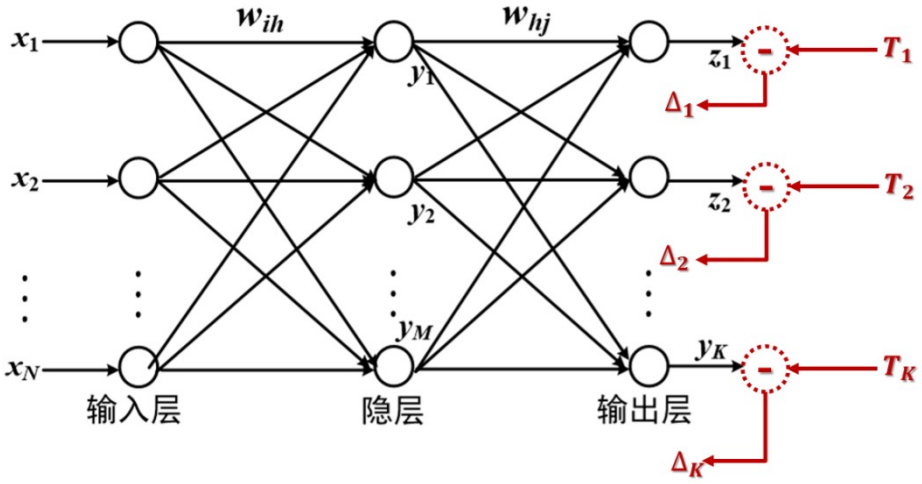


J.McClelland

- BP 算法基本原理：利用输出后的误差来估计输出层的直接前层的误差，再利用这个误差估计更前一层的误差，如此一层一层的反传下去，就获得了所有其他各层的误差估计

七、基于神经网络的信息融合

BP 网络



- 学习类型：监督学习（有导师学习）

- 核心思想：将输出误差以某种形式通过隐层向输入层逐层反传

将误差分摊给各层的所有单元 ---- 各层单元的误差信号 → 修正各单元权值

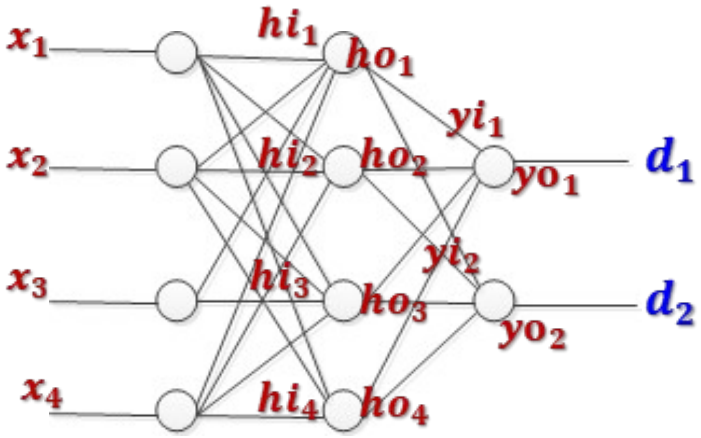
- 学习过程：

网络正向传播 → 误差的反向传播

- 学习终止判断：将网络输出误差减少到可接受的程度；或者进行到预先设定的学习次数。

七、基于神经网络的信息融合

BP 网络

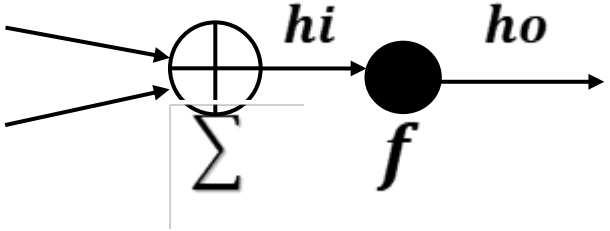


网络结构

- 输入层有 n 个神经元，隐层有 p 个神经元，输出层有 q 个神经元

变量定义

- 输入向量：$\mathrm{x} = \{x_1, x_2, \cdots, x_n\}$
- 隐层输入向量：$\mathrm{hi} = \{hi_1, hi_2, \cdots, hi_p\}$
- 隐层输出向量：$\mathrm{ho} = \{ho_1, ho_2, \cdots, ho_p\}$
- 输出层输入向量：$\mathrm{yi} = \{yi_1, yi_2, \cdots, yi_q\}$
- 输出层输出向量：$\mathrm{yo} = \{yo_1, yo_2, \cdots, yo_q\}$
- 期望输出向量：$\mathrm{d} = \{d_1, d_2, \cdots, d_q\}$

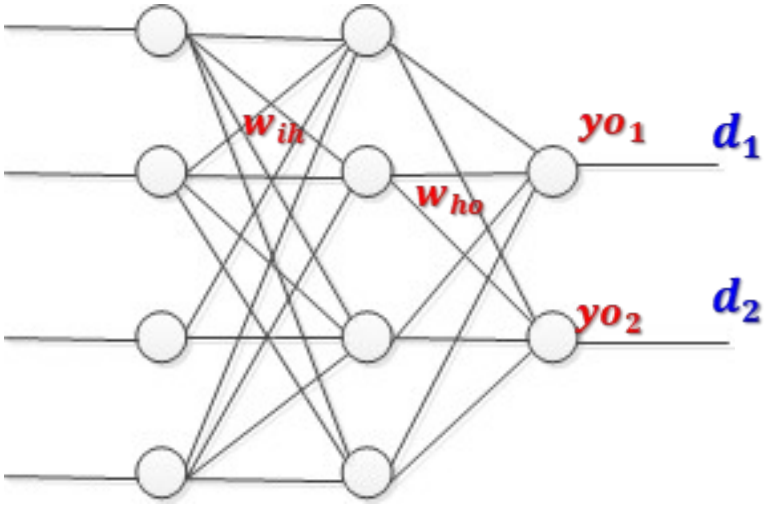


七、基于神经网络的信息融合

BP 网络

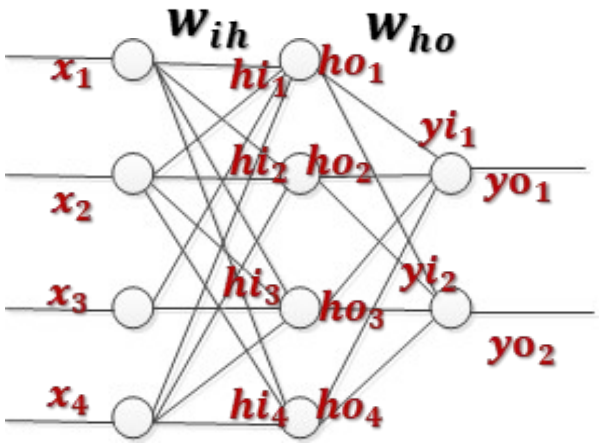
变量定义

- 输入层与隐层的连接权值：w_{ih}
- 隐层与输出层的连接权值：w_{ho}
- 隐层各神经元阈值：b_h
- 输出层各神经元阈值：b_o
- 样本数据个数：$k = 1, 2, \cdots, \mathrm{m}$
- 激活函数：$f(\cdot)$
- 误差函数：



$$e(k) = \frac{1}{2}\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)^2$$

七、基于神经网络的信息融合



BP 网络

- **Step1: 网络初始化**
  - 给各连接权值分别赋予一个区间（-1,1）内的随机数，设定误差函数e，给定计算精度值ε和最大学习次数M

- **Step2:** 随机选取第 k 个输入样本及对应期望输出

$$\mathbf{x}(k) = (x_1(k), x_2(k), \cdots, x_n(k)) \qquad \mathbf{d}(k) = \left(d_1(k), d_2(k), \cdots, d_q(k)\right)$$

- **Step3:** 计算隐层和输出层各神经元的输入和输出

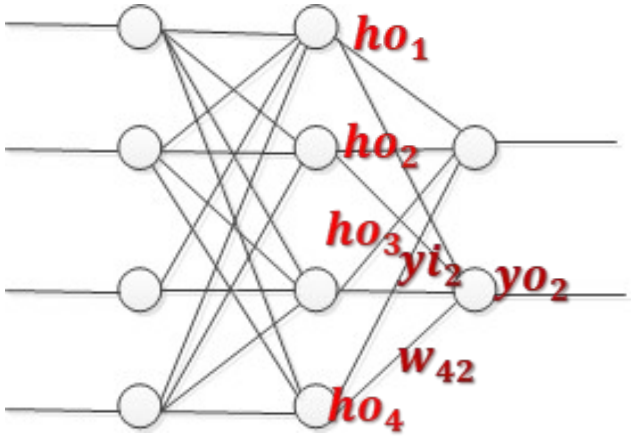
$$hi_h(k) = \sum_{i=1}^{n} w_{ih} x_i(k) - b_h \qquad yi_o(k) = \sum_{h=1}^{p} w_{ho} ho_h(k) - b_o$$

$$ho_h(k) = f(hi_h(k)) \qquad yo_o(k) = f(yi_o(k))$$

$$h = 1, 2, \cdots, p \qquad o = 1, 2, \cdots, q$$

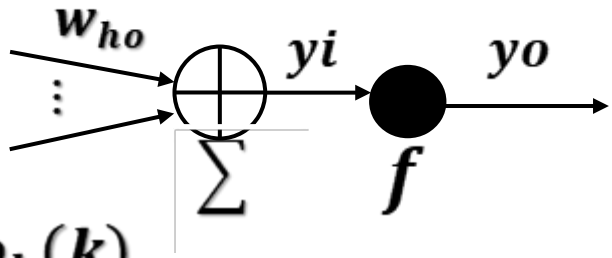
七、基于神经网络的信息融合

BP 网络



- **Step4**：利用网络期望输出和实际输出，计算误差函数对输出层各神经元的偏导数

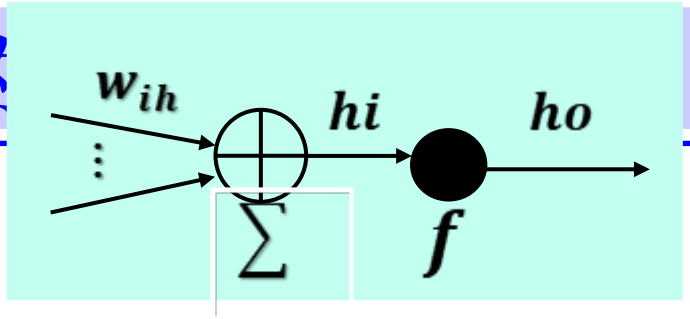
$$\frac{\partial e}{\partial w_{ho}} = \frac{\partial e}{\partial yi_o}\frac{\partial yi_o}{\partial w_{ho}} = -\delta_o(k)\, ho_h(k)$$



$$\frac{\partial yi_o}{\partial w_{ho}} = \frac{\partial\left(\sum_{h=1}^{p} w_{ho} ho_h(k) - b_o\right)}{\partial w_{ho}} = ho_h(k)$$

$$\frac{\partial e}{\partial yi_o} = \frac{\partial e}{\partial yo_o}\frac{dyo_o}{dyi_o} = \frac{\partial\left(\frac{1}{2}\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)^2\right)}{\partial yo_o(k)}\frac{dyo_o(k)}{dyi_o(k)}$$

$$= -\left(d_o(k) - yo_o(k)\right)\frac{df\left(yi_o(k)\right)}{dyi_o} = -\left(d_o(k) - yo_o(k)\right)f'\left(yi_o(k)\right) \triangleq -\delta_o(k)$$

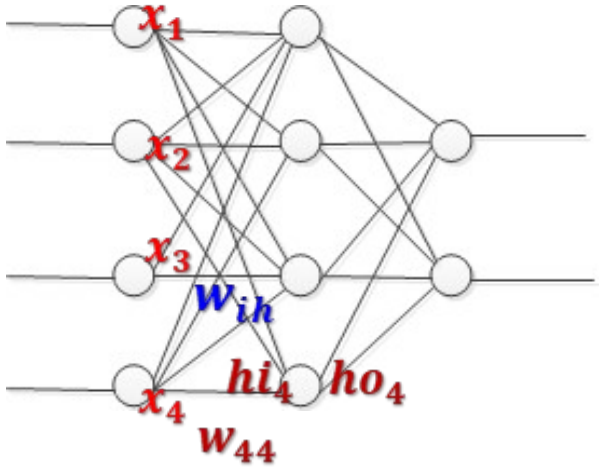


BP 网络

- **Step5：利用隐层到输出层的连接权值、输出层的$\delta_o(k)$和隐含层的输出计算误差函数对隐含层各神经元的偏导数$\delta_h(k)$。**

$$\frac{\partial e}{\partial w_{ih}} = \frac{\partial e}{\partial hi_h(k)} \frac{\partial hi_h(k)}{\partial w_{ih}}$$

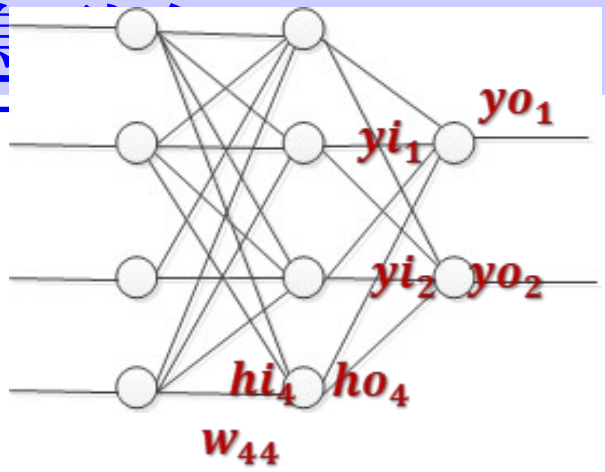
$$= -\delta_h(k) x_i(k)$$



$$\frac{\partial hi_h(k)}{\partial w_{ih}} = \frac{\partial\left(\sum_{i=1}^{n} w_{ih} x_i(k) - b_h\right)}{\partial w_{ih}} = x_i(k)$$

$$\frac{\partial e}{\partial hi_h(k)} = -\left(\sum_{o=1}^{q} \delta_o(k) w_{ho}\right) f'\left(hi_h(k)\right) = -\delta_h(k)$$

$$\delta_o(k) = \left(d_o(k) - yo_o(k)\right) f'\left(yi_o(k)\right)$$ 的信息



$$\frac{\partial e}{\partial hi_h(k)} = \frac{\partial\left(\frac{1}{2}\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)^2\right)}{\partial ho_h(k)} \frac{\partial ho_h(k)}{\partial hi_h(k)}$$

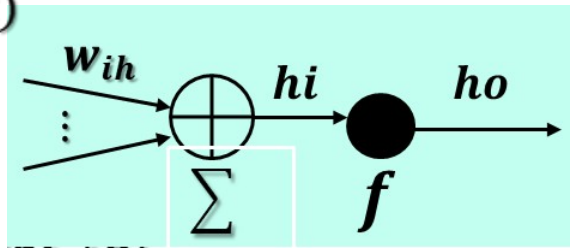
$$= -\left(\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)\frac{\partial yo_o(k)}{\partial ho_h(k)}\right)\frac{\partial ho_h(k)}{\partial hi_h(k)}$$

$$= -\left(\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)\frac{\partial yo_o(k)}{\partial yi_o(k)}\frac{\partial yi_o(k)}{\partial ho_h(k)}\right)\frac{\partial ho_h(k)}{\partial hi_h(k)}$$

$$yo_o(k) = f(yi_o(k))$$

$$= -\left(\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)f'(yi_o(k))\frac{\partial yi_o(k)}{\partial ho_h(k)}\right)\frac{\partial ho_h(k)}{\partial hi_h(k)}$$

$$= -\left(\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)f'(yi_o(k))w_{ho}\right)\frac{\partial ho_h(k)}{\partial hi_h(k)}$$

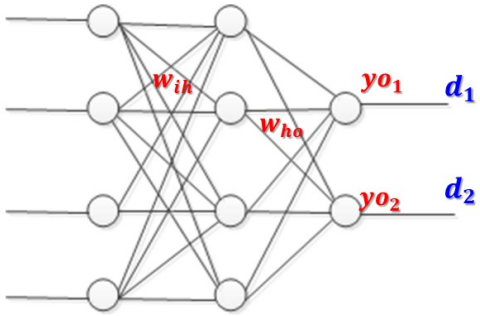


$$= -\left(\sum_{o=1}^{q}\delta_o(k)w_{ho}\right)\frac{\partial ho_h(k)}{\partial hi_h(k)}$$

$$yi_o(k) = \sum_{h=1}^{p} w_{ho} ho_h(k) - b_o$$

$$= -\left(\sum_{o=1}^{q}\delta_o(k)w_{ho}\right)f'\left(hi_h(k)\right) = -\delta_h(k)$$

$$ho_h(k) = f(hi_h(k))$$

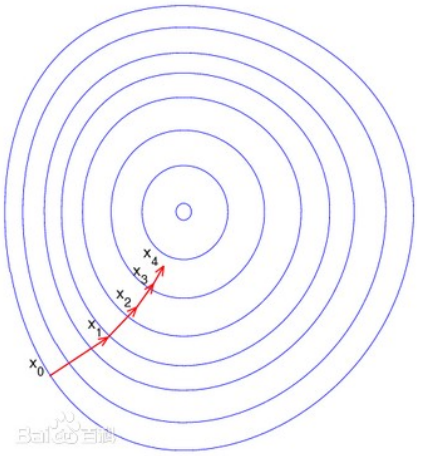


$$\frac{\partial e}{\partial w_{ho}} = -\delta_o(k)\, ho_h(k)$$

□ BP 网

$$\delta_o(k) = \big(d_o(k) - yo_o(k)\big) f'\big(yi_o(k)\big)$$

■ **Step6：利用输出层各神经元的$\delta_o(k)$和隐层各神经元输出来修正连接权值w_{ho}**



$$\Delta w_{ho} = -\mu \frac{\partial e}{\partial w_{ho}} = \mu \delta_o(k)\, ho_h(k)$$

$$w_{ho}{}^{N+1} = w_{ho}{}^{N} + \Delta w_{ho} = w_{ho}{}^{N} + \mu \delta_o(k)\, ho_h(k)$$

✓ 基本思想：梯度下降法，也称为最速下降法，是一个最优化算法。最速下降法是用负梯度方向为搜索方向的，最速下降法越接近目标值，步长越小，前进越慢。

✓ **μ步长：步长大，初期收敛速度快，能够逃离局部最小，但到后期收敛性能差。**

七、基于神经网络的信息融合

BP 网络

$$\frac{\partial e}{\partial w_{ih}} = -\delta_h(k)x_i(k) \qquad \left(\sum_{o=1}^{q}\delta_o(k)w_{ho}\right)f'(hi_h(k)) = \delta_h(k)$$

- **Step7：利用隐层各神经元的$\delta_h(k)$和输入层各神经元的输入修正连接权值w_{ih}**

$$\Delta w_{ih}(k) = -\mu\frac{\partial e}{\partial w_{ih}} = \mu\delta_h(k)x_i(k)$$

$$w_{ih}{}^{N+1} = w_{ih}{}^{N} + \Delta w_{ih} = w_{ih}{}^{N} + \mu\delta_h(k)x_i(k)$$

- **Step8**：计算全局误差

$$E = \frac{1}{2m}\sum_{k=1}^{m}\sum_{o=1}^{q}\left(d_o(k) - yo_o(k)\right)^2$$

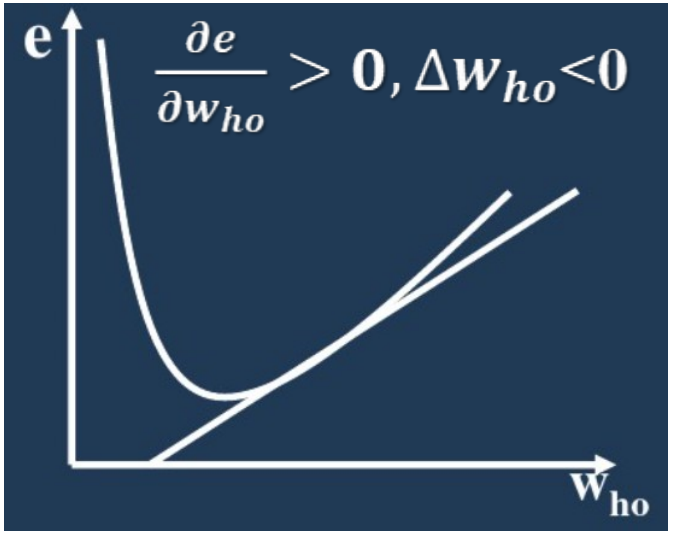
- **Step9**：判断网络误差是否满足要求。当误差达到预设精度或学习次数大于设定最大次数，则结束算法。否者，选取下一个样本及对应的期望输出，返回 **Step3**，进行下一轮学习。

七、基于神经网络的信息融合

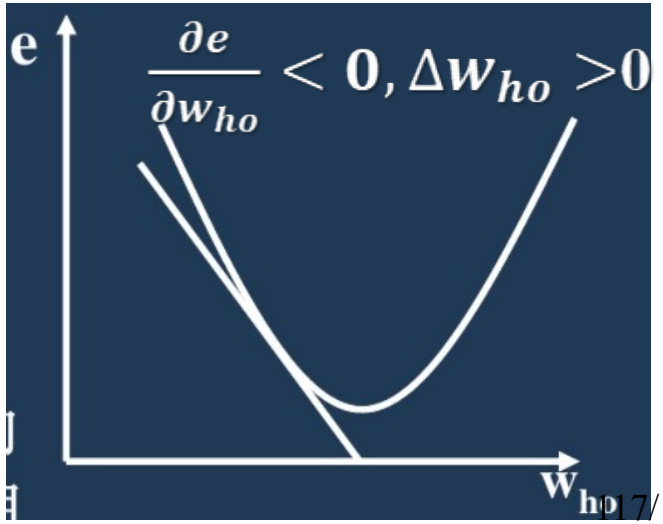
BP 网络

BP 算法的直观解释：

- 当误差对权值的偏导数大于 0 时，权值调整量为负，权值向减少方向调整，使得实际输出与期望输出之间的差减少



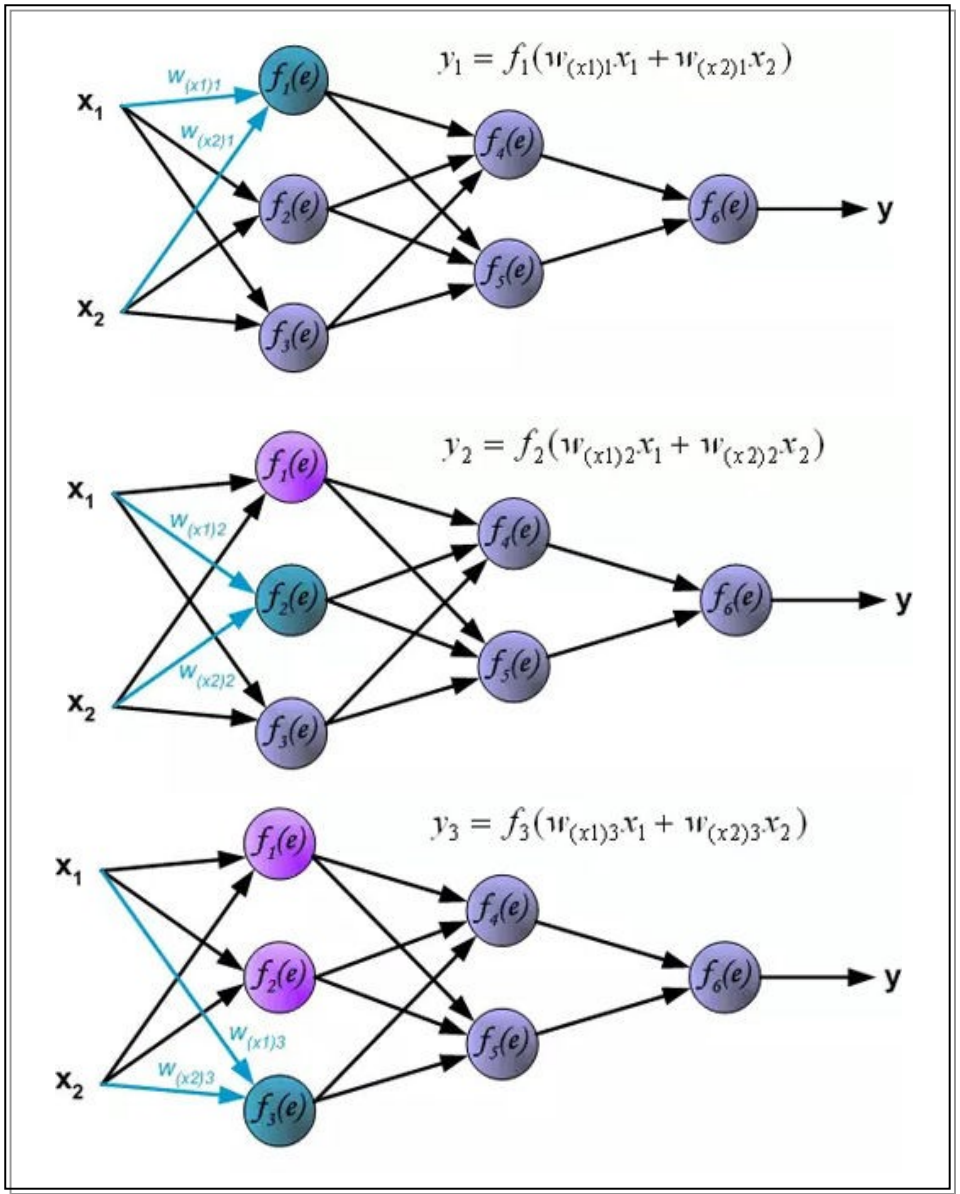
- 当误差对权值的偏导数小于 0 时，权值调整量为正，权值向增加方向调整，使得实际输出与期望输出之间的差减少

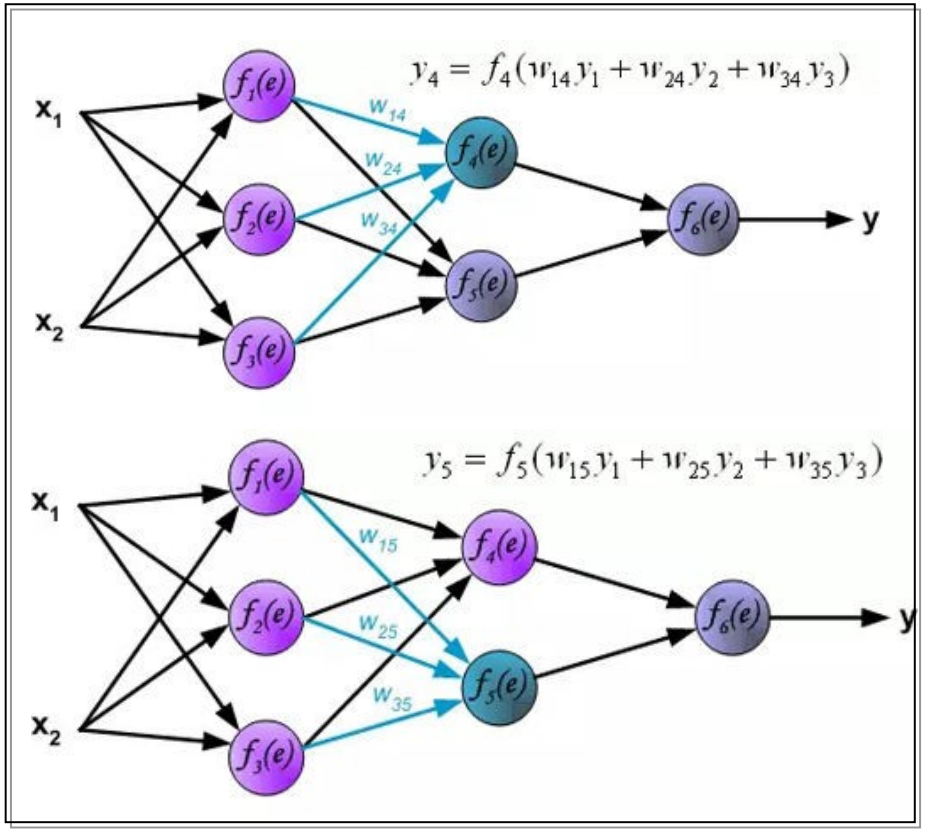


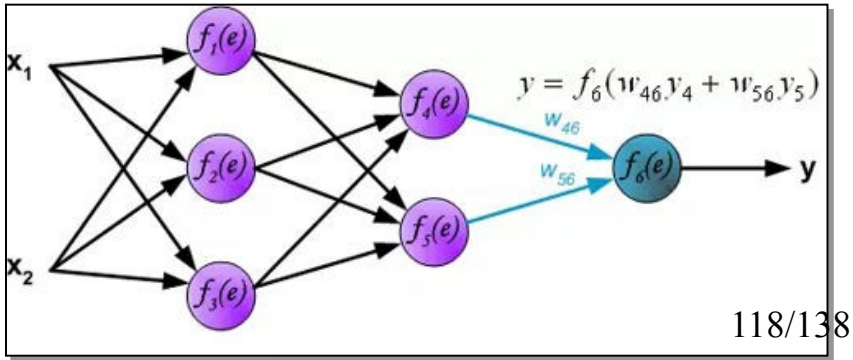
$$\Delta w_{ho} = -\mu \frac{\partial e}{\partial w_{ho}}$$

七、基于神经网络的信息融合

BP 网络：前向传播

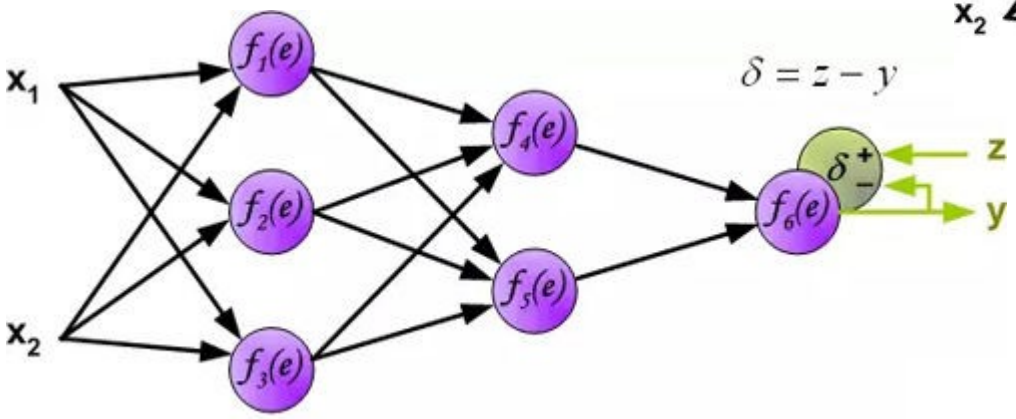


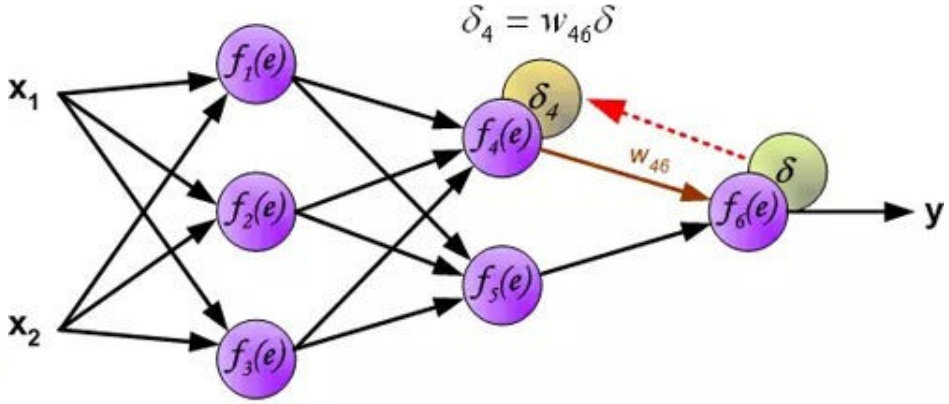


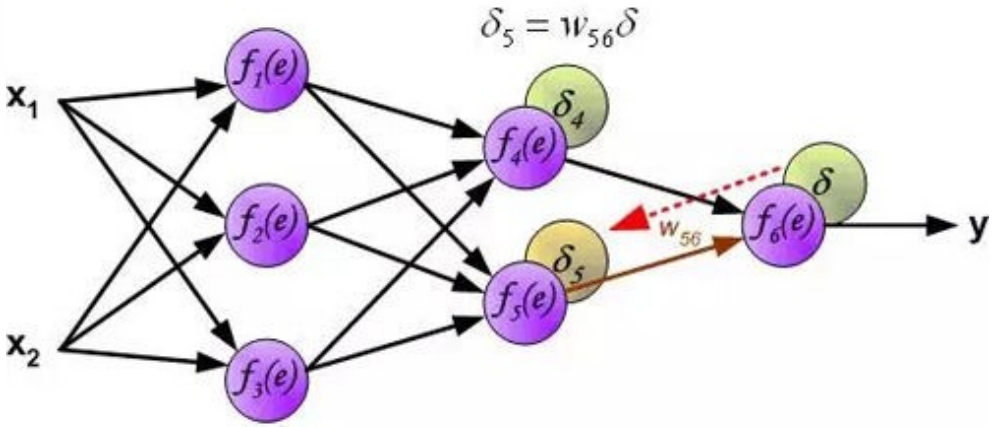


七、基于神经网络的信息融合

BP 网络：误差反向传播

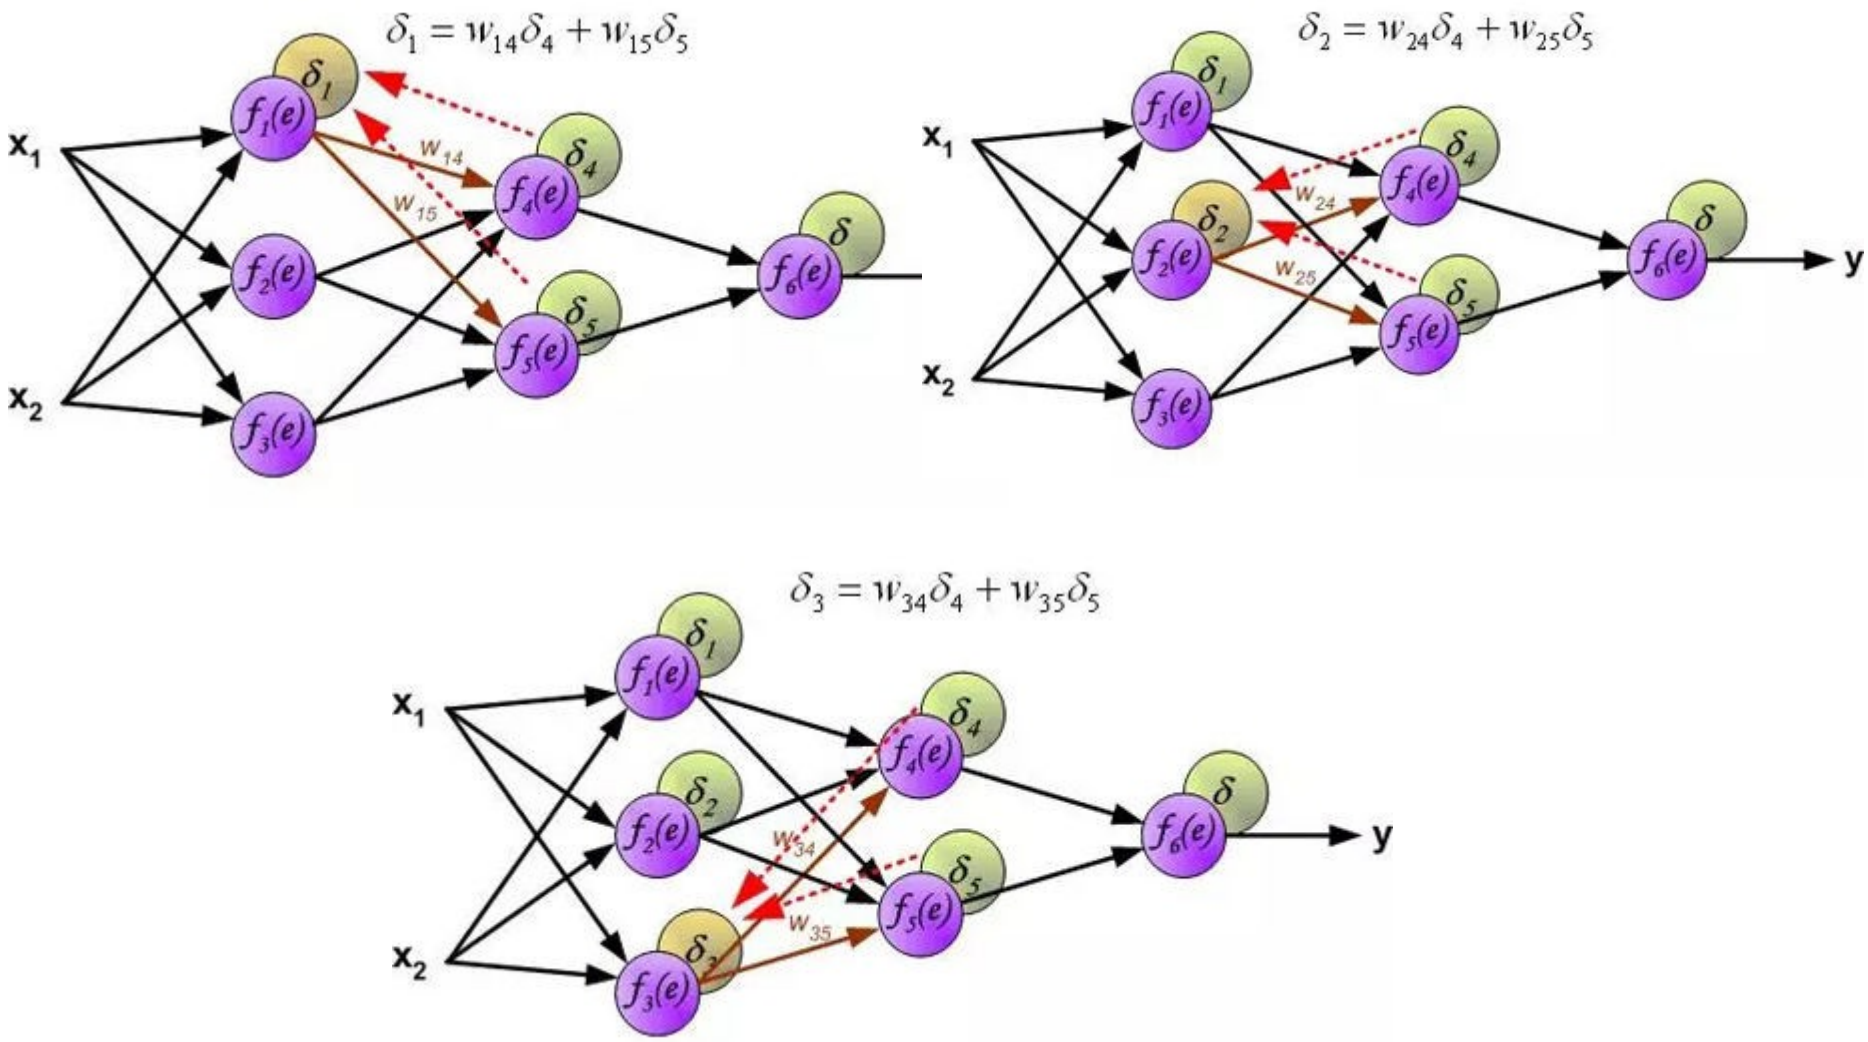






七、基于神经网络的信息融合

BP 网络：误差反向传播

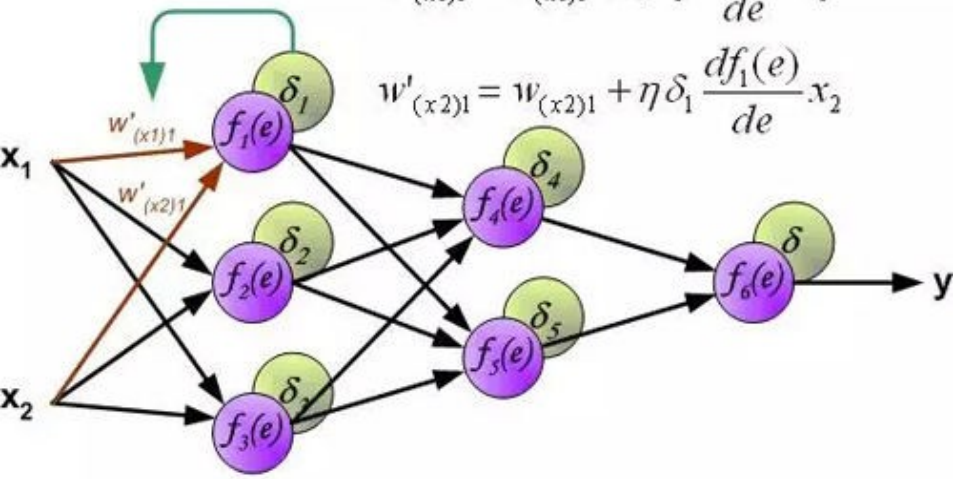


七、基于神经网络的信息融合

BP 网络：误差反向传播后的权值更新

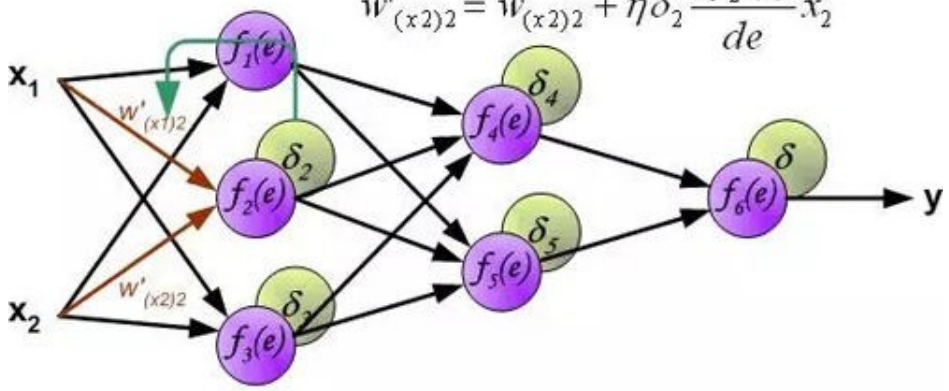
$$w'_{(x1)1} = w_{(x1)1} + \eta\delta_1 \frac{df_1(e)}{de} x_1$$

$$w'_{(x2)1} = w_{(x2)1} + \eta\delta_1 \frac{df_1(e)}{de} x_2$$



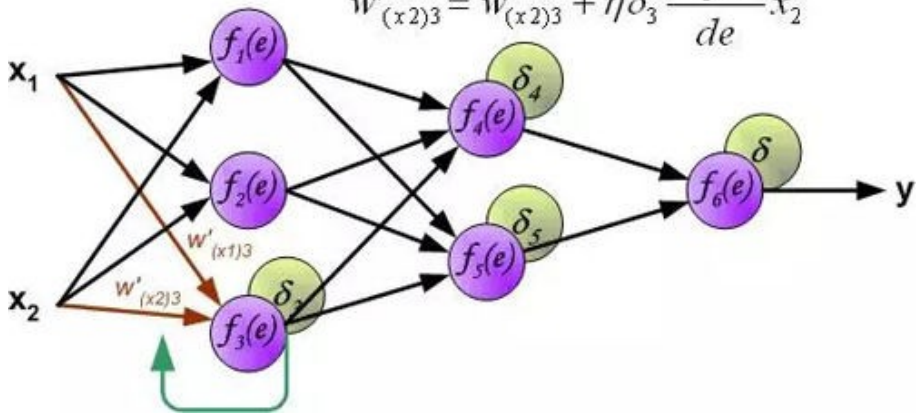
$$w'_{(x1)2} = w_{(x1)2} + \eta\delta_2 \frac{df_2(e)}{de} x_1$$

$$w'_{(x2)2} = w_{(x2)2} + \eta\delta_2 \frac{df_2(e)}{de} x_2$$



$$w'_{(x1)3} = w_{(x1)3} + \eta\delta_3 \frac{df_3(e)}{de} x_1$$

$$w'_{(x2)3} = w_{(x2)3} + \eta\delta_3 \frac{df_3(e)}{de} x_2$$



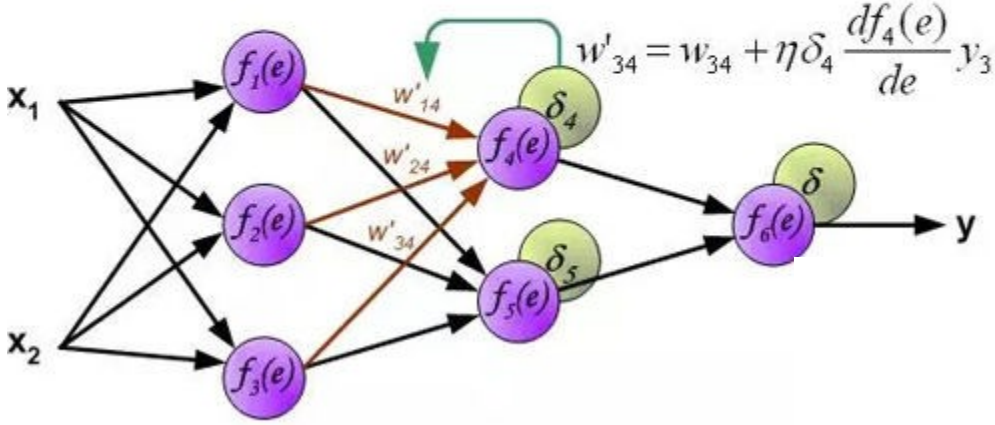
七、基于神经网络的信息融合

- **BP** 网络：误差反向传播后的权值更新

$$w'_{14} = w_{14} + \eta\delta_4 \frac{df_4(e)}{de} y_1$$

$$w'_{24} = w_{24} + \eta\delta_4 \frac{df_4(e)}{de} y_2$$

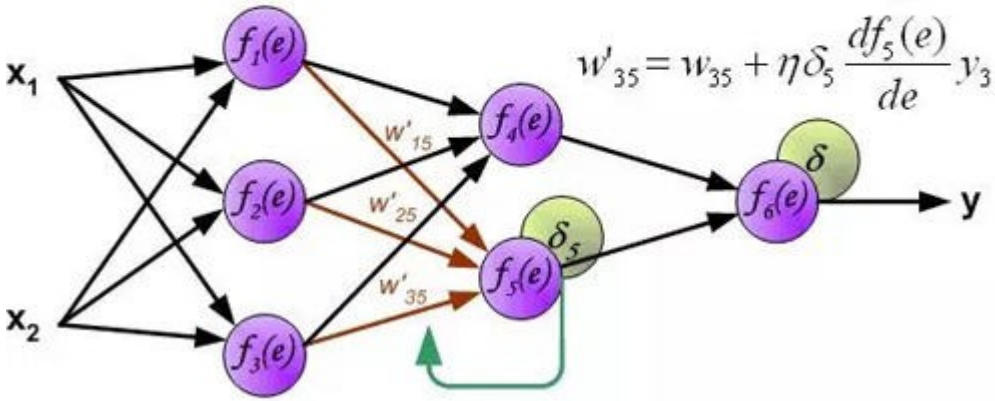
$$w'_{34} = w_{34} + \eta\delta_4 \frac{df_4(e)}{de} y_3$$



$$w'_{15} = w_{15} + \eta\delta_5 \frac{df_5(e)}{de} y_1$$

$$w'_{25} = w_{25} + \eta\delta_5 \frac{df_5(e)}{de} y_2$$

$$w'_{35} = w_{35} + \eta\delta_5 \frac{df_5(e)}{de} y_3$$

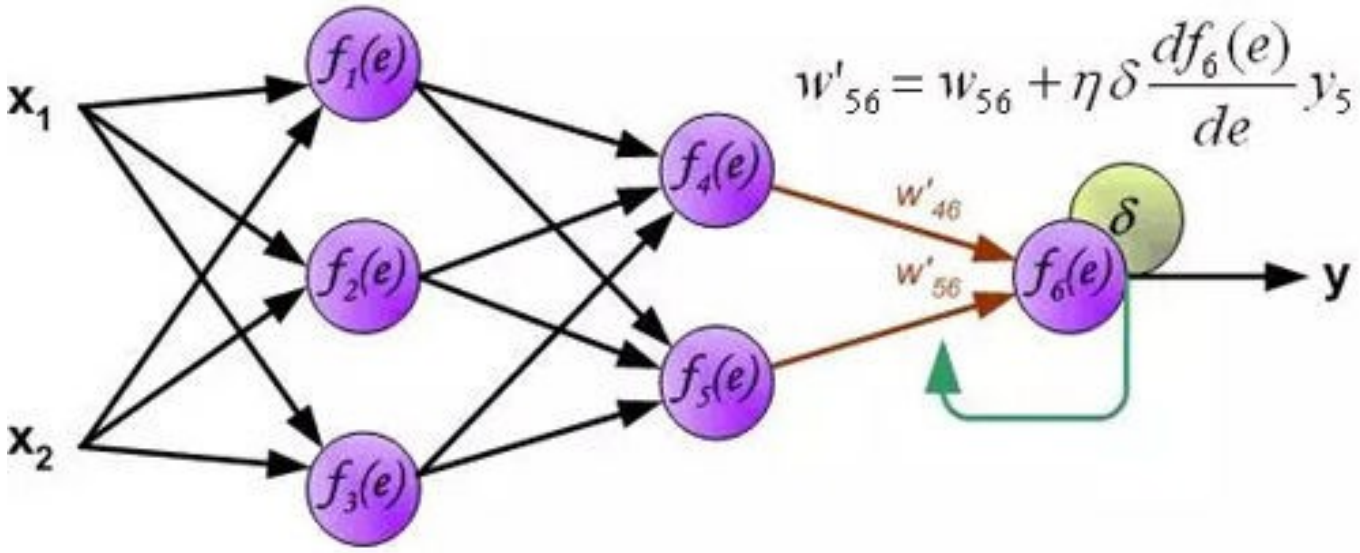


七、基于神经网络的信息融合

- **BP** 网络：误差反向传播后的权值更新

$$w'_{46} = w_{46} + \eta\delta\frac{df_6(e)}{de}y_4$$

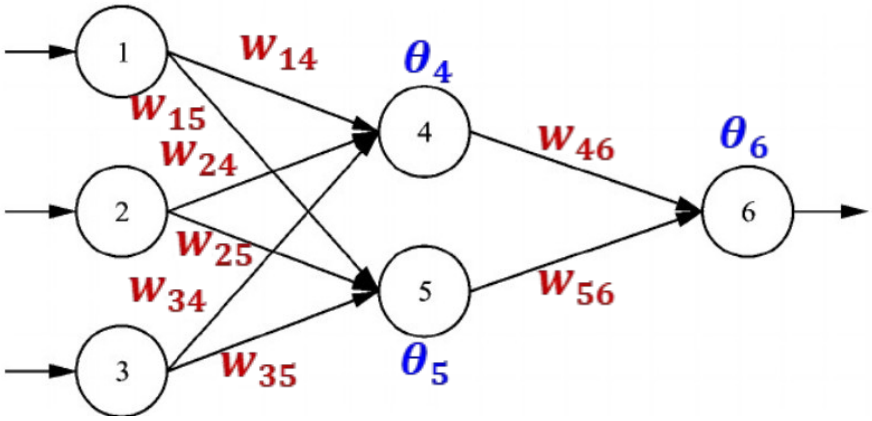
$$w'_{56} = w_{56} + \eta\delta\frac{df_6(e)}{de}y_5$$

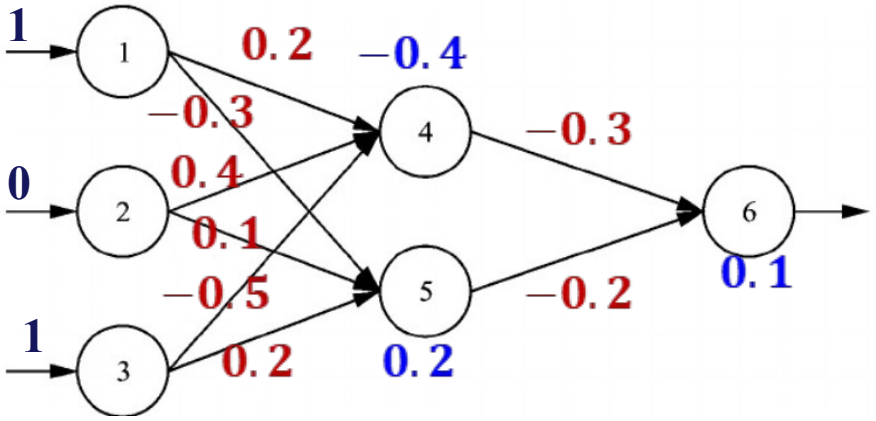


七、基于神经网络的信息融合

BP 网络： BP 算法计算案例

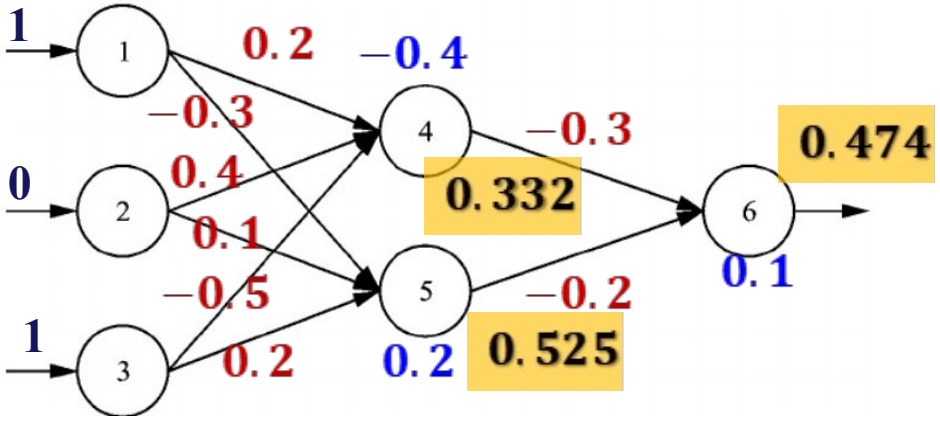
【例】假设训练样本S的属性值为$\{1, 0, 1\}$，实际类别为1，两层前馈神经网络NT如左图所示。NT中每条有向加权边的权重、每个隐层与输出层单元的偏置如右图所示。学习率为0.9。写出输入S训练NT的过程





七、基于神经网络的信息融合

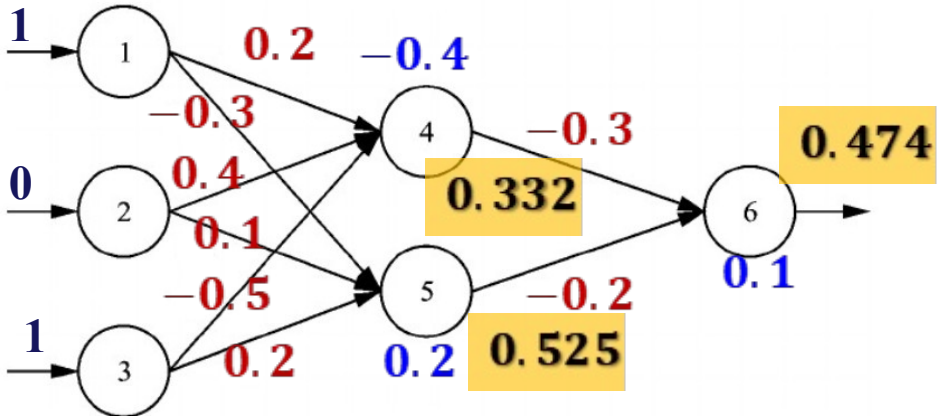
BP 网络： BP 算法计算案例



前向传播计算隐层和输出层单元的输出：

单元 j	单元j	输入I_j	单元j	
4	单元j	输入I_j	单元j	
5	单元j	输入I_j	单元j	
6	单元j	输入I_j	单元j	

七、基于神经网络的信息融合



$$o = \frac{1}{1+e^{-\sigma}}$$

$$o' = \frac{e^{-\sigma}}{(1+e^{-\sigma})^2} = o(1-o)$$

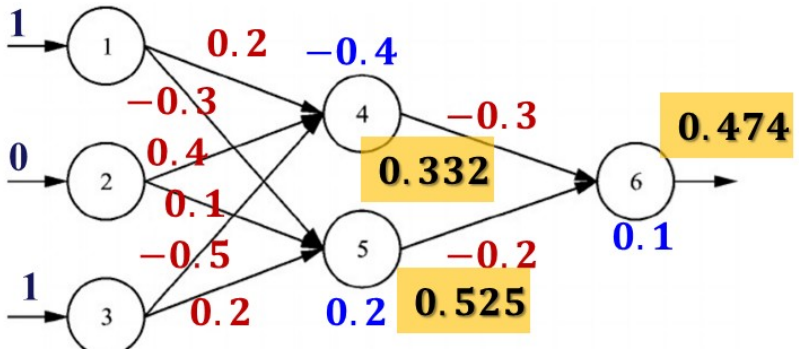
反向传播计算隐层和输出层每个单元的误差：

单元 j	误差
6	单元j 误差
	$\delta_6 = (d_6 - yo_6)f'(yi_6) = yo_6(1-yo_6)(d_6 - yo_6)$
5	单元j 误差
	6 $\delta_6 = (d_6 - yo_6)f'(yi_6) = yo_6(1-yo_6)(d_6 - yo_6)$ $= 0.474 \times (1-0.474) \times (1-0.474) = 0.1311$
	(q)
4	单元j 误差
	$\delta_6 = (d_6 - yo_6)f'(yi_6) = yo_6(1-yo_6)(d_6 - yo_6)$

$$\delta_6 = 0.1311$$

$$\delta_5 = -0.0065$$

$$\delta_4 = -0.0087$$



利用梯度下降法更新权值：

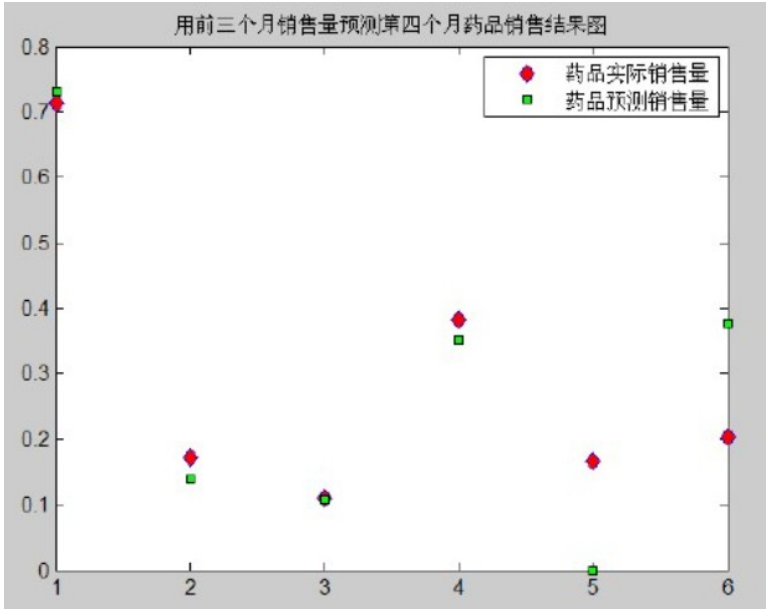
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$
w_{46}^{N+1}	w_{46}^{N+1}	$= w_{46}^{N} + \mu\delta_6 ho_4 = -0.3 + 0.9 \times 0.1311 \times 0.332 = -$

七、基于神经网络的信息融合

BP 网络：应用案例

- 示例：药品销售量预测，三层网络，用前 3 个月的销量预测第 4 个月。

月份	1	2	3	4	5	6
销量	2056	2395	2600	2298	1634	1600
月份	7	8	9	10	11	12
销量	1873	1478	1900	1500	2046	1556




```
net=newff([0 1;0 1;0 1],[5,1],{'tansig','logsig'},'traingd');
net.trainParam.epochs=15000;
net.trainParam.goal=0.01;
    %设置学习速率为0.1
LP.lr=0.1;
net=train(net,P,T);
```

七、基于神经网络的信息融合

BP 网络（其它神经网络）特性

■ 非线性映射能力

能学习和存储大量输入 - 输出模式的映射关系，无需事先了解描述这种映射关系的数学方程，只要能提供足够多的样本模式对网络进行学习训练，它便能够完成由 n 输入维空间到 m 维输出空间的非线性映射。

■ 容错能力

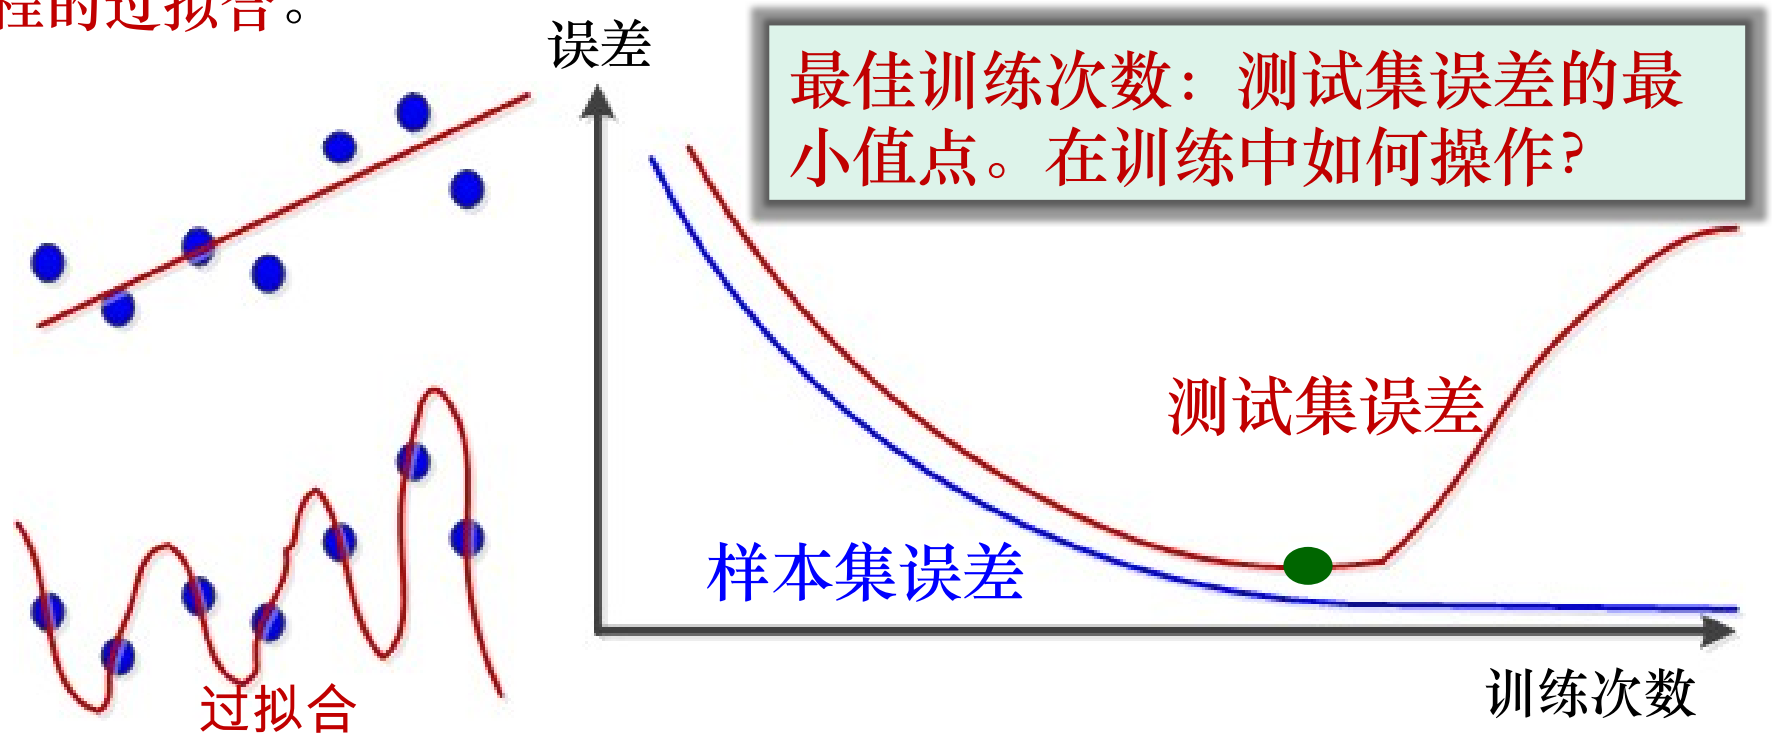
输入样本中带有较大误差甚至个别错误对网络的输入输出规律影响很小。

七、基于神经网络的信息融合

BP 网络（其它神经网络）特性

泛化能力

当向网络输入训练时未曾见过的非样本数据时，网络也能完成由输入空间向输出空间的正确映射。这种能力称为泛化能力。防止训练过程的过拟合。

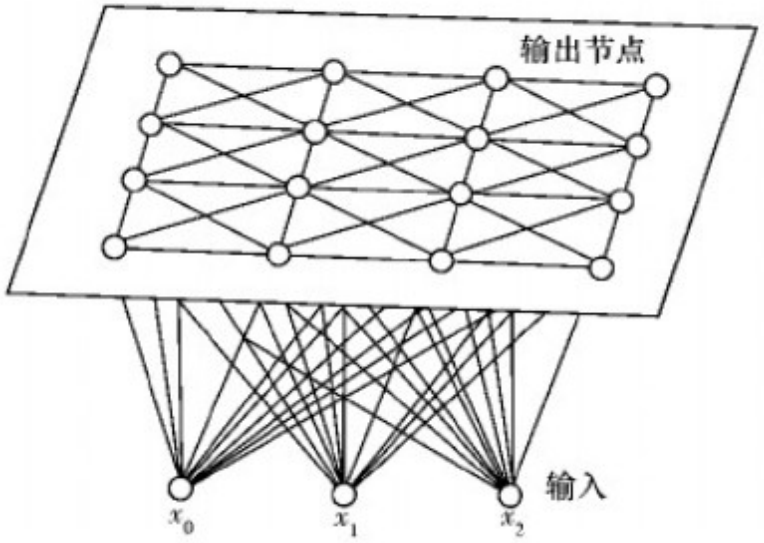


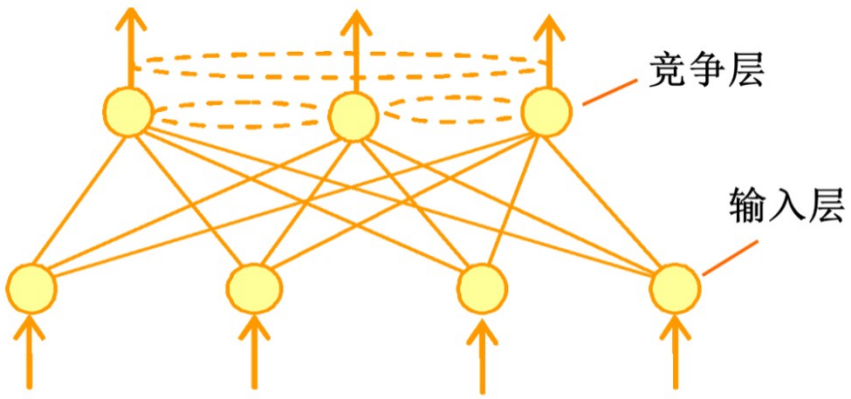
七、基于神经网络的信息融合

其它神经网络

自组织神经网（SOM）

- 输出节点与其邻域广泛连接，并互相激励。竞争关系
- 输入节点和输出节点之间通过强度权值进行连接，通过调整权值，使得在稳定时，每一邻域的所有节点对某种输入具有类似输出，并且这种聚类的概率分布与输入模式的概率分布相接近。
- 通常采用非监督学习模式。

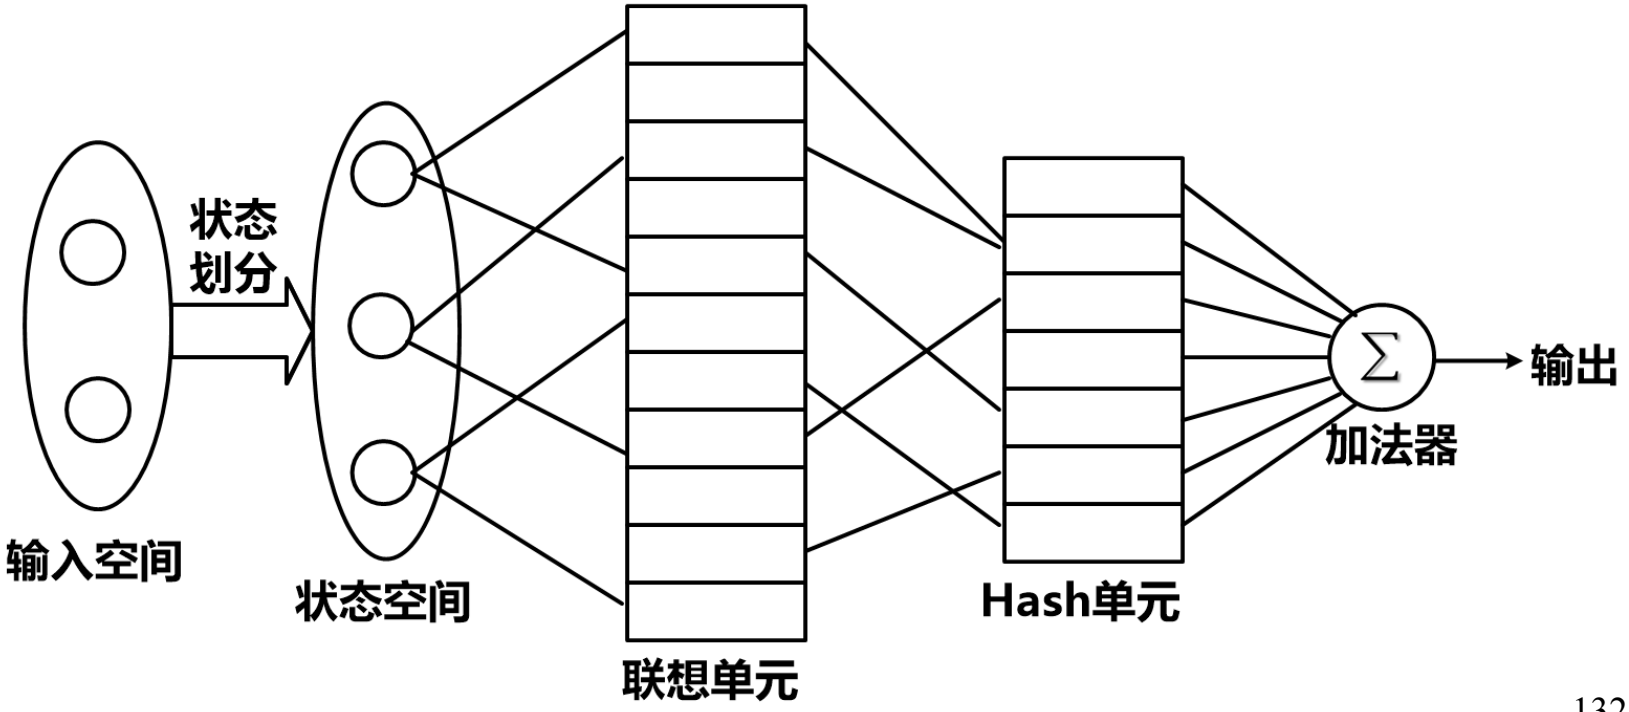




七、基于神经网络的信息融合

其它神经网络

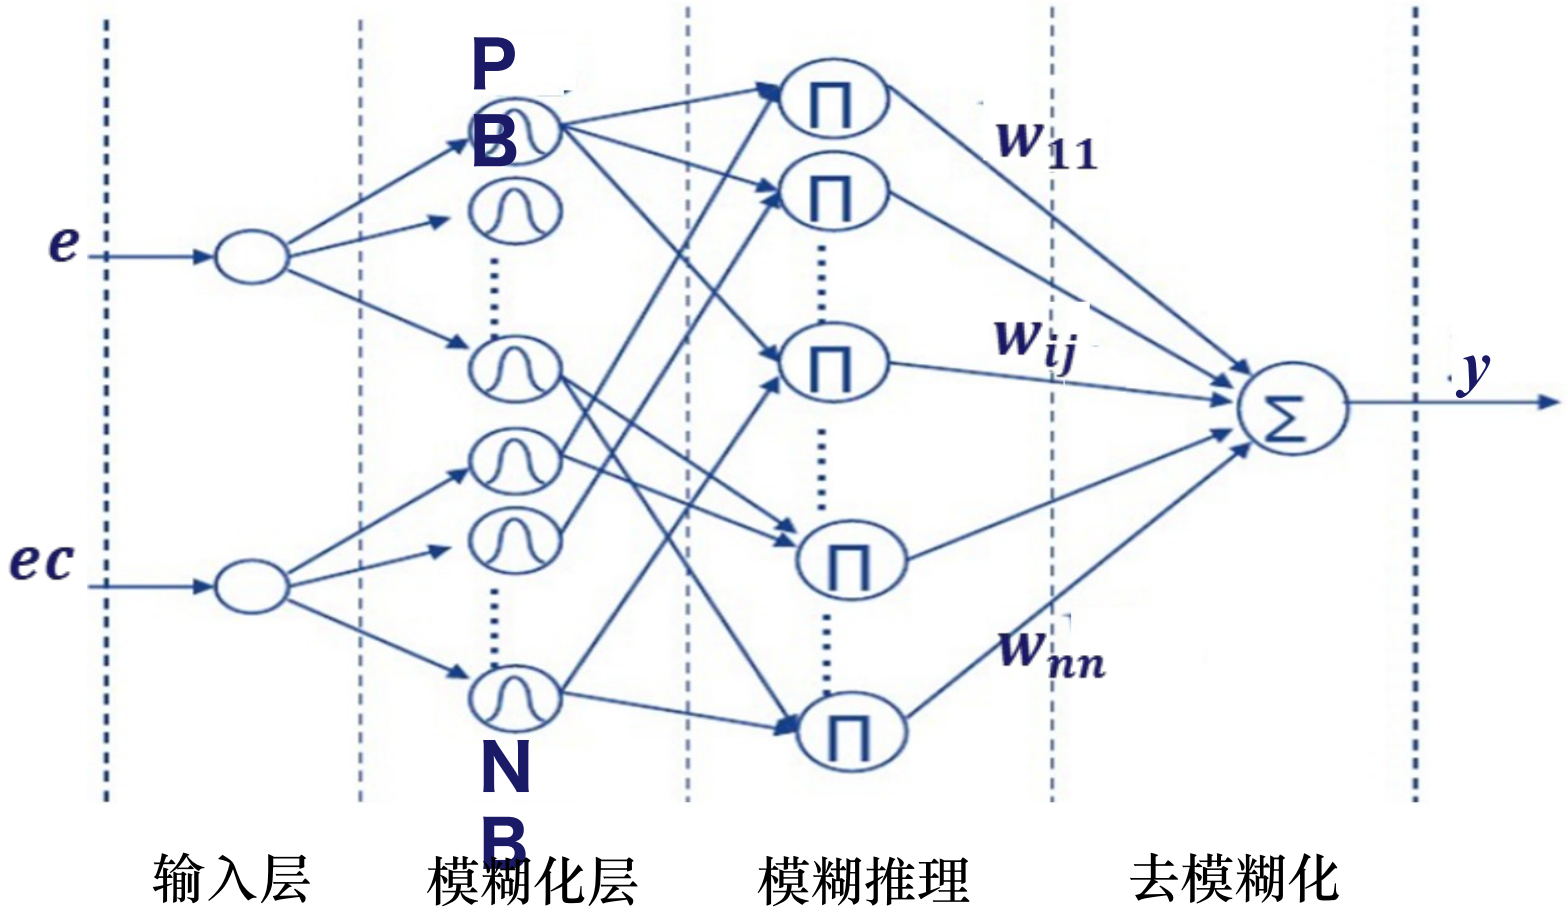
小脑神经网络（CMAC）：模仿人类小脑学习结构，每个状态变量被量化并且输入空间被划分成离散状态。量化的输入构成的向量指定了一个离散状态并且被用于产生地址来激活联想单元中存储的联想强度从而恢复这个状态的信息。



七、基于神经网络的信息融合

其它神经网络

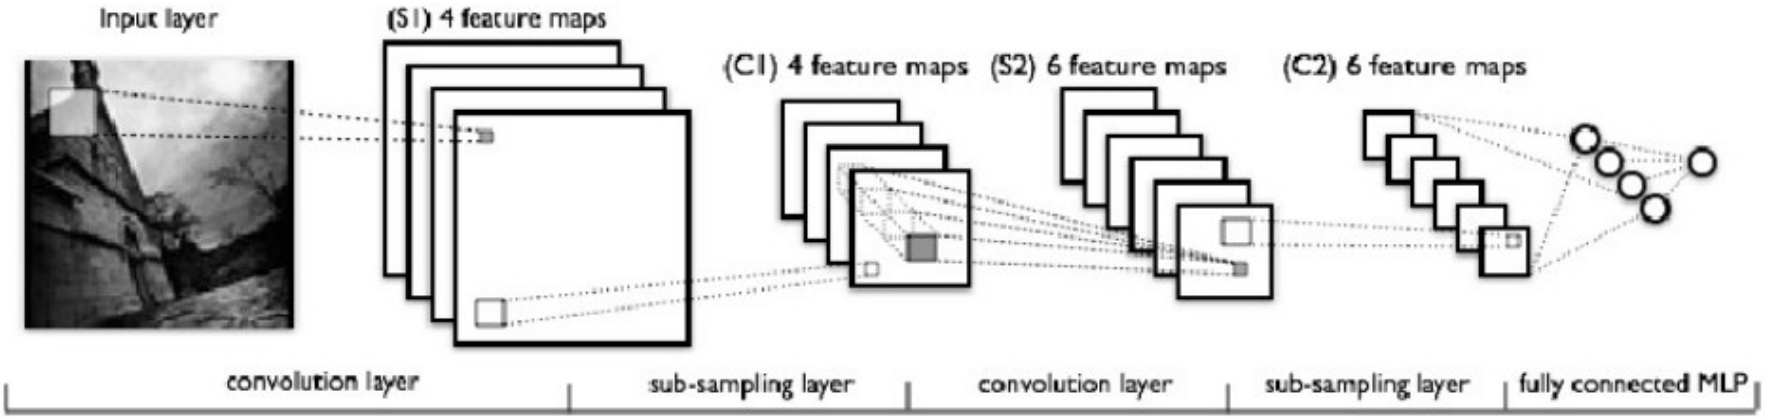
模糊神经网络：

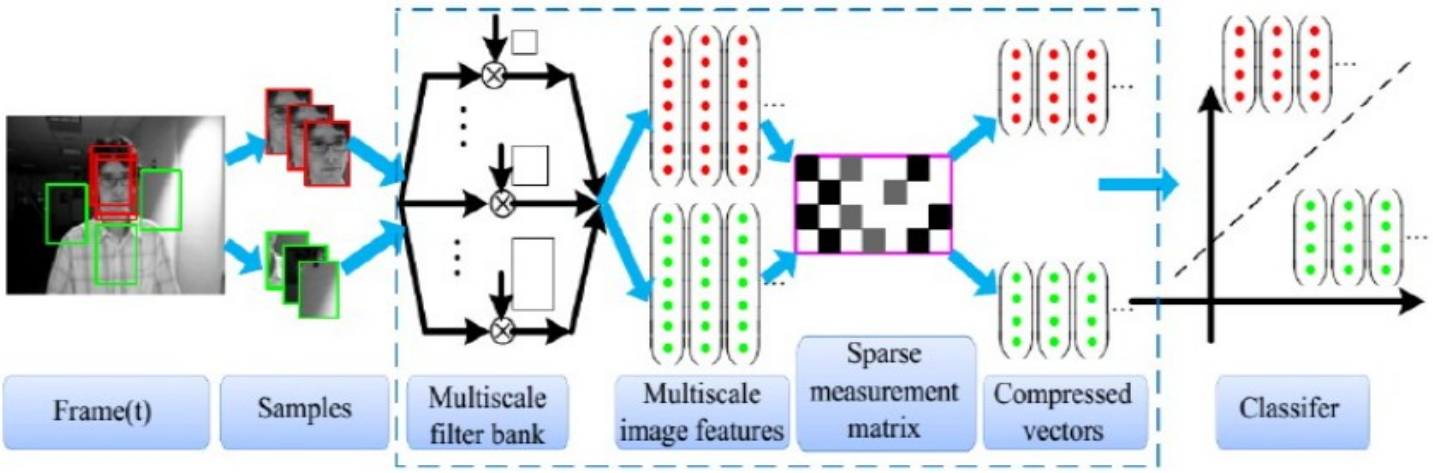


七、基于神经网络的信息融合

其它神经网络

深度学习网络：





作业

1. （1）请给出Kalman滤波器的应用条件？（2）请给出Kalman滤波器的五个核心公式，并根据你的理解对每个公式的物理意义或作用利用一句话进行解释。（3）考虑如下系统及其给定条件求$\hat{x}(1|1)$，$P(1|1)$和$\hat{y}(2|1)$

$$x(t+1)=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}x(t)+\begin{bmatrix}0\\ 1\end{bmatrix}w(t) \qquad w\sim N(0,1)$$

$$y(t)=[1 \quad 0]x(t)+v(t) \qquad v\sim N(0,1)$$

$$y(1)=9$$

$$\hat{x}(0|0)=[0 \quad 10]^T$$

$$P(0|0)=diag(2,3)$$

2. 设3个传感器测量同一物理量，服从$P(Z_k=z_k|X=x)=\frac{1}{\sqrt{2\pi}\sigma_k}e^{-\frac{(z_k-x)^2}{2\sigma_k^2}}(k=1,2,3)$的高斯观测模型，设该3传感器相互独立，试参考课件中2传感器情况利用Bayes方法计算状态X的融合估计

3. 设空间中某位置的状态集合Ω定义为{E, F}，其中E表示空，F表示有障碍物。基于状态集合Ω的环境状态描述可以表示为：$A_1=\{\phi\}$，$A_2=\{E\}$，$A_3=\{F\}$，$A_4=\{E,F\}$。如果超声传感器对该位置状态判断的基本概率赋值为：

$$m_1(A_1)=0,\ m_1(A_2)=a_1,\ m_1(A_3)=a_2,\ m_1(A_4)=1-a_1-a_2$$

红外传感器对该位置状态判断的基本概率赋值为：

$$m_2(A_1)=0,\ m_2(A_2)=b_1,\ m_2(A_3)=b_2,\ m_2(A_4)=1-b_1-b_2$$

请利用D-S证据组合规则求取融合后的$m(A_1)$、$m(A_2)$、$m(A_3)$和$m(A_4)$

作业

4. 熟悉三类模糊推理系统的工作原理及其差别，完成如下习题：根据某非线性感知系统输入-输出的大量实测数据，通过辨识已经得到描述它的三条T-S模糊规则，分别为R1、R2和R3：

$$\text{R1：if } x_1 \text{ is } mf_1 \text{ and } x_2 \text{ is } mf_3 \text{ then } y = x_1 + x_2$$

$$\text{R2：if } x_1 \text{ is } mf_2 \text{ then } y = 2x_1$$

$$\text{R3：if } x_2 \text{ is } mf_4 \text{ then } y = 3x_2$$

其中模糊集合mf_1、mf_2、mf_3和mf_4的隶属函数可视为简单直线，分别为

$$mf_1(x) = 1 - \frac{x}{16};\quad mf_2(x) = \frac{x}{60};\quad mf_3(x) = 1 - \frac{x}{8};\quad mf_4(x) = \frac{3x}{40}$$

试问当侧得$x_1 = 12$且$x_2 = 5$时，最终输出量为多少？

THANK YOU

